



Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Max Katzenberger und Mathis Köder

Abgabedatum:	18. Mai 2026
Bearbeitungszeitraum:	10.10.2025 - 18.05.2026
Matrikelnummer:	ToDo
Kurs:	TINF23B2
Gutachter der Dualen Hochschule:	apl. Prof. Dr. Markus Reischl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

gemäß § 5 der "Studien- und Prüfungsordnung DHBW Technik" vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den April 24, 2026

Nachname, Vorname

Abstract

- English -

This is the starting point of the Abstract. For the final bachelor thesis, there must be an abstract included in your document. So, start now writing it in German and English. The abstract is a short summary with around 200 to 250 words.

Try to include in this abstract the main question of your work, the methods you used or the main results of your work.

Abstract

- Deutsch -

Dies ist der Beginn des Abstracts. Für die finale Bachelorarbeit musst du ein Abstract in deinem Dokument mit einbauen. So, schreibe es am besten jetzt in Deutsch und Englisch. Das Abstract ist eine kurze Zusammenfassung mit ca. 200 bis 250 Wörtern.

Versuche in das Abstract folgende Punkte aufzunehmen: Fragestellung der Arbeit, methodische Vorgehensweise oder die Hauptergebnisse deiner Arbeit.

Contents

Formelverzeichnis	VI
Abkürzungsverzeichnis	VII
List of Figures	IX
List of Tables	X
Quellcodeverzeichnis	XI
1. Einleitung	1
1.1. Motivation	1
1.2. Probleme	1
1.3. Ziel der Arbeit	2
2. Stand der Forschung	4
2.1. Klassische statistische Verfahren	4
2.2. Machine-Learning-Ansätze	5
2.3. Hybride Modelle	6
2.4. Performance-Metriken	6
2.5. Vergleich und Forschungslücke	7
3. Konzeption	8
3.1. Überblick	8
3.2. Daten und Aktienwahl	10
3.3. Modellentwicklung	22
3.4. Marktstrategie	33
3.5. Einschränkungen und Nebenbedingungen	33
3.6. Metriken	34
4. Implementierung	41
4.1. SDEs zur Aktienauswahl	41
4.2. ARIMA-GARCH	41
4.3. Preprocessed SVR	41

4.4. StockTimesFM	41
5. Ergebnisse und Bewertung	42
5.1. Variante1	42
5.2. Variante2	42
6. Zusammenfassung und Ausblick	43
Literaturverzeichnis	XII
A. SVR Feature Engineering	I

Formelverzeichnis

A	mm ²	Fläche
D	mm	Werkstückdurchmesser
$d_{\min}$	mm	kleinster Schaftdurchmesser
L_1	mm	Länge des Werkstückes Nr. 1
	Grad	Freiwinkel
	Grad	Keilwinkel

Abkürzungsverzeichnis

EMH	Efficient Market Hypothesis
DoS	Definition of Success
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
DA	Directional Accuracy
MDD	Maximum Drawdown
LSTM	Long Short Term Memory
SVM	Support Vector Machines
OOS-R^2	Out-Of-Sample R^2
NLP	Natural Language Processing
SVM	Support Vector Machine
NN	Neural Network
SVR	Support Vector Regression
ARMA	Autoregressive Moving Average
GARCH	Generalized Autoregressive Conditional Heteroscedasticity
kNN	k-Nearest Neighbors
CNN	Convolutional Neural Network
RNN	Recurrent Neural Network
ROI	Return on Invest

SDE	Stochastische Differentialgleichung
OLS	Ordinary Least Squares
HP	Hodrick-Prescott
ADF	Augmented Dickey-Fuller
AIC	Akaike Information Criterion
RBF	Radial Basis Function

List of Figures

3.1. Struktur der Konzeption	9
3.2. Ablauf Aktienauswahl	14

List of Tables

3.1. Beispielhafte Rohdaten der Aktienpreise. Alle Preisangaben in USD.	11
3.2. Makroökonomische Faktoren	13
3.3. Bestandteile der Kovarianzmatrix	19
3.4. Komponenten der Aktienkursmodellierung	23

Quellcodeverzeichnis

1. Einleitung

1.1. Motivation

Die Vorhersage von Aktienkursen stellt eine zentrale Herausforderung der Finanzökonomie dar. Trotz umfangreicher Forschung bleibt die präzise Prognose zukünftiger Kursbewegungen aufgrund der Komplexität und Volatilität der Märkte schwierig. In den letzten Jahren wurden vermehrt mathematische und datengetriebene Methoden untersucht, um Muster in Finanzkursen zu identifizieren und Vorhersagen zu verbessern. Da ein zuverlässiger und konsistenter Algorithmus zur Vorhersage von Aktienkursen potenziell erhebliche finanzielle Vorteile bieten würde, ist das Interesse an der Entwicklung solcher Verfahren entsprechend groß.

1.2. Probleme

Ein zentrales theoretisches Problem bei der Vorhersage von Aktienkursen ergibt sich aus der Efficient Market Hypothesis (EMH). Die EMH besagt, dass alle verfügbaren Informationen bereits vollständig in den aktuellen Marktpreisen enthalten sind, sodass zukünftige Kursbewegungen per Definition nicht systematisch vorhergesagt werden können. Unter dieser Annahme verhalten sich Preisänderungen wie ein zufälliger Prozess, der durch keinen Algorithmus vorhergesagt werden kann und die Machbarkeit des Ziels dieser Arbeit in Frage stellt [1]. Trotz der theoretischen Einschränkungen durch die Markteffizienzhypothese existieren empirische Beispiele erfolgreicher quantitativer Handelsstrategien. Renaissance Technologies nutzt seit Jahrzehnten fast ausschließlich mathematis-

che Modelle und Algorithmen zur Kursprognose und erzielt mit dem Medallion Fund Renditen in Höhe von 66% p.a. Dies zeigt, dass systematische Modelle wiederkehrende Muster in Finanzdaten sehr wohl erkennen und wirtschaftlich nutzen können. Hierbei sei anzumerken, dass die genaue Funktionsweise der verwendeten Algorithmen selbstverständlich unbekannt ist. Quantitative Fonds agieren als "Black-Box", was die wissenschaftliche Nachvollziehbarkeit erschwert und somit kein gesichertes Gegenbeispiel zur EMH ist [2]. Des Weiteren gibt es empirische, öffentliche Analysen, die zeigen, dass nicht-lineare Vorhersagemethoden durchaus Gewinne erzielen können [3]. Neben der Frage nach der allgemeinen Machbarkeit ergeben sich eine Vielzahl praktischer Probleme, die die Entwicklung erschweren. Zunächst enthalten Kursdaten viel Rauschen. Es ist schwer den tatsächlichen Signalanteil des Preises herauszufiltern, um zu den Trend zu erkennen. Des Weiteren ist es eine große Schwierigkeit, den korrekten Komplexitätsgrad des Modells zu finden. Zu komplexe Modelle „overfitten“, passen sich also zu stark an historische Daten an und generalisieren somit schlecht auf neuen, realen Daten. Dies betrifft vor allem Deep Learning Modelle, welche zu viele Freiheitsgrade haben, und somit den vergangenen Kurs oder das Rauschen selbst abbilden und den Trend dabei nicht erkennen. Auf der anderen Seite sind zu simple Modelle nicht in der Lage nicht-lineare Zusammenhänge zu erkennen und generalisieren zu stark [4].

1.3. Ziel der Arbeit

Das Ziel dieser Arbeit ist das Entwickeln einer Strategie zur Auswahl von rentablen Aktien aus einem Aktienuniversum und das Entwickeln und Testen von Vorhersagemodellen auf diesen gewählten Aktien. Anschließend wird eine Marktstrategie entwickelt und die Modelle werden in einem realistischen Backtest evaluiert. Es soll eine Testumgebung geschaffen werden, mit welcher

verschiedene Analysemodelle getestet und auf realen, vergangenen Daten ausprobiert werden können.

2. Stand der Forschung

Dieses Kapitel gibt einen Überblick über den aktuellen Stand der Forschung im Bereich der mathematischen Vorhersage von Aktienkursen. Um einen Überblick zu erhalten, werden Arbeiten und Studien analysiert, die verschiedene Ansätze verwenden um Aktienkursen, Aktienkursbewegungen und Aktienkursrenditen vorherzusagen. Wie der Survey von Rundo et al. [5] zeigt, lassen sich die verschiedenen Ansätze in die zwei Hauptkategorien der klassischen statistischen Verfahren und der Machine-Learning-Ansätze unterteilt werden können. Während die klassischen Verfahren auf traditionellen Zeitreihen- und Regressionsmodellen basieren, setzen die Machine-Learning-Ansätze auf datengetriebene Methoden mit manuellem Feature Engineering oder tiefen neuronalen Netzen. Werden beide Ansätze kombiniert, entstehen hybride Modelle, die versuchen, die Stärken beider Ansätze zu kombinieren. Diese werden in einem weiteren Abschnitt behandelt. Ein zusätzlicher Abschnitt behandelt die Performance-Metriken, die in der Forschung verwendet werden. Abschließend wird ein Vergleich der verschiedenen Ansätze gezogen und eine Forschungslücke identifiziert, die den Bedarf für den eigenen Ansatz begründet.

2.1. Klassische statistische Verfahren

2.1.1. Lineare Zeitreihenmodelle

ARIMA

GARCH

2.1.2. Nichtlineare und stochastische Modelle

2.2. Machine-Learning-Ansätze

2.2.1. Feature-basierte Verfahren

kNN

SVR

Ballings et al. [6] vergleicht in seinem Paper Support Vector Machine (SVM) mit k-Nearest Neighbors (kNN) und Random Forest. Zur Bewertung der Ergebnisse wird die Area Under the Curve (AUC) verwendet, die eine Aussage darüber trifft, wie gut die Modelle im Vergleich zu Zufall abschneiden. In diesem Vergleich schneidet Random Forest am besten ab, gefolgt von SVM.

2.2.2. Deep-Learning-Modelle

Das Paper von Lu et al. [7] gibt stellt ein neues Convolutional Neural Network (CNN)-basiertes Modell vor, das eine Kombination verschiedener Deep-Learning-Architekturen verwendet. Dafür wird das neue Modell auch mit den Architekturen Long Short Term Memory (LSTM), Recurrent Neural Network (RNN) und CNN verglichen. Verglichen werden die Modelle mit den Metriken Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) und R-squared. Aus dem Paper geht hervor, dass das neue CNN-basierte Modell in allen drei Metriken besser abschneidet als die anderen Modelle. Das LSTM-Modell schneidet am zweitbesten ab, gefolgt von RNN und CNN.

LSTM

CNN

RNN

GRU

2.3. Hybride Modelle

2.4. Performance-Metriken

Das Review von Kumar et al. [8] beschreibt diese fünf Metriken aus die am häufigsten verwendeten Metriken in der Literatur zur Vorhersage von Aktienkursen:

- **Accuracy:** Wird hauptsächlich bei Klassifikationsmodellen verwendet, um den Anteil der korrekt vorhergesagten Bewegungen (z.B. Aufwärts/Abwärts) zu messen.
- **Root Mean Squared Error (RMSE):** Wird verwendet, um die durchschnittliche Abweichung der vorhergesagten Werte von den tatsächlichen Werten zu quantifizieren.
- **Mean Absolute Error (MAE):** Wird vor allem bei Regressionsmodellen verwendet, um die durchschnittliche absolute Abweichung der Vorhersagen von den tatsächlichen Werten zu messen.
- **Mean squared error (MSE):** Wird ebenfalls bei Regressionsmodellen verwendet, um die durchschnittliche quadratische Abweichung der Vorhersagen von den tatsächlichen Werten zu quantifizieren.
- **Mean Absolute Percentage Error (MAPE):** Wird verwendet, um die durchschnittliche prozentuale Abweichung der Vorhersagen von den tatsächlichen Werten zu messen, was besonders nützlich ist, wenn die Werte stark variieren. Außerdem ist MAPE die am häufigsten verwendete Metrik in der Literatur.

2.5. Vergleich und Forschungslücke

Der Survey von Rundo et al. [5] kommt zu dem Schluss, dass Machine-Learning-Modelle tendenziell akkuratere Vorhersagen liefern als klassische statistische Modelle. Allerdings weisen sie auch darauf hin, dass die Leistung von Machine-Learning-Modellen stark von der Qualität und Quantität der verfügbaren Daten abhängt. In vielen Fällen können klassische Modelle aufgrund ihrer Einfachheit und Interpretierbarkeit bevorzugt werden, insbesondere wenn die Daten begrenzt oder verrauscht sind.

Die Analyse von Gandhmal and Kumar [9] sieht eine Forschungslücke in der Integration von alternativen Datenquellen, wie z.B. Nachrichten, Sentiment-Analysen und makroökonomischen Indikatoren, in die Vorhersagemodelle. Während viele Studien sich auf historische Kursdaten und technische Indikatoren konzentrieren, gibt es nur wenige Arbeiten, die diese zusätzlichen Datenquellen systematisch in ihre Modelle integrieren.

2.5.1. Zusammenfassung

3. Konzeption

3.1. Überblick

In diesem Kapitel wird die Entwicklung der in dieser Arbeit verwendeten Modelle zur Vorhersage von Aktienkursen beschrieben. Dabei werden Ansätze aus der Zeitreihenanalyse und dem maschinellen Lernen konzeptioniert. Die grobe Struktur des gesamten Kapitels ist in Abbildung 3.1 zu sehen.

Zunächst wird in Kapitel 3.2 das Datenset erläutert. Es erfolgt die Auswahl des Aktienuniversums. Danach wird die konkrete Auswahl der untersuchten Aktien auf Basis von stochastischen Differentialgleichungen beschrieben. Die Daten werden unterteilt und bereinigt.

Daraufhin wird in Kapitel 3.5 der Rahmen der Arbeit definiert, einschließlich des Untersuchungsgegenstands, der getroffenen Annahmen sowie der Nebenbedingungen und Einschränkungen. Diese Vereinfachungen dienen der Interpretierbarkeit, unterscheiden sich aber teilweise von realen Marktbedingungen.

Anschließend werden in Kapitel 3.6 die Metriken vorgestellt, die sowohl mathematische als auch finanzwirtschaftliche Aspekte berücksichtigen.

Aufbauend auf diesen Grundlagen erfolgt die Modellentwicklung in Kapitel 3.3. Es werden drei Modelle vorgestellt:

- **LinearSeparation:** Unterteilt den Aktienkurs in drei Bestandteile und schätzt jeden über ein lineares Verfahren,




Figure 3.1.: Struktur der Konzeption

- **Preprocessed SVR:** Support Vector Regression mit vorverarbeiteten und normalisierten Kennzahlen,
- **StockTimesFM:** Anwendung eines Zeitreihen Foundation Model auf Aktienkurse.

Abschließend wird in Kapitel 3.4 die Umsetzung der Vorhersagen in einer Handelsstrategie beschrieben. Hierbei werden Risikomanagement, Positionsgrößen und Vorhersagehorizont betrachtet. Aus den Preisvorhersagen wird eine Marktentscheidung getroffen, um die praktische Anwendbarkeit der Modelle zu analysieren.

3.2. Daten und Aktienwahl

3.2.1. Daten

Unter dem Survivorship Bias versteht man die statistische Verzerrung, die entsteht, wenn nur überlebende Unternehmen ausgewählt werden und insolvente oder aus einem Index entfernte Aktien unberücksichtigt bleiben, was historische Renditen systematisch nach oben verzerrt. Für die Analyse wird ein festes Aktienuniversum herangezogen, bestehend aus den im Jahr 2020 im S&P500 gelisteten Unternehmen, wodurch ein Survivorship Bias vermieden wird.

Die Kursdaten jeder Aktie werden als Zeitreihe betrachtet. Für jeden Handelstag enthält die Zeitreihe folgende Werte:

- Open: erster Preis zu dem an diesem Tag gehandelt wurde,
- Close: letzter Preis zu dem an diesem Tag gehandelt wurde,
- High: höchster Preis zu dem an diesem Tag gehandelt wurde,
- Low: niedrigster Preis zu dem an diesem Tag gehandelt wurde,

- Volume: gesamtes kumuliertes Handelsvolumen an diesem Tag.

Die Daten werden als CSV-Dateien von Yahoo Finance heruntergeladen und ein Auszug ist in Tabelle 3.1 zu sehen. Sie werden dann in parquet-Dateien konvertiert, um Speicherplatz und Rechenzeit zu sparen.

Datum	Close	High	Low	Open	Volume
2022-11-11	147,34	147,64	142,09	143,52	93 979 700
2022-11-14	145,94	147,91	145,10	146,62	73 374 100

Table 3.1.: Beispielhafte Rohdaten der Aktienpreise. Alle Preisangaben in USD.

Die Unterteilung der Zeitreihen erfolgt in einem 60:10:30-Verhältnis, wobei 60% der Daten als Trainingsdaten, 10% als Validierungs- und 30% als Testdaten verwendet werden:

- **Trainingszeitraum (T):** 01.2020–12.2023, in dem die Modelle auf den historischen Kursen trainiert werden.
- **Validierungszeitraum (V):** 01.2024–06.2024, der zur Optimierung der Modellparameter dient.
- **Testzeitraum (Z):** 07.2024–12.2025, der ausschließlich für die abschließende Evaluierung der Modelle auf bisher ungesehenen Daten verwendet wird.

3.2.2. Aktienausswahl

Es sollen nun 10 Aktien aus dem Gesamtuniversum ausgewählt werden, auf denen später getestet wird. Dafür wird in diesem Abschnitt ein Verfahren vorgestellt, welches eine Stochastische Differentialgleichung (SDE) verwendet,

um aus dem Gesamtuniversum die Aktien auszuwählen, die am wahrscheinlichsten den höchsten Return on Invest (ROI) erzielen. Die Auswahl dieser Aktien muss stets anhand von Informationen erfolgen, die vor dem Testzeitraum bekannt waren, um einen Lookahead Bias und Selection Bias zu verhindern.

Aktienkurse setzen sich aus einem Trend und zufälligem Rauschen zusammen. Eine Aktienkursbewegung $dS(t)$ wird beschrieben durch einen Trend μ und ein Rauschen als Wienerprozess W_t , verstärkt durch einen Volatilitätskoeffizienten σ .

$$dS(t) = \underbrace{\mu S(t)dt}_{\text{Trendkomponente}} + \underbrace{\sigma S(t)dW(t)}_{\text{Rauschen}} \quad (3.1)$$

Der in dieser Arbeit gewählte Ansatz lässt sich als eine Verallgemeinerung des Modells von Ofomata et al. [10] verstehen. Ein wesentlicher Nachteil ihrer Methode liegt in der Beschränkung auf eine sehr kleine Auswahl an Aktien, die vorab durch externe Verfahren selektiert werden müssen. Das hier vorgestellte Modell hebt diese Notwendigkeit auf, um das Verfahren breiter anwendbar zu machen, indem Aktien mehrfach miteinander verglichen und schlechtere aussortiert werden. Ein weiterer Aspekt betrifft die Berechnung der Parameter μ und σ und die Kovarianz der Aktien untereinander. In der Praxis folgen Kursbewegungen externen Faktoren wie dem Ölpreis oder dem aktuellen Leitzins. Dass Aktien innerhalb desselben Index miteinander korrelieren, kann eine logische Folge ihrer gemeinsamen Reaktion auf diese makroökonomischen Einflüsse sein. Anstatt nur die Einflüsse der Aktien untereinander zu beobachten, beobachtet der folgende Ansatz die Einflüsse der makroökonomischen Faktoren auf die Aktien einzeln. Die hier betrachteten Faktoren sind dargestellt in Tabelle 3.2.

Der Ansatz in [10] teilt eine Aktienbewegung in drei diskrete Richtungen auf: Anstieg (+1), Rückgang (−1) und Stagnation (0). Bei n betrachteten Aktien

Faktor	Erklärung
Ölpreis	Öl Future-Kontrakt Preis an der NYMEX
Goldpreis	Gold Future-Kontrakt Preis an der COMEX
Staatsanleihe	10-Jahre-Staatsanleihe der USA
Gesamtindex	Marktindex des S&P500
US-Dollar	US-Dollar Index DXY
Inflation	10-Jahre Break-Even-Inflationsrate

Table 3.2.: Makroökonomische Faktoren

ergibt sich daraus ein Ergebnisraum von 3^n möglichen Bewegungskombinationen innerhalb eines Handelstages. Für $n = 4$ also bereits $3^4 = 81$ zu berücksichtigende Szenarien. Dadurch, dass in [10] nur 60 Handelstagen betrachtet werden, treten viele Bewegungen überhaupt nicht auf.

Um die genannten Probleme zu adressieren, wird die Grundstruktur beibehalten, jedoch wird der ursprüngliche 3^n -dimensionalen Aktienvektor durch einen 3^{g+f} -dimensionalen Einflussvektor aus g Aktien und f Faktoren ersetzt. Die Grundstruktur des Verfahrens ist in Abbildung 3.2 zu sehen und lässt sich kurz folgendermaßen zusammenfassen. Für jede Aktie werden die beiden makroökonomischen Faktoren f aus Tabelle 3.2 gesucht, die am meisten Einfluss auf die Kursbewegung haben. Dann werden für alle Aktien, die dasselbe dominante Einflussfaktorpaar haben, Simulationsgruppen aus je 4 Aktien und den beiden Einflussfaktoren gebildet. Innerhalb dieser Simulationsgruppen werden die Kursverläufe der Aktien und Faktoren simuliert und diejenige Aktie, die nach dem Testzeitraum Z den höchsten ROI in der Simulation erzielt, geht als „Gewinner“ aus ihrer Simulationsgruppe hervor. Dieser Auswahlprozess wird über das gesamte Aktienuniversum durchgeführt. Danach werden diese „Gewinner“ wieder in Simulationsgruppen zu je 4 Aktien aufgeteilt. Durch diesen hierarchischen Prozess bleibt der Ansatz unabhängig von der Gesamtzahl der Aktien (n). Er lässt sich somit auf beliebig große Universen anwenden und berücksichtigt direkt den Einfluss makroökonomischer Faktoren.




Figure 3.2.: Ablauf Aktienausswahl

Grupperierung

Um das vorgestellte Verfahren auf ein gesamtes Aktienuniversum anwenden zu können, muss eine Gruppierung der Aktien und Faktoren vorgenommen werden. Der bereits definierte Trainingszeitraum T hat etwa 1000 Handelstage. Um eine sinnvolle Wahrscheinlichkeitsverteilung der Aktienbewegungen zu liefern, sollte die Anzahl der möglichen Kombinationen der diskreten Aktien- und Faktorbewegungen kleiner sein als die Tage des Trainingszeitraums. Es wurde sich für $g = 4$ Aktien und $f = 2$ Faktoren pro Simulationsgruppe entschieden, was zu $3^6 = 729 < 1000$ möglichen Kombinationen führt.

Um den Einfluss der Faktoren auf jede Aktie zu messen, wird für jede Aktie-Faktor-Kombination eine lineare Regression der diskreten Aktienbewegung ΔS auf die diskrete Faktorbewegung ΔF geschätzt.

$$\Delta S_i(t) = \alpha_i + \sum_{j=1}^7 \beta_{i,j} \cdot \Delta F_j(t), \quad (3.2)$$

wobei α_i den faktorunabhängigen Trend der Aktie bezeichnet und $\beta_{i,j}$ die Sensitivität der Aktie i gegenüber Faktor j .

Die Koeffizienten α und β werden mittels Ordinary Least Squares (OLS) auf den Daten des Trainingszeitraums bestimmt:

$$\hat{\theta}_i = (X^T X)^{-1} X^T y_i, \quad (3.3)$$

mit

$$\hat{\theta}_i = \begin{pmatrix} \hat{\alpha}_i \\ \hat{\beta}_{i,1} \\ \vdots \\ \hat{\beta}_{i,7} \end{pmatrix}. \quad (3.4)$$

$X \in \mathbb{R}^{T \times 8}$ bezeichnet die Designmatrix der Faktorbewegungen über $T = 1000$ Handelstage und ergibt sich zu

$$X = \begin{pmatrix} 1 & \Delta F_1(1) & \Delta F_2(1) & \cdots & \Delta F_7(1) \\ 1 & \Delta F_1(2) & \Delta F_2(2) & \cdots & \Delta F_7(2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \Delta F_1(T) & \Delta F_2(T) & \cdots & \Delta F_7(T) \end{pmatrix}. \quad (3.5)$$

$y_i \in \mathbb{R}^T$ ist der Vektor der Aktienbewegungen im Trainingszeitraum.

$$y_i = \begin{pmatrix} \Delta S_i(1) \\ \Delta S_i(2) \\ \vdots \\ \Delta S_i(T) \end{pmatrix} \quad (3.6)$$

Da jede Simulationsgruppe genau zwei Faktoren enthalten soll, wird jeder Aktie das Faktorpaar (f_1, f_2) zugewiesen, für das die Summe der β -Koeffizienten maximal ist.

$$(f_1^*, f_2^*) = \arg \max_{j_1 \neq j_2} (|\beta_{i,f_1}| + |\beta_{i,f_2}|) \quad (3.7)$$

Dieses Paar wird als dominantes Faktorpaar $(f_{i,1}^*, f_{i,2}^*)$ der Aktie i bezeichnet. Alle Aktien die dasselbe dominante Faktorpaar haben, werden in einem Pool zusammengefasst.

$$\mathcal{P}_{j_1, j_2} = \{S_i : (j_1^*, j_2^*) = (j_1, j_2)\} \quad (3.8)$$

Bei den gewählten 7 Faktoren gibt es somit $\binom{7}{2} = 21$ mögliche Faktor pools. Jeder Pool enthält die Aktien, die auf dasselbe Faktorpaar am stärksten reagieren, wodurch auch die Korrelation unter den Aktien hoch sein sollte. Aus den Pools werden nun zufällig Simulationsgruppen zu je 4 Aktien gebildet.

Durch das hierarchische Format der Aktienausswahl kann es durch die lokalen Vergleiche passieren, dass Aktien in früheren Stufen nicht den höchsten ROI in der Simulation haben und somit nicht weiter betrachtet werden, obwohl sie im Vergleich der Grundgesamtheit unter den Top 10 vielversprechendsten Aktien gewesen wären. Dadurch wird die Aktienausswahl verschlechtert. Darum erfolgt die Aufteilung der Aktien von den Faktor pools in die Gruppen zufällig und die gesamte Aufteilung und Simulation wird $N = 100$ mal durchgeführt. Die 10 Aktien mit dem durchschnittlich besten "Platzierung" werden gewählt. Nach der gesamten Simulation ergeben sich die 10 am besten prognostizierten Aktien.

Aufstellen der SDEs

Es wird nun dargelegt, wie genau die Aktienkurse innerhalb einer Simulationsgruppe simuliert werden. Dies erfolgt durch das Aufstellen einer SDE für jeden Aktienkurs und das numerische Lösen dieser SDE.

Durch die Diskretisierung der Aktienbewegung degeneriert die SDE zu

$$dS(t) = \mu dt + \sigma dW(t), \quad (3.9)$$

da diskrete Schwankungen nicht mit dem Aktienkurs skalieren.

Der Aktienkurs könnte dadurch theoretisch negativ werden, was ignoriert werden kann, da es nur um einen qualitativen nicht quantitativen Vergleich der Aktien untereinander geht. Es wird ein Einflussvektor X aus Aktienbewegungen S und Faktorbewegungen F aufgestellt, mit

$$\Delta X(t) = [\Delta S_1(t), \Delta S_2(t), \dots, \Delta S_g(t), \Delta F_1(t), \Delta F_2(t), \dots, \Delta F_f(t)]^T.$$

Für jede Aktienbewegung und Faktorbewegung gibt es drei mögliche Werte (+1, 0, -1). Daraus ergibt sich der Ereignisraum C für den Einflussvektor X zu allen möglichen Gesamtbewegungen. Für die Kombinationen des Einflussvektors $c \in C$ wird die Wahrscheinlichkeit pro Aktie $p_i(c)$ im Trainingszeitraum T nach Formel 3.10 bestimmt. Außerdem wird eine Laplace-Glättung eingeführt. Dies soll das Problem eliminieren, dass Kombinationen die im Trainingszeitraum aus statistischen Gründen nicht aufgetreten sind, als unmöglich angesehen werden.

$$p_i(c) = \frac{N_c + 1}{T + |C|}, \quad (3.10)$$

wobei N_c der Anzahl der Zeitpunkte entspricht, an denen die Bewegung c im Zeitraum der Trainingstage T aufgetreten ist.

Der Trend einer Aktie oder eines Faktors ergibt sich aus dem Erwartungswert der Wahrscheinlichkeiten über alle möglichen Ereignisse.

$$\mu_i = \mathbb{E}[\Delta X] = \sum_{c \in C} p_i(c) \cdot c$$

Danach ergibt sich der Vektor der Trends der Aktien $\mu \in \mathbb{R}^g$, mit g als Simulationsgruppengröße zu

$$\mu = \begin{pmatrix} \mu_{S_1} \\ \mu_{S_2} \\ \vdots \\ \mu_{S_g} \\ \mu_{F_1} \\ \vdots \\ \mu_{F_f} \end{pmatrix}.$$

Zusätzlich zum Trend, soll das Rauschen der Aktien modelliert werden. Dafür wird die Kovarianz der Aktien untereinander, die Kovarianz der Faktoren und Aktien und die Kovarianz der Faktoren untereinander betrachtet. Die Kovarianzmatrix ergibt sich nach

$$\Sigma = \mathbb{E}[\Delta X \cdot \Delta X^T] = \sum_{c \in C} p(c) \cdot c \cdot c^T.$$

Die Kovarianzmatrix hat die Dimension $(f + g) \times (f + g)$ und lässt sich in die in Formel 3.11 und Tabelle 3.3 genannten Bestandteile gliedern.

$$\Sigma = \begin{pmatrix} \Sigma_{SS} & \Sigma_{SF} \\ \Sigma_{FS} & \Sigma_{FF} \end{pmatrix} \quad (3.11)$$

Block	Dimension	Bedeutung
Σ_{SS}	$g \times g$	Kovarianzen der Aktien untereinander
Σ_{FF}	$f \times f$	Kovarianzen der Faktoren untereinander
$\Sigma_{SF} = \Sigma_{FS}^T$	$g \times f$	Kovarianzen zwischen Aktien und Faktoren

Table 3.3.: Bestandteile der Kovarianzmatrix

Der Volatilitätskoeffizient σ der SDE wird bestimmt als Cholesky-Zerlegung von Σ . Da Σ mit nicht-negativen Wahrscheinlichkeiten $p(c)$ konstruiert ist, ist Σ positiv semidefinit, womit die Zerlegung existiert.

$$B \cdot B^T = \Sigma$$

Die gesamte SDE ergibt sich zu

$$dS_i(t) = \mu_{S_i} dt + \sum_{j=1}^{f+g} B_{ij} dW_j(t), \quad i = 1, 2, \dots, g,$$

wobei $W(t) \in \mathbb{R}^{f+g}$ ein Wiener-Prozess der Dimension $f + g$ ist. Die Faktoren F gehen nicht in die Auswertung ein, da sie lediglich für die Modellierung der Aktien S verwendet werden.

Zur Lösung der SDE wird das Euler-Maruyama-Schema verwendet. Der Startwert ist der Aktienkurs der jeweiligen Aktie am Beginn des Testzeitraumes Z . Danach wird die diskrete Annäherung simuliert nach der Rechenvorschrift 3.12.

$$S_i(t+1) = S_i(t) + \mu_{S_i} \Delta t + \sum_{j=1}^{f+g} B_{ij} \Delta W_{j,t} \quad (3.12)$$

Hierbei ist $\Delta W_{j,t}$ die Zunahme des Wiener-Prozesses W_j im Intervall $[t, t+1]$:

$$\Delta W_{j,t} \sim \mathcal{N}(0, \Delta t) \implies \Delta W_{j,t} = Z_{j,t} \sqrt{\Delta t},$$

wobei $Z_{j,t}$ unabhängige, standardnormalverteilte Zufallsvariablen sind. Auf diese Weise können die Aktienkurse innerhalb einer Simulationsgruppe simuliert und der prognostizierte ROI bestimmt werden.

3.2.3. Bereinigung

Die Analysen in dieser Arbeit bestehen aus Backtest. Das bedeutet, dass vergangene Daten verwendet werden, um Strategien zu testen. Aus diesem Grund ist eine Bereinigung der historischen Aktienkurse notwendig, da sich die nominalen Preise einer Aktie im Zeitverlauf durch Ereignisse wie Aktiensplits oder Dividendenzahlungen verändern, ohne dass sich der tatsächliche Unternehmenswert und demnach der Aktienwert geändert hat. Ohne eine solche Anpassung würden Kursbewegungen verzerrt dargestellt, was zu falsch trainierten Modellen oder falschen Tests führt. Sei P_t der beobachtete Schlusskurs einer Aktie zum Zeitpunkt t und $\tilde{P}_t$ der bereinigte Preis auf dem ein Modell trainiert werden kann. $\tilde{P}_t$ ergibt sich aus dem ursprünglichen Preis multipliziert mit einem Anpassungsfaktor A_t :

$$\tilde{P}_t = P_t \cdot A_t.$$

Der Anpassungsfaktor wird rekursiv rückwärts berechnet. Sei P_t für $t = 1, \dots, n$ gegeben, gilt $A_n = 1$. Bei einem Aktiensplit zum Zeitpunkt t mit Verhältnis $s_t = \frac{\text{neue Aktien}}{\text{alte Aktien}}$ gilt

$$A_{t-1} = \frac{A_t}{s_t}.$$

Dividendenzahlungen werden ebenfalls berücksichtigt. Sei D_t die Dividende zum Zeitpunkt t . Dann wird der Anpassungsfaktor wie folgt aktualisiert:

$$A_{t-1} = A_t \cdot \frac{P_t - D_t}{P_t}.$$

Somit ist der historische Preis mit dem die Modelle trainiert und getestet werden abhängig vom letzten betrachteten Wert. Der letzte Wert entspricht

somit dem aktuellen, realisierbaren Aktienwert, alle anderen Werte potenziell aber nicht den realen Aktienwerten zu dem Zeitpunkt.

3.3. Modellentwicklung

In diesem Kapitel werden drei Modelle entwickelt, die jeweils auf einer einzelnen Aktie operieren und auf Basis historischer Kursdaten sowie weiterer Eingabegrößen den Aktienkurs des nächsten Handelstages vorhersagen.

3.3.1. LinearSeparation

Es wird ein Verfahren vorgestellt, dass ohne Black-Box Modelle wie Machine Learning soll. Es wird sich dafür an den vorhandenen linearen Verfahren Autoregressive Moving Average (ARMA) und Hodrick-Prescott (HP) orientiert. Diese werden sinnvoll kombiniert, um eine Vorhersage zu treffen. Es wird die Behauptung aufgestellt, dass sich ein Aktienkurs durch die Komponenten in Tabelle 3.4 durch den Zusammenhang in Formel 3.13 beschreiben lässt.

$$P_t = T_t^{\text{lang}} \cdot T_t^{\text{kurz}} \cdot C_t \cdot \epsilon_t \quad (3.13)$$

Der Zusammenhang ist dabei multiplikativ, da Aktienkurse prozentual schwanken. Rauschen also beispielweise bei teuren Aktien größer ist. Da die Berechnung auf Log-Preisen $p_t = \ln(P_t)$ erfolgt, wird der Zusammenhang additiv.

$$p_t = \tau_t^{\text{lang}} + \tau_t^{\text{kurz}} + c_t + \epsilon_t \quad (3.14)$$

Variable	Bedeutung	Zeitraumen	Begründung
T_t^{lang}	langfristiger Trend	Jahre	Aktienmärkte bewegen sich durch Inflation und Konjunktur langfristig gleichmäßig
T_t^{kurz}	aktueller Trend	Wochen	aktienspezifische Bewegung abhängig von Earnings, Nachrichten usw.
C_t	kurzfristige Schwankungen	Tage	Autokorrelation in wenigen Tagen, teilweise begründbar
ϵ_t	Rauschen	$\mathbb{E}[\epsilon_t] = 0$	nicht erklärbar, nicht vorhersagbar

Table 3.4.: Komponenten der Aktienkursmodellierung

Die Komponenten des Preises werden dabei über verschiedene Wege modelliert und dann extrapoliert. Die längerfristigen Trends τ^{lang} und τ^{kurz} werden mithilfe eines HP-Filters [11] modelliert und mittels OLS extrapoliert.

Es wird mittels eines HP-Filters aus den historischen Log-Preisen $p_1, \dots, p_T$ (mit $t = 1, \dots, T$) der langfristige Trend τ^{lang} extrahiert:

$$\min_{\{\hat{\tau}_t^{\text{lang}}\}} \left(\sum_{t=1}^T (p_t - \hat{\tau}_t^{\text{lang}})^2 + \lambda_{\text{lang}} \sum_{t=2}^{T-1} (\hat{\tau}_{t+1}^{\text{lang}} - 2\hat{\tau}_t^{\text{lang}} + \hat{\tau}_{t-1}^{\text{lang}})^2 \right), \quad (3.15)$$

wobei λ_{lang} der Glättungsparameter ist, der bestimmt wie stark die kurzfristigen Schwankungen bereinigt werden. Der kritische Punkt bei diesem Verfahren liegt in der richtigen Wahl des Gewichtungsparameters λ_{lang} . Die genaue Wahl wird im Kapitel 4 diskutiert.

Mithilfe der daraus entstehenden geglätteten Zeitreihe $\hat{\tau}_t^{\text{lang}}$ werden die Residuen gebildet.

$$\tilde{p}_t = p_t - \hat{\tau}_t^{\text{lang}}$$

Auf der Residuenzeitreihe $\tilde{p}_t$ wird ein weiterer HP-Filter, nach Formel 3.15 mit einem kleineren λ_{kurz} angewendet, um den aktuellen Trend τ^{kurz} zu glätten. Die Größenordnung von λ_{kurz} wird im Kapitel 4 bestimmt.

Die HP-Filter liefern somit geglättete Trendverläufe $\hat{\tau}_t^{\text{lang}}$ und $\hat{\tau}_t^{\text{kurz}}$ für die historischen Daten bis zum Zeitpunkt T . Um Vorhersagen treffen zu können müssen die Trends extrapoliert werden. Da beide Trends im Kontext von Tagespreisen langfristig sind, können sie lokal durch ein lineares Modell approximiert werden. Die Idee dabei ist, dass sich der geglättete Trend innerhalb eines kurzen Zeitfensters gut durch eine Gerade beschreiben lässt, die anschließend in die Zukunft verlängert wird.

Konkret wird für jeden Trend über ein gleitendes Fenster der letzten w Beobachtungen $\{\hat{\tau}_{T-w+1}, \dots, \hat{\tau}_T\}$ mittels OLS eine lineare Funktion der Zeit gefittet. Dabei werden die Parameter $\hat{a}$ (Achsenabschnitt) und $\hat{b}$ (Steigung) so gewählt, dass

$$\hat{b} = \frac{\sum_{t=T-w+1}^T (t - \bar{t})(\hat{\tau}_t - \bar{\tau})}{\sum_{t=T-w+1}^T (t - \bar{t})^2}, \quad \hat{a} = \bar{\tau} - \hat{b}\bar{t}, \quad (3.16)$$

mit den Mittelwerten $\bar{t} = \frac{1}{w} \sum_{t=T-w+1}^T t$ und $\bar{\tau} = \frac{1}{w} \sum_{t=T-w+1}^T \hat{\tau}_t$. Die Vorhersage der Trendkomponenten für k Schritte in die Zukunft ergibt sich dann als

$$\hat{\tau}_{T+k}^{\text{lang}} = \hat{a}_1 + \hat{b}_1 \cdot (T + k), \quad (3.17)$$

$$\hat{\tau}_{T+k}^{\text{kurz}} = \hat{a}_2 + \hat{b}_2 \cdot (T + k). \quad (3.18)$$

Die Fenstergröße w bestimmt dabei, über welchen Zeitraum die lokale Steigung des Trends geschätzt wird. Ein zu kleines Fenster führt zu verrauschten Schätzungen und ein zu großes Fenster lässt aktuelle Richtungsänderungen nur langsam einfließen. Da τ^{lang} den strukturellen Trend über mehrere Jahre abbilden soll, wird die Steigung über ein Fenster von $w_{\text{lang}} = 252$ Handelstagen (einem Börsenjahr) geschätzt. Kurzfristige Schwankungen werden so herausgemittelt, und es verbleibt die mittelfristige Richtung des Marktes. τ^{kurz} soll Trendbewegungen im Bereich weniger Wochen erfassen. Deshalb wird $w_{\text{kurz}} = 40$ Handelstage (ca. zwei Monate) gewählt. Dieses kürzere Fenster erlaubt es, aktienspezifische Bewegungen zeitnah in die Extrapolation einfließen zu lassen. Nach der Trendentfernung verbleiben die Residuen c_t als kurzfristige Muster.

$$c_t = \tilde{p}_t - \hat{\tau}_t^{\text{kurz}}.$$

Diese werden durch ein ARMA(p,q)-Modell beschrieben [12]. Für die Anwendung eines ARMA-Modells, wird vorausgesetzt, dass die zugrundeliegenden Daten stationär sind. Um zu prüfen, ob dies nach der Trendentfernung der Fall ist, wird der Augmented Dickey-Fuller (ADF)-Test [13] angewendet. Der ADF-Test [13] prüft die Nullhypothese, dass eine Unit Root vorliegt, die Zeitreihe also nicht stationär ist. Wird diese bei einem p-Wert kleiner als 0,05 verworfen, kann Stationarität angenommen werden. Sollte Stationarität nicht gewährleistet werden können, wird die Wahl der HP-Filter Parameter λ variiert. Zur Modellierung der Residuen c_t wird ein Standard ARMA(p,q)-Modell verwendet:

$$\hat{c}_t = a + \sum_{i=1}^p \phi_i c_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t, \quad (3.19)$$

mit den Autokorrelationskoeffizienten ϕ_i , Fehlerkoeffizienten θ_j und einem Konstanten Achsenabschnitt a . Die Parameter ϕ_i und θ_j werden dabei für jede Kombination (p, q) mittels Maximum-Likelihood-Schätzung bestimmt. Die Ordnung p und q des Modells wird durch eine Grid-Search bestimmt. Das heißt, für alle Kombinationen (p, q) mit $p, q \in \{0, 1, \dots, 5\}$ wird das Modell geschätzt und das Akaike Information Criterion (AIC) [14] berechnet:

$$\text{AIC}(p, q) = 2(p + q) - 2 \ln(\hat{L}), \quad (3.20)$$

wobei $\hat{L}$ die maximierte Likelihood des geschätzten Modells ist. AIC bestraft dabei die Modellkomplexität und die Anpassungsgüte wird belohnt. Gewählt wird das Modell welches das AIC minimiert. So kann die optimale Modellkomplexität bestimmt werden.

Mit dem geschätzten $\text{ARMA}(p^*, q^*)$ -Modell werden die Residuen rekursiv vorhergesagt:

$$\hat{c}_{T+k} = \sum_{i=1}^{p^*} \phi_i \hat{c}_{T+k-i} + \sum_{j=1}^{q^*} \theta_j \hat{\epsilon}_{T+k-j} \quad (3.21)$$

Dabei werden für alle $k > 1$ die bereits vorhergesagten Werte als Eingabe verwendet. Außerdem werden alle zukünftigen Fehlerterme auf ihren Erwartungswert $\hat{\epsilon}_{T+k} = \mathbb{E}[\epsilon] = 0$ gesetzt.

Dies führt dazu, dass der ARMA-Beitrag zur Gesamtvorhersage für große Horizonte k exponentiell gegen null konvergiert, und die Vorhersage zunehmend

von den extrapolierten Trendkomponenten dominiert wird, was genau der Modellierung entspricht.

Die gesamte Vorhersage des Log-Preises zum Zeitpunkt $T + h$ ergibt sich aus der Summe aller drei modellierten Komponenten.

$$\hat{p}_{T+h} = \hat{\tau}_{T+h}^{\text{lang}} + \hat{\tau}_{T+h}^{\text{kurz}} + \hat{c}_{T+h} \quad (3.22)$$

Die Rücktransformation in den ursprünglichen Preisraum erfolgt durch Exponentiation.

$$\hat{P}_{T+h} = \exp(\hat{p}_{T+h}) \quad (3.23)$$

3.3.2. Preprocessed SVR

Support Vector Regression (SVR)s wurden schon häufig verwendet, um Aktienkurse vorherzusagen. In dieser Arbeit stehen zwei Unterschiede zu den bisherigen Verfahren im Vordergrund. Zunächst wird auf Log-Renditen trainiert und vorhergesagt, da diese annähernd stationär sind, additiv über die Zeit und symmetrischer verteilt. Außerdem werden in diesem Ansatz vorher berechnete technische Indikatoren und News-Sentiments als Features für die SVR verwendet, anstatt roher Lag-Preise. Die Featureauswahl wird in Anhang A gezeigt.

Es wird eine klassische SVR-Modellierung nach [15] verwendet. Es ist das Ziel aus einem Feature-Vektor x_t mit d Features, die Log-Rendite $\hat{r}_{t+1}$ vorherzusagen.

$$\hat{r}_{t+1} = f(x_t), \quad x_t \in \mathbb{R}^d \quad (3.24)$$

Im Gegensatz zu linearen Regressionen nimmt die SVR keine spezifizierte funktionale Form an, sondern lernt die Abbildung anhand historischer Trainingsbeispiele. Die Vorhersage der Rendite erfolgt nach Formel 3.25.

$$\hat{r}_{t+1} = \langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle + b, \quad (3.25)$$

wobei

- $\mathbf{w}$ der Gewichtsvektor ist, welcher angibt wie stark welches Feature aus $\mathbf{x}$ in die Vorhersage eingeht,
- $\phi(x)$ eine Funktion ist, welche die Input-Features in einen Raum höherer Dimension transformiert,
- b der Achsenabschnitt der Vorhersage ist.

Die Wahl von $\phi(x)$ wird später diskutiert und $\mathbf{w}$ und b werden durch Lösen des folgenden Optimierungsproblem bestimmt (vgl. [15]):

$$\min_{\mathbf{w}, b, \xi, \xi^*} \underbrace{\frac{1}{2} \|\mathbf{w}\|^2}_{\text{Funktionsglätte}} + C \underbrace{\sum_{t=1}^n (\xi_t + \xi_t^*)}_{\text{Fehlerterme}} \quad (3.26)$$

unter den Nebenbedingungen

$$r_{t+1} - \langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle - b \leq \varepsilon + \xi_t \quad (3.27)$$

$$\langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle + b - r_{t+1} \leq \varepsilon + \xi_t^* \quad (3.28)$$

$$\xi_t, \xi_t^* \geq 0. \quad (3.29)$$

Hierbei sorgt $\frac{1}{2}\|\mathbf{w}\|^2$ dafür, dass die Glätte der Funktion in die Optimierung miteingeht. Dies sorgt dafür, dass die Regressionsfunktion nicht overfittet, was ein häufiges Problem bei Aktienprognosemodellen ist. Der ε -Schlauch definiert dabei einen Toleranzbereich um die Regressionsfunktion, innerhalb dessen Abweichungen nicht als Fehler gewertet werden. Dies ist im Falle von Aktienrenditen hilfreich, um Rauschen zu ignorieren. Um Trainingspunkte, die außerhalb dieses Schlauchs liegen, dennoch zuzulassen, werden ξ_i und ξ_i^* eingeführt, welche die Abweichung dieser Punkte messen und in das Optimierungsproblem einbeziehen, wodurch es lösbar bleibt. Der Parameter C steuert dabei die Gewichtung zwischen Funktionsglätte und den Fehlern von Trainingsdaten, die außerhalb des ε -Schlauches liegen. Die Nebenbedingungen 3.27, 3.28 und 3.29 sorgen dafür, dass die über- bzw. unterschätzten Werte in die Minimierung eingehen.

C und ε werden im Validierungszeitraum V mit einer Grid-Search bestimmt. Das bedeutet es werden für C und ε diskrete Wertebereiche G_C und G_ε gewählt und alle möglichen Kombinationen getestet. Die Kombination, die auf dem Validierungsdatensatz im Sinne des RMSE das beste Ergebnis erzielt wird gewählt. Die Wertebereiche werden nach der Empfehlung aus [16] gewählt.

$$G_C = \{0.1, 1, 10, 100, 1000\}$$

$$G_\varepsilon = \{0.001, 0.01, 0.1, 0.5, 1\}$$

Die Abbildungsfunktion $\phi(\mathbf{x})$ transformiert die Eingabedaten in einen höherdimensionalen Raum, in dem vorher nicht-lineare Zusammenhänge linear approximiert werden können. Damit $\phi(\mathbf{x})$ jedoch explizit weder gewählt noch berechnet werden muss, wird der Kernel-Trick [17] angewendet. Das in Formel 3.26 definierte Optimierungsproblem ist konvex und lässt sich daher durch die Lagrange-Dualität in eine äquivalente duale Form überführen [18]. In dieser

dualen Form lässt sich zeigen, dass $\mathbf{w}$ als Linearkombination der transformierten Trainingspunkte dargestellt werden kann:

$$\mathbf{w} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \phi(\mathbf{x}_i), \quad (3.30)$$

wobei $\alpha_i, \alpha_i^* \geq 0$ die dualen Variablen sind. Damit lässt sich die Vorhersagefunktion schreiben als:

$$\hat{r}_{t+1} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_t) \rangle + b. \quad (3.31)$$

In dieser Form tritt $\phi(\mathbf{x})$ ausschließlich in Skalarprodukten der Form $\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ auf. Diese Skalarprodukte können direkt durch eine Kernel-Funktion $K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ berechnet werden, ohne ϕ explizit zu kennen. Als Kernel-Funktion wird der Radial Basis Function (RBF)-Kernel [18] nach Formel 3.32 gewählt, da Aktienrenditen hochgradig nichtlineare und zeitvariante Abhängigkeiten aufweisen. Ein polynomialer Kernel setzt einen festen Grad der Nichtlinearität voraus und ist deshalb nicht geeignet. Der RBF-Kernel bildet die Eingabedaten in einen unendlich-dimensionalen Merkmalsraum ab und kann dadurch beliebig komplexe Abhängigkeiten erfassen, ohne dass deren funktionale Form vorab spezifiziert werden muss.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2), \quad (3.32)$$

wobei γ ein Hyperparameter ist, der bestimmt wie stark der Kernel auf Rauschen reagiert. γ geht ebenfalls in die Grid-Search ein, mit den empfohlenen Werten nach [16]:

$$G_\gamma = \{0.01, 0.1, 1, 10, 50, 100\}.$$

Aus dem Ergebnis der SVR $\hat{r}_{t+1}$ ergibt sich die Preisvorhersage nach

$$\hat{P}_{t+1} = P_t * \exp(\hat{r}_{t+1}). \quad (3.33)$$

3.3.3. StockTimesFM

Aktienkursvorhersagemodelle sind dafür bekannt, stark zum Overfitting zu neigen. Selbst die Nutzung großer Datensätze führt in der Praxis oft nicht zu einer signifikanten Verbesserung der Generalisierungsfähigkeit [19]. Vor diesem Hintergrund wird ein alternativer Ansatz verfolgt, bei dem ein Foundation Model eingesetzt wird, um dessen Übertragbarkeit auf die Vorhersage von Aktienkursen zu untersuchen. TimesFM ist ein von Google Research entwickeltes Foundation Model für Zeitreihenprognosen [20]. Im Gegensatz zu den übrigen in dieser Arbeit vorgestellten Modellen wird TimesFM nicht auf den Aktienkursdaten trainiert, sondern im Zero-Shot-Modus eingesetzt. Das bedeutet, das Modell wird unverändert auf die Aktienrenditedaten angewendet, ohne vorher auf den Daten trainiert worden zu sein. Dadurch kann untersucht werden, ob ein allgemeines Zeitreihenwissen auf Aktienkurse übertragbar ist.

TimesFM basiert auf einer Decoder-only Transformer-Architektur, die auf einem großen Zeitreihendatensatz vortrainiert wurde. Genau wie bei großen Sprachmodellen lernt TimesFM durch das Vorhersagen des nächsten Zeitabschnitts einer Zeitreihe [20]. Dazu wird die Eingabezeitreihe in sogenannte Patches aufgeteilt, also zusammenhängende Abschnitte fixer Länge, die als Tokens in den Transformer eingehen. Formal sei $\mathbf{x} = (x_1, x_2, \dots, x_T)$ die Eingabezeitreihe der Länge T . Diese wird in nicht-überlappende Patches der Länge p aufgeteilt:

$$\mathbf{p}_k = (x_{(k-1) \cdot p + 1}, \dots, x_{k \cdot p}), \quad k = 1, \dots, \left\lfloor \frac{T}{p} \right\rfloor. \quad (3.34)$$

Die Patch-Sequenz $(\mathbf{p}_1, \dots, \mathbf{p}_K)$ wird anschließend durch mehrere Transformer-Decoder-Blöcken verarbeitet. Jeder Block besteht aus einer Masked-Self-Attention-Schicht, die sicherstellt, dass bei der Vorhersage von $\mathbf{p}_{k+1}$ ausschließlich vergangene Patches $\mathbf{p}_1, \dots, \mathbf{p}_k$ berücksichtigt werden und einer nachgelagerten Feed-Forward-Schicht. Die Vorhersage für den Horizont h ergibt sich dann als

$$\hat{x}_{T+h} = f_\theta(\mathbf{p}_1, \dots, \mathbf{p}_K), \quad (3.35)$$

wobei f_θ das Modell TimesFM mit Parametern θ bezeichnet. Da die Zero-Shot-Fähigkeit des Modells untersucht werden soll, bleiben θ unverändert.

Für die Anwendung auf Aktienkurse wird TimesFM auf Log-Renditen angewendet, um Vergleichbarkeit mit den anderen Modellen herzustellen. Da TimesFM eine variable Kontextlänge unterstützt, wird als Kontextfenster ein rollierendes Fenster der letzten w Beobachtungen verwendet. Das heißt, zum Zeitpunkt t fließen die w vorausgehenden Preisbeobachtungen als Eingabe in das Modell ein. Das Modell gibt dann eine Renditenprognose für den nächsten Zeitschritt aus, also

$$\hat{r}_{t+1} = f_\theta(r_{t-w+1}, \dots, r_t). \quad (3.36)$$

Die Preisvorhersage ergibt sich nach

$$\hat{P}_{t+1} = P_t * \exp(\hat{r}_{t+1}). \quad (3.37)$$

3.4. Marktstrategie

3.5. Einschränkungen und Nebenbedingungen

Da im Rahmen dieser Arbeit nicht alle realistischen Marktszenarien berücksichtigt werden können, müssen einige Annahmen getroffen werden.

Komission

Komission ist eine Gebühr, die ein Broker oder eine Börse für die Ausführung einer Order verlangt. Diese ist meistens prozentual abhängig vom Ordervolumen und fällt sowohl beim Kauf als auch beim Verkauf an. Dadurch wird die Profitabilität eines Portfolios reduziert. In den letzten Jahren haben sich die Komission drastisch reduziert. Im Jahr 1970 lagen sie noch bei ca. 1% des Ordervolumens. Durch Neobroker und Konkurrenz unter Brokern ist die Komission mittlerweile stark gesunken, teilweise auf bis 1US\$ pro Trade. Um die Arbeit unabhängig von Änderungen in der Praxis im Bezug auf Kommissionen zu halten, wird bei den Backtests dieser Arbeit keine Komission berechnet. [21]

Spread

Der Spread ist die Differenz zwischen Kaufpreis und Verkaufspreis einer Aktie. Dieser ist an einer Börse meist unterschiedlich, wobei der Kaufpreis höher als der Verkaufspreis ist. Wird eine Aktie gekauft und sofort wieder verkauft, entsteht also ein Verlust. Besonders bei Hochfrequenzhandel führt dies zu Verlusten. Da diese Arbeit ausschließlich Tagesöffnungs und -schlusskurse verwendet, wird kann kein Spread betrachtet werden. Als Preis wird daher in dieser Arbeit der erste bzw. letzte gehandelte Marktpreis verwendet. [21]

Liquidität

Die verwendeten Tageskurse spiegeln die tatsächlich gehandelten Preise wider, berücksichtigen jedoch nicht, ob zum angegebenen Preis tatsächlich ausreichend Volumen für eine Order verfügbar gewesen ist. Da ausschließlich liquide Aktien aus dem S&P500 verwendet werden, wird angenommen, dass alle Transaktionen zum beobachteten Preis ausgeführt werden können. Um eine Verzerrung durch simultane Informationsnutzung zu vermeiden, werden Kaufentscheidungen, die auf dem Schlusskurs eines Tages basieren, zum Eröffnungskurs des folgenden Tages ausgeführt. Auf diese Weise wird sichergestellt, dass Entscheidungen ausschließlich auf Basis von Informationen getroffen werden, die zu diesem Zeitpunkt bereits verfügbar waren. [22]

3.6. Metriken

Die Bewertung der genannten Modell erfolgt in zwei Schritten. Nachdem die Vorhersagemodelle in Kapitel 3.3 vorgestellt wurden, werden sie in dem genannten Testzeitraum in einem etablierten Walk-Forward jeweils für jede ausgewählte Aktie getestet. Das bedeutet, es wird die tatsächliche Historie der Aktienkursbewegung simuliert und es werden jeweils Vorhersagen erstellt. Die erstellten Ergebnisse werden nicht gesichert auch in der Zukunft funktionieren, aber zeigen wie gut das Modell in der Vergangenheit funktioniert hätte. [23] Anschließend werden sie anhand der in Kapitel 3.6.1 vorgestellten Fehlermaße bewertet.

Mithilfe der in Kapitel 3.4 entwickelten Marktstrategien, werden die Modelle dann praxisnah getestet. Es wird ein virtuelles Portfolio angelegt, mit einem Startkapital von $V_0 = 100.000$ US\$. Die Modelle werden in einem Walk-Forward jeweils pro Aktie getestet, wobei die Modelle eine Preisreihe ab dem aktuellen

Tag vorhersagen und anhand der in Kapitel 3.4 vorgestellten Kriterien eine Kaufs- oder Verkaufsentscheidung simuliert wird. Dadurch kann der Portfoliowert steigen und fallen. Am Ende des Testzeitraums erfolgt eine Bewertung anhand der in Kapitel 3.6.2 vorgestellten Kennzahlen.

Ziel der Bewertungen ist immer ein Modellvergleich der vorgestellten Modelle untereinander.

3.6.1. Fehlermaße

Die Extrapolation von Zeitreihen ist ein weitreichend untersuchtes Gebiet. Dadurch haben sich einige Fehlermaße zur Bewertung der Verfahren etabliert. Zu den häufigstverwendeten zählen unter anderem MAPE, RMSE, MSE, Directional Accuracy, R^2 und MAE [9], [24]. Um eine möglichst hohe Vergleichbarkeit mit anderen Arbeiten zu gewährleisten, werden die drei meistverwendeten, MAPE, RMSE und Directional Accuracy, verwendet. Um die Aussagekraft der Analyse zu erhöhen, wird auch das Out-Of-Sample R^2 (OOS- R^2) Maß genommen mit einem Random Walk als Baseline. Hierbei sei anzumerken, dass viele Arbeiten einen R^2 -Score anhand von Preisen als Metrik verwenden, zum Beispiel ([25],[26],[27],[28]). Diese Bewertung ist wenig aussagekräftig, da Aktienkurse stark autokorreliert sind ($P_t \approx P_{t-1}$), und somit ein R^2 -Score von $> 0,9$ eine nicht vorhandene, außerordentlich gute Modellqualität anzeigt. Ein so berechneter R^2 -Score ist somit nur als Vergleichswert und nicht als eigenständiges Maß interpretierbar. Als reiner Vergleichswert ist der R^2 -Score aber auch sinnlos, da der Informationsgehalt nach Formel 3.38 dem RMSE-Maß entspricht.

$$R^2 = 1 - \frac{\text{RMSE}^2 \cdot n}{\text{SS}_{\text{tot}}}, \text{SS}_{\text{tot}} = \text{const}, n = \text{const}. \quad (3.38)$$

Sinnvoll wäre nur eine R^2 -Analyse auf Renditen, anstatt auf Preisen. Da diese Arbeit das OOS- R^2 Maß auf Renditen verwendet, wird diese Ungenauigkeit eliminiert.

Root Mean Squared Error

Gegeben sei ein Signal $[x_1, x_2, \dots, x_n]$ und eine zugehörige Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$. Der RMSE misst die durchschnittliche quadratische Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{x}_i - x_i)^2}.$$

Der RMSE gewichtet Ausreißer durch die Quadratisierung stärker und ist durch die Wurzel interpretierbar, da er in derselbe Einheit wie die Werte der Zeitreihe angegeben wird.

Mean Absolute Percentage Error

Der MAPE misst die durchschnittliche prozentuale Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right|.$$

Da der MAPE relativ zum tatsächlichen Wert x_i normiert ist, ermöglicht er einen skaleninvarianten Vergleich über verschiedene Zeitreihen hinweg. Theoretisch neigt er dazu negative Fehler asymmetrisch zu bestrafen. Dies ist praktisch im Falle von Aktienkursen aber vernachlässigbar.

Out-of-Sample R^2

Der OOS- R^2 nach [29] misst, ob ein Modell bessere Vorhersagen liefert als ein naiver Benchmark. Sei $\hat{x}_i$ die Modellvorhersage und $\hat{x}_i^{\text{RW}} = x_{i-1}$ die Vorhersage eines Random-Walk-Modells, welches den letzten bekannten Wert als Schätzung verwendet. Der OOS- R^2 ist definiert als

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{\sum_{i=1}^n (x_i - \hat{x}_i^{\text{RW}})^2}.$$

Ein Wert $R_{\text{OOS}}^2 > 0$ zeigt an, dass das Modell den Random Walk übertrifft, während $R_{\text{OOS}}^2 \leq 0$ bedeutet, dass die naive Baseline mindestens gleichwertig ist.

Directional Accuracy

Alle bisher vorgestellten Fehlermaße unterscheiden nicht zwischen überschätztem oder unterschätztem Wert. Bei der Vorhersage von Aktienkursen ist dieser Unterschied aber von Relevanz, da eine Unterschätzung, die zu einem Kauf führt, weit weniger problematisch ist als eine Überschätzung. Hierfür wird die Directional Accuracy eingeführt.

Die Directional Accuracy (DA) misst, wie gut ein Modell die Richtung der Kursbewegung vorhersagt, unabhängig von der genauen Höhe des Preises. Für ein Signal $[x_1, x_2, \dots, x_n]$ und eine Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird DA definiert nach

$$DA = \frac{1}{n} \sum_{i=2}^n \mathbf{1} \left(\text{sign}(x_i - x_{i-1}) = \text{sign}(\hat{x}_i - x_{i-1}) \right),$$

wobei $1(\cdot)$ die Indikatorfunktion ist, die den Wert 1 annimmt, wenn die Vorhersage die gleiche Richtung wie die tatsächliche Kursbewegung hat, und 0 sonst.

Ein Wert von $DA = 1$ entspricht einer perfekten Klassifikation, während $DA = 0.5$ einem zufälligen Raten entspricht.

3.6.2. Finanzwirtschaftliche Kennzahlen

Viele Arbeiten, die sich mit Zeitreihenextrapolation beschäftigen und insbesondere die zu Aktienkursvorhersagen, beenden die Evaluation nach der Untersuchung der Fehlermaße [9]. Da diese Arbeit einen weiteren praktischen Fokus fasst, soll auch die praktische Anwendbarkeit, und damit finanzwirtschaftlich evaluiert werden. Außerdem ist im Falle von Aktienkursvorhersage eine Fehlerminimierung nicht zwingend das optimale Ziel im Bezug auf die praktische Anwendung [30].

Viele Arbeiten, die auch die reale Anwendbarkeit testen, fokussieren sich auf Gesamtrendite, Sharpe Ratio und Maximum Drawdown ([31], [32], [33]). Weitere, seltener verwendete Kennzahlen sind das Sortino Ratio, Calmar Ratio und Value-at-risk threshold [23]. Alle Metriken befassen sich mit Rendite oder Volatilität. Um diese beiden Kennzahlen einer Strategiequalität abzubilden, werden in dieser Arbeit die Gesamtrendite und der Maximum Drawdown verwendet. Da Risiko und Rendite in der Finanzwelt keine unabhängigen Größen darstellen, sondern sich häufig beeinflussen, wird ebenso die Sharpe-Ratio evaluiert.

Gesamtrendite

Die Gesamtrendite gibt die insgesamt erzielte Rendite über den gesamten Zeitraum an:

$$R_{cum} = \frac{V_T - V_0}{V_0},$$

wobei V_0 der Anfangswert und V_T der Endwert des Portfolios ist. Sie zeigt die absolute Profitabilität der Strategie.

Sharpe Ratio

Das Sharpe Ratio misst das Rendite-Risiko-Verhältnis eines Portfolios, indem es die Portfolio Rendite ohne die risikofreie Rendite ins Verhältnis zur Volatilität setzt. Es wird berechnet nach

$$S = \frac{R_p - R_f}{\sigma(R_p)},$$

wobei R_p die Rendite des Portfolios, R_f der risikofreie Zinssatz und $\sigma(R_p)$ die Volatilität der Portfoliorendite ist. Die Volatilität $\sigma(R_p)$ wird über die empirische Standardabweichung ermittelt:

$$\sigma(R_p) = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_{P,t} - \bar{R}_P)^2}$$

Ein hohes Sharpe Ratio bedeutet eine hohe Rendite im Vergleich zum Risiko.

Maximum Drawdown

Der Maximum Drawdown (MDD) beschreibt den größten Verlust eines Portfolios vom höchsten Punkt (Peak) bis zum Tiefpunkt (Trough) innerhalb des betrachteten Zeitraums:

$$\text{MDD} = \max_t \frac{\text{Peak}_t - \text{Value}_t}{\text{Peak}_t}.$$

Ein niedriger Maximum Drawdown zeigt, dass das untersuchte Investment nur geringe zwischenzeitliche Verluste erlitt.

4. Implementierung

Viele Arbeiten die sich bereits mit Aktienkursvorhersagen beschäftigt haben, wurden häufig kritisiert, da sie selten reproduzierbar sind. Oft fehlen theoretische Details und meist die gesamte Implementierung, sowie Datensätze. [23] Um eine gute Reproduzierbarkeit zu gewährleisten, wird in diesem Kapitel die Implementierung jeglicher Modelle vorgestellt.

4.1. SDEs zur Aktienausswahl

4.2. ARIMA-GARCH

4.3. Preprocessed SVR

4.4. StockTimesFM

5. Ergebnisse und Bewertung

5.1. Variante1

5.2. Variante2

6. Zusammenfassung und Ausblick

Literaturverzeichnis

- [1] Malkiel, B. G., “Efficient market hypothesis,” in *Finance*, Springer, 1989, pp. 127–134.
- [2] Burton, K. “Inside a moneymaking machine like no other.” Archived from the original on 14 May 2017, Accessed: 05/11/2017. [Online]. Available: <https://www.bloomberg.com/news/articles/2016-11-21/how-renaissance-medallion-fund-became-finance-s-blackest-box>.
- [3] Sewell, M., “The efficient market hypothesis: Empirical evidence,” *International Journal of Statistics and Probability*, vol. 1, no. 2, pp. 164–178, 2012.
- [4] Prakash, A./ Tuo, R./ Ding, Y., “The temporal overfitting problem with applications in wind power curve modeling,” *Technometrics*, vol. 65, no. 1, pp. 70–82, 2023. [Online]. Available: <https://arxiv.org/abs/2012.01349>.
- [5] Rundo, F./ Trenta, F./ Di Stallo, A. L./ Battiato, S., “Machine learning for quantitative finance applications: A survey,” *Applied Sciences*, vol. 9, no. 24, p. 5574, 2019.
- [6] Ballings, M./ Van den Poel, D./ Hespeels, N./ Gryp, R., “Evaluating multiple classifiers for stock price direction prediction,” *Expert systems with Applications*, vol. 42, no. 20, pp. 7046–7056, 2015.
- [7] Lu, W./ Li, J./ Wang, J./ Qin, L., “A cnn-bilstm-am method for stock price prediction,” *Neural computing and applications*, vol. 33, no. 10, pp. 4741–4753, 2021.
- [8] Kumar, D./ Sarangi, P. K./ Verma, R., “A systematic review of stock market prediction using machine learning and statistical techniques,” *Materials Today: Proceedings*, vol. 49, pp. 3187–3191, 2022.

- [9] Gandhmal, D. P./ Kumar, K., “Systematic analysis and review of stock market prediction techniques,” *Computer Science Review*, vol. 34, p. 100 190, 2019.
- [10] Ofomata, A. I. O./ Inyama, S. C./ Umana, R. A./ Omane, A. O., “A stochastic model of the dynamics of stock price for forecasting,” *Journal of Advances in Mathematics and Computer Science*, vol. 25, no. 6, pp. 1–24, 2017.
- [11] Hodrick, R. J./ Prescott, E. C., “Postwar U.S. business cycles: An empirical investigation,” *Journal of Money, Credit and Banking*, vol. 29, no. 1, pp. 1–16, 1997.
- [12] Box, G. E. P./ Jenkins, G. M./ Reinsel, G. C./ Ljung, G. M., *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ: Wiley, 2015.
- [13] Dickey, D. A./ Fuller, W. A., “Distribution of the estimators for autoregressive time series with a unit root,” *Journal of the American Statistical Association*, vol. 74, no. 366a, pp. 427–431, 1979.
- [14] Akaike, H., “A new look at the statistical model identification,” *IEEE Transactions on Automatic Control*, vol. 19, no. 6, pp. 716–723, 1974.
- [15] Drucker, H./ Burges, C. J. C./ Kaufman, L./ Smola, A. J./ Vapnik, V., “Support vector regression machines,” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 9, MIT Press, 1997.
- [16] Hsu, C.-W./ Chang, C.-C./ Lin, C.-J., “A practical guide to support vector classification,” Department of Computer Science, National Taiwan University, Tech. Rep., 2003. [Online]. Available: <https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>.
- [17] Jäkel, F./ Schölkopf, B./ Wichmann, F. A., “A tutorial on kernel methods for categorization,” *Journal of Mathematical Psychology*, vol. 51, no. 6, pp. 343–358, 12/2007.

- [18] Burges, C. J. C., “A tutorial on support vector machines for pattern recognition,” *Data Mining and Knowledge Discovery*, vol. 2, no. 2, pp. 121–167, 06/1998. [Online]. Available: <https://doi.org/10.1023/A:1009715923555>.
- [19] López de Prado, M., “Chaos, overfitting and equilibrium: To what extent can machine learning beat the financial market?” *Journal of Financial Data Science*, vol. 2, no. 4, pp. 8–25, 2020.
- [20] Das, A./ Kong, W./ Sen, R./ Zhou, Y., “A decoder-only foundation model for time-series forecasting,” *arXiv preprint arXiv:2310.10688*, 2024. [Online]. Available: <https://arxiv.org/abs/2310.10688>.
- [21] Jones, C. M., “A century of stock market liquidity and trading costs,” Columbia University, Working Paper SSRN 313681, 2002, Posted September 13, 2002; written May 23, 2002. [Online]. Available: <https://ssrn.com/abstract=313681>.
- [22] Loras, R., “The impact of transactions costs and slippage on algorithmic trading performance,” 09/2024.
- [23] Olorunnimbe, K./ Viktor, H., “Deep learning in the stock market—a systematic survey of practice, backtesting, and applications,” *Artificial Intelligence Review*, vol. 56, no. 3, pp. 2057–2109, 2023. [Online]. Available: <https://doi.org/10.1007/s10462-022-10226-0>.
- [24] “A systematic review of stock market prediction using machine learning and statistical techniques,” *Materials Today: Proceedings*, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S2214785320390337>.
- [25] “Stock price prediction with optimized deep LSTM network with artificial rabbits optimization algorithm,” *Expert Systems with Applications*, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417423008485>.

- [26] “Predicting economic trends and stock market prices with deep learning and advanced machine learning techniques,” *Electronics*, vol. 13, no. 17, p. 3396, 2024. [Online]. Available: <https://www.mdpi.com/2079-9292/13/17/3396>.
- [27] Tan, H./ Minh, L./ Minh, T./ Quyen, T./ Cao-Van, K., “Comparing LSTM models for stock market prediction: A case study with Apple’s historical prices,” in *Nature of Computation and Communication (ICTCC 2023)*, ser. LNICST, vol. 586, Springer, 2024.
- [28] Balamohan, S./ Khanaa, V./ Sivaraman, K., “Effective stock market pricing prediction using long short term memory-upgraded model (LSTM-UP) on evolving data sets,” *SN Computer Science*, vol. 4, p. 658, 2023.
- [29] Campbell, J. Y./ Thompson, S. B., “Predicting excess stock returns out of sample: Can anything beat the historical average?” *The Review of Financial Studies*, vol. 21, no. 4, pp. 1509–1531, 2008.
- [30] “Deep learning for stock performance prediction: A sharpe ratio-optimized approach,” *Asia Pacific Economic and Management Review*, vol. 2, no. 2, 2025. [Online]. Available: <https://ojs.apspublisher.com/index.php/apemr/article/view/210>.
- [31] “Deep reinforcement learning for automated stock trading: An ensemble strategy,” *arXiv*, 2025. [Online]. Available: <https://arxiv.org/abs/2511.12120>.
- [32] “Deep learning in long-short stock portfolio allocation: An empirical study,” *arXiv*, 2024. [Online]. Available: <https://arxiv.org/abs/2411.13555>.
- [33] “Stock market analysis, forecasting, and automated trading using deep learning,” *Engineering Proceedings*, vol. 128, no. 1, p. 42, 2025. [Online]. Available: <https://www.mdpi.com/2673-4591/128/1/42>.

A. SVR Feature Engineering

Es werden die Eingabe-Features der SVR vorgestellt. Gleitender Durchschnitt, Model (a) Ergebnis, Volume, Sentiment, ...