



Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Max Katzenberger und Mathis Köder

Abgabedatum:	01. Februar 2025
Bearbeitungszeitraum:	01.10.2024 - 31.01.2025
Matrikelnummer, Kurs:	0000000, TINF23B2
Ausbildungsfirma:	SAP SE Dietmar-Hopp-Allee 16 69190 Walldorf, Deutschland
Gutachter der Dualen Hochschule:	apl. Prof. Dr. Markus Reischl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

gemäß § 5 der "Studien- und Prüfungsordnung DHBW Technik" vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den March 30, 2026

Nachname, Vorname

Abstract

- English -

This is the starting point of the Abstract. For the final bachelor thesis, there must be an abstract included in your document. So, start now writing it in German and English. The abstract is a short summary with around 200 to 250 words.

Try to include in this abstract the main question of your work, the methods you used or the main results of your work.

Abstract

- Deutsch -

Dies ist der Beginn des Abstracts. Für die finale Bachelorarbeit musst du ein Abstract in deinem Dokument mit einbauen. So, schreibe es am besten jetzt in Deutsch und Englisch. Das Abstract ist eine kurze Zusammenfassung mit ca. 200 bis 250 Wörtern.

Versuche in das Abstract folgende Punkte aufzunehmen: Fragestellung der Arbeit, methodische Vorgehensweise oder die Hauptergebnisse deiner Arbeit.

Contents

Formelverzeichnis	VI
Abkürzungsverzeichnis	VII
List of Figures	VIII
List of Tables	IX
Quellcodeverzeichnis	X
1 Einleitung	1
1.1 Motivation	1
1.2 Probleme	1
1.3 Ziel der Arbeit	2
2 Stand der Forschung	4
2.1 Grundlagen	4
2.2 Zeitreihenanalyse	4
3 Konzeption	5
3.1 Überblick	5
3.2 Daten und Benchmarking	6
3.3 Bewertungskriterien	9
3.4 Einschränkungen und Nebenbedingungen	14
3.5 Modellentwicklung	16
3.6 Marktstrategie	16
4 Implementierung	17
5 Ergebnisse und Bewertung	18
5.1 Variante1	18
5.2 Variante2	18
6 Zusammenfassung und Ausblick	19

Formelverzeichnis

A	mm ²	Fläche
D	mm	Werkstückdurchmesser
$d_{\min}$	mm	kleinster Schaftdurchmesser
L_1	mm	Länge des Werkstückes Nr. 1
	Grad	Freiwinkel
	Grad	Keilwinkel

Abkürzungsverzeichnis

EMH	Efficient Market Hypothesis
DoS	Definition of Success
RMSE	Root Mean Squared Error
DA	Directional Accuracy
MDD	Maximum Drawdown
LSTM	Long Short Term Memory
SVM	Support Vector Machines

List of Figures

List of Tables

3.1	Beispielhafte Rohdaten der Aktienpreise	6
3.2	Ausgewählte Aktien	8

Quellcodeverzeichnis

1 Einleitung

1.1 Motivation

Die Vorhersage von Aktienkursen stellt eine zentrale Herausforderung der Finanzökonomie dar. Trotz umfangreicher Forschung bleibt die präzise Prognose zukünftiger Kursbewegungen aufgrund der Komplexität und Volatilität der Märkte schwierig. In den letzten Jahren wurden vermehrt mathematische und datengetriebene Methoden untersucht, um Muster in Finanzkursen zu identifizieren und Vorhersagen zu verbessern. Da ein zuverlässiger und konsistenter Algorithmus zur Vorhersage von Aktienkursen potenziell erhebliche finanzielle Vorteile bieten würde, ist das Interesse an der Entwicklung solcher Verfahren entsprechend groß.

1.2 Probleme

Ein zentrales theoretisches Problem bei der Vorhersage von Aktienkursen ergibt sich aus der Efficient Market Hypothesis (EMH). Die EMH besagt, dass alle verfügbaren Informationen bereits vollständig in den aktuellen Marktpreisen enthalten sind, sodass zukünftige Kursbewegungen per Definition nicht systematisch vorhergesagt werden können. Unter dieser Annahme verhalten sich Preisänderungen wie ein zufälliger Prozess, der durch keinen Algorithmus vorhergesagt werden kann und die Machbarkeit des Ziels dieser Arbeit in Frage stellt [1]. Trotz der theoretischen Einschränkungen durch die Markteffizienzhypothese existieren empirische Beispiele erfolgreicher quantitativer Handelsstrategien. Renaissance Technologies nutzt seit Jahrzehnten fast ausschließlich mathematis-

che Modelle und Algorithmen zur Kursprognose und erzielt mit dem Medallion Fund Renditen in Höhe von 66% p.a. Dies zeigt, dass systematische Modelle wiederkehrende Muster in Finanzdaten sehr wohl erkennen und wirtschaftlich nutzen können. Hierbei sei anzumerken, dass die genaue Funktionsweise der verwendeten Algorithmen selbstverständlich unbekannt ist. Quantitative Fonds agieren als "Black-Box", was die wissenschaftliche Nachvollziehbarkeit erschwert und somit kein gesichertes Gegenbeispiel zur EMH ist [2]. Des Weiteren gibt es empirische, öffentliche Analysen, die zeigen, dass nicht-lineare Vorhersagemethoden durchaus Gewinne erzielen können [3]. Neben der Frage nach der allgemeinen Machbarkeit ergeben sich eine Vielzahl praktischer Probleme, die die Entwicklung erschweren. Zunächst enthalten Kursdaten viel Rauschen. Es ist schwer den tatsächlichen Signalanteil des Preises herauszufiltern, um zu den Trend zu erkennen. Des Weiteren ist es eine große Schwierigkeit, den korrekten Komplexitätsgrad des Modells zu finden. Zu komplexe Modelle „overfitten“, passen sich also zu stark an historische Daten an und generalisieren somit schlecht auf neuen, realen Daten. Dies betrifft vor allem Deep Learning Modelle, welche zu viele Freiheitsgrade haben, und somit den vergangenen Kurs oder das Rauschen selbst abbilden und den Trend dabei nicht erkennen. Auf der anderen Seite sind zu simple Modelle nicht in der Lage nicht-lineare Zusammenhänge zu erkennen und generalisieren zu stark [4].

1.3 Ziel der Arbeit

Das Ziel dieser Arbeit ist die Untersuchung bestehender Algorithmen und Strategien auf deren Rentabilität und Stabilität. Es soll eine Testumgebung geschaffen werden, mit welcher verschiedene Analysemodelle getestet und auf realen, vergangenen Daten ausprobiert werden können. Des Weiteren soll ein eigenes Modell durch neue Ideen und eine Kombination von vorhandenen Strategien geschaffen werden. Diese Strategien sollen zum einen mathematischer,

quantitativer Natur sein, und zum anderen durch live Nachrichten und Social Media Posts angereichert werden. Schließlich soll jedes Modell evaluiert und bewertet werden.

2 Stand der Forschung

2.1 Grundlagen

2.2 Zeitreihenanalyse

2.2.1 stochastische Differentialgleichungen

2.2.2 ARIMA usw

:

2.2.3 Zusammenfassung

3 Konzeption

3.1 Überblick

In diesem Kapitel wird die Entwicklung der in dieser Arbeit verwendeten Modelle zur Vorhersage von Aktienkursen beschrieben. Dabei werden Ansätze aus der Zeitreihenanalyse und dem maschinellen Lernen konzeptioniert.

Zunächst wird das Datenset erläutert: Auswahl des Aktienuniversums und der konkreten Aktien, Aufteilung der Zeitreihen sowie Datenbereinigung. Anschließend werden die Metriken und Bewertungskriterien vorgestellt, die sowohl mathematische als auch finanzwirtschaftliche Aspekte berücksichtigen.

Der Rahmen der Arbeit wird definiert, einschließlich des Untersuchungsgegenstands, der getroffenen Annahmen sowie der Nebenbedingungen und Einschränkungen. Diese Vereinfachungen dienen der Interpretierbarkeit, unterscheiden sich aber teilweise von realen Marktbedingungen.

Aufbauend auf diesen Grundlagen erfolgt die Modellentwicklung. Wir stellen 4 Modelle vor: bla bla LSTM bla mit attention, bam bam...

Zum Abschluss wird die Umsetzung der Vorhersagen in einer Handelsstrategie beschrieben. Hierbei werden Risikomanagement, Positionsgrößen und Vorhersagehorizont betrachtet, um die praktische Anwendbarkeit der Modelle zu analysieren.

3.2 Daten und Benchmarking

Unter dem Survivorship Bias versteht man die statistische Verzerrung, die entsteht, wenn nur überlebende Unternehmen ausgewählt werden und insolvente oder aus dem Index entfernte Aktien unberücksichtigt bleiben, was historische Renditen systematisch nach oben verzerrt. Für die Analyse wird ein festes Aktienuniversum herangezogen, bestehend aus den im Jahr 2020 im S&P 500 gelisteten Unternehmen, wodurch ein Survivorship Bias vermieden wird.

Die Kursdaten jeder Aktie werden als Zeitreihe betrachtet. Für jeden Handelstag enthält die Zeitreihe folgende Werte:

- Open: erster Preis zu dem an diesem Tag gehandelt wurde
- Close: letzter Preis zu dem an diesem Tag gehandelt wurde
- High: höchster Preis zu dem an diesem Tag gehandelt wurde
- Low: niedrigster Preis zu dem an diesem Tag gehandelt wurde
- Volume: gesamtes kumuliertes Handelsvolumen an diesem Tag

Die Daten werden als CSV-Dateien von Yahoo Finance heruntergeladen. Sie werden dann in parquet-Dateien konvertiert, um Speicherplatz und Zeit zu sparen.

Table 3.1: Beispielhafte Rohdaten der Aktienpreise

Datum	Close	High	Low	Open	Volume
2022-11-11	147,34	147,64	142,09	143,52	93 979 700
2022-11-14	145,94	147,91	145,10	146,62	73 374 100

Quelle: Yahoo Finance. Alle Preisangaben in USD.

Für jede Zeitreihe wird eine Unterteilung in drei disjunkte Abschnitte vorgenommen:

- **Trainingszeitraum (T):** 01.2020–12.2023, in dem die Modelle auf den historischen Kursen trainiert werden.
- **Validierungszeitraum (P):** 01.2024–06.2024, der zur Optimierung der Modellparameter dient.
- **Testzeitraum (S):** 07.2024–12.2025, der ausschließlich für die abschließende Evaluierung der Modelle auf bisher ungesehenen Daten verwendet wird.

Die Modelle werden zunächst auf den Trainingsdaten trainiert. Anschließend erfolgt die Optimierung der Hyperparameter anhand des Validierungszeitraums. Die finale Leistung wird schließlich auf dem Testzeitraum bewertet, um die zeitliche Generalisierbarkeit der Modelle zu überprüfen.

Für die Analyse werden 10 Aktien verwendet. Somit sollen Ausreißer einzelner Unternehmen den Gesamterfolg der Modelle nicht übermäßig beeinflussen. Die Auswahl dieser Aktien muss stets anhand von Informationen erfolgen, die vor dem Trainingszeitraum bekannt waren, um einen Lookahead Bias zu verhindern. Da die Auswahl geeigneter Zeitreihen nicht Teil dieser Arbeit ist, werden die hier verwendeten untersuchten Aktien zufällig aus dem S&P500 vom Jahresbeginn 2020 ausgewählt. Diese Auswahl bleibt über den Gesamtzeitraum der Arbeit bestehen. Die ausgewählten Aktien sind zu sehen in Tabelle 3.2.

Da die Analysen stets auf Backtests basieren, ist eine Bereinigung der historischen Aktienkurse notwendig, da sich die nominalen Preise einer Aktie im Zeitverlauf durch Ereignisse wie Aktiensplits oder Dividendenzahlungen verändern, ohne dass sich der tatsächliche Unternehmenswert und demnach der Aktienwert geändert hat. Ohne eine solche Anpassung würden Kursbewegungen verzerrt dargestellt, was zu falsch trainierten Modellen oder falschen Tests führt.

Table 3.2: Ausgewählte Aktien

Unternehmen	Tickersymbol
Amazon	AMZN
Adobe	ADBE
CVS Health	CVS
General Motors	GM
Micron Technology	MU
PayPal	PYPL
Walgreens Boots Alliance	WBA
PepsiCo	PEP
Salesforce	CRM
3M	MMM

Sei P_t der beobachtete Schlusskurs einer Aktie zum Zeitpunkt t . Der bereinigte Preis $\tilde{P}_t$ ergibt sich aus dem ursprünglichen Preis multipliziert mit einem Anpassungsfaktor A_t :

$$\tilde{P}_t = P_t \cdot A_t.$$

Der Anpassungsfaktor wird rekursiv berechnet. Sei P_t für $t = 1, \dots, n$ gegeben, gilt $A_n = 1$. Bei einem Aktiensplit zum Zeitpunkt t mit Verhältnis $s_t = \frac{\text{neue Aktien}}{\text{alte Aktien}}$ gilt

$$A_{t-1} = \frac{A_t}{s_t}.$$

Beispielsweise führt ein 2:1-Split ($s_t = 2$) dazu, dass alle historischen Preise vor dem Split halbiert werden.

Dividendenzahlungen werden ebenfalls berücksichtigt, um eine konsistente Renditereihe zu erhalten. Sei D_t die Dividende zum Zeitpunkt t . Dann wird der Anpassungsfaktor wie folgt aktualisiert:

$$A_{t-1} = A_t \cdot \frac{P_t - D_t}{P_t}.$$

Somit ist der historische Preis mit dem die Modelle trainiert und getestet werden abhängig vom letzten betrachteten Wert. Der letzte Wert entspricht somit dem aktuellen, realisierbaren Aktienwert, alle anderen Werte potenziell aber nicht den realen Aktienwerten zu dem Zeitpunkt.

3.3 Bewertungskriterien

Die Bewertung der genannten Modell erfolgt in zwei Schritten. Nachdem die Vorhersagemodelle in Kapitel 3.5, vorgestellt wurden, werden sie auf den genannten Testzeitraum angewendet und es werden jeweils Vorhersagen erstellt. Anschließend werden sie anhand der in Kapitel 3.3.1 vorgestellten Fehlermaße bewertet.

Mithilfe der in Kapitel 3.6 entwickelten Marktstrategien, werden die Modelle dann praxisnah getestet. Es wird ein virtuelles Portfolio angelegt, mit einem Startkapital von $V_0 = 100.000$ US\$. Die Modelle werden auf den Testzeitraum angewendet, wobei die Modelle eine Preisreihe ab dem aktuellen Tag vorhersagen und anhand der in 3.6 vorgestellten Kriterien eine Kaufs- oder Verkaufsentscheidung simuliert wird. Dadurch kann der Portfoliowert steigen und fallen. Am Ende des Testzeitraums erfolgt eine Bewertung anhand der in 3.3.2 vorgestellten Kennzahlen.

Ziel der Bewertungen ist immer ein Modellvergleich der vorgestellten Modelle untereinander. Außerdem erfolgt bei ausgewählten Kennzahlen ein Vergleich zu einer jeweils angegebenen Baseline, um die Interpretierbarkeit zu erhöhen. Außerdem wird, um eine weitere Benchmark zu haben, bei jedem Model-

Ivergleich auch ein etabliertes ARIMA Modell getestet, um einen weiteren Vergleichsparameter zu haben.

3.3.1 Fehlermaße

Die Extrapolation von

Root Mean Squared Error

Gegeben sei ein Signal $[x_1, x_2, \dots, x_n]$ und eine zugehörige Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$. Der Root Mean Squared Error (RMSE) misst die durchschnittliche quadratische Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{x}_i - x_i)^2}.$$

Der RMSE gewichtet Ausreißer durch die Quadratisierung stärker und ist durch die Wurzel interpretierbar, da er in derselbe Einheit wie die Werte der Zeitreihe angegeben wird.

Bestimmtheitsmaß (R^2 -Score)

Für das Signal $[x_1, x_2, \dots, x_n]$ und die Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird zunächst der Signalmittelwert berechnet:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Darauf aufbauend wird die totale Quadratsumme

$$SS_{\text{tot}} = \sum_{i=1}^n (x_i - \bar{x})^2$$

sowie die Residuenquadratsumme

$$SS_{\text{res}} = \sum_{i=1}^n (x_i - \hat{x}_i)^2$$

bestimmt. Das Bestimmtheitsmaß ergibt sich daraus zu

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}.$$

Ein Wert von R^2 nahe 1 zeigt eine sehr gute Modellanpassung an die Daten an. Werte nahe 0 bedeuten, dass die Vorhersagen kaum besser sind als eine konstante Vorhersage des Mittelwerts. Negative Werte deuten darauf hin, dass das Modell schlechter abschneidet als diese einfache Baseline. Hierbei ist für diese Arbeit relevant dass Aktien meistens nicht stationär sind. Das Signal und die Vorhersage werden stationär gemacht, indem Renditen oder Differenzen zum Vortag als Werte verwendet werden, anstatt von absoluten Preisen.

Directional Accuracy

Die Directional Accuracy (DA) misst, wie gut ein Modell die Richtung der Kursbewegung vorhersagt, unabhängig von der genauen Höhe des Preises. Diese Metrik ist sowohl für Vorhersage- als auch Klassifizierungsmodelle sinnvoll. Für Vorhersagemodelle definieren wir sie folgendermaßen. Für ein Signal $[x_1, x_2, \dots, x_n]$ und eine Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird DA berechnet als

$$DA = \frac{1}{n} \sum_{i=2}^n \mathbf{1} \left(\text{sign}(x_i - x_{i-1}) = \text{sign}(\hat{x}_i - \hat{x}_{i-1}) \right),$$

wobei $\mathbf{1}(\cdot)$ die Indikatorfunktion ist, die den Wert 1 annimmt, wenn die Vorhersage die gleiche Richtung wie die tatsächliche Kursbewegung hat, und 0 sonst.

Da Klassifizierungsmodelle keinen Preis vorhersagen definieren wir DA für diese folgendermaßen.

DA für Klassifizierungsmodelle misst, wie gut die vorhergesagten Signale mit den tatsächlichen Marktbewegungen übereinstimmen. Sei $y_i \in \{+1, -1\}$ das tatsächliche Marktsignal für den Zeitpunkt i (+1 für Kursanstieg, -1 für Kursrückgang) und $\hat{y}_i \in \{+1, -1\}$ die vom Modell prognostizierte Richtung. Dann wird DA berechnet als

$$DA = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(\hat{y}_i = y_i),$$

Ein Wert von $DA = 1$ entspricht einer perfekten Klassifikation, während $DA = 0.5$ einem zufälligen Raten entspricht.

3.3.2 Finanzwirtschaftliche Kennzahlen

Die meisten Arbeiten, die sich mit Zeitreihenextrapolation beschäftigen und insbesondere die zu Aktienkursvorhersagen, beenden die Evaluation nach der Untersuchung der Fehlermaße. Da diese Arbeit einen weiteren praktischen Fokus fasst, soll auch die praktische Anwendbarkeit, und damit finanzwirtschaftlich evaluiert werden.

Gesamtrendite

Die Gesamtrendite gibt die insgesamt erzielte Rendite über den gesamten Zeitraum an:

$$R_{cum} = \frac{V_T - V_0}{V_0},$$

wobei V_0 der Anfangswert und V_T der Endwert des Portfolios ist. Sie zeigt die absolute Profitabilität der Strategie.

Der Vergleichswert hierfür ist die Gesamtrendite einer Buy-and-hold Strategie. Also die Rendite die erreicht wird, wenn die Aktie über den gesamten Betrachtungszeitraum gehalten wird:

$$R_{BH} = \frac{P_T - P_0}{P_0}.$$

Hiermit soll analysiert werden, ob die Modelle eine bessere Strategie darstellen als einfach "in den Markt zu investieren".

Sharpe Ratio

Die Sharpe Ratio misst das Rendite-Risiko-Verhältnis eines Portfolios und wird berechnet als

$$S = \frac{\frac{1}{T} \sum_{t=1}^T (R_{p,t} - R_{f,t})}{\sigma(R_p)},$$

wobei R_p die Rendite des Portfolios, R_f der risikofreie Zinssatz und $\sigma(R_p)$ die Standardabweichung der Portfoliorenditen ist. Eine hohe Sharpe Ratio deutet auf eine hohe Rendite bei gleichzeitig niedrigem Risiko hin.

Maximum Drawdown

Der Maximum Drawdown (MDD) beschreibt den größten Verlust eines Portfolios vom höchsten Punkt (Peak) bis zum Tiefpunkt (Trough) innerhalb des betrachteten Zeitraums:

$$MDD = \max_t \frac{Peak_t - Value_t}{Peak_t}.$$

Ein niedriger Maximum Drawdown zeigt, dass die Strategie relativ robust gegenüber großen Verlusten ist.

3.4 Einschränkungen und Nebenbedingungen

Da im Rahmen dieser Arbeit nicht alle möglichen Modellansätze und realistischen Marktszenarien berücksichtigt werden können, ist eine Eingrenzung des Untersuchungsgegenstands erforderlich. Zu diesem Zweck werden im Folgenden einige Annahmen und Nebenbedingungen festgelegt.

Komission

Komission ist eine Gebühr oder Provision, die ein Broker oder eine Börse für die Ausführung einer Order verlangt. Diese ist meistens prozentual abhängig vom Ordervolumen und fällt sowohl beim Kauf als auch beim Verkauf an. Dadurch wird die Profitabilität eines Portfolios reduziert. In den letzten Jahren haben sich die Komission drastisch reduziert. Im Jahr 1970 lagen sie noch bei ca. 1% des Ordervolumens. Durch Neobroker und Konkurrenz unter Brokern ist die Komission mittlerweile stark gesunken, teilweise auf bis 1US\$ pro Trade oder auch ganz kostenfrei. Da heute bereits ohne oder mit sehr geringer Komission

gehandelt werden kann, und es auch in Zukunft erwartbar ist, wird bei den Backtests dieser Arbeit keine Kommission betrachtet.

Spread

Der Spread ist die Differenz zwischen Kaufpreis und Verkaufspreis einer Aktie. Dieser ist an einer Börse meist unterschiedlich, wobei der Kaufpreis höher als der Verkaufspreis ist. Wird eine Aktie gekauft und sofort wieder verkauft entsteht also ein Verlust. Besonders bei Hochfrequenzhandel führt dies zu Verlusten. Da diese Arbeit ausschließlich Tagesöffnungs und -schlusskurse verwendet, wird kein Spread betrachtet. Als Preis wird daher in dieser Arbeit der erste bzw. letzte gehandelte Marktpreis verwendet. Da kein Hochfrequenzhandel untersucht wird, führt dies nicht zu einer relevanten Abweichung.

Liquidität

Die verwendeten Tageskurse spiegeln die tatsächlich gehandelten Preise wider, berücksichtigen jedoch nicht, ob zum angegebenen Preis tatsächlich ausreichend Volumen für eine Order verfügbar gewesen wäre. Es wird daher angenommen, dass alle Transaktionen zum beobachteten Preis ausgeführt werden können, auch wenn dies in der Realität möglicherweise nicht der Fall wäre. Um eine zusätzliche Verzerrung durch simultane Informationsnutzung zu vermeiden, werden Orders, die auf dem Schlusskurs eines Tages basieren, zum Eröffnungskurs des folgenden Tages ausgeführt. Auf diese Weise wird sichergestellt, dass Entscheidungen ausschließlich auf Basis von Informationen getroffen werden, die zu diesem Zeitpunkt bereits verfügbar waren. Da in dieser Arbeit ausschließlich liquide Aktien aus dem S&P500 untersucht werden, stellt diese Vereinfachung jedoch kein wesentliches Problem dar, da die Orderausführung bei diesen Aktien in

der Praxis in der Regel ohne größere Abweichungen vom beobachteten Preis möglich ist.

3.5 Modellentwicklung

3.5.1 Lineare Modelle

3.5.2 Korrelationsmatrix

3.5.3 Support Vector Machines (SVM)

3.5.4 Sentiment-Analyse mit Echtzeitinformationen

3.5.5 SVMs mit Analyse Features

3.6 Marktstrategie

4 Implementierung

5 Ergebnisse und Bewertung

5.1 Variante1

5.2 Variante2

6 Zusammenfassung und Ausblick

Literaturverzeichnis

- [1] Malkiel, B. G., “Efficient market hypothesis,” in *Finance*, Springer, 1989, pp. 127–134.
- [2] Burton, K. “Inside a moneymaking machine like no other.” Archived from the original on 14 May 2017, Accessed: 05/11/2017. [Online]. Available: <https://www.bloomberg.com/news/articles/2016-11-21/how-renaissance-s-medallion-fund-became-finance-s-blackest-box>.
- [3] Sewell, M., “The efficient market hypothesis: Empirical evidence,” *International Journal of Statistics and Probability*, vol. 1, no. 2, pp. 164–178, 2012.
- [4] Prakash, A./ Tuo, R./ Ding, Y., “The temporal overfitting problem with applications in wind power curve modeling,” *Technometrics*, vol. 65, no. 1, pp. 70–82, 2023. [Online]. Available: <https://arxiv.org/abs/2012.01349>.