



Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Max Katzenberger und Mathis Köder

Abgabedatum:	18. Mai 2026
Bearbeitungszeitraum:	10.10.2025 - 18.05.2026
Matrikelnummer:	ToDo
Kurs:	TINF23B2
Gutachter der Dualen Hochschule:	apl. Prof. Dr. Markus Reischl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

gemäß § 5 der “Studien- und Prüfungsordnung DHBW Technik” vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den May 14, 2026

Nachname, Vorname

Abstract

- English -

This is the starting point of the Abstract. For the final bachelor thesis, there must be an abstract included in your document. So, start now writing it in German and English. The abstract is a short summary with around 200 to 250 words.

Try to include in this abstract the main question of your work, the methods you used or the main results of your work.

Abstract

- Deutsch -

Dies ist der Beginn des Abstracts. Für die finale Bachelorarbeit musst du ein Abstract in deinem Dokument mit einbauen. So, schreibe es am besten jetzt in Deutsch und Englisch. Das Abstract ist eine kurze Zusammenfassung mit ca. 200 bis 250 Wörtern.

Versuche in das Abstract folgende Punkte aufzunehmen: Fragestellung der Arbeit, methodische Vorgehensweise oder die Hauptergebnisse deiner Arbeit.

Contents

Formelverzeichnis	VI
Abkürzungsverzeichnis	VII
List of Figures	IX
List of Tables	X
Quellcodeverzeichnis	XI
1. Einleitung	1
1.1. Motivation	1
1.2. Probleme	1
1.3. Ziel der Arbeit	2
2. Stand der Forschung	4
2.1. Performance-Metriken	4
2.2. Klassische statistische Verfahren	5
2.3. Machine-Learning-Ansätze	7
2.4. Hybride Modelle	9
2.5. Vergleich und Forschungslücke	10
2.6. Ansatz der Arbeit	11
3. Konzeption	12
3.1. Überblick	12
3.2. Daten und Aktienwahl	14
3.3. Modellentwicklung	25
3.4. Handelsstrategie	37
3.5. Einschränkungen und Nebenbedingungen	40
3.6. Metriken	41
4. Implementierung	47
4.1. SDEs zur Aktienauswahl	52
4.2. LinearSeparation	54
4.3. Preprocessed SVR	56
4.4. StockTimesFM	56

5. Ergebnisse und Bewertung	58
5.1. SDE Aktienauswahl	58
5.2. LinearSeparation	58
5.3. Preprocessed SVR	58
5.4. StockTimesFM	58
6. Zusammenfassung und Ausblick	59
Literaturverzeichnis	XII
A. SVR Modellierung	I

Formelverzeichnis

A	mm ²	Fläche
D	mm	Werkstückdurchmesser
$d_{\min}$	mm	kleinster Schaftdurchmesser
L_1	mm	Länge des Werkstückes Nr. 1
	Grad	Freiwinkel
	Grad	Keilwinkel

Abkürzungsverzeichnis

EMH	Efficient Market Hypothesis
DoS	Definition of Success
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
MSE	Mean Squared Error
MAPE	Mean Absolute Percentage Error
DA	Directional Accuracy
MDD	Maximum Drawdown
LSTM	Long Short Term Memory
OOS-R^2	Out-Of-Sample R^2
NLP	Natural Language Processing
SVM	Support Vector Machine
NN	Neuronal Network
SVR	Support Vector Regression
ARIMA	Autoregressive Integrated Moving Average
ARMA	Autoregressive Moving Average
GARCH	Generalized Autoregressive Conditional Heteroscedasticity
kNN	k-Nearest Neighbors
CNN	Convolutional Neural Network
RNN	Recurrent Neural Network
GRU	Gated Recurrent Unit

ROI	Return on Invest
SDE	Stochastische Differentialgleichung
OLS	Ordinary Least Squares
HP	Hodrick-Prescott
ADF	Augmented Dickey-Fuller
AIC	Akaike Information Criterion
RBF	Radial Basis Function
RSI	Relative Strength Index
MACD	Moving Average Convergence Divergence

List of Figures

3.1. Struktur der Konzeption	13
3.2. Ablauf Aktienauswahl	19
4.1. Gesamtüberblick: Datenfluss von der Beschaffung bis zur Evaluation .	47
4.2. Aktienauswahl: Datenfluss von den historischen Kursdaten und Makro- faktoren bis zu den ausgewählten Aktien	53
4.3. LinearSeparation: Datenfluss von den Trainingsdaten bis zum trainierten Modell	55
4.4. StockTimesFM: Datenfluss der Vorhersage von neuen Kursen	57

List of Tables

3.1. Beispielhafte Rohdaten der Aktienpreise. Alle Preisangaben in USD. .	15
3.2. Makroökonomische Faktoren	17
3.3. Bestandteile der Kovarianzmatrix	24
3.4. Komponenten der Aktienkursmodellierung	26

Quellcodeverzeichnis

1. Einleitung

1.1. Motivation

Die Vorhersage von Aktienkursen stellt eine zentrale Herausforderung der Finanzökonomie dar. Trotz umfangreicher Forschung bleibt die präzise Prognose zukünftiger Kursbewegungen aufgrund der Komplexität und Volatilität der Märkte schwierig. In den letzten Jahren wurden vermehrt mathematische und datengetriebene Methoden untersucht, um Muster in Finanzkursen zu identifizieren und Vorhersagen zu verbessern. Da ein zuverlässiger und konsistenter Algorithmus zur Vorhersage von Aktienkursen potenziell erhebliche finanzielle Vorteile bieten würde, ist das Interesse an der Entwicklung solcher Verfahren entsprechend groß.

1.2. Probleme

Ein zentrales theoretisches Problem bei der Vorhersage von Aktienkursen ergibt sich aus der Efficient Market Hypothesis (EMH). Die EMH besagt, dass alle verfügbaren Informationen bereits vollständig in den aktuellen Marktpreisen enthalten sind, sodass zukünftige Kursbewegungen per Definition nicht systematisch vorhergesagt werden können. Unter dieser Annahme verhalten sich Preisänderungen wie ein zufälliger Prozess, der durch keinen Algorithmus vorhergesagt werden kann und die Machbarkeit des Ziels dieser Arbeit in Frage stellt [1]. Trotz der theoretischen Einschränkungen durch die Markteffizienzhypothese existieren empirische Beispiele erfolgreicher quantitativer Handelsstrategien. Renaissance Technologies nutzt seit Jahrzehnten fast ausschließlich mathematische Modelle und Algorithmen zur Kursprognose und erzielt mit dem Medallion Fund Renditen in Höhe von 66% p.a. Dies zeigt, dass systematische Modelle wiederkehrende Muster in Finanzdaten

sehr wohl erkennen und wirtschaftlich nutzen können. Hierbei sei anzumerken, dass die genaue Funktionsweise der verwendeten Algorithmen selbstverständlich unbekannt ist. Quantitative Fonds agieren als "Black-Box", was die wissenschaftliche Nachvollziehbarkeit erschwert und somit kein gesichertes Gegenbeispiel zur EMH ist [2]. Des Weiteren gibt es empirische, öffentliche Analysen, die zeigen, dass nicht-lineare Vorhersagemethoden durchaus Gewinne erzielen können [3]. Neben der Frage nach der allgemeinen Machbarkeit ergeben sich eine Vielzahl praktischer Probleme, die die Entwicklung erschweren. Zunächst enthalten Kursdaten viel Rauschen. Es ist schwer den tatsächlichen Signalanteil des Preises herauszufiltern, um zu den Trend zu erkennen. Des Weiteren ist es eine große Schwierigkeit, den korrekten Komplexitätsgrad des Modells zu finden. Zu komplexe Modelle „overfitten“, passen sich also zu stark an historische Daten an und generalisieren somit schlecht auf neuen, realen Daten. Dies betrifft vor allem Deep Learning Modelle, welche zu viele Freiheitsgrade haben, und somit den vergangenen Kurs oder das Rauschen selbst abbilden und den Trend dabei nicht erkennen. Auf der anderen Seite sind zu simple Modelle nicht in der Lage nicht-lineare Zusammenhänge zu erkennen und generalisieren zu stark [4].

1.3. Ziel der Arbeit

Das Ziel dieser Arbeit ist das Entwickeln einer Strategie zur Auswahl von rentablen Aktien aus einem Aktienuniversum und das Entwickeln und Testen von Vorhersagemodellen auf diesen gewählten Aktien. Anschließend wird eine Marktstrategie entwickelt und die Modelle werden in einem realistischen Backtest evaluiert. Es soll eine Testumgebung geschaffen werden, mit welcher verschiedene Analysemodelle getestet und auf realen, vergangenen Daten ausprobiert werden können.

Die Arbeit ist im Weiteren wie folgt strukturiert: Kapitel 2 gibt einen Überblick über den Stand der Forschung im Bereich der Aktienkursvorhersage, Kapitel 3 erklärt wie die Daten ausgewählt und aufbereitet werden, wie die Modelle aufgebaut sind und mit welchen Metriken und wirtschaftlichen Kennzahlen die Modelle

evaluiert werden, Kapitel 4 beschreibt die Implementierung der Modelle, Kapitel 5 präsentiert die Ergebnisse der Benchmarks und die Bewertung der Modelle und Kapitel 6 fasst die Arbeit zusammen und gibt einen Ausblick auf mögliche zukünftige Arbeiten.

2. Stand der Forschung

Dieses Kapitel analysiert Arbeiten und Studien, die verschiedene Ansätze verwenden, um Aktienkurse, Aktienkursbewegungen und Aktienkursrenditen vorherzusagen. Abschnitt 2.1 behandelt die Performance-Metriken, die die Forschung verwendet. Die verschiedenen Ansätze lassen sich in die zwei Hauptkategorien der klassischen statistischen Verfahren in Abschnitt 2.2 und der Machine-Learning-Ansätze in Abschnitt 2.3 unterteilen. Durch die Kombination mehrerer Modelle entstehen hybride Modelle, die Abschnitt 2.4 behandelt. Abschließend zieht Abschnitt 2.5 einen Vergleich der verschiedenen Ansätze und identifiziert die Forschungslücke, die den Bedarf für den eigenen Ansatz begründet.

2.1. Performance-Metriken

Das Review von Kumar et al. [5] beschreibt die fünf am häufigsten verwendeten Metriken in der Literatur zur Vorhersage von Aktienkursen:

- **Accuracy:** Accuracy misst den Anteil der korrekt vorhergesagten Bewegungen. Klassifikationsmodelle verwenden hauptsächlich Accuracy.
- **cro:RMSE** Root Mean Squared Error (RMSE): RMSE misst die durchschnittliche Abweichung der vorhergesagten Werte von den tatsächlichen Werten.
- **cro:MAE** Mean Absolute Error (MAE): MAE misst die durchschnittliche absolute Abweichung der Vorhersagen von den tatsächlichen Werten. Regressionsmodelle verwenden häufig MAE.

- **cro:MSE** **Mean Squared Error (MSE)**: MSE misst die durchschnittliche quadratische Abweichung der Vorhersagen von den tatsächlichen Werten. Regressionsmodelle verwenden häufig MSE.
- **cro:MAPE** **Mean Absolute Percentage Error (MAPE)**: MAPE misst die durchschnittliche prozentuale Abweichung der Vorhersagen von den tatsächlichen Werten. MAPE eignet sich besonders, wenn die Werte stark variieren. Außerdem ist MAPE die am häufigsten verwendete Metrik in der Literatur.

2.2. Klassische statistische Verfahren

Die klassischen statistischen Verfahren lassen sich in zwei Hauptkategorien unterteilen: lineare Zeitreihenmodelle und stochastische Modelle. Lineare Zeitreihenmodelle, wie **cro:ARIMA** Autoregressive Integrated Moving Average (ARIMA) und **cro:GARCH** Generalized Autoregressive Conditional Heteroscedasticity (GARCH), sind statistische Verfahren, die Muster und Trends in zeitlich geordneten Daten erkennen, um zukünftige Werte vorherzusagen.

2.2.1. Lineare Zeitreihenmodelle

Die Übersichtsstudie von Rundo et al. [6] betrachtet die klassischen statistischen Modelle ARIMA und GARCH. Sie untersucht, wie gut ARIMA zukünftige Tagespreise von Aktien vorhersagen kann. Die Studie stellt fest, dass ARIMA die beiden untersuchten Aktienindizes befriedigend vorhersagen konnte.

Zudem betrachtet die Übersichtsstudie [6] ein Paper, das ein Kombinationsmodell aus ARIMA und GARCH verwendet, um Aktienmärkte vorherzusagen. Für die Einzschrittprognosen liefern ARIMA und GARCH akkurate Vorhersagen, während die Mehrschrittprognosen nicht mehr zuverlässig ausfallen. Um dieses Problem zu lösen, entwickeln die Autoren ein neues Kombinationsmodell aus ARIMA und

GARCH. Die Ergebnisse des Kombinationsmodells sind auch für Mehrschrittprognosen zuverlässig, selbst bei sehr volatilen Zeitreihen. Insgesamt zeigt die Übersichtsstudie, dass klassische statistische Modelle wie ARIMA und GARCH Aktienkurse vorhersagen können, insbesondere für kurzfristige Prognosen. Allerdings verlieren sie bei längeren Prognosehorizonten an Genauigkeit, was die Entwicklung von hybriden Modellen zur Verbesserung der Vorhersageleistung notwendig macht.

Eine Übersichtsstudie von Shah et al. [7] analysiert verschiedene Paper, die ARIMA untersuchen. Das erste Paper beschreibt den Prozess des Erstellens von ARIMA-Modellen und sucht dann das optimale Modell. Dieses optimale Modell kann die Aktienkurse von Nokia und Zenith Bank zufriedenstellend vorhersagen. Ein weiteres Paper arbeitet heraus, dass ARIMA bei kurzfristigen Vorhersagen mit fortgeschrittenen Vorhersagetechniken mithalten kann.

2.2.2. Stochastische Modelle

Sasikumar and Abdullah [8] stellen in ihrem Paper verschiedene stochastische Modelle und ihre Anwendungen in der Finanzwelt vor. Die Random Walk Theorie besagt, dass die zukünftigen Bewegungen von Aktienkursen unvorhersehbar sind. Verschiedene Studien bestätigen die Random Walk Theorie und zeigen, dass sich aus ihr Empfehlungen für den optimalen Investitionszeitpunkt ableiten lassen.

Aus dem Paper von Sasikumar and Abdullah [8] geht hervor, dass Markow-Ketten primär für kurzfristige Vorhersagen geeignet sind. Außerdem zeigt das Paper, dass Markow-Ketten höherer Ordnung sowie gewichtete Markow-Ketten zuverlässigere Vorhersagen liefern als einfache Markow-Ketten.

Das letzte Modell, das Sasikumar and Abdullah [8] vorstellen, ist das Hidden Markov Model. Um den Shanghai Composite Index vorherzusagen, setzen die Autoren ein duales Hidden Markov Model ein. Im direkten Vergleich mit GARCH liefert das duale Hidden Markov Model bessere Prognosen. Darüber hinaus kombiniert eine andere Arbeit das Hidden Markov Model mit Fuzzy-Logik und

vergleicht es mit anderen Prognosemodellen. Das kombinierte Modell aus Hidden Markov Model und Fuzzy-Logik erweist sich als zuverlässiger und profitabler. Hier nennen die Autoren aber auch die Einschränkung, dass das kombinierte Modell nur für kurzfristige Vorhersagen geeignet ist.

Ofomata et al. [9] entwerfen in ihrem Paper ein neues stochastisches Modell, das Aktienkurse simulieren und kurzfristig vorhersagen kann. Das Paper verwendet als Datengrundlage die Schlusskurse von vier Aktien von der Nigerian Stock Exchange. Das Modell modelliert die vier Aktien gleichzeitig und gibt für jede Aktie eine simulierte Kursveränderung zurück. Das Modell kann deshalb dabei helfen zu entscheiden, in welche Aktie investiert werden soll.

2.3. Machine-Learning-Ansätze

Die Machine-Learning-Ansätze lassen sich in zwei Hauptkategorien unterteilen: feature-basierte Verfahren und Deep-Learning-Modelle. Feature-basierte Verfahren verwenden manuell erstellte Features aus den Daten, um Vorhersagen zu treffen. Deep-Learning-Modelle nutzen tiefe neuronale Netze, um komplexe Muster in den Daten zu erkennen und Vorhersagen zu treffen.

2.3.1. Feature-basierte Verfahren

Rundo et al. [6] stellt in seiner Übersichtsstudie verschiedene Paper vor, die sich mit der Verwendung von *cro:SVM* Support Vector Machine (SVM) beschäftigen. Die vorgestellten Paper zeigen, dass SVM gut geeignet sind, um Aktienkurse vorherzusagen. Außerdem übertrifft SVM die Leistung klassischer *cro:NN* Neuronal Network (NN)-Modelle. Die guten Ergebnisse erzielen sowohl Modelle mit festgelegten als auch mit adaptiven Parametern. Ein weiteres Paper kombiniert SVM mit *cro:kNN* k-Nearest Neighbors (kNN) und verbessert dadurch die Vorhersageleistung.

Gandhmal and Kumar [10] kommen zu dem Schluss, dass SVM eine gute Wahl für die Vorhersage von Aktienkursen ist. Darüber hinaus stellen sie Paper vor, die sich mit `cro:SVR` Support Vector Regression (SVR) beschäftigen. Aus den Papern geht hervor, dass SVR ebenfalls eine gute Wahl für die Vorhersage von Aktienkursen ist. Die Paper stellen aber keinen Vergleich zwischen SVM und SVR an, sodass unklar bleibt, welches der beiden Modelle besser für die Vorhersage von Aktienkursen geeignet ist.

Ballings et al. [11] vergleicht in seinem Paper SVM mit kNN und Random Forest. Zur Bewertung der Ergebnisse dient die Area Under the Curve (AUC), die eine Aussage darüber trifft, wie gut die Modelle im Vergleich zum Zufall abschneiden. In diesem Vergleich schneidet Random Forest mit einer Median AUC von 0,9037 am besten ab, gefolgt von SVM mit 0,8395. Shah et al. [7] stellt in seiner Übersichtsstudie neben dem Paper von Ballings et al. [11] noch ein weiteres Paper vor, das die These von Ballings et al. [11] bestätigt, dass Random Forest zur Aktienkursvorhersage besser geeignet ist als SVM.

2.3.2. Deep-Learning-Modelle

Das Paper von Lu et al. [12] stellt ein neues `cro:CNN` Convolutional Neural Network (CNN)-basiertes Modell vor, das eine Kombination verschiedener Deep-Learning-Architekturen verwendet. Dafür vergleichen die Autoren das neue Modell mit den Architekturen `cro:LSTM` Long Short Term Memory (LSTM), `cro:RNN` Recurrent Neural Network (RNN) und CNN. Verglichen werden die Modelle mit den Metriken MAE, RMSE und R-squared. Aus dem Paper geht hervor, dass das neue CNN-basierte Modell in allen drei Metriken besser abschneidet als die anderen Modelle. Das LSTM-Modell schneidet am zweitbesten ab, gefolgt von RNN und CNN.

Das Übersichtspapier von Rundo et al. [6] befasst sich mit verschiedenen Deep-Learning-Modellen, die die Literatur zur Vorhersage von Aktienkursen verwendet. Es stellt ein Paper vor, das die Modelle CNN, LSTM und RNN miteinander vergleicht und untersucht, wie gut sie Indexbewegungen vorhersagen können.

CNN liefert dabei die besten Ergebnisse. Die verschiedenen Varianten von RNN liefern allerdings auch gute Ergebnisse; besonders LSTM findet besonders häufig Anwendung. Außerdem unterstreicht die Übersichtsstudie, dass Deep-Learning-Modelle in der Regel bessere Vorhersagen liefern als klassische statistische Modelle.

Auch Shah et al. [7] beschäftigt sich mit verschiedenen Deep-Learning-Modellen zur Vorhersage von Aktienkursen. Ein vorgestelltes Paper vergleicht ein einfaches RNN mit einem LSTM und einem *cro:GRUGated Recurrent Unit* (GRU). Das LSTM liefert dabei die besten Ergebnisse. Darüber hinaus stellt ein weiteres Paper ein kombiniertes Modell aus LSTM und GRU vor, das die Vorhersageleistung verbessern kann. Auch diese Übersichtsstudie kommt zu dem Schluss, dass LSTM ein gutes und viel genutztes Modell für die Vorhersage von Aktienkursen ist, da es den anderen RNN-Varianten überlegen ist.

2.4. Hybride Modelle

Die Übersichtsstudie von Rundo et al. [6] stellt auch verschiedene hybride Modelle vor. Häufig kombinieren diese hybriden Modelle klassische statistische Modelle mit Machine-Learning-Methoden. In der Literatur finden sich sehr viele verschiedene hybride Modelle, die unterschiedliche Modelle kombinieren. Diese hybriden Modelle vergleichen die Autoren in der Regel mit den einzelnen Modellen. Auch wenn einige hybride Modelle in den Vergleichen mit den einzelnen Modellen schlechter abschneiden, übertrifft der Großteil der hybriden Modelle die einzelnen Modelle. Besonders können hybride Modelle die bekannten Schwächen der einzelnen Modelle gezielt ausgleichen.

Shah et al. [7] betrachten in ihrer Übersichtsstudie ebenfalls verschiedene hybride Modelle und kommen zum selben Schluss wie Rundo et al. [6]. Auch hier liefern die hybriden Modelle in der Regel bessere Ergebnisse als die einzelnen Modelle. Besonders auffällig ist in dieser Übersichtsstudie die hohe Anzahl an Modellen, die für ein hybrides Modell kombiniert wurden. Das lässt vermuten, dass die Erhöhung

der Komplexität durch die Kombination mehrerer Modelle zu einer verbesserten Vorhersageleistung führt.

Grundsätzlich lässt sich sagen, dass die meisten hybriden Modelle bessere Ergebnisse liefern als die einzelnen Modelle, auch wenn eine Kombination nicht zwangsläufig zu einer verbesserten Prognoseleistung führt. Die einzelnen Modelle müssen sorgfältig ausgewählt und kombiniert werden, um die Stärken der einzelnen Modelle zu nutzen und die Schwächen auszugleichen.

2.5. Vergleich und Forschungslücke

Der Survey von Rundo et al. [6] kommt zu dem Schluss, dass Machine-Learning-Modelle tendenziell akkuratere Vorhersagen liefern als klassische statistische Modelle. Allerdings weisen die Autoren auch darauf hin, dass die Leistung von Machine-Learning-Modellen stark von der Qualität und Quantität der verfügbaren Daten abhängt. In vielen Fällen können klassische Modelle aufgrund ihrer Einfachheit und Interpretierbarkeit vorzuziehen sein, insbesondere wenn die Daten begrenzt oder verrauscht sind.

Eine Forschungslücke besteht in der Integration von alternativen Datenquellen, wie z.B. Nachrichten, Sentiment-Analysen und makroökonomischen Indikatoren, in die Vorhersagemodelle. Während sich viele Studien auf historische Kursdaten und technische Indikatoren konzentrieren, integrieren nur wenige Arbeiten diese zusätzlichen Datenquellen systematisch in ihre Modelle.

Die Entwicklung von Modellen, die zuverlässige Vorhersagen über kurze Zeiträume liefern, stellt eine weitere Forschungslücke dar. Vorhersagen über Kursbewegungen über kurze Zeiträume wie Tage oder Stunden sind besonders relevant für den Hochfrequenzhandel. Es gibt zwar einige Arbeiten, die sich mit der Vorhersage von kurzfristigen Kursbewegungen beschäftigen, aber es besteht weiterhin Bedarf an Modellen, die in diesem Bereich zuverlässige und genaue Vorhersagen liefern können.

Eine zusätzliche Forschungslücke besteht darin, dass viele Modelle nur auf einem begrenzten Datensatz getestet werden, was die Generalisierbarkeit der Ergebnisse einschränkt. Es besteht Bedarf an Modellen, die auf einer breiteren Palette von Aktien und Märkten getestet werden, um ihre Robustheit und Anwendbarkeit in verschiedenen Kontexten zu gewährleisten.

2.6. Ansatz der Arbeit

Die Analyse der Literatur zeigt, dass es kein klar bestes Modell gibt. Die Wahl des Modells hängt stark von den spezifischen Anforderungen und den verfügbaren Daten ab. Es gibt allerdings nur wenig Forschung zur Vorhersage von kurzfristigen Kursbewegungen und zur Integration von alternativen Datenquellen in die Vorhersagemodelle.

Diese Erkenntnisse bilden die Grundlage für den Ansatz dieser Arbeit, der darauf abzielt, diese Lücken zu adressieren und die Vorhersageleistung durch die Integration zusätzlicher Datenquellen und die Entwicklung von Modellen für kurzfristige Vorhersagen zu verbessern. Da die Literatur keinen eindeutig besten Ansatz identifiziert, entwickelt und vergleicht diese Arbeit verschiedene Modelle, um dazu beizutragen, den vielversprechendsten Ansatz für die Vorhersage von Aktienkursen zu identifizieren.

3. Konzeption

3.1. Überblick

In diesem Kapitel wird die Entwicklung der in dieser Arbeit verwendeten Modelle zur Vorhersage von Aktienkursen beschrieben. Dabei werden Ansätze aus der Zeitreihenanalyse und dem maschinellen Lernen konzeptioniert. Die grobe Struktur des gesamten Kapitels ist in Abb. 3.1 zu sehen.

Zunächst wird in Abschnitt 3.2 das Datenset erläutert. Es erfolgt die Auswahl des Aktienuniversums. Danach wird die konkrete Auswahl der untersuchten Aktien auf Basis von stochastischen Differentialgleichungen beschrieben. Die Daten werden unterteilt und bereinigt.

Daraufhin wird in Abschnitt 3.5 der Rahmen der Arbeit definiert, einschließlich des Untersuchungsgegenstands, der getroffenen Annahmen sowie der Nebenbedingungen und Einschränkungen. Diese Vereinfachungen dienen der Interpretierbarkeit, unterscheiden sich aber teilweise von realen Marktbedingungen.

Anschließend werden in Abschnitt 3.6 die Metriken vorgestellt, die sowohl mathematische als auch finanzwirtschaftliche Aspekte berücksichtigen.

Aufbauend auf diesen Grundlagen erfolgt die Modellentwicklung in Abschnitt 3.3. Es werden drei Modelle vorgestellt:

- **LinearSeparation:** Unterteilt den Aktienkurs in drei Bestandteile und schätzt jeden über ein lineares Verfahren,
- **Preprocessed SVR:** Support Vector Regression mit vorverarbeiteten und normalisierten Kennzahlen,




Figure 3.1.: Struktur der Konzeption

- **StockTimesFM:** Anwendung eines Zeitreihen Foundation Model auf Aktienkurse.

Abschließend wird in Abschnitt 3.4 die Umsetzung der Vorhersagen in einer Handelsstrategie beschrieben. Hierbei werden Risikomanagement, Positionsgrößen und Vorhersagehorizont betrachtet. Aus den Preisvorhersagen wird eine Marktentscheidung getroffen, um die praktische Anwendbarkeit der Modelle zu analysieren.

3.2. Daten und Aktienwahl

3.2.1. Daten

Unter dem Survivorship Bias versteht man die statistische Verzerrung, die entsteht, wenn nur überlebende Unternehmen ausgewählt werden und insolvente oder aus einem Index entfernte Aktien unberücksichtigt bleiben, was historische Renditen systematisch nach oben verzerrt. Für die Analyse wird ein festes Aktienuniversum herangezogen, bestehend aus den im Jahr 2020 im S&P500 gelisteten Unternehmen, wodurch ein Survivorship Bias vermieden wird.

Die Kursdaten jeder Aktie werden als Zeitreihe betrachtet. Für jeden Handelstag enthält die Zeitreihe folgende Werte:

- Open: erster Preis zu dem an diesem Tag gehandelt wurde,
- Close: letzter Preis zu dem an diesem Tag gehandelt wurde,
- High: höchster Preis zu dem an diesem Tag gehandelt wurde,
- Low: niedrigster Preis zu dem an diesem Tag gehandelt wurde,
- Volume: gesamtes kumuliertes Handelsvolumen an diesem Tag.

Die Daten werden als CSV-Dateien von Yahoo Finance heruntergeladen und ein Auszug ist in Tabelle 3.1 zu sehen. Sie werden dann in parquet-Dateien konvertiert, um Speicherplatz und Rechenzeit zu sparen.

Datum	Close	High	Low	Open	Volume
2022-11-11	147,34	147,64	142,09	143,52	93 979 700
2022-11-14	145,94	147,91	145,10	146,62	73 374 100

Table 3.1.: Beispielhafte Rohdaten der Aktienpreise. Alle Preisangaben in USD.

Die Unterteilung der Zeitreihen erfolgt in einem 60:10:30-Verhältnis, wobei 60% der Daten als Trainingsdaten, 10% als Validierungs- und 30% als Testdaten verwendet werden:

- **Trainingszeitraum (T):** 01.2020–12.2023, in dem die Modelle auf den historischen Kursen trainiert werden.
- **Validierungszeitraum (V):** 01.2024–06.2024, der zur Optimierung der Modellparameter dient.
- **Testzeitraum (Z):** 07.2024–12.2025, der ausschließlich für die abschließende Evaluierung der Modelle auf bisher ungesehenen Daten verwendet wird.

3.2.2. Bereinigung

Die Analysen in dieser Arbeit bestehen aus Backtest. Das bedeutet, dass vergangene Daten verwendet werden, um Strategien zu testen. Aus diesem Grund ist eine Bereinigung der historischen Aktienkurse notwendig, da sich die nominalen Preise einer Aktie im Zeitverlauf durch Ereignisse wie Aktiensplits oder Dividendenzahlungen verändern, ohne dass sich der tatsächliche Unternehmenswert und demnach der Aktienwert geändert hat. Ohne eine solche Anpassung würden Kursbewegungen verzerrt dargestellt, was zu falsch trainierten Modellen oder falschen Tests führt. Sei P_t der beobachtete Schlusskurs einer Aktie zum Zeitpunkt t und $\tilde{P}_t$ der bereinigte Preis auf dem ein Modell trainiert werden kann. $\tilde{P}_t$ ergibt sich aus dem ursprünglichen Preis multipliziert mit einem Anpassungsfaktor A_t :

$$\tilde{P}_t = P_t \cdot A_t.$$

Der Anpassungsfaktor wird rekursiv rückwärts berechnet. Sei P_t für $t = 1, \dots, n$ gegeben, gilt $A_n = 1$. Bei einem Aktiensplit zum Zeitpunkt t mit Verhältnis $s_t = \frac{\text{neue Aktien}}{\text{alte Aktien}}$ gilt

$$A_{t-1} = \frac{A_t}{s_t}.$$

Dividendenzahlungen werden ebenfalls berücksichtigt. Sei D_t die Dividende zum Zeitpunkt t . Dann wird der Anpassungsfaktor wie folgt aktualisiert:

$$A_{t-1} = A_t \cdot \frac{P_t - D_t}{P_t}.$$

Somit ist der historische Preis mit dem die Modelle trainiert und getestet werden abhängig vom letzten betrachteten Wert. Der letzte Wert entspricht somit dem aktuellen, realisierbaren Aktienwert, alle anderen Werte potenziell aber nicht den realen Aktienwerten zu dem Zeitpunkt.

3.2.3. Aktienausswahl

Es sollen nun 10 Aktien aus dem Gesamtuniversum ausgewählt werden, auf denen später getestet wird. Dafür wird in diesem Abschnitt ein Verfahren vorgestellt, welches eine cro:SDE Stochastische Differentialgleichung (SDE) verwendet, um aus dem Gesamtuniversum die Aktien auszuwählen, die am wahrscheinlichsten den höchsten cro:ROI Return on Invest (ROI) erzielen. Die Auswahl dieser Aktien muss stets anhand von Informationen erfolgen, die vor dem Testzeitraum bekannt waren, um einen Lookahead Bias und Selection Bias zu verhindern.

Aktienkurse setzen sich aus einem Trend und zufälligem Rauschen zusammen. Eine Aktienkursbewegung $dS(t)$ wird beschrieben durch einen Trend μ und ein Rauschen als Wienerprozess W_t , verstärkt durch einen Volatilitätskoeffizienten σ .

$$dS(t) = \underbrace{\mu S(t)dt}_{\text{Trendkomponente}} + \underbrace{\sigma S(t)dW(t)}_{\text{Rauschen}} \quad (3.1)$$

Der in dieser Arbeit gewählte Ansatz lässt sich als eine Verallgemeinerung des Modells von Ofomata et al. [9] verstehen. Ein wesentlicher Nachteil ihrer Methode liegt in der Beschränkung auf eine sehr kleine Auswahl an Aktien, die vorab durch externe Verfahren selektiert werden müssen. Das hier vorgestellte Modell hebt diese Notwendigkeit auf, um das Verfahren breiter anwendbar zu machen, indem Aktien mehrfach miteinander verglichen und schlechtere aussortiert werden. Ein weiterer Aspekt betrifft die Berechnung der Parameter μ und σ und die Kovarianz der Aktien untereinander. In der Praxis folgen Kursbewegungen externen Faktoren wie dem Ölpreis oder dem aktuellen Leitzins. Dass Aktien innerhalb desselben Index miteinander korrelieren, kann eine logische Folge ihrer gemeinsamen Reaktion auf diese makroökonomischen Einflüsse sein. Anstatt nur die Einflüsse der Aktien untereinander zu beobachten, beobachtet der folgende Ansatz die Einflüsse der makroökonomischen Faktoren auf die Aktien einzeln. Die hier betrachteten Faktoren sind dargestellt in Tabelle 3.2.

Faktor	Erklärung
Ölpreis	Öl Future-Kontrakt Preis an der NYMEX
Goldpreis	Gold Future-Kontrakt Preis an der COMEX
Staatsanleihe	10-Jahre-Staatsanleihe der USA
Gesamtindex	Marktindex des S&P500
US-Dollar	US-Dollar Index DXY
Inflation	10-Jahre Break-Even-Inflationsrate

Table 3.2.: Makroökonomische Faktoren

Der Ansatz in [9] teilt eine Aktienbewegung in drei diskrete Richtungen auf: Anstieg (+1), Rückgang (−1) und Stagnation (0). Bei n betrachteten Aktien

ergibt sich daraus ein Ergebnisraum von 3^n möglichen Bewegungskombinationen innerhalb eines Handelstages. Für $n = 4$ also bereits $3^4 = 81$ zu berücksichtigende Szenarien. Dadurch, dass in [9] nur 60 Handelstagen betrachtet werden, treten viele Bewegungen überhaupt nicht auf.

Um die genannten Probleme zu adressieren, wird die Grundstruktur beibehalten, jedoch wird der ursprüngliche 3^n -dimensionalen Aktienvektor durch einen 3^{g+f} -dimensionalen Einflussvektor aus g Aktien und f Faktoren ersetzt. Die Grundstruktur des Verfahrens ist in Abb. 3.2 zu sehen und lässt sich kurz folgendermaßen zusammenfassen. Für jede Aktie werden die beiden makroökonomischen Faktoren f aus Tabelle 3.2 gesucht, die am meisten Einfluss auf die Kursbewegung haben. Dann werden für alle Aktien, die dasselbe dominante Einflussfaktorpaar haben, Simulationsgruppen aus je 4 Aktien und den beiden Einflussfaktoren gebildet. Innerhalb dieser Simulationsgruppen werden die Kursverläufe der Aktien und Faktoren simuliert und diejenige Aktie, die nach dem Testzeitraum Z den höchsten ROI in der Simulation erzielt, geht als „Gewinner“ aus ihrer Simulationsgruppe hervor. Dieser Auswahlprozess wird über das gesamte Aktienuniversum durchgeführt. Danach werden diese „Gewinner“ wieder in Simulationsgruppen zu je 4 Aktien aufgeteilt. Durch diesen hierarchischen Prozess bleibt der Ansatz unabhängig von der Gesamtzahl der Aktien (n). Er lässt sich somit auf beliebig große Universen anwenden und berücksichtigt direkt den Einfluss makroökonomischer Faktoren.

Gruppierung

Um das vorgestellte Verfahren auf ein gesamtes Aktienuniversum anwenden zu können, muss eine Gruppierung der Aktien und Faktoren vorgenommen werden. Der bereits definierte Trainingszeitraum T hat etwa 1000 Handelstage. Um eine sinnvolle Wahrscheinlichkeitsverteilung der Aktienbewegungen zu liefern, sollte die Anzahl der möglichen Kombinationen der diskreten Aktien- und Faktorbewegungen kleiner sein als die Tage des Trainingszeitraums. Es wurde sich für $g = 4$ Aktien




Figure 3.2.: Ablauf Aktienauswahl

und $f = 2$ Faktoren pro Simulationsgruppe entschieden, was zu $3^6 = 729 < 1000$ möglichen Kombinationen führt.

Um den Einfluss der Faktoren auf jede Aktie zu messen, wird für jede Aktie-Faktor-Kombination eine lineare Regression der diskreten Aktienbewegung ΔS auf die diskrete Faktorbewegung ΔF geschätzt.

$$\Delta S_i(t) = \alpha_i + \sum_{j=1}^7 \beta_{i,j} \cdot \Delta F_j(t), \quad (3.2)$$

wobei α_i den faktorunabhängigen Trend der Aktie bezeichnet und $\beta_{i,j}$ die Sensitivität der Aktie i gegenüber Faktor j .

Die Koeffizienten α und β werden mittels `cro:OLS` Ordinary Least Squares (OLS) auf den Daten des Trainingszeitraums bestimmt:

$$\hat{\theta}_i = (X^T X)^{-1} X^T y_i, \quad (3.3)$$

mit

$$\hat{\theta}_i = \begin{pmatrix} \hat{\alpha}_i \\ \hat{\beta}_{i,1} \\ \vdots \\ \hat{\beta}_{i,7} \end{pmatrix}. \quad (3.4)$$

$X \in \mathbb{R}^{T \times 8}$ bezeichnet die Designmatrix der Faktorbewegungen über $T = 1000$ Handelstage und ergibt sich zu

$$X = \begin{pmatrix} 1 & \Delta F_1(1) & \Delta F_2(1) & \cdots & \Delta F_7(1) \\ 1 & \Delta F_1(2) & \Delta F_2(2) & \cdots & \Delta F_7(2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \Delta F_1(T) & \Delta F_2(T) & \cdots & \Delta F_7(T) \end{pmatrix}. \quad (3.5)$$

$y_i \in \mathbb{R}^T$ ist der Vektor der Aktienbewegungen im Trainingszeitraum.

$$\mathbf{y}_i = \begin{pmatrix} \Delta S_i(1) \\ \Delta S_i(2) \\ \vdots \\ \Delta S_i(T) \end{pmatrix} \quad (3.6)$$

Da jede Simulationsgruppe genau zwei Faktoren enthalten soll, wird jeder Aktie das Faktorpaar (f_1, f_2) zugewiesen, für das die Summe der β -Koeffizienten maximal ist.

$$(f_1^*, f_2^*) = \arg \max_{j_1 \neq j_2} (|\beta_{i,f_1}| + |\beta_{i,f_2}|) \quad (3.7)$$

Dieses Paar wird als dominantes Faktorpaar $(f_{i,1}^*, f_{i,2}^*)$ der Aktie i bezeichnet. Alle Aktien die dasselbe dominante Faktorpaar haben, werden in einem Pool zusammengefasst.

$$\mathcal{P}_{j_1, j_2} = \{S_i : (j_1^*, j_2^*) = (j_1, j_2)\} \quad (3.8)$$

Bei den gewählten 7 Faktoren gibt es somit $\binom{7}{2} = 21$ mögliche Faktorpools. Jeder Pool enthält die Aktien, die auf dasselbe Faktorpaar am stärksten reagieren, wodurch auch die Korrelation unter den Aktien hoch sein sollte. Aus den Pools werden nun zufällig Simulationsgruppen zu je 4 Aktien gebildet.

Durch das hierarchische Format der Aktienausswahl kann es durch die lokalen Vergleiche passieren, dass Aktien in früheren Stufen nicht den höchsten ROI in der Simulation haben und somit nicht weiter betrachtet werden, obwohl sie im Vergleich der Grundgesamtheit unter den Top 10 vielversprechendsten Aktien gewesen wären. Dadurch wird die Aktienausswahl verschlechtert. Darum erfolgt die Aufteilung der Aktien von den Faktorpools in die Gruppen zufällig und die gesamte Aufteilung und Simulation wird $N = 100$ mal durchgeführt. Die 10 Aktien

mit dem durchschnittlich besten "Platzierung" werden gewählt. Nach der gesamten Simulation ergeben sich die 10 am besten prognostizierten Aktien.

Aufstellen der SDEs

Es wird nun dargelegt, wie genau die Aktienkurse innerhalb einer Simulationsgruppe simuliert werden. Dies erfolgt durch das Aufstellen einer SDE für jeden Aktienkurs und das numerische Lösen dieser SDE.

Durch die Diskretisierung der Aktienbewegung degeneriert die SDE zu

$$dS(t) = \mu dt + \sigma dW(t), \quad (3.9)$$

da diskrete Schwankungen nicht mit dem Aktienkurs skalieren.

Der Aktienkurs könnte dadurch theoretisch negativ werden, was ignoriert werden kann, da es nur um einen qualitativen nicht quantitativen Vergleich der Aktien untereinander geht. Es wird ein Einflussvektor X aus Aktienbewegungen S und Faktorbewegungen F aufgestellt, mit

$$\Delta X(t) = [\Delta S_1(t), \Delta S_2(t), \dots, \Delta S_g(t), \Delta F_1(t), \Delta F_2(t), \dots, \Delta F_f(t)]^T.$$

Für jede Aktienbewegung und Faktorbewegung gibt es drei mögliche Werte (+1, 0, -1). Daraus ergibt sich der Ereignisraum C für den Einflussvektor X zu allen möglichen Gesamtbewegungen. Für die Kombinationen des Einflussvektors $c \in C$ wird die Wahrscheinlichkeit pro Aktie $p_i(c)$ im Trainingszeitraum T nach Gleichung (3.10) bestimmt. Außerdem wird eine Laplace-Glättung eingeführt. Dies soll das Problem eliminieren, dass Kombinationen die im Trainingszeitraum aus statistischen Gründen nicht aufgetreten sind, als unmöglich angesehen werden.

$$p_i(c) = \frac{N_c + 1}{T + |C|}, \quad (3.10)$$

wobei N_c der Anzahl der Zeitpunkte entspricht, an denen die Bewegung c im Zeitraum der Trainingstage T aufgetreten ist.

Der Trend einer Aktie oder eines Faktors ergibt sich aus dem Erwartungswert der Wahrscheinlichkeiten über alle möglichen Ereignisse.

$$\mu_i = \mathbb{E}[\Delta X] = \sum_{c \in C} p_i(c) \cdot c$$

Danach ergibt sich der Vektor der Trends der Aktien $\mu \in \mathbb{R}^g$, mit g als Simulation-sgruppengröße zu

$$\mu = \begin{pmatrix} \mu_{S_1} \\ \mu_{S_2} \\ \vdots \\ \mu_{S_g} \\ \mu_{F_1} \\ \vdots \\ \mu_{F_f} \end{pmatrix}.$$

Zusätzlich zum Trend, soll das Rauschen der Aktien modelliert werden. Dafür wird die Kovarianz der Aktien untereinander, die Kovarianz der Faktoren und Aktien und die Kovarianz der Faktoren untereinander betrachtet. Die Kovarianzmatrix ergibt sich nach

$$\Sigma = \mathbb{E}[\Delta X \cdot \Delta X^T] = \sum_{c \in C} p(c) \cdot c \cdot c^T.$$

Die Kovarianzmatrix hat die Dimension $(f + g) \times (f + g)$ und lässt sich in die in Gleichung (3.11) und Tabelle 3.3 genannten Bestandteile gliedern.

$$\Sigma = \begin{pmatrix} \Sigma_{SS} & \Sigma_{SF} \\ \Sigma_{FS} & \Sigma_{FF} \end{pmatrix} \quad (3.11)$$

Block	Dimension	Bedeutung
Σ_{SS}	$g \times g$	Kovarianzen der Aktien untereinander
Σ_{FF}	$f \times f$	Kovarianzen der Faktoren untereinander
$\Sigma_{SF} = \Sigma_{FS}^T$	$g \times f$	Kovarianzen zwischen Aktien und Faktoren

Table 3.3.: Bestandteile der Kovarianzmatrix

Der Volatilitätskoeffizient σ der SDE wird bestimmt als Cholesky-Zerlegung von Σ . Da Σ mit nicht-negativen Wahrscheinlichkeiten $p(c)$ konstruiert ist, ist Σ positiv semidefinit, womit die Zerlegung existiert.

$$B \cdot B^T = \Sigma$$

Die gesamte SDE ergibt sich zu

$$dS_i(t) = \mu_{S_i} dt + \sum_{j=1}^{f+g} B_{ij} dW_j(t), \quad i = 1, 2, \dots, g,$$

wobei $W(t) \in \mathbb{R}^{f+g}$ ein Wiener-Prozess der Dimension $f + g$ ist. Die Faktoren F gehen nicht in die Auswertung ein, da sie lediglich für die Modellierung der Aktien S verwendet werden.

Zur Lösung der SDE wird das Euler-Maruyama-Schema verwendet. Der Startwert ist der Aktienkurs der jeweiligen Aktie am Beginn des Testzeitraumes Z . Danach wird die diskrete Annäherung simuliert nach der Gleichung (3.12).

$$S_i(t+1) = S_i(t) + \mu_{S_i} \Delta t + \sum_{j=1}^{f+g} B_{ij} \Delta W_{j,t} \quad (3.12)$$

Hierbei ist $\Delta W_{j,t}$ die Zunahme des Wiener-Prozesses W_j im Intervall $[t, t+1]$:

$$\Delta W_{j,t} \sim \mathcal{N}(0, \Delta t) \implies \Delta W_{j,t} = Z_{j,t} \sqrt{\Delta t},$$

wobei $Z_{j,t}$ unabhängige, standardnormalverteilte Zufallsvariablen sind. Auf diese Weise können die Aktienkurse innerhalb einer Simulationsgruppe simuliert und der prognostizierte ROI bestimmt werden.

3.3. Modellentwicklung

In diesem Kapitel werden drei Modelle entwickelt, die jeweils auf einer einzelnen Aktie operieren und auf Basis historischer Kursdaten sowie weiterer Eingabegrößen den Aktienkurs des nächsten Handelstages vorhersagen. Zur Bestimmung der Modelqualität werden die Modelle auf den 10 ausgewählten Aktien getestet. Das Ziel ist ein Modellvergleich zwischen den vorgestellten Modellen untereinander, sowie ein Vergleich mit der Performance des Gesamtaktienuniversums (S&P500).

3.3.1. LinearSeparation

Es wird ein komplett neues Verfahren vorgestellt, dass ohne Black-Box Modelle wie Machine Learning auskommen soll. Es wird sich dafür an den vorhandenen linearen Verfahren `cro:ARMA` Autoregressive Moving Average (ARMA) und `cro:HP` Hodrick-Prescott (HP) orientiert, welche sinnvoll kombiniert werden, um eine Vorhersage zu treffen. Das Grundvorgehen des Modells ist, den Aktienkurs in einfacher schätzbare Teile zu zerlegen, jeden davon einzeln zu extrapolieren und die Vorhersagen zu einer Gesamtvorhersage zusammenzusetzen. Daraus entsteht ein Modell, welches den Preis des nächsten Tages auf Basis der vergangenen Tage schätzt:

$$\hat{P}_{t+1} = f((P_0, P_1, \dots, P_t)).$$

Diese Arbeit stellt die Behauptung auf, dass sich ein Aktienkurs durch die Komponenten T_t^{lang} , T_t^{kurz} , C_t und ϵ_t beschreiben lässt. Diese Komponenten sind in Tabelle 3.4 weiter erläutert. Weiter wird die Behauptung aufgestellt, dass sich ein Aktienkurs durch den Zusammenhang in Gleichung (3.13) beschreiben lässt.

$$P_t = T_t^{\text{lang}} \cdot T_t^{\text{kurz}} \cdot C_t \cdot \epsilon_t. \quad (3.13)$$

Variable	Bedeutung	Zeitraumen	Begründung
T_t^{lang}	langfristiger Trend	Jahre	Aktienmärkte bewegen sich durch Inflation und Konjunktur langfristig gleichmäßig
T_t^{kurz}	aktueller Trend	Wochen	aktienspezifische Bewegung abhängig von Earnings, Nachrichten usw.
C_t	kurzfristige Schwankungen	Tage	Autokorrelation in wenigen Tagen, teilweise begründbar
ϵ_t	Rauschen	$\mathbb{E}[\epsilon_t] = 0$	nicht erklärbar, nicht vorhersagbar

Table 3.4.: Komponenten der Aktienkursmodellierung

Der Zusammenhang ist multiplikativ, da Aktienkurse prozentual schwanken. Das Rauschen von teuren Aktien ist beispielsweise größer als bei billigen Aktien. Da die Berechnung auf Log-Preisen $p_t = \ln(P_t)$ erfolgt, wird der Zusammenhang additiv.

$$p_t = \tau_t^{\text{lang}} + \tau_t^{\text{kurz}} + c_t + \epsilon_t \quad (3.14)$$

Die Komponenten des Preises werden über verschiedene Wege modelliert und dann extrapoliert. Die längerfristigen Trends τ^{lang} und τ^{kurz} werden mithilfe eines HP-Filters [13] modelliert und mittels OLS extrapoliert.

Es wird mittels eines HP-Filters aus den historischen Log-Preisen $p_1, \dots, p_T$ (mit $t = 1, \dots, T$) der langfristige Trend τ^{lang} extrahiert:

$$\hat{\tau}_t^{\text{lang}} = \arg \min_{\{\hat{\tau}_t^{\text{lang}}\}} \left(\sum_{t=1}^T (p_t - \hat{\tau}_t^{\text{lang}})^2 + \lambda_{\text{lang}} \sum_{t=2}^{T-1} (\hat{\tau}_{t+1}^{\text{lang}} - 2\hat{\tau}_t^{\text{lang}} + \hat{\tau}_{t-1}^{\text{lang}})^2 \right) \quad (3.15)$$

wobei λ_{lang} der Glättungsparameter ist und bestimmt, wie stark kurzfristige Schwankungen bereinigt werden. Der kritische Punkt bei diesem Verfahren liegt in der richtigen Wahl des Gewichtungsparameters λ_{lang} . Die genaue Wahl wird im Kapitel 4 diskutiert.

Mithilfe der daraus entstehenden geglätteten Zeitreihe $\hat{\tau}_t^{\text{lang}}$ werden die Residuen gebildet.

$$\tilde{p}_t = p_t - \hat{\tau}_t^{\text{lang}}$$

Um nun aus den Residuen den kurzfristigen Trend τ^{kurz} zu extrahieren, wird auf der Residuenzeitreihe $\tilde{p}_t$ ein weiterer HP-Filter, nach Gleichung (3.16) mit einem kleineren λ_{kurz} angewendet, um den aktuellen Trend τ^{kurz} zu glätten. Die Größenordnung von λ_{kurz} wird in Kapitel 4 bestimmt.

$$\hat{\tau}_t^{\text{kurz}} = \arg \min_{\{\hat{\tau}_t^{\text{kurz}}\}} \left(\sum_{t=1}^T (p_t - \hat{\tau}_t^{\text{kurz}})^2 + \lambda_{\text{kurz}} \sum_{t=2}^{T-1} (\hat{\tau}_{t+1}^{\text{kurz}} - 2\hat{\tau}_t^{\text{kurz}} + \hat{\tau}_{t-1}^{\text{kurz}})^2 \right) \quad (3.16)$$

Die HP-Filter liefern somit geglättete Trendverläufe $\hat{\tau}_t^{\text{lang}}$ und $\hat{\tau}_t^{\text{kurz}}$ für die historischen Daten bis zum Zeitpunkt T . Um Vorhersagen treffen zu können müssen diese Trends extrapoliert werden. Da beide Trends im Kontext von Tagespreisen langfristig sind, können sie lokal durch ein lineares Modell approximiert werden.

Die Idee dabei ist, dass sich der gerade extrahierte, geglättete Trend innerhalb eines kurzen Zeitfensters gut durch eine Gerade beschreiben lässt, die anschließend in die Zukunft verlängert wird. Dafür wird die OLS-Methode verwendet.

Konkret wird für jeden Trend über ein gleitendes Fenster der letzten w diskreten Beobachtungen $\{\hat{\tau}_{T-w+1}, \dots, \hat{\tau}_T\}$ mittels OLS eine lineare Funktion der Zeit gefittet. Dabei werden die Parameter $\hat{a}$ (Achsenabschnitt) und $\hat{b}$ (Steigung) so gewählt, dass

$$\hat{b}_w = \frac{\sum_{t=T-w+1}^T (t - \bar{t})(\hat{\tau}_t - \bar{\tau})}{\sum_{t=T-w+1}^T (t - \bar{t})^2}, \quad \hat{a}_w = \bar{\tau} - \hat{b}\bar{t}. \quad (3.17)$$

Für die Mittelwerte gilt $\bar{t} = \frac{1}{w} \sum_{t=T-w+1}^T t$ und $\bar{\tau} = \frac{1}{w} \sum_{t=T-w+1}^T \hat{\tau}_t$. Die Vorhersage der Trendkomponenten für k Schritte in die Zukunft ergibt sich dann als

$$\hat{\tau}_{T+k}^{\text{lang}} = \hat{a}_1 + \hat{b}_1 \cdot (T + k), \quad (3.18)$$

$$\hat{\tau}_{T+k}^{\text{kurz}} = \hat{a}_2 + \hat{b}_2 \cdot (T + k). \quad (3.19)$$

Die Fenstergröße w bestimmt dabei, über welchen Zeitraum die lokale Steigung des Trends geschätzt wird. Ein zu kleines Fenster führt zu verrauschten Schätzungen und ein zu großes Fenster lässt aktuelle Richtungsänderungen nur langsam einfließen. Da τ^{lang} den strukturellen Trend über mehrere Jahre abbilden soll, wird die Steigung über ein Fenster von $w_{\text{lang}} = 252$ Handelstagen (einem Börsenjahr) geschätzt. Kurzfristige Schwankungen werden so herausgemittelt, und es verbleibt die mittelfristige Richtung des Marktes. τ^{kurz} soll Trendbewegungen im Bereich weniger Wochen erfassen. Deshalb wird $w_{\text{kurz}} = 40$ Handelstage (ca. zwei Monate) gewählt. Dieses kürzere Fenster erlaubt es, aktienspezifische Bewegungen zeitnah in die Extrapolation einfließen zu lassen.

Nach der Trendentfernung verbleiben die Residuen c_t als kurzfristige Muster.

$$c_t = \tilde{p}_t - \hat{\tau}_t^{\text{kurz}}.$$

Diese werden durch ein ARMA(p,q)-Modell beschrieben [14]. Für die Anwendung eines ARMA-Modells, wird vorausgesetzt, dass die zugrundeliegenden Daten stationär sind. Um zu prüfen, ob dies nach der Trendentfernung der Fall ist, wird der cro:ADFAugmented Dickey-Fuller (ADF)-Test [15] angewendet. Der ADF-Test [15] prüft die Nullhypothese, dass eine Unit Root vorliegt, die Zeitreihe also nicht stationär ist. Wird diese bei einem p-Wert kleiner als ,05 verworfen, kann Stationarität angenommen werden. Sollte Stationarität nicht gewährleistet werden können, wird die Wahl der HP-Filter Parameter λ variiert. Zur Modellierung der Residuen c_t wird ein Standard ARMA(p,q)-Modell nach [14] verwendet:

$$\hat{c}_t = a + \sum_{i=1}^p \phi_i c_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t, \quad (3.20)$$

mit den Autokorrelationskoeffizienten ϕ_i , Fehlerkoeffizienten θ_j und einem konstanten Achsenabschnitt a . Die Parameter ϕ_i und θ_j werden dabei für jede Kombination (p, q) mittels Maximum-Likelihood-Schätzung bestimmt [14]. Die Ordnung p und q des Modells wird durch eine Grid-Search bestimmt. Das heißt, für alle Kombinationen (p, q) mit $p, q \in \{0, 1, \dots, 5\}$ wird das Modell geschätzt und das cro:AICAkaike Information Criterion (AIC) [16] berechnet:

$$\text{AIC}(p, q) = 2(p + q) - 2 \ln(\hat{L}), \quad (3.21)$$

wobei $\hat{L}$ die maximierte Likelihood des geschätzten Modells ist. AIC bestraft dabei die Modellkomplexität und die Anpassungsgüte wird belohnt. Gewählt wird das Modell welches das AIC minimiert. So kann die optimale Modellkomplexität bestimmt werden. [17]

Mit dem geschätzten ARMA(p^*, q^*)-Modell werden die Residuen rekursiv vorhergesagt:

$$\hat{c}_{T+k} = \sum_{i=1}^{p^*} \phi_i \hat{c}_{T+k-i} + \sum_{j=1}^{q^*} \theta_j \hat{\varepsilon}_{T+k-j} \quad (3.22)$$

Dabei werden für alle $k > 1$ die bereits vorhergesagten Werte als Eingabe verwendet. Außerdem werden alle zukünftigen Fehlerterme auf ihren Erwartungswert $\hat{\varepsilon}_{T+k} = \mathbb{E}[\varepsilon] = 0$ gesetzt.

Dies führt dazu, dass der ARMA-Beitrag zur Gesamtvorhersage für große Horizonte k exponentiell gegen null konvergiert, und die Vorhersage zunehmend von den extrapolierten Trendkomponenten dominiert wird, was genau der Modellierung entspricht.

Die gesamte Vorhersage des Log-Preises zum Zeitpunkt $T + k$ ergibt sich aus der Summe aller drei modellierten Komponenten.

$$\hat{p}_{T+k} = \hat{\tau}_{T+k}^{\text{lang}} + \hat{\tau}_{T+k}^{\text{kurz}} + \hat{c}_{T+k} \quad (3.23)$$

Die Rücktransformation in den ursprünglichen Preisraum erfolgt durch Exponentiation.

$$\hat{P}_{T+k} = \exp(\hat{p}_{T+k}) \quad (3.24)$$

3.3.2. Preprocessed SVR

SVRs wurden schon häufig verwendet, um Aktienkurse vorherzusagen. In dieser Arbeit stehen zwei Unterschiede zu den bisherigen Verfahren im Vordergrund. Zunächst wird auf Log-Renditen trainiert und vorhergesagt, da diese annähernd stationär sind, additiv über die Zeit und symmetrischer verteilt. Außerdem werden in diesem Ansatz vorher berechnete technische Indikatoren und News-Sentiments als Features für die SVR verwendet, anstatt roher vergangener Preise.

Es wird eine klassische SVR-Modellierung nach [18] verwendet. Es ist das Ziel aus einem Feature-Vektor x_t mit d Features, die Log-Rendite $\hat{r}_{t+1}$ vorherzusagen.

$$\hat{r}_{t+1} = f(x_t), \quad x_t \in \mathbb{R}^d \quad (3.25)$$

Im Gegensatz zu linearen Regressionen nimmt die SVR keine spezifizierte funktionale Form an, sondern lernt die Abbildung anhand historischer Trainingsbeispiele, was sinnvoll für Aktienkursvorhersage ist, da Aktienkurse sich nicht durch eine spezifizierte funktionale Form beschreiben lassen. Die Modellierung der SVR orientiert sich an [18] und die genaue Beschreibung, sowie Parameterwahl ist ausführlich formuliert in Anhang A. Zur Fokussierung auf den neuen Ansatz dieser Arbeit, wird die SVR abstrahiert als eine Abbildung $f : \mathbb{R}^d \rightarrow \mathbb{R}$, welche mithilfe der vergangenen Bewegungsmuster des Kurses von einem d -dimensionalen Eingabe-Feature-Vektor den Aktienpreis des nächsten Tages schätzt und darauf abbildet. Während andere Arbeiten den Feature-Vektor nur mit vergangenen Preisen modellieren [19][20], verwendet dieser Ansatz verschiedene Informationsquellen und Eingabewerte mithilfe eines ausführlichen Feature-Engineerings, um das Erkennen von Strukturen in Marktbewegungen für die Regression zu vereinfachen.

Feature Engineering

Da Aktienkurse von einer Vielzahl von Einflussfaktoren abhängen werden Features aus den vier Bereichen kurzfristiger Preisdynamik, Marktstimmung, technischer Trendstärke und Volatilität kombiniert. Zum Zeitpunkt t setzt sich der Feature-Vektor $\mathbf{x}_t \in \mathbb{R}^9$ wie folgt zusammen:

$$\mathbf{x}_t = (r_{t-1}, r_{t-2}, r_{t-3}, \text{Sent}_t, \text{RSI}_t, \text{MACD}_t, \text{BB}_t, \sigma_{10,t}, d_t)^\top \quad (3.26)$$

Die einzelnen Komponenten sowie ihre Begründung werden in den folgenden Abschnitten erläutert.

Historische Renditen

Finanzzeitreihen weisen häufig kurzfristige Abhängigkeiten auf, die durch autoregressive Modelle erfasst werden können [21]. Die letzten drei Tagesrenditen r_{t-1} , r_{t-2} , r_{t-3} werden daher als direkte autoregressive Eingaben verwendet, um dem Modell kurzfristige Trendmuster zur Verfügung zu stellen. Die Wahl, dass Renditen bis zu drei vergangenen Tagen verwendet werden, stellt einen Kompromiss zwischen Informationsgehalt und Modellkomplexität dar. Längere Fenster erhöhen die Dimensionalität der SVR ohne Mehrwert für kurzfristige Prognosen [22]. Die Log-Rendite zum Zeitpunkt t ist definiert als

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right), \quad (3.27)$$

wobei P_t den Schlusskurs am Tag t bezeichnet. Log-Renditen werden gegenüber einfachen Renditen bevorzugt, da sie zeitlich additiv und annähernd normalverteilt sind.

Sentiment Score

Nachrichtmeldungen beeinflussen nachweislich die Kursentwicklung einer Aktie. [23]. Um diesen Effekt zu erfassen, wird die externe Sentiment-API von Alpha Vantage genutzt [24], die für jede veröffentlichte Nachricht einen Sentiment-Score $s_i \in [-1, 1]$ pro erwähnter Aktie liefert, wobei -1 stark negatives und $+1$ stark positives Sentiment bedeutet.

Da nicht alle Nachrichten gleich relevant sind, wird ein exponentiell gewichteter Durchschnitt über die letzten 10 Meldungen berechnet, um aktuelleren Nachrichten ein höheres Gewicht beizumessen:

$$\text{Sent}_t = \frac{\sum_{i=1}^{10} w_i \cdot s_i}{\sum_{i=1}^{10} w_i}, \quad w_i = e^{\lambda(i-10)}, \quad (3.28)$$

wobei die Nachrichten chronologisch geordnet sind ($i = 1$ älteste, $i = 10$ neueste) und $\lambda = 0.2$ den Abklingparameter steuert. Die exponentielle Gewichtung wird verwendet, da veraltete Meldungen die aktuelle Marktlage schnell schlechter widerspiegeln.

Relative Strength Index

Die allgemeine Marktdynamik ist aus Rohkursen allein schwer extrahierbar. Der Relative Strength Index (RSI) ist hierbei geeignet, um die Marktdynamik widerzuspiegeln, da er überkaufte oder überverkaufte Marktphasen anzeigt [25]. Er misst die relative Stärke von Aufwärts- gegenüber Abwärtsbewegungen innerhalb eines Zeitfensters von $n = 14$ Tagen und ist häufig Bestandteil technischer Analysen [25]:

$$RSI_t = 100 - \frac{100}{1 + \frac{\bar{U}_t}{\bar{D}_t}}, \quad (3.29)$$

wobei $\bar{U}_t$ den exponentiell geglätteten Durchschnitt der positiven Kursveränderungen und $\bar{D}_t$ den exponentiellen Durchschnitt der negativen Kursveränderungen der letzten 14 Handelstage bezeichnet. Der RSI liegt per Konstruktion im Intervall $[0, 100]$, was seine spätere Normalisierung vereinfacht.

Moving Average Convergence Divergence

Während der RSI kurzfristige Über- oder Untertreibungen misst, erfasst der Moving Average Convergence Divergence (MACD) mittelfristiges Momentum und Trendwechsel, wodurch die beiden Parameter kombiniert ein gutes Bild auf die Kursentwicklung geben. Der MACD bildet die Differenz zweier exponentiell geglätteter Durchschnitte [26]:

$$\text{MACD}_t = \text{EMA}_{12}(p)_t - \text{EMA}_{26}(p)_t, \quad (3.30)$$

wobei $\text{EMA}_k(p)_t$ den exponentiellen gleitenden Durchschnitt des Schlusskurses über k Handelstage zum Zeitpunkt t bezeichnet. Die Parameterwahl von 12 und 26 Tagen entspricht dem in der Literatur gebräuchlichen Standard [26].

Bollinger-Band-Position

Die relative Kursposition innerhalb der jüngsten Kursspanne ist ein weiteres, von den bisherigen Dimensionen unabhängiges Signal. Die Bollinger-Bänder bestehen aus einem gleitenden Durchschnitt $\text{MA}_{20,t}$ sowie einem oberen Band $B_t^+ = \text{MA}_{20,t} + 2\sigma_{20,t}$ und einem unteren Band $B_t^- = \text{MA}_{20,t} - 2\sigma_{20,t}$, wobei $\sigma_{20,t}$ die Standardabweichung der Schlusskurse der letzten 20 Handelstage ist [27]. Als Feature wird die normierte Position des aktuellen Kurses innerhalb der Bänder verwendet:

$$\text{BB}_t = \frac{p_t - B_t^-}{B_t^+ - B_t^-} \in [0, 1]. \quad (3.31)$$

Diese Normierung hat den Vorteil, dass das Feature bereits konstruktionsbedingt im Intervall $[0, 1]$ liegt und damit keine weitere Skalierung erfordert.

Realisierte Volatilität

Phasen erhöhter Volatilität gehen typischerweise mit größeren Renditeausschlägen einher (Volatilitätsclustering) [28]. Deshalb geht die aktuelle Volatilität als Parameter in das Modell ein. Als Maß für die kurzfristige Marktunsicherheit wird die realisierte 10-Tages-Volatilität der Log-Renditen verwendet:

$$\sigma_{10,t} = \sqrt{\frac{1}{9} \sum_{i=1}^{10} (r_{t-i} - \bar{r}_t)^2}, \quad \bar{r}_t = \frac{1}{10} \sum_{i=1}^{10} r_{t-i}. \quad (3.32)$$

Das Fenster von 10 Tagen erfasst kurzfristige Volatilität ohne übermäßige Glättung, die bei längeren Fenstern auftreten würde.

Handelspause

Der sogenannte Montag-Effekt beschreibt die empirisch beobachtete Tendenz, dass Renditen nach Handelspausen systematisch von regulären Folgetagen abweichen [29]. Dieser Effekt wird durch die aktuellen Dimensionen noch nicht abgebildet und geht durch eine Binärvariable in die Schätzung ein:

$$d_t = \begin{cases} 1 & \text{wenn zwischen } t-1 \text{ und } t \text{ mindestens ein Nicht-Handelstag liegt,} \\ 0 & \text{sonst.} \end{cases} \quad (3.33)$$

Dies trifft auf alle Montage sowie auf Tage nach Feiertagen zu.

Normalisierung

Da SVR mittels Abstandsberechnungen im Feature-Raum funktioniert, ist eine einheitliche Skalierung aller Eingaben erforderlich [30]. Ohne Normalisierung würden Features mit großen absoluten Wertebereichen die Berechnung dominieren, unabhängig von ihrem tatsächlichen Informationsgehalt. Dies würde dazu führen, dass das Modell die übrigen Features ignoriert.

Die Merkmale r_{t-1} , r_{t-2} , r_{t-3} , Sent_t , MACD_t und $\sigma_{10,t}$ werden mittels Z-Score-Normalisierung standardisiert:

$$\tilde{x} = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}. \quad (3.34)$$

Diese Methode ist kohärent, das sie keine Annahmen über den Wertebereich der Features benötigt. Der RSI wird durch Division durch 100 auf $[0, 1]$ skaliert. Die Features BB_t und d_t erfordern keine weitere Transformation, da BB_t konstruktionsbedingt in $[0, 1]$ liegt und d_t bereits binär ist. Die Normalisierungsparameter (μ_{train} , σ_{train}) werden ausschließlich auf den Trainingsdaten berechnet und anschließend auf Test- und Validierungsdaten angewendet.

3.3.3. StockTimesFM

Aktienkursvorhersagemodelle sind dafür bekannt, stark zum Overfitting zu neigen. Selbst die Nutzung großer Datensätze führt in der Praxis oft nicht zu einer signifikanten Verbesserung der Generalisierungsfähigkeit [31]. Ein grundlegender Ansatz, diesem Problem zu begegnen, besteht darin, gar nicht auf Aktiendaten zu trainieren, sondern stattdessen auf allgemeines Zeitreihenwissen zurückzugreifen. Genau diesen Ansatz verfolgt diese Arbeit mit dem Einsatz von TimesFM im Zero-Shot-Modus.

TimesFM ist ein von Google Research entwickeltes Foundation Model für Zeitreihenprognosen [32]. Analog zu großen Sprachmodellen wurde TimesFM auf einem Korpus realer Zeitreihendaten aus vielen Domänen vortrainiert, mit dem Ziel, Muster in sequenziellen Daten zu erlernen. Technisch basiert es auf einer Decoder-only Transformer-Architektur. Die Eingabezeitreihe wird in Patches gleicher Länge aufgeteilt, die als Tokens in den Transformer eingehen, und das Modell lernt durch die Vorhersage des jeweils nächsten Patches, analog zum Next-Token-Prediction-Prinzip in Sprachmodellen.

Der Ansatz dieser Arbeit besteht darin, TimesFM unverändert ohne Fine-Tuning auf Aktienrenditen anzuwenden. Dieser Zero-Shot-Einsatz erlaubt es zu untersuchen, ob allgemeines Zeitreihenwissen auf die spezifischen Muster von Ak-

Aktienkursen übertragbar ist. Im Unterschied zu allen anderen in dieser Arbeit vorgestellten Modellen wird kein datensatzspezifisches Muster gelernt, sondern die Frage beantwortet, ob domänenübergreifendes Wissen über Zeitreihen, wie Saisonalität oder Trendverhalten ausreicht, um Prognosen zu liefern, ohne dabei auf historische Aktienkurse zu overfitten.

Für die Anwendung wird TimesFM auf Log-Renditen eingesetzt, um Vergleichbarkeit mit den übrigen Modellen herzustellen. Als Eingabe dient ein rollierendes Fenster der letzten w Renditen-Beobachtungen, sodass das Modell zum Zeitpunkt t die Renditeprognose

$$\hat{r}_{t+1} = f_{\theta}(r_{t-w+1}, \dots, r_t) \quad (3.35)$$

ausgibt, wobei f_{θ} das vortrainierte TimesFM-Modell mit den unveränderten Parametern θ bezeichnet. Die zugehörige Preisvorhersage ergibt sich dann als

$$\hat{P}_{t+1} = P_t \cdot \exp(\hat{r}_{t+1}). \quad (3.36)$$

3.4. Handelsstrategie

Die in Kapitel 3.3 vorgestellten Modelle liefern jeweils eine Preisprognose für einen künftigen Zeitpunkt $t + k$. Um ihre realistische Anwendbarkeit zu bewerten, wird eine einheitliche, regelbasierte Handelsstrategie definiert, die für alle Modelle identisch ist. Dies stellt sicher, dass Performanceunterschiede im Backtesting ausschließlich auf die Prognosegüte der Modelle zurückzuführen sind und testet alle Modelle auf ihre praktische Anwendbarkeit. Die Strategie umfasst die drei Komponenten Forecasting Horizon k , das Handelssignal sowie die Positionsgröße.

3.4.1. Forecasting Horizon

Die Wahl des Forecasting Horizons k beeinflusst, welche Arten von Mustern ein Modell erlernen muss und wie stark Rauschen die Prognose beeinträchtigt. Es

lässt sich empirisch zeigen, dass auf dem Eintages-Horizont $k = 1$ der stärkste Informationsgehalt technischer Signale liegt, da sich Informationen schnell einpreisen und Prognosen über mehrere Tage von nicht modellierbarem Rauschen dominiert werden [33]. Darüber hinaus minimiert $k = 1$ das sogenannte Compounding-Risiko. Wird eine Position mehrere Tage gehalten, akkumulieren sich Prognosefehler über jeden einzelnen Schritt, sodass die tatsächliche Rendite von der erwarteten Rendite weiter abweicht [34]. Der Forecasting Horizon wird daher auf $k = 1$ festgelegt, d. h. jedes Modell gibt täglich eine Prognose $\hat{P}_{t+1}$ ab, auf deren Basis die Handelsentscheidung für den nächsten Tag getroffen wird.

3.4.2. Handelssignal

Die Strategie beschränkt sich auf Long-Positionen und Cash, d. h. Short-Selling wird ausgeschlossen. Das umgeht Liquiditätsprobleme und vermeidet das unbegrenzte Verlustrisiko von Short-Positionen [35].

Ein Kaufsignal auf Basis des Vorzeichens der vorhergesagten Rendite ($\hat{r}_{t+1} > 0 \Rightarrow$ kaufen) ist zwar einfach, aber anfällig gegenüber Modellrauschen. Kleine positive Prognosen nahe null enthalten wenig Informationen und führen zu unnötigen Transaktionen [36]. Daher wird ein Schwellenwert $\varepsilon > 0$ eingeführt, unterhalb dessen keine Position eingegangen wird:

$$\text{Signal}_t = \begin{cases} \text{Long} & \text{wenn } \hat{r}_{t+1} > \varepsilon, \\ \text{Hold} & \text{wenn } -\varepsilon \leq \hat{r}_{t+1} \leq \varepsilon, \\ \text{Cash} & \text{wenn } \hat{r}_{t+1} < -\varepsilon. \end{cases} \quad (3.37)$$

Der Schwellenwert ε wird als die mittlere absolute Prognoseabweichung (MAE) des jeweiligen Modells auf den Validierungsdaten gesetzt.

$$\varepsilon = \text{MAE}_{\text{val}} = \frac{1}{|\mathcal{V}|} \sum_{t \in \mathcal{V}} |\hat{r}_{t+1} - r_{t+1}|. \quad (3.38)$$

Das bedeutet, dass eine Kaufentscheidung nur dann getroffen wird, wenn die vorhergesagte Rendite die typische Prognoseunsicherheit des Modells übersteigt. Liegt die Vorhersage innerhalb des Unsicherheitsbereichs $[-\varepsilon, \varepsilon]$, wird die aktuelle Position beibehalten. Erst bei einer stark negativen Prognose unterhalb von $-\varepsilon$ werden alle Positionen geschlossen. [37].

3.4.3. Positionsgröße

Die Bestimmung der Positionsgröße folgt dem Kelly-Kriterium, das die langfristige Wachstumsrate des Kapitals maximiert [38]. Im Gegensatz zu einer fixen Positionsgröße berücksichtigt das Kelly-Kriterium das Verhältnis von erwartetem Gewinn zu erwartetem Verlust.

In seiner klassischen Form für kontinuierliche Renditen lautet der Kelly-Anteil [39]:

$$f^* = \frac{\mu}{\sigma^2}, \quad (3.39)$$

wobei μ die erwartete Rendite und σ^2 die Varianz der Renditen bezeichnet. Da beide Größen unbekannt sind, werden sie auf einem rollierenden Fenster der letzten $w_K = 60$ Handelstage geschätzt:

$$\hat{\mu}_t = \frac{1}{w_K} \sum_{i=1}^{w_K} r_{t-i}, \quad \hat{\sigma}_t^2 = \frac{1}{w_K - 1} \sum_{i=1}^{w_K} (r_{t-i} - \hat{\mu}_t)^2. \quad (3.40)$$

Das volle Kelly-Kriterium führt in der Praxis jedoch zu extremen Positionsgrößen und ist gegenüber Schätzfehlern in $\hat{\mu}_t$ anfällig [40]. Es ist daher üblich, einen Kelly-Anteil zu verwenden. In dieser Arbeit wird Half-Kelly eingesetzt [39]:

$$f_t = \frac{1}{2} \cdot \frac{\hat{\mu}_t}{\hat{\sigma}_t^2}. \quad (3.41)$$

Da weder Short-Selling, noch Hebel-Trading betrachtet werden, wird f_t auf das Intervall $[0, 1]$ beschränkt, indem negative Werte auf 0 und Werte größer 1 auf 1 gesetzt werden.

Ist also zum Zeitpunkt t $\text{Signal}_t = \text{Long}$, wird die Position so angepasst, dass sie dem Anteil f_t vom Gesamtportfoliowert entspricht. Dies kann auch einer Reduktion der Position entsprechen. Das Signal bedeutet hierbei lediglich, dass weiterhin investiert werden sollte. Ist $\text{Signal}_t = \text{Hold}$, wird keine Aktion durchgeführt und die aktuelle Position beibehalten. Ist $\text{Signal}_t = \text{Cash}$, werden alle Positionen geschlossen, also alle Anteile verkauft.

3.5. Einschränkungen und Nebenbedingungen

Da im Rahmen dieser Arbeit nicht alle realistischen Marktszenarien berücksichtigt werden können, müssen einige Annahmen getroffen werden.

Komission

Komission ist eine Gebühr, die ein Broker oder eine Börse für die Ausführung einer Order verlangt. Diese ist meistens prozentual abhängig vom Ordervolumen und fällt sowohl beim Kauf als auch beim Verkauf an. Dadurch wird die Profitabilität eines Portfolios reduziert. In den letzten Jahren haben sich die Komission drastisch reduziert. Im Jahr 1970 lagen sie noch bei ca. 1% des Ordervolumens. Durch Neobroker und Konkurrenz unter Brokern ist die Komission mittlerweile stark gesunken, teilweise auf bis 1US\$ pro Trade. Um die Arbeit unabhängig von Änderungen in der Praxis im Bezug auf Kommissionen zu halten, wird bei den Backtests dieser Arbeit keine Komission berechnet. [41]

Spread

Der Spread ist die Differenz zwischen Kaufpreis und Verkaufspreis einer Aktie. Dieser ist an einer Börse meist unterschiedlich, wobei der Kaufpreis höher als der Verkaufspreis ist. Wird eine Aktie gekauft und sofort wieder verkauft, entsteht also ein Verlust. Besonders bei Hochfrequenzhandel führt dies zu Verlusten. Da diese Arbeit ausschließlich Tagesöffnungs und -schlusskurse verwendet, wird kein Spread betrachtet werden. Als Preis wird daher in dieser Arbeit der erste bzw. letzte gehandelte Marktpreis verwendet. [41]

Liquidität

Die verwendeten Tageskurse spiegeln die tatsächlich gehandelten Preise wider, berücksichtigen jedoch nicht, ob zum angegebenen Preis tatsächlich ausreichend Volumen für eine Order verfügbar gewesen ist. Da ausschließlich liquide Aktien aus dem S&P500 verwendet werden, wird angenommen, dass alle Transaktionen zum beobachteten Preis ausgeführt werden können. Um eine Verzerrung durch simultane Informationsnutzung zu vermeiden, werden Kaufentscheidungen, die auf dem Schlusskurs eines Tages basieren, zum Eröffnungskurs des folgenden Tages ausgeführt. Auf diese Weise wird sichergestellt, dass Entscheidungen ausschließlich auf Basis von Informationen getroffen werden, die zu diesem Zeitpunkt bereits verfügbar waren. [42]

3.6. Metriken

Die Bewertung der genannten Modell erfolgt in zwei Schritten. Nachdem die Vorhersagemodelle in Abschnitt 3.3 vorgestellt wurden, werden sie in dem genannten Testzeitraum in einem etablierten Walk-Forward jeweils für jede ausgewählte Aktie getestet. Das bedeutet, es wird die tatsächliche Historie der Aktienkursbewegung simuliert und es werden jeweils Vorhersagen erstellt. Die erstellten

Ergebnisse werden nicht gesichert auch in der Zukunft funktionieren, aber zeigen wie gut das Modell in der Vergangenheit funktioniert hätte. [43] Anschließend werden sie anhand der in Abschnitt 3.6.1 vorgestellten Fehlermaße bewertet.

Mithilfe der in Abschnitt 3.4 entwickelten Handelsstrategien, werden die Modelle dann praxisnah getestet. Es wird ein virtuelles Portfolio angelegt, mit einem Startkapital von $V_0 = 100.000$ US\$. Die Modelle werden in einem Walk-Forward jeweils pro Aktie getestet, wobei die Modelle eine Preisreihe ab dem aktuellen Tag vorhersagen und anhand der in Abschnitt 3.4 vorgestellten Kriterien eine Kaufs- oder Verkaufsentscheidung simuliert wird. Dadurch kann der Portfoliowert steigen und fallen. Am Ende des Testzeitraums erfolgt eine Bewertung anhand der in ?? vorgestellten Kennzahlen.

Ziel der Bewertungen ist immer ein Modellvergleich der vorgestellten Modelle untereinander.

3.6.1. Fehlermaße

Die Extrapolation von Zeitreihen ist ein weitreichend untersuchtes Gebiet. Dadurch haben sich einige Fehlermaße zur Bewertung der Verfahren etabliert. Zu den häufigstverwendeten zählen unter anderem MAPE, RMSE, MSE, Directional Accuracy, R^2 und MAE [10], [44]. Um eine möglichst hohe Vergleichbarkeit mit anderen Arbeiten zu gewährleisten, werden die drei meistverwendeten, MAPE, RMSE und Directional Accuracy, verwendet. Um die Aussagekraft der Analyse zu erhöhen, wird auch das $\text{cro:OOS-}R^2$ Out-Of-Sample R^2 (OOS- R^2) Maß genommen mit einem Random Walk als Baseline. Hierbei sei anzumerken, dass viele Arbeiten einen R^2 -Score anhand von Preisen als Metrik verwenden, zum Beispiel ([45],[46],[47],[48]). Diese Bewertung ist wenig aussagekräftig, da Aktienkurse stark autokorreliert sind ($P_t \approx P_{t-1}$), und somit ein R^2 -Score von $> 0,9$ eine nicht vorhandene, außerordentlich gute Modellqualität anzeigt. Ein so berechneter R^2 -Score ist somit nur als Vergleichswert und nicht als eigenständiges Maß interpretierbar. Als reiner Vergleichswert ist der R^2 -Score aber auch sinnlos, da der Informationsgehalt nach

Gleichung (3.42) dem RMSE-Maß entspricht.

$$R^2 = 1 - \frac{\text{RMSE}^2 \cdot n}{\text{SS}_{\text{tot}}}, \text{SS}_{\text{tot}} = \text{const}, n = \text{const}. \quad (3.42)$$

Sinnvoll wäre nur eine R^2 -Analyse auf Renditen, anstatt auf Preisen. Da diese Arbeit das OOS- R^2 Maß auf Renditen verwendet, wird diese Ungenauigkeit eliminiert.

Root Mean Squared Error

Gegeben sei ein Signal $[x_1, x_2, \dots, x_n]$ und eine zugehörige Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$. Der RMSE misst die durchschnittliche quadratische Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{x}_i - x_i)^2}.$$

Der RMSE gewichtet Ausreißer durch die Quadratisierung stärker und ist durch die Wurzel interpretierbar, da er in derselbe Einheit wie die Werte der Zeitreihe angegeben wird.

Mean Absolute Percentage Error

Der MAPE misst die durchschnittliche prozentuale Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right|.$$

Da der MAPE relativ zum tatsächlichen Wert x_i normiert ist, ermöglicht er einen skaleninvarianten Vergleich über verschiedene Zeitreihen hinweg. Theoretisch neigt

er dazu negative Fehler assymetrisch zu bestrafen. Dies ist praktisch im Falle von Aktienkursen aber vernachlässigbar.

Out-of-Sample R^2

Der OOS- R^2 nach [49] misst, ob ein Modell bessere Vorhersagen liefert als ein naiver Benchmark. Sei $\hat{x}_i$ die Modellvorhersage und $\hat{x}_i^{\text{RW}} = x_{i-1}$ die Vorhersage eines Random-Walk-Modells, welches den letzten bekannten Wert als Schätzung verwendet. Der OOS- R^2 ist definiert als

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{\sum_{i=1}^n (x_i - \hat{x}_i^{\text{RW}})^2}.$$

Ein Wert $R_{\text{OOS}}^2 > 0$ zeigt an, dass das Modell den Random Walk übertrifft, während $R_{\text{OOS}}^2 \leq 0$ bedeutet, dass die naive Baseline mindestens gleichwertig ist.

Directional Accuracy

Alle bisher vorgestellten Fehlermaße unterscheiden nicht zwischen überschätztem oder unterschätztem Wert. Bei der Vorhersage von Aktienkursen ist dieser Unterschied aber von Relevanz, da eine Unterschätzung, die zu einem Kauf führt, weit weniger problematisch ist als eine Überschätzung. Hierfür wird die Directional Accuracy eingeführt.

Die cro:DADirectional Accuracy (DA) misst, wie gut ein Modell die Richtung der Kursbewegung vorhersagt, unabhängig von der genauen Höhe des Preises. Für ein Signal $[x_1, x_2, \dots, x_n]$ und eine Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird DA definiert nach

$$DA = \frac{1}{n} \sum_{i=2}^n \mathbf{1}(\text{sign}(x_i - x_{i-1}) = \text{sign}(\hat{x}_i - x_{i-1})),$$

wobei $\mathbf{1}(\cdot)$ die Indikatorfunktion ist, die den Wert 1 annimmt, wenn die Vorhersage die gleiche Richtung wie die tatsächliche Kursbewegung hat, und 0 sonst.

Ein Wert von $DA = 1$ entspricht einer perfekten Klassifikation, während $DA = 0.5$ einem zufälligen Raten entspricht.

3.6.2. Finanzwirtschaftliche Kennzahlen

Viele Arbeiten, die sich mit Zeitreihenextrapolation beschäftigen und insbesondere die zu Aktienkursvorhersagen, beenden die Evaluation nach der Untersuchung der Fehlermaße [10]. Da diese Arbeit einen weiteren praktischen Fokus fasst, soll auch die praktische Anwendbarkeit, und damit finanzwirtschaftlich evaluiert werden. Außerdem ist im Falle von Aktienkursvorhersage eine Fehlerminimierung nicht zwingend das optimale Ziel im Bezug auf die praktische Anwendung [50].

Viele Arbeiten, die auch die reale Anwendbarkeit testen, fokussieren sich auf Gesamtrendite, Sharpe Ratio und Maximum Drawdown ([51], [52], [53]). Weitere, seltener verwendete Kennzahlen sind das Sortino Ratio, Calmar Ratio und Value-at-risk threshold [43]. Alle Metriken befassen sich mit Rendite oder Volatilität. Um diese beiden Kennzahlen einer Strategiequalität abzubilden, werden in dieser Arbeit die Gesamtrendite und der Maximum Drawdown verwendet. Da Risiko und Rendite in der Finanzwelt keine unabhängigen Größen darstellen, sondern sich häufig beeinflussen, wird ebenso die Sharpe-Ratio evaluiert.

Gesamtrendite

Die Gesamtrendite gibt die insgesamt erzielte Rendite über den gesamten Zeitraum an:

$$R_{cum} = \frac{V_T - V_0}{V_0},$$

wobei V_0 der Anfangswert und V_T der Endwert des Portfolios ist. Sie zeigt die absolute Profitabilität der Strategie.

Sharpe Ratio

Das Sharpe Ratio misst das Rendite-Risiko-Verhältnis eines Portfolios, indem es die Portfolio Rendite ohne die risikofreie Rendite ins Verhältnis zur Volatilität setzt. Es wird berechnet nach

$$S = \frac{R_p - R_f}{\sigma(R_p)},$$

wobei R_p die Rendite des Portfolios, R_f der risikofreie Zinssatz und $\sigma(R_p)$ die Volatilität der Portfoliorendite ist. Die Volatilität $\sigma(R_p)$ wird über die empirische Standardabweichung ermittelt:

$$\sigma(R_p) = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_{P,t} - \bar{R}_P)^2}$$

Ein hohes Sharpe Ratio bedeutet eine hohe Rendite im Vergleich zum Risiko.

Maximum Drawdown

Der Maximum Drawdown (MDD) beschreibt den größten Verlust eines Portfolios vom höchsten Punkt (Peak) bis zum Tiefpunkt (Trough) innerhalb des betrachteten Zeitraums:

$$\text{MDD} = \max_t \frac{\text{Peak}_t - \text{Value}_t}{\text{Peak}_t}.$$

Ein niedriger Maximum Drawdown zeigt, dass das untersuchte Investment nur geringe zwischenzeitliche Verluste erlitt.

4. Implementierung

Die Implementierung ist in zwei Skripte aufgeteilt. Das erste Skript ist für die Aktienausswahl zuständig, während das zweite Skript die drei Modelle trainiert und evaluiert. Abb. 4.1 zeigt den Datenfluss der Implementierung über beide Skripte hinweg. Diese Aufteilung ermöglicht es, die Aktienausswahl unabhängig von der Modellevaluation durchzuführen und umgekehrt.




Figure 4.1.: Gesamtüberblick: Datenfluss von der Beschaffung bis zur Evaluation

Aktienauswahl

Voraussetzung für die Ausführung des Skripts sind die Konfigurationsdatei, die historischen Kursdaten der Aktien und die historischen Daten der Makrofaktoren. Sind diese Voraussetzungen nicht erfüllt, bricht das Skript mit einem Fehler ab. Die Konfigurationsdatei ist wie folgt aufgebaut:

- **Liste an Aktien:** Die Liste enthält alle Aktien, die zum Training der Modelle verwendet werden, wenn das Skript zur Aktienauswahl nicht ausgeführt wird.
- **Start- und Enddatum für Trainingsdaten**
- **Start- und Enddatum für Validierungsdaten**
- **Start- und Enddatum für Testdaten**
- **Start- und Enddatum für den gesamten Zeitraum:** Diese Daten werden vom Skript verwendet, das die Daten herunterlädt.
- **Konfigurationsparameter für den Download:** Mit den Parametern lässt sich festlegen, ob bereinigte Daten heruntergeladen werden sollen und ob die Daten auch nochmal heruntergeladen werden sollen, wenn bereits Daten vorhanden sind.
- **Liste der Makrofaktoren:** Die Liste enthält die Makrofaktoren, die zum Training der Modelle verwendet werden.
- **Konfigurationsparameter die Aktienauswahl:** Mit den Parametern lässt sich festlegen, wie viele Simulationen durchgeführt werden sollen, wie groß die Gruppen sein sollen und wie viele Aktien ausgewählt werden sollen.

Die historischen Kursdaten der Aktien und die historischen Daten der Makrofaktoren können über ein Hilfsskript heruntergeladen werden. Dieses Skript nutzt die Yahoo-Finance-API, um die Daten herunterzuladen. Die Daten werden als CSV-Dateien gespeichert.

Sind diese Voraussetzungen erfüllt, kann das Skript fehlerfrei ausgeführt werden. Das Skript ist in Algorithmus 1 dargestellt. Das Skript lädt als Erstes die Konfig-

Algorithm 1 Skript Aktienauswahl

Require: Konfigurationsdatei, historische Kursdaten, Makrofaktoren

```

1: config  $\leftarrow$  LOADCONFIG
2: train_start, train_end  $\leftarrow$  config.trainStart, config.trainEnd
3: tickers  $\leftarrow$  S&P 500 Ticker
4: stockData  $\leftarrow$   $\emptyset$ 
5: for all ticker  $\in$  tickers do
6:   Lade die Aktienkursdaten für Trainingszeitraum
7:   if Datenpunkte  $\geq$  500 then
8:     Füge die Schlusskurse der Aktie zu stockData hinzu
9:   end if
10: end for
11: factors  $\leftarrow$  Liste der Makrofaktoren aus config
12: factorData  $\leftarrow$   $\emptyset$ 
13: for all factor  $\in$  factors do
14:   Lade Makrofaktor-Zeitreihe für Trainingszeitraum
15:   if Datenpunkte  $\geq$  500 then
16:     Füge factor zu factorData hinzu
17:   end if
18: end for
19: numSimulations, groupSize, numSelected  $\leftarrow$  Werte aus config
20: selector  $\leftarrow$  SDESELECTOR(numSimulations, groupSize, numSelected)
21: selected  $\leftarrow$  SELECTOR.SELECT(stockData, factorData) Selector wird ausgeführt
22: Speichere selected als JSON
23: Die JSON Datei mit den ausgewählten Aktien wird gespeichert.
```

urationsdatei und dann die Liste aller Aktien, die im S&P 500 gelistet sind. Es wird eine leere Datenstruktur erstellt, die die Schlusskurse der Aktien speichert. Dann werden für alle Aktien in der Liste die historischen Kursdaten für den Trainingszeitraum geladen. Diese Kursdaten werden direkt aus der CSV-Datei gelesen, sollten die Daten nicht vorhanden sein, bricht das Skript mit einem Fehler ab. Wenn die Anzahl der Datenpunkte größer oder gleich 500 ist, werden die Schlusskurse der Aktie zu der Datenstruktur hinzugefügt. Analog wird mit den Makrofaktoren verfahren, dadurch entstehen die Datenstrukturen mit den Aktienkursen und den Makrofaktoren. Anschließend lädt das Skript die Konfigurationsparameter

für die Aktienausswahl und erstellt eine Instanz des SDE-Selectors. Der Selector wird mit den historischen Kursdaten der Aktien und den historischen Daten der Makrofaktoren ausgeführt. Die genaue Beschreibung des Auswahlprozesses ist in Abschnitt 4.1 zu finden. Das Ergebnis ist eine Liste der ausgewählten Aktien, die als JSON-Datei gespeichert wird.

Modelevaluation

Voraussetzung für die Ausführung des Skripts sind die Konfigurationsdatei, die Modellkonfiguration, die historischen Kursdaten der ausgewählten Aktien und die Liste mit den ausgewählten Aktien. Sind diese Voraussetzungen nicht erfüllt, werden die betroffenen Aktien und Modelle übersprungen. Das Skript ist in Algorithmus 2 dargestellt. Das Skript lädt als Erstes die Konfigurationsdatei

Algorithm 2 Skript Modelevaluation

Require: Konfigurationsdatei, Modellkonfiguration, historische Kursdaten, ausgewählte Aktien

```

1: config ← LOADCONFIG
2: stocks ← Liste der ausgewählten Aktien
3: models ← Modellkonfiguration (LinearSeparation, SVR, TimesFM)
4: results ← ∅
5: for all ticker ∈ stocks do
6:   train, val, test ← GETDATASPLIT(ticker, config)           ▷ 60/10/30 Split
7:   if |test| < 60 then
8:     Überspringe ticker
9:   end if
10:  for all model ∈ models do
11:    trainedModel ← MODEL.TRAIN(train, val)
12:    metrics ← RUNBACKTEST(trainedModel, test, model.config)
13:    Füge metrics mit ticker und model.name zu results hinzu
14:  end for
15: end for
16: Ausgeben der results
17: Ausgeben der aggregierten Durchschnittswerte pro Modell

```

und die Liste der Aktien. Beim Laden der Aktienliste wird überprüft, ob die

JSON-Datei aus dem Aktienausswahl-Skript vorhanden ist. Ist dies der Fall lädt das Skript die dort hinterlegten Aktien, andernfalls liest das Skript die Aktien aus der Konfigurationsdatei. Im nächsten Schritt lädt das Skript die Modellkonfiguration, für die drei Modelle. Die Modellkonfiguration enthält alle Modelle mit dem Namen des Modells, der Funktion zum Trainieren des Modells und den modelspezifischen Parametern für die Backtest-Engine. Die Parameter für die Backtest-Engine sind Signal Threshold, Forecast Horizon und Warmup Period. Außerdem wird eine leere Datenstruktur erstellt, die die Ergebnisse der Evaluation angelegt. Anschließend geht das Skript alle Aktien der Liste durch und lädt die historischen Kursdaten für die Aktien. Die Kursdaten liest das Skript direkt aus der CSV-Datei und teilt die Daten in Trainings-, Validierungs- und Testdaten auf, basierend auf den Start- und Enddaten aus der Konfigurationsdatei. Im nächsten Schritt nutzt das Skript die Trainings- und Validierungsdaten, um die Modelle zu trainieren. Dafür wird die modelspezifische Methode aus der Modellkonfiguration aufgerufen. Die Methode erzeugt immer das spezifische Modell, trainiert es auf den Daten und gibt es zurück. Das genaue Training der Modelle wird in Abschnitt 4.2, Abschnitt 4.3 und Abschnitt 5.4 beschrieben. Die trainierten Modelle werden dann mit den Testdaten in der Backtest-Engine evaluiert. Eine genaue Beschreibung der Backtest-Engine findet sich in Kapitel 4. Die Ergebnisse der Evaluation werden mit dem Namen der Aktie und dem Namen des Modells in der Datenstruktur gespeichert. Nachdem alle Aktien und Modelle durchlaufen wurden, werden die Ergebnisse ausgegeben, sowie die aggregierten Durchschnittswerte pro Modell.

Backtest

Die Methode `RunBacktest` ist in Algorithmus 3 dargestellt. Sie simuliert eine Handelsstrategie auf den Testdaten und berechnet die Evaluationsmetriken. Voraussetzung für die Ausführung der Methode ist ein trainiertes Modell, die Testdaten und die Modellkonfiguration.

Algorithm 3 RunBacktest Methode

Require: trainiertes Modell, Testdaten, Modellkonfiguration

- 1: $cerebro \leftarrow$ neue Backtest-Engine
 - 2: Füge $testDaten$ im Yahoo-Finance-Format zu $cerebro$ hinzu
 - 3: Füge **PredictionStrategy** mit Modell und Konfigurationsparametern hinzu
 - 4: Setze Startkapital auf \$100.000
 - 5: Füge Analyzer hinzu: Sharpe-Ratio, Drawdown, MAE, RMSE, MAPE, R_{OOS}^2 , DA
 - 6: $ergebnis \leftarrow$ Führe $cerebro$ aus
 - 7: $totalReturn \leftarrow (Endwert - Startkapital) / Startkapital$
 - 8: $bhReturn \leftarrow (letzterKurs - ersterKurs) / ersterKurs$
 - 9: $excessReturn \leftarrow totalReturn - bhReturn$
 - 10: Extrahiere Sharpe-Ratio, max. Drawdown und Vorhersagemetriken aus Analyzern
 - 11: **return** Metriken: $totalReturn$, $bhReturn$, $excessReturn$, Sharpe, Drawdown, MAPE, R_{OOS}^2 , DA
-

4.1. SDEs zur Aktienausswahl

Der Datenfluss der Aktienausswahl ist in Abb. 4.2 dargestellt. Wie in Kapitel 4 beschrieben, wird der SDE-Selector mit den historischen Kursdaten der Aktien und den historischen Daten der Makrofaktoren ausgeführt. Im ersten Schritt diskretisiert der Selector die historischen Kursdaten und die historischen Daten der Makrofaktoren. Daraus ergibt sich ein Richtungsvektor für jede Aktie und jeden Makrofaktor, der die Richtung der Kursbewegung bzw. der Veränderung des Makrofaktors angibt. Im zweiten Schritt berechnet der Selector dann mithilfe einer multiple lineare Regression die Koeffizienten, die die Stärke der Beziehung zwischen den Aktienkursen und den Makrofaktoren angeben und sucht dann im dritten Schritt die zwei Faktoren aus, die die stärkste Beziehung zu den Aktienkursen haben. Der vierte Schritt bildet basierend auf den zwei Faktoren jeder Aktie Pools von Aktien. Alle Aktien in einem Pool haben die gleichen zwei Makrofaktoren. Jetzt beginnt die Schleife des Selectors. Die Schleife wird standardmäßig 100 Mal durchlaufen, kann aber über die Konfigurationsdatei angepasst werden. In dem Durchlauf der Schleife werden erste die Aktienpools in Gruppen von je standardmäßig 4 Aktien aufgeteilt. Im zweiten Schritt stellt die Schleife für jede Gruppe die SDE auf und löst diese mit dem Euler-Maruyama-Schema. Nach dem

Lösen der SDE wird der ROI für jede Aktie berechnet. Der letzte Schritt der Schleife gibt die Aktie mit ihrem Rang innerhalb der Gruppe zurück. Nachdem die Schleife alle Durchläufe gemacht hat, berechnet der Selector den durchschnittlichen Rang jeder Aktie über alle Durchläufe und gibt die 10 Aktien mit dem besten durchschnittlichen Rang zurück. Diese 10 Aktien werden dann für das Training der Modelle verwendet.




Figure 4.2.: Aktienausswahl: Datenfluss von den historischen Kursdaten und Makro-faktoren bis zu den ausgewählten Aktien

4.2. LinearSeparation

Der Datenfluss von der Erstellung des Modells bis zum trainierten Modell ist in Abb. 4.3 dargestellt. Das Modell besteht aus drei Pfaden, die parallel zueinander verlaufen. Alle drei Pfade beginnen mit den logarithmierten historischen Schlusskursen der Aktie, die als Input für das Modell dienen. Auf diese Kurse wird dann ein HP-Filter mit einem Lambda von $1600 \cdot 252^2$ angewendet, der den langfristigen Trend der Daten ermittelt. Der erste Pfad bestimmt den langfristigen Trend der Aktie. Dafür wird der vom HP-Filter bestimmte Trend verwendet, um eine lineare Regression durchzuführen. Die Steigung und der Achsenabschnitt der Regressionsgeraden bilden die Vorhersage für den langfristigen Trend der Aktie. Um den kurzfristigen Trend der Aktie zu bestimmen, zieht das Modell den langfristigen Trend von den logarithmierten Schlusskursen ab, um die zyklische Komponente der Daten zu erhalten. Auf diese zyklische Komponente wird dann nochmal ein HP-Filter mit einem Lambda von 1600 angewendet, um den kurzfristigen Trend zu bestimmen. Der zweite Pfad nutzt dann den kurzfristigen Trend und modelliert eine lineare Regression, um die Vorhersage für den kurzfristigen Trend zu erhalten. Der dritte Pfad nutzt die zyklische Komponente des zweiten HP-Filters, um ein ARMA-Modell zu trainieren. Die Vorhersage der ARMA-Komponente wird dann als Vorhersage für die zyklische Komponente der Daten verwendet. Am Ende werden die drei Vorhersagen für den langfristigen Trend, den kurzfristigen Trend und die zyklische Komponente zusammengeführt, um die endgültige Vorhersage für die Aktie zu erhalten. Da die drei Pfade auf logarithmierten Kursen arbeiten, muss die Vorhersage am Ende exponentiert werden, um die Vorhersage für den tatsächlichen Kurs zu erhalten. Zur Vorhersage des nächsten Tageskurses, bildet das Modell die Differenz zwischen dem ersten Trainingsdatum und dem Datum für die Vorhersage. Dies ist der Tag der dann in die beiden linearen Funktionen eingesetzt wird, die die Vorhersage für den langfristigen und kurzfristigen Trend liefern. In die ARMA-Komponente wird die Differenz zwischen dem letzten Trainingsdatum und dem Datum für die Vorhersage eingesetzt, um die Vorhersage für




Figure 4.3.: LinearSeparation: Datenfluss von den Trainingsdaten bis zum trainierten Modell

die zyklische Komponente zu liefern. Die drei Vorhersagen werden dann addiert und exponentiert, um die Vorhersage für den tatsächlichen Kurs zu erhalten.

4.3. Preprocessed SVR

4.4. StockTimesFM

Da mit dem StockTimesFM Modell ein Zero-Shot Ansatz verfolgt wird, muss das Modell nicht trainiert werden. Dem Modell werden ausschließlich die Trainingsdaten übergeben, die später als Basis für den Kontext der Vorhersage dienen. Deshalb zeigt Abb. 4.4 auch den Datenfluss bei der Vorhersage von neuen Kursen, da dies der einzige Schritt ist, der mit diesem Modell durchgeführt wird. Für die bessere Vergleichbarkeit arbeitet auch dieses Modell auf logerithmierten Kursen. Aus diesem Grund werden im ersten Schritt die alle historischen Schlusskurse der Aktie logerithmiert. Die letzten 512 logerithmierten Schlusskurse bilden dann den Kontext für die Vorhersage. Dieser Kontext wird dann in das StockTimesFM Modell eingespeist, um die Vorhersage für den nächsten Log-Return zu erhalten. Das Modell nimmt dann die ersten N prognostizierten Log>Returns. N ist die Anzahl der Tage, die vorhergesagt werden sollen. Im letzten Schritt wandelt das Modell die prognostizierten Log>Returns in prognostizierte Kurse um, indem es die Log>Returns exponentiert und mit dem letzten Schlusskurs multipliziert. Der nächste Preis baut somit auf dem letzten prognostizierten Preis auf.




Figure 4.4.: StockTimesFM: Datenfluss der Vorhersage von neuen Kursen

5. Ergebnisse und Bewertung

5.1. SDE Aktienauswahl

5.2. LinearSeparation

5.3. Preprocessed SVR

5.4. StockTimesFM

6. Zusammenfassung und Ausblick

Literaturverzeichnis

- [1] Malkiel, B. G., “Efficient market hypothesis,” in *Finance*, Springer, 1989, pp. 127–134.
- [2] Burton, K. “Inside a moneymaking machine like no other.” Archived from the original on 14 May 2017, Accessed: 05/11/2017. [Online]. Available: <https://www.bloomberg.com/news/articles/2016-11-21/how-renaissance-s-medallion-fund-became-finance-s-blackest-box>.
- [3] Sewell, M., “The efficient market hypothesis: Empirical evidence,” *International Journal of Statistics and Probability*, vol. 1, no. 2, pp. 164–178, 2012.
- [4] Prakash, A./ Tuo, R./ Ding, Y., “The temporal overfitting problem with applications in wind power curve modeling,” *Technometrics*, vol. 65, no. 1, pp. 70–82, 2023. [Online]. Available: <https://arxiv.org/abs/2012.01349>.
- [5] Kumar, D./ Sarangi, P. K./ Verma, R., “A systematic review of stock market prediction using machine learning and statistical techniques,” *Materials Today: Proceedings*, vol. 49, pp. 3187–3191, 2022.
- [6] Rundo, F./ Trenta, F./ Di Stallo, A. L./ Battiato, S., “Machine learning for quantitative finance applications: A survey,” *Applied Sciences*, vol. 9, no. 24, p. 5574, 2019.
- [7] Shah, D./ Isah, H./ Zulkernine, F., “Stock market analysis: A review and taxonomy of prediction techniques,” *International Journal of Financial Studies*, vol. 7, no. 2, p. 26, 2019.
- [8] Sasikumar, R./ Abdullah, A. S., “Applications of various stochastic models in financial prediction,” *International Journal of Scientific and Innovative Mathematical Research (IJSIMR)*, vol. 3, no. 3, pp. 852–857, 2015.

- [9] Ofomata, A. I. O./ Inyama, S. C./ Umana, R. A./ Omane, A. O., “A stochastic model of the dynamics of stock price for forecasting,” *Journal of Advances in Mathematics and Computer Science*, vol. 25, no. 6, pp. 1–24, 2017.
- [10] Gandhmal, D. P./ Kumar, K., “Systematic analysis and review of stock market prediction techniques,” *Computer Science Review*, vol. 34, p. 100 190, 2019.
- [11] Ballings, M./ Van den Poel, D./ Hespeels, N./ Gryp, R., “Evaluating multiple classifiers for stock price direction prediction,” *Expert systems with Applications*, vol. 42, no. 20, pp. 7046–7056, 2015.
- [12] Lu, W./ Li, J./ Wang, J./ Qin, L., “A cnn-bilstm-am method for stock price prediction,” *Neural computing and applications*, vol. 33, no. 10, pp. 4741–4753, 2021.
- [13] Hodrick, R. J./ Prescott, E. C., “Postwar U.S. business cycles: An empirical investigation,” *Journal of Money, Credit and Banking*, vol. 29, no. 1, pp. 1–16, 1997.
- [14] Box, G. E. P./ Jenkins, G. M./ Reinsel, G. C./ Ljung, G. M., *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ: Wiley, 2015.
- [15] Dickey, D. A./ Fuller, W. A., “Distribution of the estimators for autoregressive time series with a unit root,” *Journal of the American Statistical Association*, vol. 74, no. 366a, pp. 427–431, 1979.
- [16] Akaike, H., “A new look at the statistical model identification,” *IEEE Transactions on Automatic Control*, vol. 19, no. 6, pp. 716–723, 1974.
- [17] Hyndman, R. J./ Khandakar, Y., “Automatic time series forecasting: The forecast package for R,” *Journal of Statistical Software*, vol. 27, no. 3, pp. 1–22, 2008.
- [18] Drucker, H./ Burges, C. J. C./ Kaufman, L./ Smola, A. J./ Vapnik, V., “Support vector regression machines,” in *Advances in Neural Information Processing Systems (NIPS)*, vol. 9, MIT Press, 1997.

- [19] Tay, F. E. H./ Cao, L., “Application of support vector machines in financial time series forecasting,” *Omega*, vol. 29, no. 4, pp. 309–317, 2001.
- [20] Oliveira, N./ Cortez, P./ Areal, N., “Stock price prediction using support vector regression on daily and up to the minute prices,” *The Journal of Finance and Data Science*, vol. 4, no. 2, pp. 183–201, 2018.
- [21] Campbell, J. Y./ Lo, A. W./ MacKinlay, A. C., *The Econometrics of Financial Markets*. Princeton University Press, 1997.
- [22] Fama, E. F., “Efficient capital markets: A review of theory and empirical work,” *The Journal of Finance*, vol. 25, no. 2, pp. 383–417, 1970.
- [23] Tetlock, P. C., “Giving content to investor sentiment: The role of media in the stock market,” *The Journal of Finance*, vol. 62, no. 3, pp. 1139–1168, 2007.
- [24] Alpha Vantage, *Alpha vantage api documentation – news and sentiment data*, Accessed: 2026-05-14, 2026. [Online]. Available: <https://www.alphavantage.co/documentation/>.
- [25] Wilder, J. W., *New Concepts in Technical Trading Systems*. Trend Research, 1978.
- [26] Appel, G., *The Moving Average Convergence-Divergence Trading Method*. Traders Press, 1979.
- [27] Bollinger, J. A., *Bollinger on Bollinger Bands*. McGraw-Hill, 2001.
- [28] Engle, R. F., “Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation,” *Econometrica*, vol. 50, no. 4, pp. 987–1007, 1982.
- [29] French, K. R., “Stock returns and the weekend effect,” *Journal of Financial Economics*, vol. 8, no. 1, pp. 55–69, 1980.
- [30] Schölkopf, B./ Smola, A. J., *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.

- [31] López de Prado, M., “Chaos, overfitting and equilibrium: To what extent can machine learning beat the financial market?” *Journal of Financial Data Science*, vol. 2, no. 4, pp. 8–25, 2020.
- [32] Das, A./ Kong, W./ Sen, R./ Zhou, Y., “A decoder-only foundation model for time-series forecasting,” *arXiv preprint arXiv:2310.10688*, 2024. [Online]. Available: <https://arxiv.org/abs/2310.10688>.
- [33] Aït-Sahalia, Y./ Hansen, L. P., *Handbook of Financial Econometrics*. Elsevier, 2010.
- [34] Lo, A. W./ Mamaysky, H./ Wang, J., “Foundations of technical analysis: Computational algorithms, statistical inference, and empirical implementation,” *The Journal of Finance*, vol. 55, no. 4, pp. 1705–1765, 2000.
- [35] Asness, C./ Frazzini, A./ Israel, R./ Moskowitz, T., *Fact, Fiction and Momentum Investing*. AQR Capital Management, 2015.
- [36] Avellaneda, M./ Lee, J.-H., “Statistical arbitrage in the us equities market,” *Quantitative Finance*, vol. 10, no. 7, pp. 761–782, 2010.
- [37] Prado, M. L. de, *Advances in Financial Machine Learning*. Wiley, 2018.
- [38] Kelly, J. L., “A new interpretation of information rate,” *Bell System Technical Journal*, vol. 35, no. 4, pp. 917–926, 1956.
- [39] Thorp, E. O., “The kelly criterion in blackjack, sports betting, and the stock market,” in *Handbook of Asset and Liability Management*, Elsevier, 2006.
- [40] MacLean, L. C./ Thorp, E. O./ Ziemba, W. T., “The kelly capital growth investment criterion,” *World Scientific*, 2011.
- [41] Jones, C. M., “A century of stock market liquidity and trading costs,” Columbia University, Working Paper SSRN 313681, 2002, Posted September 13, 2002; written May 23, 2002. [Online]. Available: <https://ssrn.com/abstract=313681>.
- [42] Loras, R., “The impact of transactions costs and slippage on algorithmic trading performance,” 09/2024.

- [43] Olorunnimbe, K./ Viktor, H., “Deep learning in the stock market—a systematic survey of practice, backtesting, and applications,” *Artificial Intelligence Review*, vol. 56, no. 3, pp. 2057–2109, 2023. [Online]. Available: <https://doi.org/10.1007/s10462-022-10226-0>.
- [44] “A systematic review of stock market prediction using machine learning and statistical techniques,” *Materials Today: Proceedings*, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S2214785320390337>.
- [45] “Stock price prediction with optimized deep LSTM network with artificial rabbits optimization algorithm,” *Expert Systems with Applications*, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417423008485>.
- [46] “Predicting economic trends and stock market prices with deep learning and advanced machine learning techniques,” *Electronics*, vol. 13, no. 17, p. 3396, 2024. [Online]. Available: <https://www.mdpi.com/2079-9292/13/17/3396>.
- [47] Tan, H./ Minh, L./ Minh, T./ Quyen, T./ Cao-Van, K., “Comparing LSTM models for stock market prediction: A case study with Apple’s historical prices,” in *Nature of Computation and Communication (ICTCC 2023)*, ser. LNICST, vol. 586, Springer, 2024.
- [48] Balamohan, S./ Khanaa, V./ Sivaraman, K., “Effective stock market pricing prediction using long short term memory-upgraded model (LSTM-UP) on evolving data sets,” *SN Computer Science*, vol. 4, p. 658, 2023.
- [49] Campbell, J. Y./ Thompson, S. B., “Predicting excess stock returns out of sample: Can anything beat the historical average?” *The Review of Financial Studies*, vol. 21, no. 4, pp. 1509–1531, 2008.
- [50] “Deep learning for stock performance prediction: A sharpe ratio-optimized approach,” *Asia Pacific Economic and Management Review*, vol. 2, no. 2, 2025. [Online]. Available: <https://ojs.apspublisher.com/index.php/apemr/article/view/210>.

- [51] “Deep reinforcement learning for automated stock trading: An ensemble strategy,” *arXiv*, 2025. [Online]. Available: <https://arxiv.org/abs/2511.12120>.
- [52] “Deep learning in long-short stock portfolio allocation: An empirical study,” *arXiv*, 2024. [Online]. Available: <https://arxiv.org/abs/2411.13555>.
- [53] “Stock market analysis, forecasting, and automated trading using deep learning,” *Engineering Proceedings*, vol. 128, no. 1, p. 42, 2025. [Online]. Available: <https://www.mdpi.com/2673-4591/128/1/42>.
- [54] Hsu, C.-W./ Chang, C.-C./ Lin, C.-J., “A practical guide to support vector classification,” Department of Computer Science, National Taiwan University, Tech. Rep., 2003. [Online]. Available: <https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>.
- [55] Jäkel, F./ Schölkopf, B./ Wichmann, F. A., “A tutorial on kernel methods for categorization,” *Journal of Mathematical Psychology*, vol. 51, no. 6, pp. 343–358, 12/2007.
- [56] Burges, C. J. C., “A tutorial on support vector machines for pattern recognition,” *Data Mining and Knowledge Discovery*, vol. 2, no. 2, pp. 121–167, 06/1998. [Online]. Available: <https://doi.org/10.1023/A:1009715923555>.

A. SVR Modellierung

Die SVR-Modellierung orientiert sich an der Beschreibung in [18]. Die Vorhersage der Rendite erfolgt nach

$$\hat{r}_{t+1} = \langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle + b, \quad (\text{A.1})$$

wobei

- $\mathbf{w}$ der Gewichtsvektor ist, welcher angibt wie stark welches Feature aus $\mathbf{x}$ in die Vorhersage eingeht,
- $\phi(x)$ eine Funktion ist, welche die Input-Features in einen Raum höherer Dimension transformiert,
- b der Achsenabschnitt der Vorhersage ist.

Die Wahl von $\phi(x)$ wird später diskutiert, da sie über den Kernel-Trick vereinfacht wird und $\mathbf{w}$ und b werden durch Lösen des folgenden Optimierungsproblem bestimmt (vgl. [18]):

$$\min_{\mathbf{w}, b, \xi, \xi^*} \underbrace{\frac{1}{2} \|\mathbf{w}\|^2}_{\text{Funktionsglätte}} + C \underbrace{\sum_{t=1}^n (\xi_t + \xi_t^*)}_{\text{Fehlerterme}} \quad (\text{A.2})$$

unter den Nebenbedingungen

$$r_{t+1} - \langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle - b \leq \varepsilon + \xi_t \quad (\text{A.3})$$

$$\langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle + b - r_{t+1} \leq \varepsilon + \xi_t^* \quad (\text{A.4})$$

$$\xi_t, \xi_t^* \geq 0. \quad (\text{A.5})$$

Hierbei sorgt $\frac{1}{2}\|\mathbf{w}\|^2$ dafür, dass die Glätte der Funktion in die Optimierung miteingeht. Dies sorgt dafür, dass die Regressionsfunktion nicht overfittet, was ein häufiges Problem bei Aktienprognosemodellen ist. Der ε -Schlauch definiert dabei einen Toleranzbereich um die Regressionsfunktion, innerhalb dessen Abweichungen nicht als Fehler gewertet werden. Dies ist im Falle von Aktienrenditen hilfreich, um Rauschen zu ignorieren. Um Trainingspunkte, die außerhalb dieses Schlauchs liegen, dennoch zuzulassen, werden ξ_i und ξ_i^* eingeführt, welche die Abweichung dieser Punkte messen und in das Optimierungsproblem einbeziehen, wodurch es lösbar bleibt. Der Parameter C steuert dabei die Gewichtung zwischen Funktionsglätte und den Fehlern von Trainingsdaten, die außerhalb des ε -Schlauches liegen. Die Nebenbedingungen A.3, A.4 und A.5 sorgen dafür, dass die über- bzw. unterschätzten Werte in die Minimierung eingehen.

C und ε werden im Validierungszeitraum V mit einer Grid-Search bestimmt. Das bedeutet es werden für C und ε diskrete Wertebereiche G_C und G_ε gewählt und alle möglichen Kombinationen getestet. Die Kombination, die auf dem Validierungsdatensatz im Sinne des RMSE das beste Ergebnis erzielt wird gewählt. Die Wertebereiche werden nach der Empfehlung aus [54] gewählt.

$$G_C = \{0.1, 1, 10, 100, 1000\}$$

$$G_\varepsilon = \{0.001, 0.01, 0.1, 0.5, 1\}$$

Die Abbildungsfunktion $\phi(\mathbf{x})$ transformiert die Eingabedaten in einen höherdimensionalen Raum, in dem vorher nicht-lineare Zusammenhänge linear approximiert werden können. Damit $\phi(\mathbf{x})$ jedoch explizit weder gewählt noch berechnet werden muss, wird der Kernel-Trick [55] angewendet. Das in Gleichung (A.2) definierte Optimierungsproblem ist konvex und lässt sich daher durch die Lagrange-Dualität in eine äquivalente duale Form überführen [56]. In dieser dualen Form lässt sich zeigen, dass $\mathbf{w}$ als Linearkombination der transformierten Trainingspunkte dargestellt werden kann:

$$\mathbf{w} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \phi(\mathbf{x}_i), \quad (\text{A.6})$$

wobei $\alpha_i, \alpha_i^* \geq 0$ die dualen Variablen sind. Damit lässt sich die Vorhersagefunktion schreiben als:

$$\hat{r}_{t+1} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_t) \rangle + b. \quad (\text{A.7})$$

In dieser Form tritt $\phi(\mathbf{x})$ ausschließlich in Skalarprodukten der Form $\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ auf. Diese Skalarprodukte können direkt durch eine Kernel-Funktion $K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ berechnet werden, ohne ϕ explizit zu kennen. Als Kernel-Funktion wird der cro:RBF Radial Basis Function (RBF)-Kernel [56] nach Gleichung (A.8) gewählt, da Aktienrenditen hochgradig nichtlineare und zeitvariante Abhängigkeiten aufweisen. Ein polynomialer Kernel setzt einen festen Grad der Nichtlinearität voraus und ist deshalb nicht geeignet. Der RBF-Kernel bildet die Eingabedaten in einen unendlich-dimensionalen Merkmalsraum ab und kann dadurch beliebig komplexe Abhängigkeiten erfassen, ohne dass deren funktionale Form vorab spezifiziert werden muss.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2), \quad (\text{A.8})$$

wobei γ ein Hyperparameter ist, der bestimmt wie stark der Kernel auf Rauschen reagiert. γ geht ebenfalls in die Grid-Search ein, mit den empfohlenen Werten nach [54]:

$$G_\gamma = \{0.01, 0.1, 1, 10, 50, 100\}.$$

Aus dem Ergebnis der SVR $\hat{r}_{t+1}$ ergibt sich die Preisvorhersage nach

$$\hat{P}_{t+1} = P_t * \exp(\hat{r}_{t+1}). \tag{A.9}$$