



Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Max Katzenberger und Mathis Köder

Abgabedatum:	01. Februar 2025
Bearbeitungszeitraum:	01.10.2024 - 31.01.2025
Matrikelnummer, Kurs:	0000000, TINF23B2
Ausbildungsfirma:	SAP SE Dietmar-Hopp-Allee 16 69190 Walldorf, Deutschland
Gutachter der Dualen Hochschule:	apl. Prof. Dr. Markus Reischl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

gemäß § 5 der "Studien- und Prüfungsordnung DHBW Technik" vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den April 8, 2026

Nachname, Vorname

Abstract

- English -

This is the starting point of the Abstract. For the final bachelor thesis, there must be an abstract included in your document. So, start now writing it in German and English. The abstract is a short summary with around 200 to 250 words.

Try to include in this abstract the main question of your work, the methods you used or the main results of your work.

Abstract

- Deutsch -

Dies ist der Beginn des Abstracts. Für die finale Bachelorarbeit musst du ein Abstract in deinem Dokument mit einbauen. So, schreibe es am besten jetzt in Deutsch und Englisch. Das Abstract ist eine kurze Zusammenfassung mit ca. 200 bis 250 Wörtern.

Versuche in das Abstract folgende Punkte aufzunehmen: Fragestellung der Arbeit, methodische Vorgehensweise oder die Hauptergebnisse deiner Arbeit.

Contents

Formelverzeichnis	VI
Abkürzungsverzeichnis	VII
List of Figures	VIII
List of Tables	IX
Quellcodeverzeichnis	X
1 Einleitung	1
1.1 Motivation	1
1.2 Probleme	1
1.3 Ziel der Arbeit	2
2 Stand der Forschung	4
2.1 Grundlagen	4
2.2 Zeitreihenanalyse	4
3 Konzeption	5
3.1 Überblick	5
3.2 Daten und Benchmarking	7
3.3 Bewertungskriterien	10
3.4 Einschränkungen und Nebenbedingungen	16
3.5 Modellentwicklung	18
3.6 Marktstrategie	18
4 Implementierung	19
5 Ergebnisse und Bewertung	20
5.1 Variante1	20
5.2 Variante2	20
6 Zusammenfassung und Ausblick	21

Formelverzeichnis

A	mm ²	Fläche
D	mm	Werkstückdurchmesser
$d_{\min}$	mm	kleinster Schaftdurchmesser
L_1	mm	Länge des Werkstückes Nr. 1
	Grad	Freiwinkel
	Grad	Keilwinkel

Abkürzungsverzeichnis

EMH	Efficient Market Hypothesis
DoS	Definition of Success
RMSE	Root Mean Squared Error
MAPE	Mean Absolute Percentage Error
DA	Directional Accuracy
MDD	Maximum Drawdown
LSTM	Long Short Term Memory
SVM	Support Vector Machines
OOS-R^2	Out-Of-Sample R^2
NLP	Natural Language Processing
SVM	Support Vector Machine
NN	Neural Network
SVR	Support Vector Regression
ARIMA	Autoregressive Integrated Moving Average
GARCH	Generalized Autoregressive Conditional Heteroscedasticity

List of Figures

List of Tables

3.1	Beispielhafte Rohdaten der Aktienpreise	8
3.2	Ausgewählte Aktien	9

Quellcodeverzeichnis

1 Einleitung

1.1 Motivation

Die Vorhersage von Aktienkursen stellt eine zentrale Herausforderung der Finanzökonomie dar. Trotz umfangreicher Forschung bleibt die präzise Prognose zukünftiger Kursbewegungen aufgrund der Komplexität und Volatilität der Märkte schwierig. In den letzten Jahren wurden vermehrt mathematische und datengetriebene Methoden untersucht, um Muster in Finanzkursen zu identifizieren und Vorhersagen zu verbessern. Da ein zuverlässiger und konsistenter Algorithmus zur Vorhersage von Aktienkursen potenziell erhebliche finanzielle Vorteile bieten würde, ist das Interesse an der Entwicklung solcher Verfahren entsprechend groß.

1.2 Probleme

Ein zentrales theoretisches Problem bei der Vorhersage von Aktienkursen ergibt sich aus der Efficient Market Hypothesis (EMH). Die EMH besagt, dass alle verfügbaren Informationen bereits vollständig in den aktuellen Marktpreisen enthalten sind, sodass zukünftige Kursbewegungen per Definition nicht systematisch vorhergesagt werden können. Unter dieser Annahme verhalten sich Preisänderungen wie ein zufälliger Prozess, der durch keinen Algorithmus vorhergesagt werden kann und die Machbarkeit des Ziels dieser Arbeit in Frage stellt [1]. Trotz der theoretischen Einschränkungen durch die Markteffizienzhypothese existieren empirische Beispiele erfolgreicher quantitativer Handelsstrategien. Renaissance Technologies nutzt seit Jahrzehnten fast ausschließlich mathematis-

che Modelle und Algorithmen zur Kursprognose und erzielt mit dem Medallion Fund Renditen in Höhe von 66% p.a. Dies zeigt, dass systematische Modelle wiederkehrende Muster in Finanzdaten sehr wohl erkennen und wirtschaftlich nutzen können. Hierbei sei anzumerken, dass die genaue Funktionsweise der verwendeten Algorithmen selbstverständlich unbekannt ist. Quantitative Fonds agieren als "Black-Box", was die wissenschaftliche Nachvollziehbarkeit erschwert und somit kein gesichertes Gegenbeispiel zur EMH ist [2]. Des Weiteren gibt es empirische, öffentliche Analysen, die zeigen, dass nicht-lineare Vorhersagemethoden durchaus Gewinne erzielen können [3]. Neben der Frage nach der allgemeinen Machbarkeit ergeben sich eine Vielzahl praktischer Probleme, die die Entwicklung erschweren. Zunächst enthalten Kursdaten viel Rauschen. Es ist schwer den tatsächlichen Signalanteil des Preises herauszufiltern, um zu den Trend zu erkennen. Des Weiteren ist es eine große Schwierigkeit, den korrekten Komplexitätsgrad des Modells zu finden. Zu komplexe Modelle „overfitten“, passen sich also zu stark an historische Daten an und generalisieren somit schlecht auf neuen, realen Daten. Dies betrifft vor allem Deep Learning Modelle, welche zu viele Freiheitsgrade haben, und somit den vergangenen Kurs oder das Rauschen selbst abbilden und den Trend dabei nicht erkennen. Auf der anderen Seite sind zu simple Modelle nicht in der Lage nicht-lineare Zusammenhänge zu erkennen und generalisieren zu stark [4].

1.3 Ziel der Arbeit

Das Ziel dieser Arbeit ist die Untersuchung bestehender Algorithmen und Strategien auf deren Rentabilität und Stabilität. Es soll eine Testumgebung geschaffen werden, mit welcher verschiedene Analysemodelle getestet und auf realen, vergangenen Daten ausprobiert werden können. Des Weiteren werden eigene Modelle durch neue Ideen und eine Kombination von vorhandenen

Strategien vorgestellt. Schließlich soll jedes Modell evaluiert und bewertet werden.

2 Stand der Forschung

2.1 Grundlagen

2.2 Zeitreihenanalyse

2.2.1 Lineare Modelle

2.2.2 Nichtlineare Modelle

2.2.3 Stochastische Differentialgleichungen

⋮

2.2.4 Zusammenfassung

3 Konzeption

3.1 Überblick

In diesem Kapitel wird die Entwicklung der in dieser Arbeit verwendeten Modelle zur Vorhersage von Aktienkursen beschrieben. Dabei werden Ansätze aus der Zeitreihenanalyse und dem maschinellen Lernen konzeptioniert.

Zunächst wird das Datenset erläutert: Auswahl des Aktienuniversums und der konkreten Aktien, Aufteilung der Zeitreihen sowie Datenbereinigung. Anschließend werden die Metriken und Bewertungskriterien vorgestellt, die sowohl mathematische als auch finanzwirtschaftliche Aspekte berücksichtigen.

Der Rahmen der Arbeit wird definiert, einschließlich des Untersuchungsgegenstands, der getroffenen Annahmen sowie der Nebenbedingungen und Einschränkungen. Diese Vereinfachungen dienen der Interpretierbarkeit, unterscheiden sich aber teilweise von realen Marktbedingungen.

Aufbauend auf diesen Grundlagen erfolgt die Modellentwicklung. Es werden 4 Modelle vorgestellt:

ARIMA-GARCH

Autoregressive Integrated Moving Average (ARIMA) ist ein etabliertes statistisches Modell zur Vorhersage von Zeitreihen. Während Deep-Learning-Modelle oft als Black-Box agieren und dadurch viele Freiheitsgrade bieten, sind lineare Modelle besser nachvollziehbar und interpretierbar. In dieser Arbeit wird ein lineares Vorhersagemodell auf Basis von ARIMA vorgestellt. Um die Prognosege-

nauigkeit zu erhöhen, wird die Preisvorhersage mit einer Volatilitätsbetrachtung durch ein Generalized Autoregressive Conditional Heteroscedasticity (GARCH)-Modell kombiniert.

Preprocessed SVR

Viele Studien untersuchen den Einsatz von Deep Learning zur Vorhersage von Aktienkursen, wobei häufig Support Vector Machines (SVMs) und Neural Networks (NNs) eingesetzt werden. In wenigen Arbeiten wird auch Support Vector Regression (SVR) angewendet. [5] In dieser Arbeit wird ein Ansatz untersucht, der SVR mit zusätzlichen Analyseverfahren kombiniert. Die Eingabedaten für das SVR-Modell bestehen aus vorverarbeiteten und normalisierten Kennzahlen, darunter technische Preisindikatoren, Social-Media-Sentiment-Analysen sowie Einflussgrößen anderer Unternehmen. Die SVR erfolgt hierbei vollständig auf Log-Renditen, um die Zeitreihen annähernd stationär zu machen.

Stochastische Differentialgleichungen

Aktienkurse setzen sich aus einem Trend und starkem zufälligem Rauschen zusammen. In dieser Arbeit wird ein Modell vorgestellt, das das zufällige Rauschen eines Aktienkurses als Brownsche Bewegung beschreibt und den Trend als Funktion abbildet. Auf Basis einer stochastischen Differentialgleichung soll der zukünftige Kurs über Simulationen vorhergesagt werden.

StockTimesFM

Aktienkursvorhersagemodelle sind dafür bekannt, stark zum Overfitting zu neigen. Selbst die Nutzung großer Datensätze führt in der Praxis oft nicht zu einer signifikanten Verbesserung der Generalisierungsfähigkeit [6]. Vor diesem

Hintergrund wird in dieser Arbeit ein alternativer Ansatz verfolgt, bei dem ein Foundation Model eingesetzt wird, um dessen Übertragbarkeit auf die Vorhersage von Aktienkursen zu untersuchen. Im Zuge der zunehmenden Verbreitung von Transformer-Architekturen im Bereich des Natural Language Processing (NLP) haben Abhimanyu Das et al. in [7] ein transformerbasiertes Foundation Model für Zeitreihen vorgestellt. Aufbauend auf diesem Modell wird in der vorliegenden Arbeit analysiert, inwieweit sich damit verlässliche Vorhersagen für Aktienkurse erzielen lassen.

Anschließend wird die Umsetzung der Vorhersagen in einer Handelsstrategie beschrieben. Hierbei werden Risikomanagement, Positionsgrößen und Vorhersagehorizont betrachtet. Aus den Preisvorhersagen wird eine Marktentscheidung getroffen, um die praktische Anwendbarkeit der Modelle zu analysieren.

3.2 Daten und Benchmarking

Unter dem Survivorship Bias versteht man die statistische Verzerrung, die entsteht, wenn nur überlebende Unternehmen ausgewählt werden und insolvente oder aus einem Index entfernte Aktien unberücksichtigt bleiben, was historische Renditen systematisch nach oben verzerrt. Für die Analyse wird ein festes Aktienuniversum herangezogen, bestehend aus den im Jahr 2020 im S&P 500 gelisteten Unternehmen, wodurch ein Survivorship Bias vermieden wird.

Die Kursdaten jeder Aktie werden als Zeitreihe betrachtet. Für jeden Handelstag enthält die Zeitreihe folgende Werte:

- Open: erster Preis zu dem an diesem Tag gehandelt wurde
- Close: letzter Preis zu dem an diesem Tag gehandelt wurde
- High: höchster Preis zu dem an diesem Tag gehandelt wurde

- Low: niedrigster Preis zu dem an diesem Tag gehandelt wurde
- Volume: gesamtes kumuliertes Handelsvolumen an diesem Tag

Die Daten werden als CSV-Dateien von Yahoo Finance heruntergeladen. Sie werden dann in parquet-Dateien konvertiert, um Speicherplatz und Rechenzeit zu sparen.

Table 3.1: Beispielhafte Rohdaten der Aktienpreise

Datum	Close	High	Low	Open	Volume
2022-11-11	147,34	147,64	142,09	143,52	93 979 700
2022-11-14	145,94	147,91	145,10	146,62	73 374 100

Quelle: Yahoo Finance. Alle Preisangaben in USD.

Die Unterteilung der Zeitreihen erfolgt in einem 80:20-Verhältnis, wobei 80% der Daten als Trainingsdaten verwendet werden und 20% als Validierungs- und Testdaten:

- **Trainingszeitraum (T):** 01.2020–12.2023, in dem die Modelle auf den historischen Kursen trainiert werden.
- **Validierungszeitraum (P):** 01.2024–06.2024, der zur Optimierung der Modellparameter dient.
- **Testzeitraum (S):** 07.2024–12.2025, der ausschließlich für die abschließende Evaluierung der Modelle auf bisher ungesehenen Daten verwendet wird.

Die Modelle werden zunächst auf den Trainingsdaten trainiert. Anschließend erfolgt die Optimierung der Hyperparameter anhand des Validierungszeitraums. Die finale Leistung wird schließlich auf dem Testzeitraum bewertet, um die zeitliche Generalisierbarkeit der Modelle zu überprüfen.

Für die Analyse werden 10 Aktien verwendet. Somit sollen Ausreißer einzelner Unternehmen den Gesamterfolg der Modelle nicht übermäßig beeinflussen. Die Auswahl dieser Aktien muss stets anhand von Informationen erfolgen, die vor dem Trainingszeitraum bekannt waren, um einen Lookahead Bias zu verhindern. Da die Auswahl geeigneter Zeitreihen nicht Teil dieser Arbeit ist, werden die hier verwendeten untersuchten Aktien zufällig aus dem S&P500 vom Jahresbeginn 2020 ausgewählt. Diese Auswahl bleibt über den Gesamtzeitraum der Arbeit bestehen. Die ausgewählten Aktien sind zu sehen in Tabelle 3.2.

Table 3.2: Ausgewählte Aktien

Unternehmen	Tickersymbol	Branche
Amazon	AMZN	xx
Adobe	ADBE	xx
CVS Health	CVS	xx
General Motors	GM	xx
Micron Technology	MU	xx
PayPal	PYPL	xx
Walgreens Boots Alliance	WBA	xx
PepsiCo	PEP	xx
Salesforce	CRM	xx
3M	MMM	xx

Da die Analysen stets auf Backtests basieren, ist eine Bereinigung der historischen Aktienkurse notwendig, da sich die nominalen Preise einer Aktie im Zeitverlauf durch Ereignisse wie Aktiensplits oder Dividendenzahlungen verändern, ohne dass sich der tatsächliche Unternehmenswert und demnach der Aktienwert geändert hat. Ohne eine solche Anpassung würden Kursbewegungen verzerrt dargestellt, was zu falsch trainierten Modellen oder falschen Tests führt. Sei P_t der beobachtete Schlusskurs einer Aktie zum Zeitpunkt t und $\tilde{P}_t$ der bereinigte Preis auf dem ein Modell trainiert werden kann. $\tilde{P}_t$ ergibt sich aus dem ursprünglichen Preis multipliziert mit einem Anpassungsfaktor A_t :

$$\tilde{P}_t = P_t \cdot A_t.$$

Der Anpassungsfaktor wird rekursiv rückwärts berechnet. Sei P_t für $t = 1, \dots, n$ gegeben, gilt $A_n = 1$. Bei einem Aktiensplit zum Zeitpunkt t mit Verhältnis $s_t = \frac{\text{neue Aktien}}{\text{alte Aktien}}$ gilt

$$A_{t-1} = \frac{A_t}{s_t}.$$

Beispielsweise führt ein 2:1-Split ($s_t = 2$) dazu, dass alle historischen Preise vor dem Split halbiert werden.

Dividendenzahlungen werden ebenfalls berücksichtigt. Sei D_t die Dividende zum Zeitpunkt t . Dann wird der Anpassungsfaktor wie folgt aktualisiert:

$$A_{t-1} = A_t \cdot \frac{P_t - D_t}{P_t}.$$

Somit ist der historische Preis mit dem die Modelle trainiert und getestet werden abhängig vom letzten betrachteten Wert. Der letzte Wert entspricht somit dem aktuellen, realisierbaren Aktienwert, alle anderen Werte potenziell aber nicht den realen Aktienwerten zu dem Zeitpunkt.

3.3 Bewertungskriterien

Die Bewertung der genannten Modell erfolgt in zwei Schritten. Nachdem die Vorhersagemodelle in Kapitel 3.5 vorgestellt wurden, werden sie in dem genannten Testzeitraum in einem etablierten Walk-Forward jeweils für jede asugewählte Aktie getestet. Das bedeutet es wird die tatsächliche Historie der Aktienkursbewegung simuliert und es werden jeweils Vorhersagen erstellt.

Die dabei erstellten Ergebnisse werden nicht gesichert auch in der Zukunft funktionieren, aber zeigen wie gut das Modell in der Vergangenheit funktioniert hätte. [8] Anschließend werden sie anhand der in Kapitel 3.3.1 vorgestellten Fehlermaße bewertet.

Mithilfe der in Kapitel 3.6 entwickelten Marktstrategien, werden die Modelle dann praxisnah getestet. Es wird ein virtuelles Portfolio angelegt, mit einem Startkapital von $V_0 = 100.000$ US\$. Die Modelle werden in einem Walk-Forward jeweils pro Aktie getestet, wobei die Modelle eine Preisreihe ab dem aktuellen Tag vorhersagen und anhand der in 3.6 vorgestellten Kriterien eine Kaufs- oder Verkaufsentscheidung simuliert wird. Dadurch kann der Portfoliowert steigen und fallen. Am Ende des Testzeitraums erfolgt eine Bewertung anhand der in Kapitel 3.3.2 vorgestellten Kennzahlen.

Ziel der Bewertungen ist immer ein Modellvergleich der vorgestellten Modelle untereinander. Außerdem erfolgt bei ausgewählten Kennzahlen ein Vergleich zu einer jeweils angegebenen Baseline, um die Interpretierbarkeit zu erhöhen. Des Weiteren wird, um eine weitere Benchmark zu haben, bei jedem Modellvergleich auch ein ARIMA Modell getestet, um einen weiteren Vergleich zu liefern.

3.3.1 Fehlermaße

Die Extrapolation von Zeitreihen ist ein weitreichend untersuchtes Gebiet. Dadurch haben sich einige Fehlermaße zur Bewertung der Verfahren etabliert. Zu den häufigstverwendeten zählen unter anderem MAPE, RMSE, MSE, Directional Accuracy, R^2 und MAE [9], [10]. Um eine möglichst hohe Vergleichbarkeit mit anderen Arbeiten zu gewährleisten, werden die drei meistverwendeten, MAPE, RMSE und Directional Accuracy verwendet. Um die Aussagekraft der Analyse zu erhöhen, wird auch das Out-Of-Sample R^2 (OOS- R^2) Maß genommen mit einem Random Walk als Baseline. Hierbei sei anzumerken,

dass viele Arbeiten einen R^2 -Score anhand von Preisen als Metrik verwenden, zum Beispiel [11],[12],[13],[14]. Diese Bewertung ist wenig aussagekräftig, da Aktienkurse stark autokorreliert sind ($P_t \approx P_{t-1}$), und somit ein R^2 -Score von $> 0,9$ eine nicht vorhandene, außerordentliche Modellqualität vorgaukelt. Ein so berechneter R^2 -Score ist somit nur als Vergleichswert und nicht als selbstständiges Maß interpretierbar. Als reiner Vergleichswert ist der R^2 -Score danach aber auch sinnlos, da der Informationsgehalt nach Formel 3.1 dem RMSE-Maß entspricht.

$$R^2 = 1 - \frac{\text{RMSE}^2 \cdot n}{\text{SS}_{\text{tot}}}, \text{SS}_{\text{tot}} = \text{const}, n = \text{const}. \quad (3.1)$$

Sinnvoll wäre nur eine R^2 -Analyse auf Renditen, anstatt auf Preisen. Da diese Arbeit das OOS- R^2 Maß auf Renditen verwendet, wird diese Ungenauigkeit eliminiert.

Root Mean Squared Error

Gegeben sei ein Signal $[x_1, x_2, \dots, x_n]$ und eine zugehörige Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$. Der Root Mean Squared Error (RMSE) misst die durchschnittliche quadratische Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{x}_i - x_i)^2}.$$

Der RMSE gewichtet Ausreißer durch die Quadratisierung stärker und ist durch die Wurzel interpretierbar, da er in derselbe Einheit wie die Werte der Zeitreihe angegeben wird.

Mean Absolute Percentage Error

Der Mean Absolute Percentage Error (MAPE) misst die durchschnittliche prozentuale Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right|.$$

Da der MAPE relativ zum tatsächlichen Wert x_i normiert ist, ermöglicht er einen skaleninvarianten Vergleich über verschiedene Zeitreihen hinweg. Theoretisch neigt er dazu negative Fehler assymetrisch zu bestrafen. Dies ist praktisch im Falle von Aktienkursen aber vernachlässigbar.

Out-of-Sample R^2

Der OOS- R^2 nach [15] misst, ob ein Modell bessere Vorhersagen liefert als ein naiver Benchmark. Sei $\hat{x}_i$ die Modellvorhersage und $\hat{x}_i^{\text{RW}} = x_{i-1}$ die Vorhersage eines Random-Walk-Modells, welches den letzten bekannten Wert als Schätzung verwendet. Der OOS- R^2 ist definiert als

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{\sum_{i=1}^n (x_i - \hat{x}_i^{\text{RW}})^2}.$$

Ein Wert $R_{\text{OOS}}^2 > 0$ zeigt an, dass das Modell den Random Walk übertrifft, während $R_{\text{OOS}}^2 \leq 0$ bedeutet, dass die naive Baseline mindestens gleichwertig ist.

Directional Accuracy

Alle bisher vorgestellten Fehlermaße unterscheiden nicht zwischen überschätztem oder unterschätztem Wert. Bei der Vorhersage von Aktienkursen ist dieser Unterschied aber von signifikanter Relevanz, da eine Unterschätzung, die zu einem Kauf führt, weit weniger problematisch ist als eine Überschätzung. Hierfür wird die Directional Accuracy eingeführt.

Die Directional Accuracy (DA) misst, wie gut ein Modell die Richtung der Kursbewegung vorhersagt, unabhängig von der genauen Höhe des Preises. Für ein Signal $[x_1, x_2, \dots, x_n]$ und eine Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird DA definiert nach

$$DA = \frac{1}{n} \sum_{i=2}^n \mathbf{1}(\text{sign}(x_i - x_{i-1}) = \text{sign}(\hat{x}_i - x_{i-1})),$$

wobei $\mathbf{1}(\cdot)$ die Indikatorfunktion ist, die den Wert 1 annimmt, wenn die Vorhersage die gleiche Richtung wie die tatsächliche Kursbewegung hat, und 0 sonst.

Ein Wert von $DA = 1$ entspricht einer perfekten Klassifikation, während $DA = 0.5$ einem zufälligen Raten entspricht.

3.3.2 Finanzwirtschaftliche Kennzahlen

Viele Arbeiten, die sich mit Zeitreihenextrapolation beschäftigen und insbesondere die zu Aktienkursvorhersagen, beenden die Evaluation nach der Untersuchung der Fehlermaße [9]. Da diese Arbeit einen weiteren praktischen Fokus fasst, soll auch die praktische Anwendbarkeit, und damit finanzwirtschaftlich evaluiert werden. Außerdem ist im Falle von Aktienkursvorhersage eine Fehlerminimierung nicht zwingend das optimale Ziel im Bezug auf die praktische Anwendung [16].

Viele Arbeiten, die auch die reale Anwendbarkeit testen, fokussieren sich auf Gesamtrendite, Sharpe Ratio und Maximum Drawdown [17], [18], [19]. Weitere, seltener verwendete Kennzahlen sind das Sortino Ratio, Calmar Ratio und Value-at-risk threshold [8]. Alle Metriken befassen sich mit Rendite oder Volatilität. Um diese beiden Kennzahlen einer Strategiequalität abzubilden werden in dieser Arbeit die Gesamtrendite und der Maximum Drawdown verwendet. Da Risiko und Rendite in der Finanzwelt keine unabhängigen Größen darstellen, sondern sich häufig beeinflussen, wird ebenso die Sharpe-Ratio evaluiert.

Gesamtrendite

Die Gesamtrendite gibt die insgesamt erzielte Rendite über den gesamten Zeitraum an:

$$R_{cum} = \frac{V_T - V_0}{V_0},$$

wobei V_0 der Anfangswert und V_T der Endwert des Portfolios ist. Sie zeigt die absolute Profitabilität der Strategie.

Sharpe Ratio

Das Sharpe Ratio misst das Rendite-Risiko-Verhältnis eines Portfolios, indem es die Portfolio Rendite ohne die risikofreie Rendite ins Verhältnis zur Volatilität setzt. Es wird berechnet nach

$$S = \frac{R_p - R_f}{\sigma(R_p)},$$

wobei R_p die Rendite des Portfolios, R_f der risikofreie Zinssatz und $\sigma(R_p)$ die Volatilität der Portfoliorendite ist. Die Volatilität $\sigma(R_p)$ wird über die empirische Standardabweichung ermittelt:

$$\sigma(R_p) = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_{P,t} - \bar{R}_P)^2}$$

Ein hohes Sharpe Ratio bedeutet eine hohe Rendite im Vergleich zum Risiko.

Maximum Drawdown

Der Maximum Drawdown (MDD) beschreibt den größten Verlust eines Portfolios vom höchsten Punkt (Peak) bis zum Tiefpunkt (Trough) innerhalb des betrachteten Zeitraums:

$$\text{MDD} = \max_t \frac{\text{Peak}_t - \text{Value}_t}{\text{Peak}_t}.$$

Ein niedriger Maximum Drawdown zeigt, dass das untersuchte Investment nur geringe zwischenzeitliche Verluste erlitt.

3.4 Einschränkungen und Nebenbedingungen

Da im Rahmen dieser Arbeit nicht alle realistischen Marktszenarien berücksichtigt werden können, müssen einige Annahmen getroffen werden.

Komission

Komission ist eine Gebühr, die ein Broker oder eine Börse für die Ausführung einer Order verlangt. Diese ist meistens prozentual abhängig vom Ordervolumen und fällt sowohl beim Kauf als auch beim Verkauf an. Dadurch wird die Profitabilität eines Portfolios reduziert. In den letzten Jahren haben sich die Komission drastisch reduziert. Im Jahr 1970 lagen sie noch bei ca. 1% des Ordervolumens. Durch Neobroker und Konkurrenz unter Brokern ist die Komission mittlerweile stark gesunken, teilweise auf bis 1US\$ pro Trade. Um die Arbeit unabhängig von Änderungen in der Praxis im Bezug auf Kommissionen zu halten, wird bei den Backtests dieser Arbeit keine Komission berechnet. [20]

Spread

Der Spread ist die Differenz zwischen Kaufpreis und Verkaufspreis einer Aktie. Dieser ist an einer Börse meist unterschiedlich, wobei der Kaufpreis höher als der Verkaufspreis ist. Wird eine Aktie gekauft und sofort wieder verkauft entsteht also ein Verlust. Besonders bei Hochfrequenzhandel führt dies zu Verlusten. Da diese Arbeit ausschließlich Tagesöffnungs und -schlusskurse verwendet, wird kann kein Spread betrachtet werden. Als Preis wird daher in dieser Arbeit der erste bzw. letzte gehandelte Marktpreis verwendet. [20]

Liquidität

Die verwendeten Tageskurse spiegeln die tatsächlich gehandelten Preise wider, berücksichtigen jedoch nicht, ob zum angegebenen Preis tatsächlich ausreichend Volumen für eine Order verfügbar gewesen wäre. Da ausschließlich liquide Aktien aus dem S&P500 verwendet werden, wird angenommen, dass alle Transaktionen zum beobachteten Preis ausgeführt werden können. Um eine Verzerrung durch

simultane Informationsnutzung zu vermeiden, werden Kaufentscheidungen, die auf dem Schlusskurs eines Tages basieren, zum Eröffnungskurs des folgenden Tages ausgeführt. Auf diese Weise wird sichergestellt, dass Entscheidungen ausschließlich auf Basis von Informationen getroffen werden, die zu diesem Zeitpunkt bereits verfügbar waren. [21]

3.5 Modellentwicklung

3.5.1 ARIMA-GARCH

3.5.2 Preprocessed SVR

3.5.3 Stochastische Differentialgleichungen

3.5.4 StockTimesFM

3.6 Marktstrategie

4 Implementierung

Viele Arbeiten die sich bereits mit Aktienkursvorhersagen beschäftigt haben, wurden häufig kritisiert, da sie selten reproduzierbar sind. Oft fehlen theoretische Details und meist die gesamte Implementierung, sowie Datensätze. [8] Um eine gute Reproduzierbarkeit zu gewährleisten, wird in diesem Kapitel die Implementierung jeglicher Modelle vorgestellt.

5 Ergebnisse und Bewertung

5.1 Variante1

5.2 Variante2

6 Zusammenfassung und Ausblick

Literaturverzeichnis

- [1] Malkiel, B. G., “Efficient market hypothesis,” in *Finance*, Springer, 1989, pp. 127–134.
- [2] Burton, K. “Inside a moneymaking machine like no other.” Archived from the original on 14 May 2017, Accessed: 05/11/2017. [Online]. Available: <https://www.bloomberg.com/news/articles/2016-11-21/how-renaissance-s-medallion-fund-became-finance-s-blackest-box>.
- [3] Sewell, M., “The efficient market hypothesis: Empirical evidence,” *International Journal of Statistics and Probability*, vol. 1, no. 2, pp. 164–178, 2012.
- [4] Prakash, A./ Tuo, R./ Ding, Y., “The temporal overfitting problem with applications in wind power curve modeling,” *Technometrics*, vol. 65, no. 1, pp. 70–82, 2023. [Online]. Available: <https://arxiv.org/abs/2012.01349>.
- [5] Kumar, D./ Sarangi, P. K./ Verma, R., “A systematic review of stock market prediction using machine learning and statistical techniques,” *Materials Today: Proceedings*, vol. 49, pp. 3187–3191, 2022. [Online]. Available: <https://doi.org/10.1016/j.matpr.2020.11.399>.
- [6] López de Prado, M., “Chaos, overfitting and equilibrium: To what extent can machine learning beat the financial market?” *Journal of Financial Data Science*, vol. 2, no. 4, pp. 8–25, 2020.
- [7] Das, A./ Kong, W./ Sen, R./ Zhou, Y., “A decoder-only foundation model for time-series forecasting,” *arXiv preprint arXiv:2310.10688*, 2024. [Online]. Available: <https://arxiv.org/abs/2310.10688>.

- [8] Olorunnimbe, K./ Viktor, H., “Deep learning in the stock market—a systematic survey of practice, backtesting, and applications,” *Artificial Intelligence Review*, vol. 56, no. 3, pp. 2057–2109, 2023. [Online]. Available: <https://doi.org/10.1007/s10462-022-10226-0>.
- [9] Gandhmal, D. P./ Kumar, K., “Systematic analysis and review of stock market prediction techniques,” 2019, Available online 28 August 2019.
- [10] “A systematic review of stock market prediction using machine learning and statistical techniques,” *Materials Today: Proceedings*, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S2214785320390337>.
- [11] “Stock price prediction with optimized deep LSTM network with artificial rabbits optimization algorithm,” *Expert Systems with Applications*, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417423008485>.
- [12] “Predicting economic trends and stock market prices with deep learning and advanced machine learning techniques,” *Electronics*, vol. 13, no. 17, p. 3396, 2024. [Online]. Available: <https://www.mdpi.com/2079-9292/13/17/3396>.
- [13] Tan, H./ Minh, L./ Minh, T./ Quyen, T./ Cao-Van, K., “Comparing LSTM models for stock market prediction: A case study with Apple’s historical prices,” in *Nature of Computation and Communication (ICTCC 2023)*, ser. LNICST, vol. 586, Springer, 2024.
- [14] Balamohan, S./ Khanaa, V./ Sivaraman, K., “Effective stock market pricing prediction using long short term memory-upgraded model (LSTM-UP) on evolving data sets,” *SN Computer Science*, vol. 4, p. 658, 2023.
- [15] Campbell, J. Y./ Thompson, S. B., “Predicting excess stock returns out of sample: Can anything beat the historical average?” *The Review of Financial Studies*, vol. 21, no. 4, pp. 1509–1531, 2008.

- [16] “Deep learning for stock performance prediction: A sharpe ratio-optimized approach,” *Asia Pacific Economic and Management Review*, vol. 2, no. 2, 2025. [Online]. Available: <https://ojs.apspublisher.com/index.php/apemr/article/view/210>.
- [17] “Deep reinforcement learning for automated stock trading: An ensemble strategy,” *arXiv*, 2025. [Online]. Available: <https://arxiv.org/abs/2511.12120>.
- [18] “Deep learning in long-short stock portfolio allocation: An empirical study,” *arXiv*, 2024. [Online]. Available: <https://arxiv.org/abs/2411.13555>.
- [19] “Stock market analysis, forecasting, and automated trading using deep learning,” *Engineering Proceedings*, vol. 128, no. 1, p. 42, 2025. [Online]. Available: <https://www.mdpi.com/2673-4591/128/1/42>.
- [20] Jones, C. M., “A century of stock market liquidity and trading costs,” Columbia University, Working Paper SSRN 313681, 2002, Posted September 13, 2002; written May 23, 2002. [Online]. Available: <https://ssrn.com/abstract=313681>.
- [21] Loras, R., “The impact of transactions costs and slippage on algorithmic trading performance,” 09/2024.