



Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Max Katzenberger und Mathis Köder

Abgabedatum:	18. Mai 2026
Bearbeitungszeitraum:	10.10.2025 - 18.05.2026
Matrikelnummer:	4008573 und 3360189
Kurs:	TINF23B2
Gutachter der Dualen Hochschule:	apl. Prof. Dr. Markus Reischl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

gemäß § 5 der „Studien- und Prüfungsordnung DHBW Technik“ vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den 17. Mai 2026

Gez. Max Katzenberger und Mathis Köder

Abstract

- English -

Predicting stock prices poses a significant challenge due to the volatility and non-linear nature of stock prices. This work presents a complete pipeline for algorithmic stock price prediction and evaluation. Ten profitable stocks are selected from the S&P 500 using stochastic differential equations while accounting for macroeconomic factors. Three different modelling approaches for stock price prediction are then examined. LinearSeparation is a newly developed method based on HP filters and ARMA, Preprocessed SVR uses Support Vector Regression with technical indicators and sentiment data, and TimesFM employs a pre-trained foundation model in zero-shot mode. The models are tested and evaluated on the ten selected stocks. The evaluation is conducted in two stages. First, the models are assessed using statistical error metrics (MAPE, RMSE, OOS- R^2 , Directional Accuracy), and subsequently tested in a simulated trading strategy with Half-Kelly position sizing and signal-based trading. The results show that despite good point forecast quality (MAPE 1.08–1.30%), none of the models consistently outperforms the buy-and-hold strategy. SVR achieves the best performance with an average return of 6.56% and the lowest maximum drawdown (13.95%). The discrepancy between precise point forecasts and weak trading performance highlights the fundamental difficulty of deriving profitable trading signals from accurate predictions.

Abstract

- Deutsch -

Die Vorhersage von Aktienkursen stellt aufgrund der Volatilität und nicht-linearen Natur von Aktienkursen eine große Herausforderung dar. Diese Arbeit stellt eine vollständige Pipeline zur algorithmischen Aktienkursvorhersage und Evaluation vor. Aus dem S&P 500 werden mittels stochastischer Differentialgleichungen unter Berücksichtigung makroökonomischer Faktoren zehn profitable Aktien ausgewählt. Daraufhin werden drei unterschiedliche Modellansätze zur Aktienkursvorhersage untersucht. LinearSeparation ist ein neu entwickeltes Verfahren basierend auf HP-Filtern und ARMA, Preprocessed SVR verwendet Support Vector Regression mit technischen Indikatoren und Sentiment-Daten und TimesFM verwendet ein vortrainiertes Foundation Model im Zero-Shot-Modus. Die Modelle werden auf den zehn gewählten Aktien getestet und evaluiert. Die Evaluation erfolgt zweistufig. Zunächst werden die Modelle anhand statistischer Fehlermaße (MAPE, RMSE, OOS- R^2 , Directional Accuracy) bewertet und anschließend in einer simulierten Handelsstrategie mit Half-Kelly-Positionsgrößen und signalbasiertem Trading getestet. Die Ergebnisse zeigen, dass trotz guter Punktvorhersagequalität (MAPE 1,08-1,30%) keines der Modelle die Buy-and-Hold-Strategie konsistent übertrifft. SVR erzielt mit durchschnittlich 6,56% Return und dem niedrigsten Maximum Drawdown (13,95%) die beste Performance. Die Diskrepanz zwischen präzisen Punktvorhersagen und schwacher Trading-Performance verdeutlicht die fundamentale Schwierigkeit, aus guten Vorhersagen profitable Handelssignale abzuleiten.

Inhaltsverzeichnis

Abkürzungsverzeichnis	VI
Abbildungsverzeichnis	VIII
Tabellenverzeichnis	IX
Quellcodeverzeichnis	X
1. Einleitung	1
1.1. Motivation	1
1.2. Probleme	1
1.3. Ziel der Arbeit	2
2. Stand der Forschung	3
2.1. Performance-Metriken	3
2.2. Klassische statistische Verfahren	4
2.3. Machine-Learning-Ansätze	6
2.4. Hybride Modelle	8
2.5. Vergleich und Forschungslücke	9
2.6. Ansatz der Arbeit	10
3. Konzeption	11
3.1. Überblick	11
3.2. Daten und Aktienwahl	13
3.3. Modellentwicklung	24
3.4. Handelsstrategie	36
3.5. Einschränkungen und Nebenbedingungen	39
3.6. Metriken	40
4. Implementierung	43
5. Ergebnisse und Bewertung	59
5.1. SDE Aktienausswahl	59
5.2. LinearSeparation	64
5.3. Preprocessed SVR	68
5.4. TimesFM	74

5.5. Modellvergleich	78
6. Zusammenfassung	83
7. Ausblick	85
Literaturverzeichnis	XI
A. Mathematische Definitionen der Metriken	XVII
A.1. Fehlermaße	XVII
A.2. Finanzwirtschaftliche Kennzahlen	XVIII
B. SVR Modellierung	XXI
C. Vollständige Ergebnisse der Aktienauswahl	XXIV
C.1. Dominante Faktorpaare aller Aktien	XXIV
C.2. Durchschnittliche simulierte ROIs	XXXI

Abkürzungsverzeichnis

EMH	Efficient Market Hypothesis
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
MSE	Mean Squared Error
MAPE	Mean Absolute Percentage Error
DA	Directional Accuracy
MDD	Maximum Drawdown
LSTM	Long Short Term Memory
OOS-R^2	Out-Of-Sample R^2
SVM	Support Vector Machine
NN	Neuronal Network
SVR	Support Vector Regression
ARIMA	Autoregressive Integrated Moving Average
ARMA	Autoregressive Moving Average
GARCH	Generalized Autoregressive Conditional Heteroscedasticity
kNN	k-Nearest Neighbors
CNN	Convolutional Neural Network
RNN	Recurrent Neural Network
GRU	Gated Recurrent Unit
ROI	Return on Invest
SDE	Stochastische Differentialgleichung

OLS	Ordinary Least Squares
HP	Hodrick-Prescott
ADF	Augmented Dickey-Fuller
AIC	Akaike Information Criterion
RBF	Radial Basis Function
RSI	Relative Strength Index
MACD	Moving Average Convergence Divergence

Abbildungsverzeichnis

3.1. Struktur der Konzeption	12
3.2. Ablauf Aktienauswahl	18
4.1. Gesamtüberblick: Datenfluss von der Beschaffung bis zur Evaluation .	45
4.2. Aktienauswahl: Datenfluss von den historischen Kursdaten und Makro- faktoren bis zu den ausgewählten Aktien	49
4.3. LinearSeparation: Datenfluss von den Trainingsdaten bis zum trainierten Modell	54
4.4. Preprocessed SVR: Datenfluss von den Trainingsdaten bis zur Preis- prognose	56
4.5. TimesFM: Datenfluss der Vorhersage von neuen Kursen	57
5.1. Beispielhafte Euler-Maruyama Simulation einer Gruppe	61
5.2. Walk-Forward-Backtest für RMD mit LinearSeparation-Modell. Oben: Portfoliowert. Unten: Aktienkurs (schwarz), Vorhersagen (blau), Kaufsi- gnale (grün), Verkaufssignale (rot).	67
5.3. Walk-Forward-Backtest für GWW mit SVR-Modell. Oben: Portfolio- wert. Unten: Aktienkurs (schwarz), Vorhersagen (blau), Kaufsignale (grün), Verkaufssignale (rot).	73
5.4. Walk-Forward-Backtest für TT mit TimesFM-Modell. Oben: Portfo- liowert. Unten: Aktienkurs (schwarz), Vorhersagen (blau), Kaufsignale (grün), Verkaufssignale (rot).	77

Tabellenverzeichnis

3.1. Beispielhafte Rohdaten der Aktienpreise. Alle Preisangaben in USD. . .	14
3.2. Makroökonomische Faktoren	16
3.3. Bestandteile der Kovarianzmatrix	23
3.4. Komponenten der Aktienkursmodellierung	25
4.1. Parameter der Konfigurationsdatei für die Aktienausswahl	46
5.1. Aktien mit höchsten Beta-Summen (Ausschnitt)	60
5.2. Verteilung der dominanten Faktorpaare	60
5.3. Die zehn durch SDE-Verfahren ausgewählten Aktien nach durchschnittlicher Platzierung	62
5.4. Vergleich von prognostizierten und tatsächlichen Renditen	63
5.5. Schwellenwerte ε für das Handelssignal pro Aktie	64
5.6. Fehlermaße des LinearSeparation-Modells im Testzeitraum	65
5.7. Trading-Performance des LinearSeparation-Modells	66
5.8. Trade-Verteilung des LinearSeparation-Modells über den Testzeitraum	68
5.9. Optimale SVR-Hyperparameter pro Aktie (Grid-Search auf Validierungsdaten)	69
5.10. Schwellenwerte ε für das Handelssignal pro Aktie (SVR)	70
5.11. Fehlermaße des SVR-Modells im Testzeitraum	70
5.12. Trading-Performance des SVR-Modells	71
5.13. Trade-Verteilung des SVR-Modells über den Testzeitraum	72
5.14. Schwellenwerte ε für das Handelssignal pro Aktie (TimesFM)	74
5.15. Fehlermaße des TimesFM-Modells im Testzeitraum	75
5.16. Trading-Performance des TimesFM-Modells	76
5.17. Trade-Verteilung des TimesFM-Modells über den Testzeitraum	76
5.18. Vergleich der durchschnittlichen Performance-Metriken über alle Aktien	79
C.1. Dominante Faktorpaare aller analysierten Aktien	XXIV
C.2. Durchschnittliche simulierte ROIs aller analysierten Aktien	XXXI

Quellcodeverzeichnis

1.	Skript Aktienauswahl	47
2.	SDE-Selector Implementierung	50
3.	Skript Modellevaluation	51
4.	RunBacktest Methode	53
5.	PredictionStrategy – Handelsstrategie	58

1. Einleitung

1.1. Motivation

Die Vorhersage von Aktienkursen stellt eine zentrale Herausforderung der Finanzökonomie dar. Trotz umfangreicher Forschung bleibt die präzise Prognose zukünftiger Kursbewegungen aufgrund der Komplexität und Volatilität der Märkte schwierig. In den letzten Jahren wurden vermehrt mathematische und datengetriebene Methoden untersucht, um Muster in Finanzkursen zu identifizieren und Vorhersagen zu verbessern. Da ein zuverlässiger und konsistenter Algorithmus zur Vorhersage von Aktienkursen potenziell erhebliche finanzielle Vorteile bieten würde, ist das Interesse an der Entwicklung solcher Verfahren entsprechend groß.

1.2. Probleme

Ein zentrales theoretisches Problem bei der Vorhersage von Aktienkursen ergibt sich aus der Efficient Market Hypothesis (EMH). Die EMH besagt, dass alle verfügbaren Informationen bereits vollständig in den aktuellen Marktpreisen enthalten sind, sodass zukünftige Kursbewegungen definitionsgemäß nicht systematisch vorhergesagt werden können. Unter dieser Annahme verhalten sich Preisänderungen wie ein zufälliger Prozess, der durch keinen Algorithmus vorhergesagt werden kann und die Machbarkeit des Ziels dieser Arbeit infrage stellt [1]. Trotz der theoretischen Einschränkungen durch die Markteffizienzhypothese existieren empirische Beispiele erfolgreicher quantitativer Handelsstrategien. Renaissance Technologies nutzt seit Jahrzehnten fast ausschließlich mathematische Modelle und Algorithmen zur Kursprognose und erzielt mit dem Medallion Fund Renditen in Höhe von 66% p.a. Dies zeigt, dass systematische Modelle wiederkehrende Muster in

Finanzdaten sehr wohl erkennen und wirtschaftlich nutzen können. Hierbei sei anzumerken, dass die genaue Funktionsweise der verwendeten Algorithmen unbekannt ist. Quantitative Fonds agieren als „Black-Box“, was die wissenschaftliche Nachvollziehbarkeit erschwert und somit kein gesichertes Gegenbeispiel zur EMH ist [2]. Des Weiteren gibt es empirische, öffentliche Analysen, die zeigen, dass nicht-lineare Vorhersagemethoden durchaus Gewinne erzielen können [3]. Neben der Frage nach der allgemeinen Machbarkeit ergeben sich eine Vielzahl praktischer Probleme, die die Entwicklung erschweren. Zunächst enthalten Kursdaten viel Rauschen. Es ist schwer den tatsächlichen Signalanteil des Preises herauszufiltern, um den Trend zu erkennen. Des Weiteren ist es eine große Schwierigkeit, den korrekten Komplexitätsgrad des Modells zu finden. Zu komplexe Modelle „overfitten“, passen sich also zu stark an historische Daten an und generalisieren somit schlecht auf neuen, realen Daten. Dies betrifft vor allem Deep Learning Modelle, welche zu viele Freiheitsgrade haben, und somit den vergangenen Kurs oder das Rauschen abbilden und den Trend dabei nicht erkennen. Auf der anderen Seite sind zu simple Modelle nicht in der Lage nicht-lineare Zusammenhänge zu erkennen und generalisieren zu stark [4].

1.3. Ziel der Arbeit

Das Ziel dieser Arbeit ist das Entwickeln einer Strategie zur Auswahl von rentablen Aktien aus einem Aktienuniversum. Anschließend das Entwickeln und Testen von Vorhersagemodellen auf diesen gewählten Aktien. Danach wird eine Handelsstrategie entwickelt und die Modelle werden in einem realistischen Backtest evaluiert. Es soll eine Testumgebung geschaffen werden, mit welcher verschiedene Analysemodelle getestet und auf realen, vergangenen Daten ausprobiert werden.

2. Stand der Forschung

Dieses Kapitel analysiert Arbeiten und Studien, die verschiedene Ansätze verwenden, um Aktienkurse, Aktienkursbewegungen und Aktienkursrenditen vorherzusagen. Abschnitt 2.1 behandelt die Performance-Metriken, die die Forschung verwendet. Die verschiedenen Ansätze lassen sich in die zwei Hauptkategorien der klassischen statistischen Verfahren in Abschnitt 2.2 und der Machine-Learning-Ansätze in Abschnitt 2.3 unterteilen. Durch die Kombination mehrerer Modelle entstehen hybride Modelle, die Abschnitt 2.4 behandelt. Abschließend zieht Abschnitt 2.5 einen Vergleich der verschiedenen Ansätze und identifiziert die Forschungslücke, die den Bedarf für den eigenen Ansatz begründet.

2.1. Performance-Metriken

Das Review von Kumar, Sarangi und Verma [5] beschreibt die fünf am häufigsten verwendeten Metriken in der Literatur zur Vorhersage von Aktienkursen:

- **Accuracy:** Accuracy misst den Anteil der korrekt vorhergesagten Bewegungen. Klassifikationsmodelle verwenden hauptsächlich Accuracy.
- **Root Mean Squared Error (RMSE):** RMSE misst die durchschnittliche Abweichung der vorhergesagten Werte von den tatsächlichen Werten.
- **Mean Absolute Error (MAE):** MAE misst die durchschnittliche absolute Abweichung der Vorhersagen von den tatsächlichen Werten. Regressionsmodelle verwenden häufig MAE.
- **Mean Squared Error (MSE):** MSE misst die durchschnittliche quadratische Abweichung der Vorhersagen von den tatsächlichen Werten. Regressionsmodelle verwenden häufig MSE.

- **Mean Absolute Percentage Error (MAPE):** MAPE misst die durchschnittliche prozentuale Abweichung der Vorhersagen von den tatsächlichen Werten. MAPE eignet sich besonders, wenn die Werte stark variieren. Außerdem ist MAPE die am häufigsten verwendete Metrik in der Literatur.

2.2. Klassische statistische Verfahren

Die klassischen statistischen Verfahren lassen sich in zwei Hauptkategorien unterteilen: lineare Zeitreihenmodelle und stochastische Modelle. Lineare Zeitreihenmodelle, wie Autoregressive Integrated Moving Average (ARIMA) und Generalized Autoregressive Conditional Heteroscedasticity (GARCH), sind statistische Verfahren, die Muster und Trends in zeitlich geordneten Daten erkennen, um zukünftige Werte vorherzusagen.

2.2.1. Lineare Zeitreihenmodelle

Die Übersichtsstudie von Rundo u. a. [6] betrachtet die klassischen statistischen Modelle ARIMA und GARCH. Sie untersucht, wie gut ARIMA zukünftige Tagespreise von Aktien vorhersagen kann. Die Studie stellt fest, dass ARIMA die beiden untersuchten Aktienindizes befriedigend vorhersagen konnte.

Zudem betrachtet die Übersichtsstudie [6] ein Paper, das ein Kombinationsmodell aus ARIMA und GARCH verwendet, um Aktienmärkte vorherzusagen. Für die Einschrittprognosen liefern ARIMA und GARCH akkurate Vorhersagen, während die Mehrschrittprognosen nicht mehr zuverlässig ausfallen. Um dieses Problem zu lösen, entwickeln die Autoren ein neues Kombinationsmodell aus ARIMA und GARCH. Die Ergebnisse des Kombinationsmodells sind auch für Mehrschrittprognosen zuverlässig, selbst bei sehr volatilen Zeitreihen. Insgesamt zeigt die Übersichtsstudie, dass klassische statistische Modelle wie ARIMA und GARCH Aktienkurse vorhersagen können, insbesondere für kurzfristige Prognosen. Allerdings

verlieren sie bei längeren Prognosehorizonten an Genauigkeit, was die Entwicklung von hybriden Modellen zur Verbesserung der Vorhersageleistung notwendig macht.

Eine Übersichtsstudie von Shah, Isah und Zulkernine [7] analysiert verschiedene Paper, die ARIMA untersuchen. Das erste Paper beschreibt den Prozess des Erstellens von ARIMA-Modellen und sucht dann das optimale Modell. Dieses optimale Modell kann die Aktienkurse von Nokia und Zenith Bank zufriedenstellend vorhersagen. Ein weiteres Paper arbeitet heraus, dass ARIMA bei kurzfristigen Vorhersagen mit fortgeschrittenen Vorhersagetechniken mithalten kann.

2.2.2. Stochastische Modelle

Sasikumar und Abdullah [8] stellen in ihrem Paper verschiedene stochastische Modelle und ihre Anwendungen in der Finanzwelt vor. Die Random Walk Theorie besagt, dass die zukünftigen Bewegungen von Aktienkursen unvorhersehbar sind. Verschiedene Studien bestätigen die Random Walk Theorie und zeigen, dass sich aus ihr Empfehlungen für den optimalen Investitionszeitpunkt ableiten lassen.

Aus dem Paper von Sasikumar und Abdullah [8] geht hervor, dass Markow-Ketten primär für kurzfristige Vorhersagen geeignet sind. Außerdem zeigt das Paper, dass Markow-Ketten höherer Ordnung sowie gewichtete Markow-Ketten zuverlässigere Vorhersagen liefern als einfache Markow-Ketten.

Das letzte Modell, das Sasikumar und Abdullah [8] vorstellen, ist das Hidden Markov Model. Um den Shanghai Composite Index vorherzusagen, setzen die Autoren ein duales Hidden Markov Model ein. Im direkten Vergleich mit GARCH liefert das duale Hidden Markov Model bessere Prognosen. Darüber hinaus kombiniert eine andere Arbeit das Hidden Markov Model mit Fuzzy-Logik und vergleicht es mit anderen Prognosemodellen. Das kombinierte Modell aus Hidden Markov Model und Fuzzy-Logik erweist sich als zuverlässiger und profitabler. Hier nennen die Autoren aber auch die Einschränkung, dass das kombinierte Modell nur für kurzfristige Vorhersagen geeignet ist.

Ofomata u. a. [9] entwerfen in ihrem Paper ein neues stochastisches Modell, das Aktienkurse simulieren und kurzfristig vorhersagen kann. Das Paper verwendet als Datengrundlage die Schlusskurse von vier Aktien von der Nigerian Stock Exchange. Das Modell modelliert die vier Aktien gleichzeitig und gibt für jede Aktie eine simulierte Kursveränderung zurück. Das Modell kann deshalb dabei helfen zu entscheiden, in welche Aktie investiert werden soll.

2.3. Machine-Learning-Ansätze

Die Machine-Learning-Ansätze lassen sich in zwei Hauptkategorien unterteilen: Feature-basierte Verfahren und Deep-Learning-Modelle. Feature-basierte Verfahren verwenden manuell erstellte Features aus den Daten, um Vorhersagen zu treffen. Deep-Learning-Modelle nutzen tiefe neuronale Netze, um komplexe Muster in den Daten zu erkennen und Vorhersagen zu treffen.

2.3.1. Feature-basierte Verfahren

Rundo u. a. [6] stellen in seiner Übersichtsstudie verschiedene Paper vor, die sich mit der Verwendung von Support Vector Machine (SVM) beschäftigen. Die vorgestellten Paper zeigen, dass SVM gut geeignet sind, um Aktienkurse vorherzusagen. Außerdem übertrifft SVM die Leistung klassischer Neuronal Network (NN)-Modelle. Die guten Ergebnisse erzielen sowohl Modelle mit festgelegten als auch mit adaptiven Parametern. Ein weiteres Paper kombiniert SVM mit k-Nearest Neighbors (kNN) und verbessert dadurch die Vorhersageleistung.

Gandhmal und Kumar [10] kommen zu dem Schluss, dass SVM eine gute Wahl für die Vorhersage von Aktienkursen ist. Darüber hinaus stellen sie Paper vor, die sich mit Support Vector Regression (SVR) beschäftigen. Aus den Papern geht hervor, dass SVR ebenfalls eine gute Wahl für die Vorhersage von Aktienkursen ist. Die Paper stellen aber keinen Vergleich zwischen SVM und SVR an, sodass unklar

bleibt, welches der beiden Modelle besser für die Vorhersage von Aktienkursen geeignet ist.

Ballings u. a. [11] vergleicht in seinem Paper SVM mit kNN und Random Forest. Zur Bewertung der Ergebnisse dient die Area Under the Curve (AUC), die eine Aussage darüber trifft, wie gut die Modelle im Vergleich zum Zufall abschneiden. In diesem Vergleich schneidet Random Forest mit einer Median AUC von 0,9037 am besten ab, gefolgt von SVM mit 0,8395. Shah, Isah und Zulkernine [7] stellt in seiner Übersichtsstudie neben dem Paper von Ballings u. a. [11] noch ein weiteres Paper vor, das die These von Ballings u. a. [11] bestätigt, dass Random Forest zur Aktienkursvorhersage besser geeignet ist als SVM.

2.3.2. Deep-Learning-Modelle

Das Paper von Lu u. a. [12] stellt ein neues Convolutional Neural Network (CNN)-basiertes Modell vor, das eine Kombination verschiedener Deep-Learning-Architekturen verwendet. Dafür vergleichen die Autoren das neue Modell mit den Architekturen Long Short Term Memory (LSTM), Recurrent Neural Network (RNN) und CNN. Verglichen werden die Modelle mit den Metriken MAE, RMSE und R^2 . Aus dem Paper geht hervor, dass das neue CNN-basierte Modell in allen drei Metriken besser abschneidet als die anderen Modelle. Das LSTM-Modell schneidet am zweitbesten ab, gefolgt von RNN und CNN.

Das Übersichtspapier von Rundo u. a. [6] befasst sich mit verschiedenen Deep-Learning-Modellen, die die Literatur zur Vorhersage von Aktienkursen verwendet. Es stellt ein Paper vor, das die Modelle CNN, LSTM und RNN miteinander vergleicht und untersucht, wie gut sie Indexbewegungen vorhersagen können. CNN liefert dabei die besten Ergebnisse. Die verschiedenen Varianten von RNN liefern allerdings auch gute Ergebnisse; besonders LSTM findet besonders häufig Anwendung. Außerdem unterstreicht die Übersichtsstudie, dass Deep-Learning-Modelle in der Regel bessere Vorhersagen liefern als klassische statistische Modelle.

Auch Shah, Isah und Zulkernine [7] beschäftigt sich mit verschiedenen Deep-Learning-Modellen zur Vorhersage von Aktienkursen. Ein vorgestelltes Paper vergleicht ein einfaches RNN mit einem LSTM und einem Gated Recurrent Unit (GRU). Das LSTM liefert dabei die besten Ergebnisse. Darüber hinaus stellt ein weiteres Paper ein kombiniertes Modell aus LSTM und GRU vor, das die Vorhersageleistung verbessern kann. Auch diese Übersichtsstudie kommt zu dem Schluss, dass LSTM ein gutes und viel genutztes Modell für die Vorhersage von Aktienkursen ist, da es den anderen RNN-Varianten überlegen ist.

2.4. Hybride Modelle

Die Übersichtsstudie von Rundo u. a. [6] stellt auch verschiedene hybride Modelle vor. Häufig kombinieren diese hybriden Modelle klassische statistische Modelle mit Machine-Learning-Methoden. In der Literatur finden sich sehr viele verschiedene hybride Modelle, die unterschiedliche Modelle kombinieren. Diese hybriden Modelle vergleichen die Autoren in der Regel mit den einzelnen Modellen. Auch wenn einige hybride Modelle in den Vergleichen mit den einzelnen Modellen schlechter abschneiden, übertrifft der Großteil der hybriden Modelle die einzelnen Modelle. Besonders können hybride Modelle die bekannten Schwächen der einzelnen Modelle gezielt ausgleichen.

Shah, Isah und Zulkernine [7] betrachten in ihrer Übersichtsstudie ebenfalls verschiedene hybride Modelle und kommen zum selben Schluss wie Rundo u. a. [6]. Auch hier liefern die hybriden Modelle in der Regel bessere Ergebnisse als die einzelnen Modelle. Besonders auffällig ist in dieser Übersichtsstudie die hohe Anzahl an Modellen, die für ein hybrides Modell kombiniert wurden. Das lässt vermuten, dass die Erhöhung der Komplexität durch die Kombination mehrerer Modelle zu einer verbesserten Vorhersageleistung führt.

Grundsätzlich lässt sich sagen, dass die meisten hybriden Modelle bessere Ergebnisse liefern als die einzelnen Modelle, auch wenn eine Kombination nicht

zwangsläufig zu einer verbesserten Prognoseleistung führt. Die einzelnen Modelle müssen sorgfältig ausgewählt und kombiniert werden, um die Stärken der einzelnen Modelle zu nutzen und die Schwächen auszugleichen.

2.5. Vergleich und Forschungslücke

Der Survey von Rundo u. a. [6] kommt zu dem Schluss, dass Machine-Learning-Modelle tendenziell akkuratere Vorhersagen liefern als klassische statistische Modelle. Allerdings weisen die Autoren auch darauf hin, dass die Leistung von Machine-Learning-Modellen stark von der Qualität und Quantität der verfügbaren Daten abhängt. In vielen Fällen können klassische Modelle aufgrund ihrer Einfachheit und Interpretierbarkeit vorzuziehen sein, insbesondere wenn die Daten begrenzt oder verrauscht sind.

Eine Forschungslücke besteht in der Integration von alternativen Datenquellen, wie z.B. Nachrichten, Sentiment-Analysen und makroökonomischen Indikatoren, in die Vorhersagemodelle. Während sich viele Studien auf historische Kursdaten und technische Indikatoren konzentrieren, integrieren nur wenige Arbeiten diese zusätzlichen Datenquellen systematisch in ihre Modelle.

Die Entwicklung von Modellen, die zuverlässige Vorhersagen über kurze Zeiträume liefern, stellt eine weitere Forschungslücke dar. Vorhersagen über Kursbewegungen über kurze Zeiträume wie Tage oder Stunden sind besonders relevant für den Hochfrequenzhandel. Es gibt zwar einige Arbeiten, die sich mit der Vorhersage von kurzfristigen Kursbewegungen beschäftigen, aber es besteht weiterhin Bedarf an Modellen, die in diesem Bereich zuverlässige und genaue Vorhersagen liefern können.

Eine zusätzliche Forschungslücke besteht darin, dass viele Modelle nur auf einem begrenzten Datensatz getestet werden, was die Generalisierbarkeit der Ergebnisse einschränkt. Es besteht Bedarf an Modellen, die auf einer breiteren Palette von

Aktien und Märkten getestet werden, um ihre Robustheit und Anwendbarkeit in verschiedenen Kontexten zu gewährleisten.

2.6. Ansatz der Arbeit

Die Analyse der Literatur zeigt, dass es kein klar bestes Modell gibt. Die Wahl des Modells hängt stark von den spezifischen Anforderungen und den verfügbaren Daten ab. Es gibt allerdings nur wenig Forschung zur Vorhersage von kurzfristigen Kursbewegungen und zur Integration von alternativen Datenquellen in die Vorhersagemodelle.

Diese Erkenntnisse bilden die Grundlage für den Ansatz dieser Arbeit, der darauf abzielt, diese Lücken zu adressieren und die Vorhersageleistung durch die Integration zusätzlicher Datenquellen und die Entwicklung von Modellen für kurzfristige Vorhersagen zu verbessern. Da die Literatur keinen eindeutig besten Ansatz identifiziert, entwickelt und vergleicht diese Arbeit verschiedene Modelle, um dazu beizutragen, den vielversprechendsten Ansatz für die Vorhersage von Aktienkursen zu identifizieren.

3. Konzeption

3.1. Überblick

In diesem Kapitel wird die Entwicklung der in dieser Arbeit verwendeten Modelle zur Vorhersage von Aktienkursen beschrieben. Die Struktur des gesamten Kapitels ist in Abb. 3.1 zu sehen.

Zunächst wird in Abschnitt 3.2 das Datenset erläutert. Es erfolgt die Auswahl des Aktienuniversums. Danach wird die konkrete Auswahl der untersuchten Aktien auf Basis von stochastischen Differentialgleichungen beschrieben. Die Daten werden unterteilt und bereinigt.

Daraufhin wird in Abschnitt 3.5 der Rahmen der Arbeit definiert, einschließlich des Untersuchungsgegenstands, der getroffenen Annahmen sowie der Nebenbedingungen und Einschränkungen. Diese Vereinfachungen dienen der Interpretierbarkeit, unterscheiden sich aber teilweise von realen Marktbedingungen.

Anschließend werden in Abschnitt 3.6 die Metriken vorgestellt, die sowohl mathematische als auch finanzwirtschaftliche Aspekte berücksichtigen.

Aufbauend auf diesen Grundlagen erfolgt die Modellentwicklung in Abschnitt 3.3. Es werden drei Modelle vorgestellt:

- **LinearSeparation:** Unterteilt den Aktienkurs in drei Bestandteile und schätzt jeden über ein lineares Verfahren,
- **Preprocessed SVR:** Support Vector Regression mit vorverarbeiteten und normalisierten Kennzahlen,
- **TimesFM:** Anwendung eines Zeitreihen Foundation Model auf Aktienkurse.




Abbildung 3.1.: Struktur der Konzeption

Abschließend wird in Abschnitt 3.4 die Umsetzung der Vorhersagen in einer Handelsstrategie beschrieben. Hierbei werden Risikomanagement, Positionsgrößen und Vorhersagehorizont betrachtet. Aus den Preisvorhersagen wird eine Marktentscheidung getroffen, um die praktische Anwendbarkeit der Modelle zu analysieren.

3.2. Daten und Aktienwahl

3.2.1. Daten

Unter dem Survivorship Bias versteht man die statistische Verzerrung, die entsteht, wenn nur überlebende Unternehmen ausgewählt werden und insolvente oder aus einem Index entfernte Aktien unberücksichtigt bleiben, was historische Renditen systematisch nach oben verzerrt. Für die Analyse wird ein festes Aktienuniversum herangezogen, bestehend aus den im Jahr 2020 im S&P500 gelisteten Unternehmen, wodurch ein Survivorship Bias vermieden wird.

Die Kursdaten jeder Aktie werden als Zeitreihe betrachtet. Für jeden Handelstag enthält die Zeitreihe folgende Werte:

- Open: erster Preis zu dem an diesem Tag gehandelt wurde,
- Close: letzter Preis zu dem an diesem Tag gehandelt wurde,
- High: höchster Preis zu dem an diesem Tag gehandelt wurde,
- Low: niedrigster Preis zu dem an diesem Tag gehandelt wurde,
- Volume: gesamtes kumuliertes Handelsvolumen an diesem Tag.

Die Daten werden als CSV-Dateien von Yahoo Finance heruntergeladen und ein Auszug ist in Tabelle 3.1 zu sehen. Sie werden in parquet-Dateien konvertiert, um Speicherplatz und Rechenzeit zu sparen.

Datum	Close	High	Low	Open	Volume
2022-11-11	147,34	147,64	142,09	143,52	93 979 700
2022-11-14	145,94	147,91	145,10	146,62	73 374 100

Tabelle 3.1.: Beispielhafte Rohdaten der Aktienpreise. Alle Preisangaben in USD.

Die Unterteilung der Zeitreihen erfolgt in einem 60:10:30-Verhältnis, wobei 60% der Daten als Trainingsdaten, 10% als Validierungs- und 30% als Testdaten verwendet werden:

- **Trainingszeitraum (T):** 01.2020–12.2023, in dem die Modelle auf den historischen Kursen trainiert werden.
- **Validierungszeitraum (V):** 01.2024–06.2024, der zur Optimierung der Modellparameter dient.
- **Testzeitraum (Z):** 07.2024–12.2025, der ausschließlich für die abschließende Evaluierung der Modelle auf bisher ungesehenen Daten verwendet wird.

3.2.2. Bereinigung

Die Analysen in dieser Arbeit bestehen aus Backtest. Das bedeutet, dass vergangene Daten verwendet werden, um Strategien zu testen. Aus diesem Grund ist eine Bereinigung der historischen Aktienkurse notwendig, da sich die nominalen Preise einer Aktie im Zeitverlauf durch Ereignisse wie Aktiensplits oder Dividendenzahlungen verändern, ohne dass sich der tatsächliche Unternehmenswert und demnach der Aktienwert geändert hat. Ohne eine solche Anpassung würden Kursbewegungen verzerrt dargestellt, was zu falsch trainierten Modellen oder falschen Tests führt. Sei P_t der beobachtete Schlusskurs einer Aktie zum Zeitpunkt t und $\tilde{P}_t$ der bereinigte Preis, auf dem ein Modell trainiert werden kann. $\tilde{P}_t$ ergibt sich aus dem ursprünglichen Preis multipliziert mit einem Anpassungsfaktor A_t :

$$\tilde{P}_t = P_t \cdot A_t.$$

Der Anpassungsfaktor wird rekursiv rückwärts berechnet. Sei P_t für $t = 1, \dots, n$ gegeben, gilt $A_n = 1$. Bei einem Aktiensplit zum Zeitpunkt t mit Verhältnis $s_t = \frac{\text{neue Aktien}}{\text{alte Aktien}}$ gilt

$$A_{t-1} = \frac{A_t}{s_t}.$$

Dividendenzahlungen werden ebenfalls berücksichtigt. Sei D_t die Dividende zum Zeitpunkt t . Dann wird der Anpassungsfaktor wie folgt aktualisiert:

$$A_{t-1} = A_t \cdot \frac{P_t - D_t}{P_t}.$$

Somit ist der historische Preis mit dem die Modelle trainiert und getestet werden abhängig vom letzten betrachteten Wert. Der letzte Wert entspricht somit dem aktuellen, realisierbaren Aktienwert, alle anderen Werte potenziell aber nicht den realen Aktienwerten zu dem Zeitpunkt.

3.2.3. Aktienauswahl

Es sollen nun 10 Aktien aus dem Gesamtuniversum ausgewählt werden, auf denen später getestet wird. Dafür wird in diesem Abschnitt ein Verfahren vorgestellt, welches eine Stochastische Differentialgleichung (SDE) verwendet, um aus dem Gesamtuniversum die Aktien auszuwählen, die am wahrscheinlichsten den höchsten Return on Invest (ROI) erzielen. Die Auswahl dieser Aktien muss stets anhand von Informationen erfolgen, die vor dem Testzeitraum bekannt waren, um einen Lookahead Bias und Selection Bias zu verhindern.

Aktienkurse setzen sich aus einem Trend und zufälligem Rauschen zusammen. Es wird die These aufgestellt, dass eine Aktienkursbewegung $dS(t)$ sich durch

einen Trend μ und ein Rauschen als Wienerprozess W_t , verstärkt durch einen Volatilitätskoeffizienten σ darstellen lässt.

$$dS(t) = \underbrace{\mu S(t)dt}_{\text{Trendkomponente}} + \underbrace{\sigma S(t)dW(t)}_{\text{Rauschen}} \quad (3.1)$$

Der in dieser Arbeit gewählte Ansatz lässt sich als eine Verallgemeinerung des Modells von Ofomata u. a. [9] verstehen. Ein wesentlicher Nachteil ihrer Methode liegt in der Beschränkung auf eine sehr kleine Auswahl an Aktien, die vorab durch externe Verfahren selektiert werden müssen. Das hier vorgestellte Modell hebt diese Notwendigkeit auf, um das Verfahren breiter anwendbar zu machen, indem Aktien mehrfach miteinander verglichen und schlechtere aussortiert werden. Ein weiterer Aspekt betrifft die Berechnung der Parameter μ und σ und die Kovarianz der Aktien untereinander. In der Praxis folgen Kursbewegungen externen Faktoren wie dem Ölpreis oder dem aktuellen Leitzins. Dass Aktien innerhalb desselben Index miteinander korrelieren, kann eine logische Folge ihrer gemeinsamen Reaktion auf diese makroökonomischen Einflüsse sein. Anstatt nur die Einflüsse der Aktien untereinander zu beobachten, beobachtet der folgende Ansatz die Einflüsse der makroökonomischen Faktoren auf die Aktien einzeln. Die hier betrachteten Faktoren sind dargestellt in Tabelle 3.2.

Faktor	Erklärung
Ölpreis	Öl Future-Kontrakt Preis an der NYMEX
Goldpreis	Gold Future-Kontrakt Preis an der COMEX
Staatsanleihe	10-Jahre-Staatsanleihe der USA
Gesamtindex	Marktindex des S&P500
US-Dollar	US-Dollar Index DXY
Inflation	10-Jahre Break-Even-Inflationsrate

Tabelle 3.2.: Makroökonomische Faktoren

Der Ansatz in [9] teilt eine Aktienbewegung in drei diskrete Richtungen auf: Anstieg (+1), Rückgang (−1) und Stagnation (0). Bei n betrachteten Aktien ergibt sich daraus ein Ergebnisraum von 3^n möglichen Bewegungskombinationen

innerhalb eines Handelstages. Für $n = 4$ also bereits $3^4 = 81$ zu berücksichtigende Szenarien. Dadurch, dass in [9] nur 60 Handelstagen betrachtet werden, treten viele Bewegungen überhaupt nicht auf.

Um die genannten Probleme zu adressieren, wird die Grundstruktur beibehalten, jedoch wird der ursprüngliche 3^n -dimensionale Aktienvektor durch einen 3^{g+f} -dimensionalen Einflussvektor aus g Aktien und f Faktoren ersetzt. Die Grundstruktur des Verfahrens ist in Abb. 3.2 zu sehen und lässt sich folgendermaßen zusammenfassen. Für jede Aktie werden die beiden makroökonomischen Faktoren f aus Tabelle 3.2 gesucht, die am meisten Einfluss auf die Kursbewegung haben. Dann werden für alle Aktien, die dasselbe dominante Einflussfaktorpaar haben, Simulationsgruppen aus je 4 Aktien und den beiden Einflussfaktoren gebildet. Innerhalb dieser Simulationsgruppen werden die Kursverläufe der Aktien und Faktoren simuliert und diejenige Aktie, die nach dem Testzeitraum Z den höchsten ROI in der Simulation erzielt, geht als „Gewinner“ aus ihrer Simulationsgruppe hervor. Dieser Auswahlprozess wird über das gesamte Aktienuniversum durchgeführt. Danach werden diese „Gewinner“ wieder in Simulationsgruppen zu je 4 Aktien aufgeteilt. Durch diesen hierarchischen Prozess bleibt der Ansatz unabhängig von der Gesamtzahl der Aktien (n). Er lässt sich somit auf beliebig große Universen anwenden und berücksichtigt direkt den Einfluss makroökonomischer Faktoren.

Gruppierung

Um das vorgestellte Verfahren auf ein gesamtes Aktienuniversum anwenden zu können, muss eine Gruppierung der Aktien und Faktoren vorgenommen werden. Der bereits definierte Trainingszeitraum T hat etwa 1000 Handelstage. Um eine sinnvolle Wahrscheinlichkeitsverteilung der Aktienbewegungen zu liefern, sollte die Anzahl der möglichen Kombinationen der diskreten Aktien- und Faktorbewegungen kleiner sein als die Tage des Trainingszeitraums. Es wurde sich für $g = 4$ Aktien und $f = 2$ Faktoren pro Simulationsgruppe entschieden, was zu $3^6 = 729 < 1000$ möglichen Kombinationen führt.




Abbildung 3.2.: Ablauf Aktienauswahl

Um den Einfluss der Faktoren auf jede Aktie zu messen, wird für jede Aktie-Faktor-Kombination eine lineare Regression der diskreten Aktienbewegung ΔS auf die diskrete Faktorbewegung ΔF geschätzt.

$$\Delta S_i(t) = \alpha_i + \sum_{j=1}^7 \beta_{i,j} \cdot \Delta F_j(t), \quad (3.2)$$

wobei α_i den faktorunabhängigen Trend der Aktie bezeichnet und $\beta_{i,j}$ die Sensitivität der Aktie i gegenüber Faktor j .

Die Koeffizienten α und β werden mittels Ordinary Least Squares (OLS) auf den Daten des Trainingszeitraums bestimmt:

$$\hat{\theta}_i = (X^T X)^{-1} X^T y_i, \quad (3.3)$$

mit

$$\hat{\theta}_i = \begin{pmatrix} \hat{\alpha}_i \\ \hat{\beta}_{i,1} \\ \vdots \\ \hat{\beta}_{i,7} \end{pmatrix}. \quad (3.4)$$

$X \in \mathbb{R}^{T \times 8}$ bezeichnet die Designmatrix der Faktorbewegungen über $T = 1000$ Handelstage und ergibt sich zu

$$X = \begin{pmatrix} 1 & \Delta F_1(1) & \Delta F_2(1) & \cdots & \Delta F_7(1) \\ 1 & \Delta F_1(2) & \Delta F_2(2) & \cdots & \Delta F_7(2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \Delta F_1(T) & \Delta F_2(T) & \cdots & \Delta F_7(T) \end{pmatrix}. \quad (3.5)$$

$y_i \in \mathbb{R}^T$ ist der Vektor der Aktienbewegungen im Trainingszeitraum.

$$\mathbf{y}_i = \begin{pmatrix} \Delta S_i(1) \\ \Delta S_i(2) \\ \vdots \\ \Delta S_i(T) \end{pmatrix} \quad (3.6)$$

Da jede Simulationsgruppe genau zwei Faktoren enthalten soll, wird jeder Aktie das Faktorpaar (f_1, f_2) zugewiesen, für das die Summe der β -Koeffizienten maximal ist.

$$(f_1^*, f_2^*) = \arg \max_{j_1 \neq j_2} (|\beta_{i,f_1}| + |\beta_{i,f_2}|) \quad (3.7)$$

Dieses Paar wird als dominantes Faktorpaar $(f_{i,1}^*, f_{i,2}^*)$ der Aktie i bezeichnet. Alle Aktien, die dasselbe dominante Faktorpaar haben, werden in einem Pool zusammengefasst.

$$\mathcal{P}_{j_1, j_2} = \{S_i : (j_1^*, j_2^*) = (j_1, j_2)\} \quad (3.8)$$

Bei den gewählten 7 Faktoren gibt es somit $\binom{7}{2} = 21$ mögliche Faktorpools. Jeder Pool enthält die Aktien, die auf dasselbe Faktorpaar am stärksten reagieren, wodurch auch die Korrelation unter den Aktien hoch sein sollte. Aus den Pools werden nun zufällig Simulationsgruppen zu je 4 Aktien gebildet.

Durch das hierarchische Format der Aktienauswahl kann es durch die lokalen Vergleiche passieren, dass Aktien in früheren Stufen nicht den höchsten ROI in der Simulation haben und somit nicht weiter betrachtet werden, obwohl sie im Vergleich der Grundgesamtheit unter den Top 10 vielversprechendsten Aktien gewesen wären. Dadurch wird die Aktienauswahl verschlechtert. Darum erfolgt die Aufteilung der Aktien von den Faktorpools in die Gruppen zufällig und die gesamte Aufteilung und Simulation wird $N = 100$ Mal durchgeführt. Die 10 Aktien

mit der durchschnittlich besten Platzierung werden gewählt. Nach der gesamten Simulation ergeben sich die 10 am besten prognostizierten Aktien.

Aufstellen der SDEs

Es wird nun dargelegt, wie genau die Aktienkurse innerhalb einer Simulationsgruppe simuliert werden. Dies erfolgt durch das Aufstellen einer SDE für jeden Aktienkurs und das numerische Lösen dieser SDE.

Durch die Diskretisierung der Aktienbewegung degeneriert die SDE zu

$$dS(t) = \mu dt + \sigma dW(t), \quad (3.9)$$

da diskrete Schwankungen nicht mit dem Aktienkurs skalieren.

Der Aktienkurs könnte dadurch theoretisch negativ werden, was ignoriert werden kann, da es nur um einen qualitativen, nicht quantitativen Vergleich der Aktien untereinander geht. Es wird ein Einflussvektor X aus Aktienbewegungen S und Faktorbewegungen F aufgestellt, mit

$$\Delta X(t) = [\Delta S_1(t), \Delta S_2(t), \dots, \Delta S_g(t), \Delta F_1(t), \Delta F_2(t), \dots, \Delta F_f(t)]^T.$$

Für jede Aktienbewegung und Faktorbewegung gibt es drei mögliche Werte (+1, 0, -1). Daraus ergibt sich der Ereignisraum C für den Einflussvektor X zu allen möglichen Gesamtbewegungen. Für die Kombinationen des Einflussvektors $c \in C$ wird die Wahrscheinlichkeit pro Aktie $p_i(c)$ im Trainingszeitraum T nach Gleichung (3.10) bestimmt. Außerdem wird eine Laplace-Glättung eingeführt. Dies soll das Problem eliminieren, dass Kombinationen die im Trainingszeitraum aus statistischen Gründen nicht aufgetreten sind, als unmöglich angesehen werden.

$$p_i(c) = \frac{N_c + 1}{T + |C|}, \quad (3.10)$$

wobei N_c der Anzahl der Zeitpunkte entspricht, an denen die Bewegung c im Zeitraum der Trainingstage T aufgetreten ist.

Der Trend einer Aktie oder eines Faktors ergibt sich aus dem Erwartungswert der Wahrscheinlichkeiten über alle möglichen Ereignisse.

$$\mu_i = \mathbb{E}[\Delta X] = \sum_{c \in C} p_i(c) \cdot c$$

Danach ergibt sich der Vektor der Trends der Aktien $\mu \in \mathbb{R}^g$, mit g als Simulationsgruppengröße zu

$$\mu = \begin{pmatrix} \mu_{S_1} \\ \mu_{S_2} \\ \vdots \\ \mu_{S_g} \\ \mu_{F_1} \\ \vdots \\ \mu_{F_f} \end{pmatrix}.$$

Zusätzlich zum Trend soll das Rauschen der Aktien modelliert werden. Dafür wird die Kovarianz der Aktien untereinander, die Kovarianz der Faktoren und Aktien und die Kovarianz der Faktoren untereinander betrachtet. Die Kovarianzmatrix ergibt sich nach

$$\Sigma = \mathbb{E}[\Delta X \cdot \Delta X^T] = \sum_{c \in C} p(c) \cdot c \cdot c^T.$$

Die Kovarianzmatrix hat die Dimension $(f + g) \times (f + g)$ und lässt sich in die in Gleichung (3.11) und Tabelle 3.3 genannten Bestandteile gliedern.

$$\Sigma = \begin{pmatrix} \Sigma_{SS} & \Sigma_{SF} \\ \Sigma_{FS} & \Sigma_{FF} \end{pmatrix} \quad (3.11)$$

Block	Dimension	Bedeutung
Σ_{SS}	$g \times g$	Kovarianzen der Aktien untereinander
Σ_{FF}	$f \times f$	Kovarianzen der Faktoren untereinander
$\Sigma_{SF} = \Sigma_{FS}^T$	$g \times f$	Kovarianzen zwischen Aktien und Faktoren

Tabelle 3.3.: Bestandteile der Kovarianzmatrix

Der Volatilitätskoeffizient σ der SDE wird bestimmt als Cholesky-Zerlegung von Σ . Da Σ mit nicht-negativen Wahrscheinlichkeiten $p(c)$ konstruiert ist, ist Σ positiv semidefinit, womit die Zerlegung existiert.

$$B \cdot B^T = \Sigma$$

Die gesamte SDE ergibt sich zu

$$dS_i(t) = \mu_{S_i} dt + \sum_{j=1}^{f+g} B_{ij} dW_j(t), \quad i = 1, 2, \dots, g,$$

wobei $W(t) \in \mathbb{R}^{f+g}$ ein Wiener-Prozess der Dimension $f + g$ ist. Die Faktoren F werden nicht simuliert, da sie lediglich für die Modellierung der Aktien S verwendet werden.

Zur Lösung der SDE wird das Euler-Maruyama-Schema verwendet. Der Startwert ist der Aktienkurs der jeweiligen Aktie zu Beginn des Testzeitraums Z . Danach wird die diskrete Annäherung simuliert nach der Gleichung (3.12).

$$S_i(t+1) = S_i(t) + \mu_{S_i} \Delta t + \sum_{j=1}^{f+g} B_{ij} \Delta W_{j,t} \quad (3.12)$$

Hierbei ist $\Delta W_{j,t}$ die Zunahme des Wiener-Prozesses W_j im Intervall $[t, t+1]$:

$$\Delta W_{j,t} \sim \mathcal{N}(0, \Delta t) \implies \Delta W_{j,t} = Z_{j,t} \sqrt{\Delta t},$$

wobei $Z_{j,t}$ unabhängige, standardnormalverteilte Zufallsvariablen sind. Auf diese Weise können die Aktienkurse innerhalb einer Simulationsgruppe simuliert und der prognostizierte ROI bestimmt werden.

3.3. Modellentwicklung

In diesem Kapitel werden drei Modelle entwickelt, die jeweils auf einer einzelnen Aktie operieren und auf Basis historischer Kursdaten sowie weiterer Eingabegrößen den Aktienkurs des nächsten Handelstages vorhersagen. Zur Bestimmung der Modellqualität werden die Modelle auf den 10 ausgewählten Aktien getestet. Das Ziel ist ein Modellvergleich zwischen den vorgestellten Modellen untereinander.

3.3.1. LinearSeparation

Es wird ein komplett neues Verfahren vorgestellt, dass ohne Black-Box-Modelle wie Machine Learning auskommen soll. Es wird sich dafür an den vorhandenen linearen Verfahren Autoregressive Moving Average (ARMA) und Hodrick-Prescott (HP) orientiert, welche sinnvoll kombiniert werden, um eine Vorhersage zu treffen. Das Grundvorgehen des Modells ist, den Aktienkurs in einfacher schätzbare Teile zu zerlegen, jeden davon einzeln zu extrapolieren und die Vorhersagen zu einer Gesamtvorhersage zusammenzusetzen. Daraus entsteht ein Modell, welches den Preis des nächsten Tages auf Basis der vergangenen Tage schätzt:

$$\hat{P}_{t+1} = f((P_0, P_1, \dots, P_t)).$$

Diese Arbeit stellt die Behauptung auf, dass sich ein Aktienkurs durch die Komponenten T_t^{lang} , T_t^{kurz} , C_t und ϵ_t beschreiben lässt. Diese Komponenten sind in Tabelle 3.4 weiter erläutert. Weiter wird die Behauptung aufgestellt, dass sich ein Aktienkurs durch den Zusammenhang in Gleichung (3.13) beschreiben lässt.

$$P_t = T_t^{\text{lang}} \cdot T_t^{\text{kurz}} \cdot C_t \cdot \epsilon_t. \quad (3.13)$$

Variable	Bedeutung	Zeitraumen	Begründung
T_t^{lang}	langfristiger Trend	Jahre	Aktienmärkte bewegen sich durch Inflation und Konjunktur langfristig gleichmäßig
T_t^{kurz}	aktueller Trend	Wochen	aktienspezifische Bewegung abhängig von Earnings, Nachrichten usw.
C_t	kurzfristige Schwankungen	Tage	Autokorrelation in wenigen Tagen, teilweise begründbar
ϵ_t	Rauschen	$\mathbb{E}[\epsilon_t] = 0$	nicht erklärbar, nicht vorhersagbar

Tabelle 3.4.: Komponenten der Aktienkursmodellierung

Der Zusammenhang ist multiplikativ, da Aktienkurse prozentual schwanken. Das Rauschen von teuren Aktien ist beispielsweise größer als bei billigen Aktien. Da die Berechnung auf Log-Preisen $p_t = \ln(P_t)$ erfolgt, wird der Zusammenhang additiv.

$$p_t = \tau_t^{\text{lang}} + \tau_t^{\text{kurz}} + c_t + \epsilon_t \quad (3.14)$$

Die Komponenten des Preises werden über verschiedene Wege modelliert und dann extrapoliert. Die längerfristigen Trends τ^{lang} und τ^{kurz} werden mithilfe eines HP-Filters [13] modelliert und mittels OLS extrapoliert.

Es wird mittels eines HP-Filters aus den historischen Log-Preisen $p_1, \dots, p_T$ (mit $t = 1, \dots, T$) der langfristige Trend τ^{lang} extrahiert:

$$\hat{\tau}_t^{\text{lang}} = \arg \min_{\{\hat{\tau}_t^{\text{lang}}\}} \left(\sum_{t=1}^T (p_t - \hat{\tau}_t^{\text{lang}})^2 + \lambda_{\text{lang}} \sum_{t=2}^{T-1} (\hat{\tau}_{t+1}^{\text{lang}} - 2\hat{\tau}_t^{\text{lang}} + \hat{\tau}_{t-1}^{\text{lang}})^2 \right) \quad (3.15)$$

wobei λ_{lang} der Glättungsparameter ist und bestimmt, wie stark kurzfristige Schwankungen bereinigt werden. Der kritische Punkt bei diesem Verfahren liegt in der richtigen Wahl des Gewichtungsparameters λ_{lang} . Die genaue Wahl wird im Kapitel 4 diskutiert.

Mithilfe der daraus entstehenden geglätteten Zeitreihe $\hat{\tau}_t^{\text{lang}}$ werden die Residuen gebildet.

$$\tilde{p}_t = p_t - \hat{\tau}_t^{\text{lang}}$$

Um nun aus den Residuen den kurzfristigen Trend τ^{kurz} zu extrahieren, wird auf der Residuenzeitreihe $\tilde{p}_t$ ein weiterer HP-Filter, nach Gleichung (3.16) mit einem kleineren λ_{kurz} angewendet, um den aktuellen Trend τ^{kurz} zu glätten. Die Größenordnung von λ_{kurz} wird in Kapitel 4 bestimmt.

$$\hat{\tau}_t^{\text{kurz}} = \arg \min_{\{\hat{\tau}_t^{\text{kurz}}\}} \left(\sum_{t=1}^T (p_t - \hat{\tau}_t^{\text{kurz}})^2 + \lambda_{\text{kurz}} \sum_{t=2}^{T-1} (\hat{\tau}_{t+1}^{\text{kurz}} - 2\hat{\tau}_t^{\text{kurz}} + \hat{\tau}_{t-1}^{\text{kurz}})^2 \right) \quad (3.16)$$

Die HP-Filter liefern somit geglättete Trendverläufe $\hat{\tau}_t^{\text{lang}}$ und $\hat{\tau}_t^{\text{kurz}}$ für die historischen Daten bis zum Zeitpunkt T . Um Vorhersagen treffen zu können müssen diese Trends extrapoliert werden. Da beide Trends im Kontext von Tagespreisen langfristig sind, können sie lokal durch ein lineares Modell approximiert werden. Die Idee dabei ist, dass sich der gerade extrahierte, geglättete Trend innerhalb eines kurzen Zeitfensters gut durch eine Gerade beschreiben lässt, die anschließend in die Zukunft verlängert wird. Dafür wird die OLS-Methode verwendet.

Konkret wird für jeden Trend über ein gleitendes Fenster der letzten w Beobachtungen $\{\hat{\tau}_{T-w+1}, \dots, \hat{\tau}_T\}$ mittels OLS eine lineare Funktion der Zeit gefittet. Dabei werden die Parameter $\hat{a}$ (Achsenabschnitt) und $\hat{b}$ (Steigung) so gewählt, dass

$$\hat{b}_w = \frac{\sum_{t=T-w+1}^T (t - \bar{t})(\hat{\tau}_t - \bar{\tau})}{\sum_{t=T-w+1}^T (t - \bar{t})^2}, \quad \hat{a}_w = \bar{\tau} - \hat{b}\bar{t}. \quad (3.17)$$

Für die Mittelwerte gilt $\bar{t} = \frac{1}{w} \sum_{t=T-w+1}^T t$ und $\bar{\tau} = \frac{1}{w} \sum_{t=T-w+1}^T \hat{\tau}_t$. Die Vorhersage der Trendkomponenten für k Schritte in die Zukunft ergibt sich dann als

$$\hat{\tau}_{T+k}^{\text{lang}} = \hat{a}_1 + \hat{b}_1 \cdot (T + k), \quad (3.18)$$

$$\hat{\tau}_{T+k}^{\text{kurz}} = \hat{a}_2 + \hat{b}_2 \cdot (T + k). \quad (3.19)$$

Die Fenstergröße w bestimmt dabei, über welchen Zeitraum die lokale Steigung des Trends geschätzt wird. Ein zu kleines Fenster führt zu verrauschten Schätzungen und ein zu großes Fenster lässt aktuelle Richtungsänderungen nur langsam einfließen. Da τ^{lang} den strukturellen Trend über mehrere Jahre abbilden soll, wird die Steigung über ein Fenster von $w_{\text{lang}} = 252$ Handelstagen (einem Börsenjahr) geschätzt. Kurzfristige Schwankungen werden so herausgemittelt, und es verbleibt die mittelfristige Richtung des Marktes. τ^{kurz} soll Trendbewegungen im Bereich weniger Wochen erfassen. Deshalb wird $w_{\text{kurz}} = 40$ Handelstage (ca. zwei Monate) gewählt. Dieses kürzere Fenster erlaubt es, aktienspezifische Bewegungen zeitnah in die Extrapolation einfließen zu lassen.

Nach der Trendentfernung verbleiben die Residuen c_t als kurzfristige Muster.

$$c_t = \tilde{p}_t - \hat{\tau}_t^{\text{kurz}}.$$

Diese werden durch ein ARMA(p,q)-Modell beschrieben [14]. Für die Anwendung eines ARMA-Modells, wird vorausgesetzt, dass die zugrundeliegenden Daten sta-

tionär sind. Um zu prüfen, ob dies nach der Trendentfernung der Fall ist, wird der Augmented Dickey-Fuller (ADF)-Test [15] angewendet. Der ADF-Test [15] prüft die Nullhypothese, dass eine Unit Root vorliegt, die Zeitreihe also nicht stationär ist. Wird diese bei einem p-Wert kleiner als 0,05 verworfen, kann Stationarität angenommen werden. Sollte Stationarität nicht gewährleistet werden können, wird die Wahl der HP-Filter Parameter λ variiert. Zur Modellierung der Residuen c_t wird ein Standard ARMA(p,q)-Modell nach [14] verwendet:

$$\hat{c}_t = a + \sum_{i=1}^p \phi_i c_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \epsilon_t, \quad (3.20)$$

mit den Autokorrelationskoeffizienten ϕ_i , Fehlerkoeffizienten θ_j und einem konstanten Achsenabschnitt a . Die Parameter ϕ_i und θ_j werden dabei für jede Kombination (p, q) mittels Maximum-Likelihood-Schätzung bestimmt [14]. Die Ordnung p und q des Modells wird durch eine Grid-Search bestimmt. Das heißt, für alle Kombinationen (p, q) mit $p, q \in \{0, 1, \dots, 5\}$ wird das Modell geschätzt und das Akaike Information Criterion (AIC) [16] berechnet:

$$\text{AIC}(p, q) = 2(p + q) - 2 \ln(\hat{L}), \quad (3.21)$$

wobei $\hat{L}$ die maximierte Likelihood des geschätzten Modells ist. AIC bestraft dabei die Modellkomplexität und die Anpassungsgüte wird belohnt. Gewählt wird das Modell, welches das AIC minimiert. So kann die optimale Modellkomplexität bestimmt werden [17].

Mit dem geschätzten ARMA(p^*, q^*)-Modell werden die Residuen rekursiv vorhergesagt:

$$\hat{c}_{T+k} = \sum_{i=1}^{p^*} \phi_i \hat{c}_{T+k-i} + \sum_{j=1}^{q^*} \theta_j \hat{\epsilon}_{T+k-j} \quad (3.22)$$

Dabei werden für alle $k > 1$ die bereits vorhergesagten Werte als Eingabe verwendet. Außerdem werden alle zukünftigen Fehlerterme auf ihren Erwartungswert $\hat{\varepsilon}_{T+k} = \mathbb{E}[\varepsilon] = 0$ gesetzt.

Dies führt dazu, dass der ARMA-Beitrag zur Gesamtvorhersage für große Horizonte k exponentiell gegen null konvergiert, und die Vorhersage zunehmend von den extrapolierten Trendkomponenten dominiert wird, was genau der Modellierung entspricht.

Die gesamte Vorhersage des Log-Preises zum Zeitpunkt $T + k$ ergibt sich aus der Summe aller drei modellierten Komponenten.

$$\hat{p}_{T+k} = \hat{\tau}_{T+k}^{\text{lang}} + \hat{\tau}_{T+k}^{\text{kurz}} + \hat{c}_{T+k} \quad (3.23)$$

Die Rücktransformation in den ursprünglichen Preisraum erfolgt durch Exponentiation.

$$\hat{P}_{T+k} = \exp(\hat{p}_{T+k}) \quad (3.24)$$

3.3.2. Preprocessed SVR

SVRs wurden schon häufig verwendet, um Aktienkurse vorherzusagen. In dieser Arbeit stehen zwei Unterschiede zu den bisherigen Verfahren im Vordergrund. Zunächst wird auf Log-Renditen trainiert und vorhergesagt, da diese annähernd stationär sind, additiv über die Zeit und symmetrischer verteilt. Zudem werden in diesem Ansatz vorher berechnete technische Indikatoren und News-Sentiments als Features für die SVR verwendet, anstatt roher vergangener Preise.

Es wird eine klassische SVR-Modellierung nach Drucker u. a. [18] verwendet. Es ist das Ziel aus einem Feature-Vektor x_t mit d Features, die Log-Rendite $\hat{r}_{t+1}$ vorherzusagen.

$$\hat{r}_{t+1} = f(x_t), \quad x_t \in \mathbb{R}^d \quad (3.25)$$

Im Gegensatz zu linearen Regressionen nimmt die SVR keine spezifizierte funktionale Form an, sondern lernt die Abbildung anhand historischer Trainingsbeispiele, was sinnvoll für Aktienkursvorhersage ist, da Aktienkurse sich nicht durch eine spezifizierte funktionale Form beschreiben lassen. Die Modellierung der SVR orientiert sich an [18] und die genaue Beschreibung, sowie Parameterwahl ist ausführlich formuliert in Anhang B. Zur Fokussierung auf den neuen Ansatz dieser Arbeit, wird die SVR als eine Abbildung $f : \mathbb{R}^d \rightarrow \mathbb{R}$ abstrahiert, welche mithilfe der vergangenen Bewegungsmuster des Kurses einem d -dimensionalen Eingabe-Feature-Vektor auf den geschätzten Aktienpreis des nächsten Tages abbildet. Während andere Arbeiten den Feature-Vektor nur mit vergangenen Preisen modellieren [19, 20], verwendet dieser Ansatz verschiedene Informationsquellen und Eingabewerte mithilfe eines ausführlichen Feature-Engineerings, um das Erkennen von Strukturen in Marktbewegungen für die Regression zu vereinfachen

Feature Engineering

Da Aktienkurse von einer Vielzahl von Einflussfaktoren abhängen, werden Features aus den vier Bereichen kurzfristiger Preisdynamik, Marktstimmung, technischer Trendstärke und Volatilität kombiniert. Zum Zeitpunkt t setzt sich der Feature-Vektor $\mathbf{x}_t \in \mathbb{R}^9$ wie folgt zusammen:

$$\mathbf{x}_t = (r_{t-1}, r_{t-2}, r_{t-3}, \text{Sent}_t, \text{RSI}_t, \text{MACD}_t, \text{BB}_t, \sigma_{10,t}, d_t)^\top \quad (3.26)$$

Die einzelnen Komponenten sowie ihre Begründung werden in den folgenden Abschnitten erläutert.

Historische Renditen

Finanzzeitreihen weisen häufig kurzfristige Abhängigkeiten auf, die durch autoregressive Modelle erfasst werden können [21]. Die letzten drei Tagesrenditen r_{t-1} , r_{t-2} , r_{t-3} werden daher als direkte autoregressive Eingaben verwendet, um dem Modell kurzfristige Trendmuster zur Verfügung zu stellen. Die Wahl, dass Renditen bis zu drei vergangenen Tagen verwendet werden, stellt einen Kompromiss zwischen Informationsgehalt und Modellkomplexität dar. Längere Fenster erhöhen die Dimensionalität der SVR ohne Mehrwert für kurzfristige Prognosen [22]. Die Log-Rendite zum Zeitpunkt t ist definiert als

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right), \quad (3.27)$$

wobei P_t den Schlusskurs am Tag t bezeichnet. Log-Renditen werden gegenüber einfachen Renditen bevorzugt, da sie zeitlich additiv und annähernd normalverteilt sind.

Sentiment Score

Nachrichtmeldungen beeinflussen nachweislich die Kursentwicklung einer Aktie [23]. Um diesen Effekt zu erfassen, wird die externe Sentiment-API von Alpha Vantage genutzt [24], die für jede veröffentlichte Nachricht einen Sentiment-Score $s_i \in [-1, 1]$ pro erwähnter Aktie liefert, wobei -1 stark negatives und $+1$ stark positives Sentiment bedeutet.

Da nicht alle Nachrichten gleich relevant sind, wird ein exponentiell gewichteter Durchschnitt über die letzten 10 Meldungen berechnet, um aktuelleren Nachrichten ein höheres Gewicht beizumessen:

$$\text{Sent}_t = \frac{\sum_{i=1}^{10} w_i \cdot s_i}{\sum_{i=1}^{10} w_i}, \quad w_i = e^{\lambda(i-10)}, \quad (3.28)$$

wobei die Nachrichten chronologisch geordnet sind ($i = 1$ älteste, $i = 10$ neueste) und $\lambda = 0,2$ den Abklingparameter steuert. Durch die Wahl von $\lambda = 0,2$ erhält die neueste Meldung das höchste Gewicht, während die älteste mit $e^{-1,8} \approx 0,17$ auf etwa ein Sechstel abgemildert wird, was einen Kompromiss zwischen Gewichtung und Relevanz darstellt. Die exponentielle Gewichtung wird verwendet, da veraltete Meldungen die aktuelle Marktlage schnell schlechter widerspiegeln, als eine lineare Milderung abbilden würde.

Relative Strength Index

Die allgemeine Marktdynamik ist aus Rohkursen allein schwer extrahierbar. Der Relative Strength Index (RSI) ist hierbei geeignet, um die Marktdynamik widerzuspiegeln, da er überkaufte oder überverkaufte Marktphasen anzeigt [25]. Er misst die relative Stärke von Aufwärts- gegenüber Abwärtsbewegungen innerhalb eines Zeitfensters von $n = 14$ Tagen und ist häufig Bestandteil technischer Analysen [25]:

$$\text{RSI}_t = 100 - \frac{100}{1 + \frac{\overline{U}_t}{\overline{D}_t}}, \quad (3.29)$$

wobei $\overline{U}_t$ den exponentiell geglätteten Durchschnitt der positiven Kursveränderungen und $\overline{D}_t$ den exponentiellen Durchschnitt der negativen Kursveränderungen der letzten 14 Handelstage bezeichnet. Der RSI liegt per Konstruktion im Intervall $[0, 100]$, was seine spätere Normalisierung vereinfacht.

Moving Average Convergence Divergence

Während der RSI kurzfristige Über- oder Untertreibungen misst, erfasst der Moving Average Convergence Divergence (MACD) mittelfristiges Momentum und Trendwechsel, wodurch die beiden Parameter kombiniert ein gutes Bild auf

die Kursentwicklung geben. Der MACD bildet die Differenz zweier exponentiell geglätteter Durchschnitte [26]:

$$\text{MACD}_t = \text{EMA}_{12}(p)_t - \text{EMA}_{26}(p)_t, \quad (3.30)$$

wobei $\text{EMA}_k(p)_t$ den exponentiellen gleitenden Durchschnitt des Schlusskurses über k Handelstage zum Zeitpunkt t bezeichnet. Die Parameterwahl von 12 und 26 Tagen entspricht dem in der Literatur gebräuchlichen Standard [26].

Bollinger-Band-Position

Die relative Kursposition innerhalb der jüngsten Kursspanne ist ein weiteres, von den bisherigen Dimensionen unabhängiges Signal. Die Bollinger-Bänder bestehen aus einem gleitenden Durchschnitt $\text{MA}_{20,t}$ sowie einem oberen Band $B_t^+ = \text{MA}_{20,t} + 2\sigma_{20,t}$ und einem unteren Band $B_t^- = \text{MA}_{20,t} - 2\sigma_{20,t}$, wobei $\sigma_{20,t}$ die Standardabweichung der Schlusskurse der letzten 20 Handelstage ist [27]. Als Feature wird die normierte Position des aktuellen Kurses innerhalb der Bänder verwendet:

$$\text{BB}_t = \frac{p_t - B_t^-}{B_t^+ - B_t^-} \in [0, 1]. \quad (3.31)$$

Diese Normierung hat den Vorteil, dass das Feature bereits konstruktionsbedingt im Intervall $[0, 1]$ liegt und damit keine weitere Skalierung erfordert.

Realisierte Volatilität

Phasen erhöhter Volatilität gehen typischerweise mit größeren Renditeausschlägen einher (Volatilitätsclustering) [28]. Deshalb geht die aktuelle Volatilität als Parameter in das Modell ein. Als Maß für die kurzfristige Marktunsicherheit wird die realisierte 10-Tages-Volatilität der Log-Renditen verwendet:

$$\sigma_{10,t} = \sqrt{\frac{1}{9} \sum_{i=1}^{10} (r_{t-i} - \bar{r}_t)^2}, \quad \bar{r}_t = \frac{1}{10} \sum_{i=1}^{10} r_{t-i}. \quad (3.32)$$

Das Fenster von 10 Tagen erfasst kurzfristige Volatilität ohne übermäßige Glättung, die bei längeren Fenstern auftreten würde.

Handelspause

Der sogenannte Montag-Effekt beschreibt die empirisch beobachtete Tendenz, dass Renditen nach Handelspausen systematisch von regulären Folgetagen abweichen [29]. Dieser Effekt wird durch die aktuellen Dimensionen noch nicht abgebildet und geht durch eine Binärvariable in die Schätzung ein:

$$d_t = \begin{cases} 1 & \text{wenn zwischen } t-1 \text{ und } t \text{ mindestens ein Nicht-Handelstag liegt,} \\ 0 & \text{sonst.} \end{cases} \quad (3.33)$$

Dies trifft auf alle Montage sowie auf Tage nach Feiertagen zu.

Normalisierung

Da SVR mittels Abstandsberechnungen im Feature-Raum funktioniert, ist eine einheitliche Skalierung aller Eingaben erforderlich [30]. Ohne Normalisierung würden Features mit großen absoluten Wertebereichen die Berechnung dominieren, unabhängig von ihrem tatsächlichen Informationsgehalt. Dies würde dazu führen, dass das Modell die übrigen Features ignoriert.

Die Merkmale r_{t-1} , r_{t-2} , r_{t-3} , Sent_t , MACD_t und $\sigma_{10,t}$ werden mittels Z-Score-Normalisierung standardisiert:

$$\tilde{x} = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}. \quad (3.34)$$

Diese Methode ist kohärent, da sie keine Annahmen über den Wertebereich der Features benötigt. Der RSI wird durch Division durch 100 auf $[0, 1]$ skaliert. Die Features BB_t und d_t erfordern keine weitere Transformation, da BB_t konstruktionsbedingt in $[0, 1]$ liegt und d_t bereits binär ist. Die Normalisierungsparameter (μ_{train} , σ_{train}) werden ausschließlich auf den Trainingsdaten berechnet und anschließend auf Test- und Validierungsdaten angewendet.

3.3.3. TimesFM

Aktienkursvorhersagemodelle sind dafür bekannt, stark zum Overfitting zu neigen. Selbst die Nutzung großer Datensätze führt in der Praxis oft nicht zu einer signifikanten Verbesserung der Generalisierungsfähigkeit [31]. Ein grundlegender Ansatz, diesem Problem zu begegnen, besteht darin, gar nicht auf Aktiendaten zu trainieren, sondern stattdessen auf allgemeines Zeitreihenwissen zurückzugreifen. Genau diesen Ansatz verfolgt diese Arbeit mit dem Einsatz von TimesFM im Zero-Shot-Modus.

TimesFM ist ein von Google Research entwickeltes Foundation Model für Zeitreihenprognosen [32]. Analog zu großen Sprachmodellen wurde TimesFM auf einem Korpus realer Zeitreihendaten aus vielen Domänen vortrainiert, mit dem Ziel, Muster in sequenziellen Daten zu erlernen. Technisch basiert es auf einer Decoder-only Transformer-Architektur. Die Eingabezeitreihe wird in Patches gleicher Länge aufgeteilt, die als Tokens in den Transformer eingehen, und das Modell lernt durch die Vorhersage des jeweils nächsten Patches, analog zum Next-Token-Prediction-Prinzip in Sprachmodellen.

Der Ansatz dieser Arbeit besteht darin, TimesFM unverändert ohne Fine-Tuning auf Aktienrenditen anzuwenden. Dieser Zero-Shot-Einsatz erlaubt es zu untersuchen, ob allgemeines Zeitreihenwissen auf die spezifischen Muster von Aktienkursen

übertragbar ist. Im Unterschied zu allen anderen in dieser Arbeit vorgestellten Modellen wird kein datensatzspezifisches Muster gelernt, sondern die Frage beantwortet, ob domänenübergreifendes Wissen über Zeitreihen, wie Saisonalität oder Trendverhalten ausreicht, um Prognosen zu liefern, ohne dabei auf historische Aktienkurse zu overfitten.

Für die Anwendung wird TimesFM auf Log-Renditen eingesetzt, um Vergleichbarkeit mit den übrigen Modellen herzustellen. Als Eingabe dient ein rollierendes Fenster der letzten w Renditen-Beobachtungen, sodass das Modell zum Zeitpunkt t die Renditeprognose

$$\hat{r}_{t+1} = f_{\theta}(r_{t-w+1}, \dots, r_t) \quad (3.35)$$

ausgibt, wobei f_{θ} das vortrainierte TimesFM-Modell mit den unveränderten Parametern θ bezeichnet. Die zugehörige Preisvorhersage ergibt sich dann als

$$\hat{P}_{t+1} = P_t \cdot \exp(\hat{r}_{t+1}). \quad (3.36)$$

3.4. Handelsstrategie

Die in Abschnitt 3.3 vorgestellten Modelle liefern jeweils eine Preisprognose für einen künftigen Zeitpunkt $t + k$. Um ihre realistische Anwendbarkeit zu bewerten, wird eine einheitliche, regelbasierte Handelsstrategie definiert, die für alle Modelle identisch ist. Dies stellt sicher, dass Performanceunterschiede im Backtesting ausschließlich auf die Prognosegüte der Modelle zurückzuführen sind und testet alle Modelle auf ihre praktische Anwendbarkeit. Die Strategie umfasst die drei Komponenten Forecasting Horizon k , das Handelssignal sowie die Positionsgröße.

3.4.1. Forecasting Horizon

Die Wahl des Forecasting Horizons k beeinflusst, welche Arten von Mustern ein Modell erlernen muss und wie stark Rauschen die Prognose beeinträchtigt. Es lässt

sich empirisch zeigen, dass auf dem Eintages-Horizont $k = 1$ der stärkste Informationsgehalt technischer Signale liegt, da sich Informationen schnell einpreisen und Prognosen über mehrere Tage von nicht modellierbarem Rauschen dominiert werden [33]. Darüber hinaus minimiert $k = 1$ das sogenannte Compounding-Risiko. Wird eine Position mehrere Tage gehalten, akkumulieren sich Prognosefehler über jeden einzelnen Schritt, sodass die tatsächliche Rendite von der erwarteten Rendite weiter abweicht [34]. Der Forecasting Horizon wird daher auf $k = 1$ festgelegt, d. h. jedes Modell gibt täglich eine Prognose $\hat{P}_{t+1}$ ab, auf deren Basis die Handelsentscheidung für den nächsten Tag getroffen wird.

3.4.2. Handelssignal

Die Strategie beschränkt sich auf Long-Positionen und Cash, d. h. Short-Selling wird ausgeschlossen. Das umgeht Liquiditätsprobleme und vermeidet das unbegrenzte Verlustrisiko von Short-Positionen [35].

Ein Kaufsignal auf Basis des Vorzeichens der vorhergesagten Rendite ($\hat{r}_{t+1} > 0 \Rightarrow$ kaufen) ist zwar einfach, aber anfällig gegenüber Modellrauschen. Kleine positive Prognosen nahe null enthalten wenig Informationen und führen zu unnötigen Transaktionen [36]. Daher wird ein Schwellenwert $\varepsilon > 0$ eingeführt, unterhalb dessen keine Position eingegangen wird:

$$\text{Signal}_t = \begin{cases} \text{Long} & \text{wenn } \hat{r}_{t+1} > \varepsilon, \\ \text{Hold} & \text{wenn } -\varepsilon \leq \hat{r}_{t+1} \leq \varepsilon, \\ \text{Cash} & \text{wenn } \hat{r}_{t+1} < -\varepsilon. \end{cases} \quad (3.37)$$

Der Schwellenwert ε wird als die mittlere absolute Prognoseabweichung (MAE) des jeweiligen Modells auf den Validierungsdaten $\mathcal{V}$ gesetzt.

$$\varepsilon = \text{MAE}_{\text{val}} = \frac{1}{|\mathcal{V}|} \sum_{t \in \mathcal{V}} |\hat{r}_{t+1} - r_{t+1}|. \quad (3.38)$$

Das bedeutet, dass eine Kaufentscheidung nur dann getroffen wird, wenn die vorhergesagte Rendite die typische Prognoseunsicherheit des Modells übersteigt. Liegt die Vorhersage innerhalb des Unsicherheitsbereichs $[-\varepsilon, \varepsilon]$, wird die aktuelle Position beibehalten. Erst bei einer stark negativen Prognose unterhalb von $-\varepsilon$ werden alle Positionen geschlossen [37].

3.4.3. Positionsgröße

Die Bestimmung der Positionsgröße folgt dem Kelly-Kriterium, das die langfristige Wachstumsrate des Kapitals maximiert [38]. Im Gegensatz zu einer fixen Positionsgröße berücksichtigt das Kelly-Kriterium das Verhältnis von erwartetem Gewinn zu erwartetem Verlust.

In seiner klassischen Form für kontinuierliche Renditen lautet der Kelly-Anteil [39]:

$$f^* = \frac{\mu}{\sigma^2}, \quad (3.39)$$

wobei μ die erwartete Rendite und σ^2 die Varianz der Renditen bezeichnet. Da beide Größen unbekannt sind, werden sie auf einem rollierenden Fenster der letzten $w_K = 60$ Handelstage geschätzt:

$$\hat{\mu}_t = \frac{1}{w_K} \sum_{i=1}^{w_K} r_{t-i}, \quad \hat{\sigma}_t^2 = \frac{1}{w_K - 1} \sum_{i=1}^{w_K} (r_{t-i} - \hat{\mu}_t)^2. \quad (3.40)$$

Das volle Kelly-Kriterium führt in der Praxis jedoch zu extremen Positionsgrößen und ist gegenüber Schätzfehlern in $\hat{\mu}_t$ anfällig [40]. Es ist daher üblich, einen Kelly-Anteil zu verwenden. In dieser Arbeit wird Half-Kelly eingesetzt [39]:

$$f_t = \frac{1}{2} \cdot \frac{\hat{\mu}_t}{\hat{\sigma}_t^2}. \quad (3.41)$$

Da weder Short-Selling noch Hebel-Trading betrachtet werden, wird f_t auf das Intervall $[0, 1]$ beschränkt, indem negative Werte auf 0 und Werte größer 1 auf 1 gesetzt werden.

Ist also zum Zeitpunkt t $\text{Signal}_t = \text{Long}$, wird die Position so angepasst, dass sie dem Anteil f_t vom Gesamtportfoliowert entspricht. Dies kann auch einer Reduktion der Position entsprechen. Das Signal bedeutet hierbei lediglich, dass weiterhin investiert werden sollte. Ist $\text{Signal}_t = \text{Hold}$, wird keine Aktion durchgeführt und die aktuelle Position beibehalten. Ist $\text{Signal}_t = \text{Cash}$, werden alle Positionen geschlossen, also alle Anteile verkauft.

3.5. Einschränkungen und Nebenbedingungen

Da im Rahmen dieser Arbeit nicht alle realistischen Marktszenarien berücksichtigt werden können, müssen einige Annahmen getroffen werden.

Kommission

Kommission ist eine Gebühr, die ein Broker oder eine Börse für die Ausführung einer Order verlangt. Diese ist meistens prozentual abhängig vom Ordervolumen und fällt sowohl beim Kauf als auch beim Verkauf an. Dadurch wird die Profitabilität eines Portfolios reduziert. In den letzten Jahren haben sich die Kommission drastisch reduziert. Im Jahr 1970 lagen sie noch bei ca. 1% des Ordervolumens. Durch Neobroker und Konkurrenz unter Brokern ist die Kommission mittlerweile stark gesunken, teilweise auf bis zu 1US\$ pro Trade. Um die Arbeit unabhängig von Änderungen in der Praxis in Bezug auf Kommissionen zu halten, wird bei den Backtests dieser Arbeit keine Kommission berechnet [41].

Spread

Der Spread ist die Differenz zwischen Kaufpreis und Verkaufspreis einer Aktie. Dieser ist an einer Börse meist unterschiedlich, wobei der Kaufpreis höher als der Verkaufspreis ist. Wird eine Aktie gekauft und sofort wieder verkauft, entsteht also ein Verlust. Besonders bei Hochfrequenzhandel führt dies zu Verlusten. Da diese Arbeit ausschließlich Tagesöffnungs- und -schlusskurse verwendet, kann kein Spread betrachtet werden. Als Preis wird daher in dieser Arbeit der erste bzw. letzte gehandelte Marktpreis verwendet [41].

Liquidität

Die verwendeten Tageskurse spiegeln die tatsächlich gehandelten Preise wider, berücksichtigen jedoch nicht, ob zum angegebenen Preis tatsächlich ausreichend Volumen für eine Order verfügbar gewesen ist. Da ausschließlich liquide Aktien aus dem S&P500 verwendet werden, wird angenommen, dass alle Transaktionen zum beobachteten Preis ausgeführt werden können. Um eine Verzerrung durch simultane Informationsnutzung zu vermeiden, werden Kaufentscheidungen, die auf dem Schlusskurs eines Tages basieren, zum Eröffnungskurs des folgenden Tages ausgeführt. Auf diese Weise wird sichergestellt, dass Entscheidungen ausschließlich auf Basis von Informationen getroffen werden, die zu diesem Zeitpunkt bereits verfügbar waren [42].

3.6. Metriken

Die Bewertung der genannten Modelle erfolgt in zwei Schritten. Nachdem die Vorhersagemodelle in Abschnitt 3.3 vorgestellt wurden, werden sie in dem genannten Testzeitraum in einem etablierten Walk-Forward jeweils für jede ausgewählte Aktie getestet. Das bedeutet, es wird die tatsächliche Historie der Aktienkursbewegung simuliert und es werden jeweils Vorhersagen erstellt. Die erstellten Ergebnisse

lassen sich nicht gesichert auf die Zukunft übertragen, aber zeigen wie gut das Modell in der Vergangenheit funktioniert hätte [43]. Anschließend werden sie anhand der in Abschnitt 3.6.1 vorgestellten Fehlermaße bewertet.

Mithilfe der in Abschnitt 3.4 entwickelten Handelsstrategien, werden die Modelle dann praxisnah getestet. Es wird ein virtuelles Portfolio angelegt, mit einem Startkapital von $V_0 = 100.000$ US\$. Die Modelle werden in einem Walk-Forward jeweils pro Aktie getestet, wobei die Modelle eine Preisreihe ab dem aktuellen Tag vorhersagen und anhand der in Abschnitt 3.4 vorgestellten Kriterien eine Kauf- oder Verkaufsentscheidung simuliert wird. Dadurch kann der Portfoliowert steigen und fallen. Am Ende des Testzeitraums erfolgt eine Bewertung anhand der in Kennzahlen in Abschnitt 3.6.2.

Ziel der Bewertungen ist immer ein Modellvergleich der vorgestellten Modelle untereinander.

3.6.1. Fehlermaße

Die Extrapolation von Zeitreihen ist ein weitreichend untersuchtes Gebiet. Dadurch haben sich einige Fehlermaße zur Bewertung der Verfahren etabliert. Zu den am häufigsten verwendeten zählen unter anderem MAPE, RMSE, MSE, Directional Accuracy (DA), R^2 und MAE [10, 44]. Um eine möglichst hohe Vergleichbarkeit mit anderen Arbeiten zu gewährleisten, werden MAPE und DA verwendet. Um die Aussagekraft der Analyse zu erhöhen, wird zudem das Out-Of-Sample R^2 (OOS- R^2)-Maß herangezogen, welches misst, wie viel Varianz ein Modell im Vergleich zu einem Random Walk ($P_{t+1} = P_t$) als naivem Benchmark erklärt.

Hierbei sei anzumerken, dass viele Arbeiten einen R^2 -Score anhand von Preisen als Metrik verwenden, zum Beispiel [45, 46, 47, 48]. Diese Bewertung ist wenig aussagekräftig, da Aktienkurse stark autokorreliert sind ($P_t \approx P_{t-1}$), und somit ein R^2 -Score von $> 0,9$ eine nicht vorhandene, außerordentlich gute Modellqualität anzeigt. Ein so berechneter R^2 -Score ist somit nur als Vergleichswert und nicht als

eigenständiges Maß interpretierbar. Sinnvoll ist nur eine R^2 -Analyse auf Renditen, anstatt auf Preisen. Da diese Arbeit das OOS- R^2 -Maß auf Renditen verwendet, wird diese Ungenauigkeit eliminiert.

Die formalen mathematischen Definitionen aller verwendeten Fehlermaße sind in Anhang A zu finden.

3.6.2. Finanzwirtschaftliche Kennzahlen

Viele Arbeiten, die sich mit Zeitreihenextrapolation beschäftigen und insbesondere die zu Aktienkursvorhersagen, beenden die Evaluation nach der Untersuchung der Fehlermaße [10]. Da diese Arbeit einen weiteren praktischen Fokus fasst, soll auch die praktische Anwendbarkeit, und damit finanzwirtschaftlich evaluiert werden. Außerdem ist im Falle von Aktienkursvorhersage eine Fehlerminimierung nicht zwingend das optimale Ziel in Bezug auf die praktische Anwendung [49].

Viele Arbeiten, die auch die reale Anwendbarkeit testen, fokussieren sich auf Gesamtrendite, Sharpe Ratio und Maximum Drawdown [50, 51, 52]. Weitere, seltener verwendete Kennzahlen sind das Sortino Ratio, Calmar Ratio und Value-at-risk threshold [43]. Alle Metriken befassen sich mit Rendite oder Volatilität. Um diese beiden Kennzahlen einer Strategiequalität abzubilden, werden in dieser Arbeit die Gesamtrendite, der Excess Return und der Maximum Drawdown verwendet. Da Risiko und Rendite in der Finanzwelt keine unabhängigen Größen darstellen, sondern sich häufig beeinflussen, wird ebenso die Sharpe-Ratio evaluiert.

Die formalen mathematischen Definitionen aller verwendeten finanzwirtschaftlichen Kennzahlen sind in Anhang A zu finden.

4. Implementierung

4.1. Technische Grundlagen

4.1.1. Backtrader Framework

Für die Evaluation der Handelsstrategien wird das Python-Framework **Backtrader** [53] verwendet. **Backtrader** ist eine etablierte Open-Source-Lösung für Backtesting und Live-Trading, die eine ereignisgesteuerte Architektur bietet. Die Wahl fiel auf **Backtrader** aus folgenden Gründen:

- **Walk-Forward-Unterstützung:** Das Framework ermöglicht die sequentielle Verarbeitung historischer Daten Bar-für-Bar, wodurch ein realistischer Handelsverlauf simuliert wird, bei dem zu jedem Zeitpunkt nur vergangene Informationen verfügbar sind.
- **Integrierte Metriken:** Analyzer-Klassen für Sharpe Ratio, Maximum Drawdown und weitere Finanzkennzahlen sind bereits implementiert und können erweitert werden.
- **Modularität:** Strategien, Datenfeeds und Analyzer sind unabhängige Komponenten, die flexibel kombiniert werden können.
- **Reproduzierbarkeit:** Deterministisches Verhalten bei festen Seeds ermöglicht wiederholbare Experimente.

Die zentrale Steuerungsklasse **Cerebro** orchestriert den Backtest-Prozess. Sie verwaltet Datenfeeds, führt die Handelsstrategie aus, protokolliert Transaktionen und aggregiert Metriken über die eingebundenen Analyzer.

4.1.2. Walk-Forward Testing

Der Backtest erfolgt im Walk-Forward-Verfahren, um Lookahead Bias zu vermeiden. Bei jedem simulierten Handelstag t führt das Backtrader-System folgende Schritte aus:

1. Laden des aktuellen Schlusskurses p_t und aller historischen Kurse bis einschließlich t
2. Aktualisierung des Modells mit p_t (z. B. Hinzufügen zum Zeitfenster)
3. Generierung einer Vorhersage $\hat{p}_{t+1}$ ausschließlich auf Basis von Daten bis t
4. Berechnung des Handelssignals und Ausführung von Transaktionen zum Schlusskurs von Tag t
5. Fortschreiten zum nächsten Tag $t + 1$
6. Nach Ablauf des Zeitraums T werden die Analyser automatisch ausgeführt und die definierten Metriken zurückgegeben.

Dieses Vorgehen stellt sicher, dass das Modell zu keinem Zeitpunkt Zugriff auf zukünftige Informationen hat. Die Vorhersage für Tag $t + 1$ basiert ausschließlich auf der Historie bis einschließlich Tag t .

4.1.3. Datenhaltung

Die historischen Kursdaten werden als CSV-Dateien von der Yahoo Finance API bezogen. CSV wurde als Austauschformat gewählt, da es menschenlesbar ist und von den meisten Finanzmarkt-APIs unterstützt wird. Für die Verarbeitung werden die Daten in das Parquet-Format konvertiert, da der Speicherbedarf etwa 80% geringer ist als bei CSV und Spaltenweise Speicherung effiziente Zugriffe ermöglicht. Außerdem erfolgt so weniger String-Konvertierung, die zu Fehlern führen kann. Die Konvertierung erfolgt einmalig nach dem Download. Alle nachfolgenden Verarbeitungsschritte arbeiten mit den Parquet-Dateien.

4.2. Systemarchitektur

Die Implementierung ist in zwei Skripte aufgeteilt. Das erste Skript ist für die Aktienausswahl zuständig, während das zweite Skript die drei Modelle trainiert und evaluiert. Abb. 4.1 zeigt den Datenfluss der Implementierung über beide Skripte hinweg. Diese Aufteilung ermöglicht es, die Aktienausswahl unabhängig von der Modellevaluation durchzuführen.




Abbildung 4.1.: Gesamtüberblick: Datenfluss von der Beschaffung bis zur Evaluation

4.3. Aktienauswahl

4.3.1. Skript zur Aktienauswahl

Voraussetzung für die Ausführung des Skripts sind die Konfigurationsdatei, die historischen Kursdaten der Aktien und die historischen Daten der Makrofaktoren. Sind diese Voraussetzungen nicht erfüllt, bricht das Skript mit einem Fehler ab. Die Konfigurationsdatei (YAML-Format) enthält folgende Parameter:

Parameter	Beschreibung
Liste an Aktien	Alle Aktien, die zum Training verwendet werden, falls das Auswahlskript nicht ausgeführt wird
Trainingszeitraum	Start- und Enddatum für Trainingsdaten
Validierungszeitraum	Start- und Enddatum für Validierungsdaten
Testzeitraum	Start- und Enddatum für Testdaten
Gesamtzeitraum	Start- und Enddatum für den Download aller Daten
Download-Konfiguration	Optionen für bereinigte Daten und Überschreiben vorhandener Daten
Liste der Makrofaktoren	Makrofaktoren, die zum Training verwendet werden
Auswahlparameter	Anzahl Simulationen, Gruppengröße und Anzahl auszuwählender Aktien

Tabelle 4.1.: Parameter der Konfigurationsdatei für die Aktienauswahl

Die in dieser Arbeit verwendeten Werte lauten: Trainingszeitraum 2020–01–02 bis 2023–12–29, Validierungszeitraum 2024–01–02 bis 2024–06–28, Testzeitraum 2024–07–01 bis 2025–12–31, 100 Simulationen, Gruppengröße 4, Auswahl der 10 bestplatzierten Aktien. Als Makrofaktoren werden die 6 in Tabelle 3.2 genannten Zeitreihen verwendet.

Die historischen Kursdaten der Aktien und die historischen Daten der Makrofaktoren werden über ein separates Download-Skript bereitgestellt, das die `yfinance`-Bibliothek nutzt. Die Implementierung verwendet `pandas` für das Laden und

Filtern der Zeitreihendaten, PyYAML für das Parsen der Konfiguration und `numpy` für numerische Berechnungen im SDE-Selector.

Das Skript verwendet eine statische Liste der S&P-500-Konstituenten vom Januar 2020, um Survivorship Bias zu vermeiden. Die Aktienausswahl ist in Algorithmus 1 dargestellt. Die 500-Datenpunkte-Schwelle entspricht etwa 2 Jahren Handelshistorie

Algorithmus 1 Skript Aktienausswahl

Voraussetzung: Konfigurationsdatei, historische Kursdaten, Makrofaktoren

```

1: config ← LOADCONFIG
2: train_start, train_end ← config.trainStart, config.trainEnd
3: tickers ← S&P 500 Ticker
4: stockData ← ∅
5: for all ticker ∈ tickers do
6:   Lade die Aktienkursdaten für Trainingszeitraum
7:   if Datenpunkte ≥ 500 then
8:     Füge die Schlusskurse der Aktie zu stockData hinzu
9:   end if
10: end for
11: factors ← Liste der Makrofaktoren aus config
12: factorData ← ∅
13: for all factor ∈ factors do
14:   Lade Makrofaktor-Zeitreihe für Trainingszeitraum
15:   if Datenpunkte ≥ 500 then
16:     Füge factor zu factorData hinzu
17:   end if
18: end for
19: numSimulations, groupSize, numSelected ← Werte aus config
20: selector ← SDESELECTOR(numSimulations, groupSize, numSelected)
21: selected ← SELECTOR.SELECT(stockData, factorData) Selector wird ausgeführt
22: Speichere selected als JSON
23: Die JSON-Datei mit den ausgewählten Aktien wird gespeichert.
```

(bei 252 Handelstagen pro Jahr) und schließt Aktien mit IPO, Delisting oder unvollständiger Historie während des Trainingszeitraums automatisch aus. Falls weniger als 20 Aktien oder weniger als 2 Makrofaktoren die Kriterien erfüllen, bricht das Skript mit einem Fehler ab.

Die Ausgabe erfolgt als JSON-Datei. Diese enthält die Liste der 10 ausgewählten Ticker, für jeden Ticker das dominante Faktorpaar, die Summe der Regressions-Koeffizienten $|\beta_{f_1}| + |\beta_{f_2}|$, den durchschnittlichen ROI über alle Simulationen sowie eine Beispiel-Simulationsgruppe zur Nachvollziehbarkeit.

4.3.2. SDE-basierter Auswahlprozess

Der Datenfluss der Aktienausswahl ist in Abb. 4.2 dargestellt. Die Implementierung folgt der in Abschnitt 3.2.3 beschriebenen Konzeption und ist in Algorithmus 2 als Pseudocode zusammengefasst.




Abbildung 4.2.: Aktienausswahl: Datenfluss von den historischen Kursdaten und Makrofaktoren bis zu den ausgewählten Aktien

Algorithmus 2 SDE-Selector Implementierung

Voraussetzung: *stockData*, *factorData*, *numSimulations*, *groupSize*, *numSelected*

```

1:                                     ▷ 1. Diskretisierung: Preise → Richtungen  $\{-1, 0, +1\}$ 
2: for all ticker  $\in$  stockData do
3:   stockDirs[ticker]  $\leftarrow$  np.sign(np.diff(stockData[ticker]))
4: end for
5: for all factor  $\in$  factorData do
6:   factorDirs[factor]  $\leftarrow$  np.sign(np.diff(factorData[factor]))
7: end for
8:                                     ▷ 2–3. Beta-Koeffizienten via OLS + dominantes Faktorpaar
9: X  $\leftarrow$  [1, factorDirs]T                                     ▷ Design-Matrix
10: for all ticker  $\in$  stockData do
11:    $\beta \leftarrow$  np.linalg.lstsq(X, stockDirs[ticker])
12:   dominantPairs[ticker]  $\leftarrow$  arg max(i,j)  $|\beta_i| + |\beta_j|$  via combinations(6,2)
13: end for
14:                                     ▷ 4. Poolbildung nach dominantem Faktorpaar
15: Gruppieren Aktien mit identischem dominantPairs in Pools
16: rankings  $\leftarrow$   $\emptyset$ 
17: for iteration = 1 to numSimulations do
18:                                     ▷ 5. Zufällige Simulationsgruppen à 4 Aktien pro Pool
19:   groups  $\leftarrow$  zufällige Gruppen à groupSize aus jedem Pool
20:   for all group  $\in$  groups do                                     ▷ 6. SDE-Simulation via Euler-Maruyama
21:     Berechne  $\mu$ ,  $\Sigma$  aus Wahrscheinlichkeiten  $p(c)$  (Gl. 3.10)
22:     B  $\leftarrow$  np.linalg.cholesky( $\Sigma$ )
23:     S  $\leftarrow$  [1, ..., 1], F  $\leftarrow$  [1, ..., 1]
24:     for day = 1 to 378 do
25:       Z  $\sim \mathcal{N}(0, I)$ 
26:       S  $\leftarrow$  S +  $\mu_S \Delta t$  + Bstock  $\sqrt{\Delta t}$  Z
27:       F  $\leftarrow$  F +  $\mu_F \Delta t$  + Bfactor  $\sqrt{\Delta t}$  Z
28:     end for
29:     roi  $\leftarrow$  (S – 1), winner  $\leftarrow$  arg max(roi)
30:     Speichere Platzierung in rankings
31:   end for
32: end for
33:                                     ▷ 7. Durchschnittsrang berechnen und Top-N auswählen
34: Rückgabe Top numSelected Aktien nach durchschnittlichem Rang

```

Zur Nachvollziehbarkeit wird die erste Simulationsgruppe als Plot gespeichert, der die normalisierten Verläufe aller 4 Aktien und 2 Faktoren über 378 Tage zeigt.

4.4. Vorhersagemodelle

4.4.1. Evaluationsskript

Voraussetzung für die Ausführung des Skripts sind die Konfigurationsdatei, die Modellkonfiguration, die historischen Kursdaten der ausgewählten Aktien und die Liste mit den ausgewählten Aktien. Sind diese Voraussetzungen nicht erfüllt, werden die betroffenen Aktien und Modelle übersprungen. Das Skript ist in Algorithmus 3 dargestellt. Die Imple-

Algorithmus 3 Skript Modellevaluation

Voraussetzung: Konfigurationsdatei, Modellkonfiguration, historische Kursdaten, ausgewählte Aktien

```

1: config ← LOADCONFIG
2: stocks ← Liste der ausgewählten Aktien
3: models ← Modellkonfiguration (LinearSeparation, Preprocessed SVR, TimesFM)
4: results ← ∅
5: for all ticker ∈ stocks do
6:   train, val, test ← GETDATASPLIT(ticker, config)           ▷ 60/10/30 Split
7:   if |test| < 60 then
8:     Überspringe ticker
9:   end if
10:  for all model ∈ models do
11:    trainedModel ← MODEL.TRAIN(train, val)
12:    metrics ← RUNBACKTEST(trainedModel, test, model.config)
13:    Füge metrics mit ticker und model.name zu results hinzu
14:  end for
15: end for
16: Ausgeben der results
17: Ausgeben der aggregierten Durchschnittswerte pro Modell

```

mentierung verwendet **pandas** für Datenverarbeitung, **backtrader** als Backtest-Engine und **argparse** für ein Command-Line-Interface. Das Skript definiert ein Dictionary, das für jedes Modell die Trainingsmethode, den Forecast-Horizon und die Warmup-Period spezifiziert.

Die Modellauswahl erfolgt über Command-Line-Argumente (`-models LinearSeparation SVR TimesFM`), was eine flexible Evaluation einzelner oder aller Modelle ermöglicht.

Das genaue Training der Modelle wird in Abschnitt 4.4.3, Abschnitt 4.4.4 und Abschnitt 4.4.5 beschrieben. Für jede Aktie wird auf den Validierungsdaten der MAE berechnet, um den Signal-Threshold ε zu bestimmen. Dies erfolgt außerhalb von Backtrader durch eine dedizierte Funktion, die die Validierungsdaten manuell durchläuft, für jeden Zeitpunkt die Vorhersage und den tatsächlichen Log-Return berechnet und die absoluten Fehler mittelt. Der so ermittelte ε -Wert wird anschließend der Backtest-Engine übergeben.

Die trainierten Modelle werden dann mit den Testdaten in der Backtest-Engine evaluiert. Eine genaue Beschreibung der Backtest-Engine findet sich in Abschnitt 4.4.2. Die Ausgabe erfolgt strukturiert pro Modell in separaten Verzeichnissen. Jedes Modell erhält eine JSON-Datei mit allen Metriken und eine CSV-Datei mit Trade-Statistiken (Anzahl Käufe/Verkäufe/Closes pro Aktie). Zusätzlich wird für jede Aktie ein Walk-Forward-Plot mit `matplotlib` generiert, der Portfoliowert, tatsächliche Kurse, Vorhersagen und Handelssignale visualisiert.

4.4.2. Backtest-Engine

Die Methode `RunBacktest` ist in Algorithmus 4 dargestellt. Sie simuliert eine Handelsstrategie auf den Testdaten und berechnet die Evaluationsmetriken im Walk-Forward-Verfahren gemäß Abschnitt 4.1.2. Die Backtest-Engine nutzt die `Cerebro`-Klasse von Backtrader als zentrale Steuerungseinheit (siehe Abschnitt 4.1.1). Die Testdaten werden als `PandasDataFeed` eingebunden, der Backtrader das schrittweise Durchlaufen der historischen Daten im Walk-Forward-Verfahren ermöglicht. Die Handelsstrategie `PredictionStrategy` erhält das trainierte Modell sowie die modellspezifischen Parameter (ε , Forecast-Horizon, Warmup-Period).

Backtrader bietet integrierte Analyzer für Sharpe Ratio (mit Riskfreerate 2%) und Maximum Drawdown. Für die Vorhersagemetriken werden custom Analyzer implementiert, die bei jedem Zeitschritt die Modelvorhersage mit dem tatsächlichen Kurs vergleichen und MAPE, R^2_{OOS} und DA akkumulieren. Nach Ausführung der Simulation extrahiert das Skript die Finanzkennzahlen (Total Return, Buy-and-Hold Return, Excess Return) sowie die Analyzer-Ergebnisse und gibt diese als Dictionary zurück.

Algorithmus 4 RunBacktest Methode

Voraussetzung: trainiertes Modell, Testdaten, Modellkonfiguration

- 1: *cerebro* $\leftarrow$ neue Backtest-Engine
 - 2: Füge *testDaten* im Yahoo-Finance-Format zu *cerebro* hinzu
 - 3: Füge *PredictionStrategy* mit Modell und Konfigurationsparametern hinzu
 - 4: Setze Startkapital auf \$100.000
 - 5: Füge Analyzer hinzu: Sharpe-Ratio, Drawdown, MAPE, R_{OOS}^2 , DA
 - 6: *ergebnis* $\leftarrow$ Führe *cerebro* aus
 - 7: *totalReturn* $\leftarrow$ (*Endwert* – *Startkapital*)/*Startkapital*
 - 8: *bhReturn* $\leftarrow$ (*letzterKurs* – *ersterKurs*)/*ersterKurs*
 - 9: *excessReturn* $\leftarrow$ *totalReturn* – *bhReturn*
 - 10: Extrahiere Sharpe-Ratio, max. Drawdown und Vorhersagemetriken aus Analyzern
 - 11: **Rückgabe** Metriken: *totalReturn*, *bhReturn*, *excessReturn*, Sharpe, Drawdown, MAPE, R_{OOS}^2 , DA
-

4.4.3. LinearSeparation

Das Modell ist als Python-Klasse implementiert, die als Objekt in der Backtrader-Strategie gehalten wird. Der Datenfluss ist in Abb. 4.3 dargestellt. Die Implementierung verwendet `statsmodels` für HP-Filter und ARMA-Modellierung.

Die logarithmierten Schlusskurse werden mit zwei aufeinanderfolgenden HP-Filtern zerlegt. Hodrick und Prescott [13] empfehlen für Quartalsdaten $\lambda = 1600$. Bei Tagesdaten liegen etwa $252/4 = 63$ Beobachtungen pro Quartal vor, also eine um Faktor 63 höhere Frequenz. Um bei höherer Datenfrequenz die gleiche relative Glättungswirkung zu erzielen, wird λ mit dem Quadrat der Frequenzerhöhung multipliziert: $\lambda_{\text{lang}} = 1600 \cdot 63^2 \approx 6,35 \times 10^6$. In der Implementierung wird vereinfacht $\lambda_{\text{lang}} = 1600 \cdot 252^2 \approx 1,01 \times 10^8$ verwendet, um einen mehrjährigen strukturellen Trend zu erfassen. Das erste Residuum wird erneut gefiltert mit $\lambda_{\text{kurz}} = 1600$, was Bewegungen im Wochenbereich erfasst.

Die Trends werden über Rolling Windows ($w_{\text{lang}} = 252$ Tage, $w_{\text{kurz}} = 40$ Tage) linear extrapoliert. Das ARMA-Modell wird auf die zyklische Komponente gefittet. Die drei Vorhersagen werden addiert und exponentiert.

Bei jedem Walk-Forward-Schritt wird `update()` aufgerufen, das den neuen Preis anhängt (Rolling Window 500 Tage) und die HP-Filter neu berechnet. Das ARMA-Modell wird aus Performancegründen nur alle 5 Tage neu gefittet.




Abbildung 4.3.: LinearSeparation: Datenfluss von den Trainingsdaten bis zum trainierten Modell

4.4.4. Preprocessed SVR

Das Modell ist als Python-Klasse implementiert, die als Objekt in der Backtrader-Strategie gehalten wird. Die Implementierung verwendet `sklearn.svm.SVR` mit RBF-Kernel sowie `sklearn.preprocessing.StandardScaler` zur Feature-Normalisierung.

In jedem Backtrader-Event-Loop-Schritt werden aus den bis dahin verfügbaren historischen OHLCV-Daten die neun Features berechnet, deren Komponenten in Abschnitt 3.3.2 beschrieben sind. Diese Berechnung erfolgt über die vergangenen Tage im internen Datenpuffer. Als Target-Werte dienen die Log>Returns des Schlusskurses. Die Features werden mittels `StandardScaler` z-standardisiert.

Für die Hyperparameteroptimierung wird ein Grid Search über die Validierungsdaten durchgeführt. Die durchsuchten Wertebereiche sind $C \in \{0.1, 1, 10, 100, 1000\}$, $\varepsilon \in \{0.001, 0.01, 0.05, 0.1, 0.5\}$ und $\gamma \in \{0.001, 0.01, 0.1, 1, 10, \text{'scale'}, \text{'auto'}\}$. Die Parameterkombination mit dem niedrigsten RMSE auf den Validierungsdaten wird für die finalen Tests verwendet.

Im Walk-Forward-Verfahren werden neue OHLCV-Daten täglich in einen internen Datenpuffer eingefügt. Zur Vorhersage werden die aktuellen Features skaliert und in das trainierte SVR-Modell eingespeist. Der prognostizierte Log-Return wird durch Exponentiation und Multiplikation mit dem letzten Schlusskurs in einen prognostizierten Kurs umgewandelt. Der Datenfluss ist in Abb. 4.4 dargestellt.




Abbildung 4.4.: Preprocessed SVR: Datenfluss von den Trainingsdaten bis zur Preisprognose

4.4.5. TimesFM

Das Modell ist als Python-Klasse implementiert, die als Objekt in der Backtrader-Strategie gehalten wird. Es handelt sich um ein Zero-Shot-Modell, das nicht trainiert wird. Die Implementierung verwendet das vortrainierte Google-Modell `google/timesfm-1.0-200m-pytorch`, das von HuggingFace geladen wird. Die Inferenz wurde auf einem Apple M2 Pro Chip mit CPU-Backend ausgeführt.

Das Modell arbeitet auf Log>Returns und verwendet die letzten 512 historischen Log>Returns als Kontext für die Vorhersage. Im Walk-Forward-Verfahren werden neue Schlusskurse täglich in den internen Datenpuffer eingefügt. Zur Vorhersage wird der aktuelle Kontext in das TimesFM-Modell eingespeist, das den prognostizierten Log-Return für den nächsten Tag liefert. Dieser wird durch Exponentiation und Multiplikation mit dem letzten Schlusskurs in einen prognostizierten Kurs umgewandelt. Der Datenfluss ist in Abb. 4.5 dargestellt.




Abbildung 4.5.: TimesFM: Datenfluss der Vorhersage von neuen Kursen

4.4.6. Handelsstrategie

Die Handelsentscheidungen sind als Teil der Backtrader-Strategie implementiert. Die Positionsgrößenbestimmung erfolgt über einen separaten Backtrader-Sizer, der das Half-Kelly-Kriterium aus Abschnitt 3.4.3 implementiert.

Die Signal-Schwelle ε wird aus dem MAE auf den Validierungsdaten berechnet. In jedem Event-Loop-Schritt wird der prognostizierte Log-Return $\hat{r}_{t+1}$ mit ε verglichen. Bei $\hat{r}_{t+1} > \varepsilon$ wird ein Long-Signal generiert, bei $\hat{r}_{t+1} < -\varepsilon$ ein Cash-Signal, ansonsten wird die Position gehalten.

Der Half-Kelly-Sizer verwendet ein rollendes Fenster von 60 Handelstagen zur Berechnung der Zielfraktion. Bei einem Long-Signal wird die Differenz zwischen Zielposition und aktueller Position als Order ausgeführt, was sowohl einem Kauf als auch einem Verkauf entsprechen kann. Bei einem Cash-Signal werden alle Positionen geschlossen. Der Ablauf ist in Algorithmus 5 dargestellt.

Algorithmus 5 PredictionStrategy – Handelsstrategie

Voraussetzung: trainiertes Modell M , Testdaten, ε (Signal-Schwelle)

```

1: for all Tag  $t$  in Testdaten do
2:    $p_t \leftarrow$  aktueller Schlusskurs
3:   Aktualisiere Modell  $M$  mit  $p_t$ 
4:    $\hat{p}_{t+1} \leftarrow$  Vorhersage von  $M$  für nächsten Tag
5:    $\hat{r}_{t+1} \leftarrow \log(\hat{p}_{t+1}/p_t)$ 
6:   if  $\hat{r}_{t+1} > \varepsilon$  then
7:     Passe Position an Half-Kelly-Ziel an (Kaufen oder Reduzieren)
8:   else if  $\hat{r}_{t+1} < -\varepsilon$  then
9:     Schließe alle Positionen (Verkaufen)
10:  else
11:    Halte aktuelle Position
12:  end if
13: end for

```

5. Ergebnisse und Bewertung

In diesem Kapitel werden die Ergebnisse der in Kapitel 3 vorgestellten Verfahren präsentiert. Zunächst wird in Abschnitt 5.1 die SDE-basierte Aktienausswahl durchgeführt, um aus dem S&P500-Universum zehn Aktien für die weitere Analyse zu selektieren und die Zwischenergebnisse so wie Endergebnisse der SDE-Simulation vorgestellt. In Abschnitt 5.1.3 werden die final gewählten Aktien aufgelistet und die Qualität des SDE Ansatzes evaluiert, sowie Stärken und Schwächen benannt und Gründe für die Performance diskutiert. Anschließend folgt die Evaluation der Vorhersagemodelle und danach die Bewertung. In Abschnitt 5.2, Abschnitt 5.3 und Abschnitt 5.4 werden jeweils die gemessenen Metriken der jeweiligen Modelle vorgestellt. Für jedes Modell werden die Ergebnisse für ε -Threshold, Fehlermaße, Finanzkennzahlen und Trading Performance vorgestellt. Außerdem wird je ein beispielhafter Walk-Foward Durchlauf präsentiert. In Abschnitt 5.5 werden dann die Vorhersagemodelle verglichen. Explizit wird in Abschnitt 5.5.1 die Performance der Vorhersagemodelle in allen Metriken einander gegenüber gestellt. In Abschnitt 5.5.2 wird das Handelsverhalten der Modelle verglichen. In Abschnitt 5.5.3 erfolgt abschließend die Bewertung und Interpretation aller Ergebnisse. Es werden Gründe für die Performance der Modelle diskutiert, es werden Schlüsse aus den Vergleichen gezogen und eine Bewertung der Modelle präsentiert.

5.1. SDE Aktienausswahl

Das in Abschnitt 3.2.3 beschriebene Verfahren zur Aktienausswahl wurde auf dem S&P500-Universum (Stand Januar 2020) angewendet. Es wurden Kursdaten, sowie die Preisdaten der sechs makroökonomischen Faktoren aus Tabelle 3.2 für den Trainingszeitraum (01.2020–12.2023) verwendet.

5.1.1. Dominante Faktorpaare

Im ersten Schritt wurde für jede Aktie mittels OLS-Regression das dominante Faktorpaar bestimmt. Die Summe der Betragskoeffizienten $|\beta_{i,j}| + |\beta_{i,k}|$ gibt an, wie stark die diskretisierten Kursbewegungen der Aktie mit den beiden Faktoren korrelieren. Tabelle 5.1 zeigt einen Ausschnitt der Aktien mit den höchsten Beta-Summen.

Ticker	Faktor 1	Faktor 2	$\sum \beta $
MSFT	Staatsanleihe	S&P500	0,661
TEL	Gold	S&P500	0,656
MCO	Staatsanleihe	S&P500	0,647
ACN	Staatsanleihe	S&P500	0,641
TXN	Öl	S&P500	0,638
AAPL	Staatsanleihe	S&P500	0,628
AMP	Staatsanleihe	S&P500	0,628
APA	Öl	S&P500	0,626

Tabelle 5.1.: Aktien mit höchsten Beta-Summen (Ausschnitt)

Die Verteilung der dominanten Faktorpaare über alle Aktien zeigt, dass der S&P500-Index in fast allen Kombinationen vertreten ist (Tabelle 5.2). Dies entspricht der Erwartung, dass Aktien innerhalb des Index stark mit dem Gesamtmarkt korrelieren.

Faktorpaar	Anzahl Aktien	Anteil
Staatsanleihe, S&P500	179	39,8 %
Dollar, S&P500	139	30,9 %
Öl, S&P500	86	19,1 %
Gold, S&P500	30	6,7 %
Inflation, S&P500	14	3,1 %
Gold, Öl	2	0,4 %

Tabelle 5.2.: Verteilung der dominanten Faktorpaare

5.1.2. Euler-Maruyama Simulation

Nach der Gruppierung wurden 100 Monte-Carlo-Simulationen durchgeführt. In jeder Simulation wurden Gruppen aus je vier Aktien mit gemeinsamem Faktorpaar gebildet und deren Kursverläufe über 378 Handelstage, also dem gesamten Testzeitraum simuliert.

Abb. 5.1 zeigt exemplarisch eine solche Simulation für eine Gruppe mit den dominanten Faktoren Gold und S&P500. Die Kurse sind auf einen Startwert von 100 normalisiert, um die relativen Entwicklungen vergleichbar zu machen. Die durchgezogenen Linien zeigen die simulierten Aktienkurse, die gestrichelten Linien die Faktorverläufe.




Abbildung 5.1.: Beispielhafte Euler-Maruyama Simulation einer Gruppe

5.1.3. Vorhergesagte ROI und Ranking

Das hierarchische SDE-Verfahren wurde mit 100 Monte-Carlo-Simulationen durchgeführt. Für jede Aktie wurde über alle Simulationsrunden die durchschnittliche Platzierung berechnet. Eine Aktie, die häufig als Gewinner ihrer Simulationsgruppe hervorgeht, erhält eine bessere Durchschnittsplatzierung. Die qualitative Platzierung ist das entscheidende Auswahlkriterium, da der absolute simulierte ROI durch die zufällige Gruppierung stark schwanken kann.

Tabelle 5.3 zeigt die zehn durch das Verfahren ausgewählten Aktien, sortiert nach ihrer durchschnittlichen Platzierung über alle 100 Simulationsrunden. Zusätzlich werden der durchschnittliche simulierte ROI und das dominante Faktorpaar angegeben.

Rang	Ticker	Unternehmen	Ø Platz	Ø sim. ROI	Faktorpaar
1	CARR	Carrier Global Corp.	12,3	22,68 %	Öl, Gold
2	OTIS	Otis Worldwide Corp.	14,7	21,15 %	Staatsanleihe, S&P500
3	RSG	Republic Services Inc.	15,2	24,50 %	Inflation, S&P500
4	CTAS	Cintas Corp.	16,8	24,48 %	Dollar, S&P500
5	AJG	Arthur J. Gallagher & Co.	17,4	25,39 %	Dollar, S&P500
6	PEP	PepsiCo Inc.	18,9	22,92 %	Staatsanleihe, S&P500
7	TT	Trane Technologies	19,5	23,39 %	Dollar, S&P500
8	GWW	W.W. Grainger Inc.	20,1	22,74 %	Öl, S&P500
9	RMD	ResMed Inc.	21,6	20,87 %	Gold, S&P500
10	BLK	BlackRock Inc.	22,3	19,94 %	Staatsanleihe, Dollar

Tabelle 5.3.: Die zehn durch SDE-Verfahren ausgewählten Aktien nach durchschnittlicher Platzierung

Die durchschnittliche Platzierung zeigt, wie konsistent eine Aktie über verschiedene Gruppierungen abschneidet. CARR erreicht mit Platz 12,3 die beste durchschnittliche Position, obwohl der simulierte ROI mit 22,68% nicht der höchste ist. Im Gegensatz dazu erreicht AJG mit dem höchsten durchschnittlichen simulierten ROI von 25,39% nur Rang 5, da die Performance stärker von der jeweiligen Gruppierung abhängt. Diese Diskrepanz unterstreicht die Notwendigkeit des Monte-Carlo-Ansatzes, da die durchschnittliche Platzierung robuster gegenüber der zufälligen Gruppierung ist als der absolute ROI-Wert einer einzelnen Simulation.

Um die Qualität des SDE-Verfahrens zu bewerten, werden die prognostizierten ROIs mit den tatsächlich realisierten Buy-and-Hold-Renditen im Testzeitraum verglichen. Tabelle 5.4 stellt die Vorhersagen den tatsächlichen Ergebnissen gegenüber.

Die durchschnittliche Abweichung beträgt +11,19 Prozentpunkte, wobei das SDE-Verfahren die Renditen tendenziell überschätzt.

Diese Abweichungen können durch verschiedene Limitierungen des SDE-Verfahrens begründet werden. Die Diskretisierung der Kursbewegungen in lediglich drei Zustände (+1, 0, -1) führt zu einem Informationsverlust, da die tatsächliche Magnitude von Preisbewegungen ignoriert wird. Eine Aktie, die konstant um +2% steigt, wird identisch behandelt

Ticker	Ø sim. ROI	Tatsächl. B&H	Abweichung
CARR	22,68 %	-12,29 %	+34,97 PP
OTIS	21,15 %	-4,88 %	+26,03 PP
RSG	24,50 %	13,11 %	+11,39 PP
CTAS	24,48 %	11,02 %	+13,46 PP
AJG	25,39 %	2,30 %	+23,09 PP
PEP	22,92 %	-6,47 %	+29,39 PP
TT	23,39 %	23,33 %	+0,06 PP
GWV	22,74 %	15,40 %	+7,34 PP
RMD	20,87 %	31,79 %	-10,92 PP
BLK	19,94 %	42,86 %	-22,92 PP
Ø	22,81 %	11,62 %	+11,19 PP

Tabelle 5.4.: Vergleich von prognostizierten und tatsächlichen Renditen

wie eine, die um +0,5% steigt. Außerdem kann die hierarchische Gruppenzuteilung zu unvorteilhaften Paarungen führen. Die Modellierung über lediglich zwei makroökonomische Faktoren und drei weitere Aktien pro Simulationsgruppe vereinfacht die komplexe Marktdynamik stark. Möglicherweise reichen die Informationen aus vergangenem Kurs sowie Einfluss von ähnlichen Aktien und den Faktoren nicht aus, um einen Aktienkurs langfristig zu skizzieren. Trotz dieser Diskrepanzen werden die ausgewählten Aktien für die Modellevaluation beibehalten. Dies gewährleistet die Vermeidung eines Lookahead Bias, da die Auswahl ausschließlich auf Informationen vor dem Testzeitraum basiert. Zudem ist das Ziel dieser Arbeit, eine stringente End-to-End-Strategie von Aktienausswahl bis zur Vorhersagemodellierung zu testen.

Ausführliche Ergebnisse der Aktienausswahl, einschließlich der dominanten Faktorpaare, Beta-Summen und durchschnittlichen ROIs für die analysierten Aktien, sind in Anhang C zu finden.

5.2. LinearSeparation

In diesem Abschnitt werden die Ergebnisse des in Abschnitt 3.3.1 vorgestellten LinearSeparation-Modells präsentiert. Das Modell wurde auf den zehn durch das SDE-Verfahren ausgewählten Aktien im Testzeitraum (07.2024–12.2025) evaluiert.

Wie in Abschnitt 3.4.2 beschrieben, wird der Schwellenwert ε für das Handelssignal aus dem MAE auf den Validierungsdaten bestimmt. Tabelle 5.5 zeigt die ermittelten Schwellenwerte für jede Aktie. Die Werte für das Modell variieren zwischen 0,28% und 1,37%.

Ticker	ε
CARR	0,58%
OTIS	1,37%
RSG	0,28%
CTAS	0,34%
AJG	0,38%
PEP	0,32%
TT	0,45%
GWW	0,44%
RMD	0,76%
BLK	0,46%
Ø	0,54%

Tabelle 5.5.: Schwellenwerte ε für das Handelssignal pro Aktie

Aktien mit höherer Volatilität wie OTIS weisen einen größeren Schwellenwert auf, da das Modell hier größere Prognosefehler produziert. Niedrigere Schwellenwerte bei Aktien wie RSG führen zu häufigeren Handelssignalen.

Die Vorhersagequalität des LinearSeparation-Modells wird anhand der in Abschnitt 3.6.1 definierten Fehlermaße bewertet. Tabelle 5.6 fasst die Ergebnisse zusammen.

Der durchschnittliche MAPE von 1,13% zeigt, dass die Vorhersagen im Mittel um etwa 1% vom tatsächlichen Kurs abweichen. Die negativen OOS- R^2 -Werte von durchschnittlich $-0,10$ deuten darauf hin, dass das Modell den Random-Walk-Benchmark nicht übertrifft. Es lässt sich beobachten, dass die Vorhersagen häufig sehr nah an den Kursen vom Vortag liegen, was bedeutet, dass das Modell zu stark interpoliert.

Ticker	MAPE (%)	OOS- R^2	DA
CARR	1,53	-0,08	0,47
OTIS	1,02	-0,14	0,48
RSG	0,83	-0,06	0,56
CTAS	1,01	-0,07	0,55
AJG	1,13	-0,15	0,53
PEP	0,97	-0,07	0,48
TT	1,26	-0,10	0,50
GWG	1,09	-0,10	0,48
RMD	1,30	-0,13	0,53
BLK	1,15	-0,09	0,55
Ø	1,13	-0,10	0,51

Tabelle 5.6.: Fehlermaße des LinearSeparation-Modells im Testzeitraum

Die DA liegt mit durchschnittlich 51,3% knapp über dem Zufallsniveau von 50%. Einzelne Aktien wie RSG (56,1%), CTAS (55,1%) und BLK (54,8%) zeigen eine leicht überdurchschnittliche Trefferquote bei der Richtungsvorhersage.

Die finanzwirtschaftliche Bewertung erfolgt anhand der in Abschnitt 3.6.2 definierten Kennzahlen. Tabelle 5.7 zeigt die Ergebnisse der simulierten Handelsstrategie mit einem Startkapital von 100.000 US\$.

Die durchschnittliche Gesamtrendite beträgt 4,06%, was unter der Buy-and-Hold-Rendite von 11,62% liegt. Die Excess-Rendite von durchschnittlich -7,56% zeigt, dass die aktive Strategie im Mittel schlechter abschneidet als ein passives Investment.

Einzelne Aktien zeigen positive Excess-Renditen:

- **AJG:** +16,70% Excess-Rendite bei positivem Sharpe Ratio von 2,49
- **RSG:** +6,82% Excess-Rendite bei Sharpe Ratio von 1,08
- **CARR:** +5,29% Excess-Rendite trotz negativer Gesamtrendite

Der durchschnittliche Maximum Drawdown von 17,58% zeigt das Risiko der Strategie. Die niedrigsten Drawdowns treten bei RSG (8,55%) und RMD (9,42%) auf, während CARR (26,46%) und GWG (25,05%) die höchsten Verlustphasen aufweisen.

Ticker	Return (%)	B&H (%)	Excess (%)	Sharpe	MDD (%)
CARR	-7,00	-12,29	5,29	-0,36	26,46
OTIS	-21,02	-4,88	-16,14	-27,93	24,44
RSG	19,93	13,11	6,82	1,08	8,55
CTAS	-3,46	11,02	-14,48	-0,76	23,58
AJG	19,00	2,30	16,70	2,49	9,95
PEP	-13,00	-6,47	-6,52	-5,06	18,21
TT	4,49	23,33	-18,83	0,07	18,33
GWW	0,50	15,40	-14,90	-0,08	25,05
RMD	8,87	31,79	-22,92	0,52	9,42
BLK	32,28	42,86	-10,58	1,70	11,79
Ø	4,06	11,62	-7,56	-2,83	17,58

Tabelle 5.7.: Trading-Performance des LinearSeparation-Modells

Die Handelsaktivität der Strategie wird in Tabelle 5.8 dargestellt. Der Signal-Threshold ε begrenzt die Häufigkeit der Trades. Im Durchschnitt werden 12,2 Trades pro Aktie über den gesamten Testzeitraum von 377 Tagen ausgeführt, was einer Frequenz von etwa einem Trade alle 31 Tage entspricht.

Die Strategie zeigt eine Long-Bias mit 68 Buy-Orders gegenüber 39 Sell-Orders. Close-Positionen (15 insgesamt) werden bei stark negativen Signalen verwendet, um vollständig aus dem Markt zu gehen. Die Handelsaktivität variiert zwischen 8 Trades (PEP) und 16 Trades (AJG), was auf unterschiedliche Marktbedingungen und Volatilitätsniveaus der einzelnen Aktien hinweist.

Eine moderate Korrelation ($r = 0,46$) zwischen der Anzahl der Trades und der Gesamtrendite deutet darauf hin, dass Aktien mit mehr Trades tendenziell bessere Ergebnisse erzielen.

Abb. 5.2 zeigt exemplarisch den Walk-Forward-Backtest für die Aktie RMD. Im oberen Teil ist der Portfoliowert über den Testzeitraum dargestellt, im unteren Teil der Aktienkurs zusammen mit den Vorhersagen und Handelssignalen. Die Visualisierung zeigt wiederholt, wie nah die Vorhersagen an den jeweiligen Kursen des Vortages orientiert sind.

Insgesamt zeigt das LinearSeparation-Modell eine moderate Performance, die deutlich unter Buy-and-Hold liegt. Die starke Orientierung der Vorhersagen am Kurs des Vortages




Abbildung 5.2.: Walk-Forward-Backtest für RMD mit LinearSeparation-Modell. Oben: Portfoliowert. Unten: Aktienkurs (schwarz), Vorhersagen (blau), Kaufsignale (grün), Verkaufssignale (rot).

Ticker	Buy	Sell	Close	Total
CARR	5	4	0	9
OTIS	7	3	4	14
RSG	9	5	1	15
CTAS	7	6	0	13
AJG	9	4	3	16
PEP	5	0	3	8
TT	8	5	1	14
GWW	5	4	0	9
RMD	6	3	2	11
BLK	7	5	1	13
Ø	6,8	3,9	1,5	12,2

Tabelle 5.8.: Trade-Verteilung des LinearSeparation-Modells über den Testzeitraum

und die negativen OOS- R^2 -Werte deuten darauf hin, dass das Modell zu wenig echte Vorhersagekraft besitzt und in vielen Fällen einer Random-Walk-Schätzung nahe kommt. Die niedrige Handelsfrequenz aufgrund des vergleichsweise hohen Schwellenwertes verstärkt zudem das Problem, dass profitable Marktbewegungen häufig nicht ausgenutzt werden können. Eine ausführliche Diskussion dieser Beobachtungen im Vergleich mit den anderen Modellen erfolgt in Abschnitt 5.5.3.

5.3. Preprocessed SVR

In diesem Abschnitt werden die Ergebnisse des in Abschnitt 3.3.2 vorgestellten Preprocessed SVR-Modells präsentiert. Das Modell wurde auf den zehn durch das SDE-Verfahren ausgewählten Aktien im Testzeitraum (07.2024–12.2025) evaluiert.

Für jede Aktie wurde mittels Grid-Search auf den Validierungsdaten die optimale Kombination der SVR-Hyperparameter bestimmt. Der Suchraum umfasste:

- $C \in \{0.1, 1, 10, 100, 1000\}$ (Regularisierung)
- $\varepsilon \in \{0.001, 0.01, 0.05, 0.1, 0.5\}$ (Epsilon-Tube)

- $\gamma \in \{0.001, 0.01, 0.1, 1, 10, \text{'scale'}, \text{'auto'}\}$ (RBF-Kernel)

Tabelle 5.9 zeigt die durch Grid-Search ermittelten optimalen Parameter für jede Aktie.

Ticker	C	ε_{SVR}	γ
CARR	0,1	0,100	0,001
OTIS	1	0,010	10,0
RSG	0,1	0,001	0,001
CTAS	0,1	0,001	0,001
AJG	0,1	0,010	0,010
PEP	1000	0,010	0,001
TT	0,1	0,001	10,0
GWW	0,1	0,010	1,0
RMD	0,1	0,050	0,010
BLK	10	0,050	0,010

Tabelle 5.9.: Optimale SVR-Hyperparameter pro Aktie (Grid-Search auf Validierungsdaten)

Die optimalen Parameter variieren stark zwischen den Aktien. Die besten Performer (CTAS, RSG) nutzen kleine ε -Werte (0,001), was auf präzisere Anpassungen hindeutet. Der Regularisierungsparameter C liegt meist bei 0,1, mit einem Ausreißer, PEP (1000), was auf eine extreme Kursbewegung hindeutet.

Wie in Abschnitt 3.4.2 beschrieben, wird der Schwellenwert ε für das Handelssignal aus dem MAE auf den Validierungsdaten bestimmt. Tabelle 5.10 zeigt die ermittelten Schwellenwerte für jede Aktie. Die Werte variieren zwischen 0,20% (RSG) und 0,47% (RMD).

Die Vorhersagequalität des SVR-Modells wird anhand der in Abschnitt 3.6.1 definierten Fehlermaße bewertet. Tabelle 5.11 fasst die Ergebnisse zusammen.

Der durchschnittliche MAPE von 1,30% zeigt, dass die Vorhersagen im Mittel um etwa 1,3% vom tatsächlichen Kurs abweichen. Die OOS- R^2 -Werte deuten mit durchschnittlich $-0,43$ darauf hin, dass das Modell bei der reinen Punktvorhersage den Random-Walk-Benchmark nicht übertrifft.

Ticker	ε
CARR	0,45%
OTIS	0,25%
RSG	0,20%
CTAS	0,24%
AJG	0,28%
PEP	0,26%
TT	0,32%
GWW	0,40%
RMD	0,47%
BLK	0,36%
Ø	0,32%

Tabelle 5.10.: Schwellenwerte ε für das Handelssignal pro Aktie (SVR)

Ticker	MAPE (%)	OOS- R^2	DA
CARR	1,70	-0,28	0,48
OTIS	0,97	-0,08	0,55
RSG	0,92	-0,24	0,56
CTAS	1,14	-0,25	0,53
AJG	1,37	-0,52	0,54
PEP	1,16	-0,48	0,49
TT	1,24	-0,09	0,53
GWW	1,58	-1,13	0,48
RMD	1,32	-0,14	0,52
BLK	1,62	-1,07	0,49
Ø	1,30	-0,43	0,52

Tabelle 5.11.: Fehlermaße des SVR-Modells im Testzeitraum

Die DA liegt mit durchschnittlich 51,8% über dem Zufallsniveau von 50%. Besonders hohe Trefferquoten zeigen RSG (55,9%), OTIS (55,1%) und AJG (53,7%).

Die finanzwirtschaftliche Bewertung erfolgt anhand der in Abschnitt 3.6.2 definierten Kennzahlen. Tabelle 5.12 zeigt die Ergebnisse der simulierten Handelsstrategie mit einem Startkapital von 100.000 US\$.

Ticker	Return (%)	B&H (%)	Excess (%)	Sharpe	MDD (%)
CARR	7,15	-12,29	19,44	0,20	15,77
OTIS	-31,80	-4,88	-26,92	-3,59	33,76
RSG	14,50	13,11	1,39	2,45	10,62
CTAS	25,73	11,02	14,71	5,25	15,96
AJG	14,40	2,30	12,10	1,08	10,68
PEP	-1,57	-6,47	4,91	-4,58	12,21
TT	9,37	23,33	-13,96	0,34	15,03
GWW	16,82	15,40	1,42	1,39	11,81
RMD	-2,42	31,79	-34,20	-1,73	8,13
BLK	13,47	42,86	-29,39	1,24	5,50
Ø	6,56	11,62	-5,05	0,20	13,95

Tabelle 5.12.: Trading-Performance des SVR-Modells

Die durchschnittliche Gesamtrendite beträgt 6,56%. Die Excess-Rendite liegt bei durchschnittlich -5,05%, was bedeutet, dass die aktive Strategie im Mittel unter Buy-and-Hold liegt.

Die Handelsaktivität der Strategie wird in Tabelle 5.13 dargestellt.

Im Durchschnitt werden 20,7 Trades pro Aktie ausgeführt, was einer Frequenz von etwa einem Trade alle 18 Tage entspricht. Die Handelsfrequenz resultiert aus dem Signal-Threshold und der Richtungsvorhersage.

Die Strategie zeigt mit 118 Buy-Orders (57,0%) und 55 Sell-Orders (26,6%) eine ausgewogenere Balance als LinearSeparation. Die 34 Close-Positionen (16,4%) deuten auf ein aktiveres Risikomanagement hin.

Ticker	Buy	Sell	Close	Total
CARR	10	6	0	16
OTIS	16	12	0	28
RSG	16	8	3	27
CTAS	10	8	1	19
AJG	15	8	5	28
PEP	14	3	6	23
TT	9	7	0	16
GWW	13	2	7	22
RMD	6	1	4	11
BLK	9	0	8	17
Ø	11,8	5,5	3,4	20,7

Tabelle 5.13.: Trade-Verteilung des SVR-Modells über den Testzeitraum

Abb. 5.3 zeigt exemplarisch den Walk-Forward-Backtest für die Aktie GWW. Im oberen Teil ist der Portfoliowert über den Testzeitraum dargestellt, im unteren Teil der Aktienkurs zusammen mit den Vorhersagen und Handelssignalen.

Die Visualisierung zeigt mehrere charakteristische Eigenschaften:

- **Vorhersagen:** Die blauen Punkte liegen weiter vom aktuellen Kurs entfernt
- **Trendfolge:** Das Modell erkennt mittelfristige Trends
- **Aktives Trading:** Häufigere Kauf- und Verkaufssignale durch niedrigeren Threshold
- **Risikomanagement:** Rechtzeitige Verkäufe bei negativen Trends

Insgesamt zeigt das SVR-Modell die beste Trading-Performance der drei Ansätze, obwohl die reine Punktvorhersagequalität laut Fehlermaßen schwächer ausfällt als bei den anderen Modellen. Die höhere Handelsfrequenz, kombiniert mit der besten DA, scheint mehr Marktgelegenheiten profitabel auszunutzen. Auch der niedrigste Maximum Drawdown deutet auf ein vergleichsweise gutes Risikomanagement hin. Die Gründe für diese Ergebnisse, insbesondere der scheinbare Widerspruch zwischen schwächeren Fehlermaßen und besserer Rendite, werden in Abschnitt 5.5.3 ausführlich diskutiert.




Abbildung 5.3.: Walk-Forward-Backtest für GWW mit SVR-Modell. Oben: Portfoliowert. Unten: Aktienkurs (schwarz), Vorhersagen (blau), Kaufsignale (grün), Verkaufssignale (rot).

5.4. TimesFM

In diesem Abschnitt werden die Ergebnisse des in Abschnitt 3.3.3 vorgestellten TimesFM Foundation Model präsentiert. Im Gegensatz zu den vorherigen Modellen arbeitet TimesFM im Zero-Shot-Modus ohne Training auf den Aktiendaten und nutzt Googles vortrainiertes 200M-Parameter-Modell.

TimesFM unterscheidet sich fundamental von den bisherigen Ansätzen, da das Modell direkt auf den Testdaten angewendet wird, ohne auf den spezifischen Aktien trainiert worden zu sein. Außerdem gehen bis zu 512 vergangene Werte im Kontextfenster in die Vorhersage ein. Die Schwellenwert-Bestimmung ε erfolgt wie bei den anderen Modellen aus dem MAE auf den Validierungsdaten. Tabelle 5.14 zeigt die ermittelten Schwellenwerte.

Ticker	ε
CARR	0,41%
OTIS	0,26%
RSG	0,16%
CTAS	0,23%
AJG	0,24%
PEP	0,22%
TT	0,32%
GWW	0,25%
RMD	0,51%
BLK	0,29%
Ø	0,29%

Tabelle 5.14.: Schwellenwerte ε für das Handelssignal pro Aktie (TimesFM)

Die Vorhersagequalität wird anhand der etablierten Fehlermaße bewertet. Tabelle 5.15 fasst die Ergebnisse zusammen.

Die OOS- R^2 -Werte liegen bei durchschnittlich $-0,03$. Ein Wert nahe null bedeutet, dass das Modell etwa gleich gut wie der Random-Walk-Benchmark abschneidet, was für ein Zero-Shot-Modell ohne aktienspezifisches Training bemerkenswert ist.

Die DA liegt mit 50,0% exakt am Zufallsniveau.

Ticker	MAPE (%)	OOS- R^2	DA
CARR	1,46	-0,02	0,49
OTIS	0,97	-0,05	0,47
RSG	0,82	-0,05	0,52
CTAS	1,01	-0,04	0,49
AJG	1,05	-0,01	0,55
PEP	0,95	-0,02	0,49
TT	1,19	-0,01	0,51
GWW	1,04	-0,03	0,48
RMD	1,24	-0,04	0,45
BLK	1,08	-0,03	0,54
Ø	1,08	-0,03	0,50

Tabelle 5.15.: Fehlermaße des TimesFM-Modells im Testzeitraum

Tabelle 5.16 zeigt die finanziellen Ergebnisse der TimesFM-basierten Handelsstrategie.

Anzumerken ist die heterogene Performance bei einzelnen Aktien. Aktien schneiden entweder ziemlich gut oder ziemlich schlecht ab, mit den Extrema

- **TT:** +22,54% Return,
- **RSG:** +14,21% Return,
- **OTIS:** -23,80% Return.

Tabelle 5.17 zeigt die Handelsaktivität des TimesFM-Modells.

Im Durchschnitt werden 13,0 Trades pro Aktie ausgeführt. Die niedrigere Handelsfrequenz (ein Trade alle 29 Tage) resultiert aus der konservativen Zero-Shot-Vorhersage des Foundation Model.

Die Trade-Verteilung zeigt eine starke Long-Bias mit 75 Buy-Orders (57,7%), nur 20 Sell-Orders (15,4%) und 35 Close-Positionen (26,9%). Dies deutet darauf hin, dass das Modell primär Aufwärtstrends identifiziert und bei Unsicherheit eher aus dem Markt geht.

Abb. 5.4 zeigt exemplarisch den Walk-Forward-Backtest für die Aktie TT.

Die Visualisierung zeigt charakteristische Eigenschaften des Zero-Shot Foundation Model:

Ticker	Return (%)	B&H (%)	Excess (%)	Sharpe	MDD (%)
CARR	-7,93	-12,29	4,36	-11,39	25,01
OTIS	-23,80	-4,88	-18,92	-1,42	29,23
RSG	14,21	13,11	1,10	1,49	8,80
CTAS	1,96	11,02	-9,06	-0,17	16,92
AJG	4,12	2,30	1,82	0,05	14,74
PEP	-4,88	-6,47	1,60	-65,80	10,40
TT	22,54	23,33	-0,79	6,59	15,53
GWW	10,40	15,40	-5,00	0,40	13,96
RMD	13,78	31,79	-18,00	1,14	9,29
BLK	9,61	42,86	-33,25	0,31	14,38
Ø	4,00	11,62	-7,62	-6,88	15,83

Tabelle 5.16.: Trading-Performance des TimesFM-Modells

Ticker	Buy	Sell	Close	Total
CARR	7	0	4	11
OTIS	8	0	5	13
RSG	11	5	3	19
CTAS	10	1	5	16
AJG	8	6	3	17
PEP	4	0	2	6
TT	8	2	2	12
GWW	6	1	2	9
RMD	6	2	4	12
BLK	7	3	5	15
Ø	7,5	2,0	3,5	13,0

Tabelle 5.17.: Trade-Verteilung des TimesFM-Modells über den Testzeitraum




Abbildung 5.4.: Walk-Forward-Backtest für TT mit TimesFM-Modell. Oben: Portfoliowert. Unten: Aktienkurs (schwarz), Vorhersagen (blau), Kaufsignale (grün), Verkaufssignale (rot).

- **Konservative Vorhersagen:** Die blauen Punkte zeigen Bewegung sehr nahe an den vergangenen Kursen ($P_{t+1} \approx P_t$),
- **Seltene Trades:** Nur 12 Trades über 377 Tage zeigen ein selektives Vorgehen,
- **Reaktives Verhalten:** Das Modell sagt häufig nach deutlichen Kursbewegungen eine weitere Bewegung in die aktuelle Richtung vorher. Reagiert also eher, als vorherzusagen.

Die Stärke von TimesFM liegt in der Zero-Shot-Generalisierung ohne aktienspezifisches Training. Bei einzelnen Aktien wie TT erreicht das Modell exzellente Ergebnisse (Sharpe 6,59), während die durchschnittliche Performance durch konservative Vorhersagen gemindert wird.

Insgesamt liefert TimesFM die beste reine Vorhersagepräzision der drei Modelle, was angesichts des Zero-Shot-Ansatzes ohne aktienspezifisches Training bemerkenswert ist. Allerdings übersetzt sich diese Präzision nicht in eine entsprechend gute Trading-Performance: Die DA liegt exakt am Zufallsniveau und die Vorhersagen folgen nahe am Kurs des Vortages, was wenig handelbare Signale erzeugt. Die heterogene Performance über die einzelnen Aktien hinweg deutet zudem darauf hin, dass das Modell für manche Kursverläufe gut geeignet ist, für andere jedoch keinerlei Vorteil bietet. Die Implikationen dieser Beobachtungen werden in Abschnitt 5.5.3 im Modellvergleich vertieft.

5.5. Modellvergleich

In diesem Abschnitt werden die drei evaluierten Vorhersagemodelle systematisch verglichen. Tabelle 5.18 fasst die zentralen Performance-Metriken zusammen, aufgeteilt in die drei Dimensionen Trading-Performance anhand der Finanzkennzahlen, Vorhersagequalität anhand der Fehlermaße und der Handelsaktivität.

Metrik	LinearSep.	SVR	TimesFM
Trading-Performance			
Avg. Return	4,06 %	6,56 %	4,00 %
Avg. Excess Return	-7,56 %	-5,05 %	-7,62 %
Avg. Sharpe Ratio	-2,83	0,20	-6,88
Avg. Max Drawdown	17,58 %	13,95 %	15,83 %
Vorhersagequalität			
Avg. MAPE	1,13 %	1,30 %	1,08 %
Avg. OOS- R^2	-0,10	-0,43	-0,03
Avg. DA	51,3 %	51,8 %	50,0 %
Handelsaktivität			
Avg. Trades/Aktie	12,2	20,7	13,0
Avg. ε	0,54 %	0,32 %	0,29 %

Tabelle 5.18.: Vergleich der durchschnittlichen Performance-Metriken über alle Aktien

5.5.1. Gesamtpformance

SVR zeigt die beste durchschnittliche Gesamtrendite (6,56%), gefolgt von LinearSeparation (4,06%) und TimesFM (4,00%). Alle drei Modelle liegen jedoch unter der Buy-and-Hold-Rendite von durchschnittlich 11,62%, was sich in negativen Excess Returns widerspiegelt.

Beim Risikomanagement zeigt SVR mit einem durchschnittlichen Sharpe Ratio von 0,20 die beste Balance zwischen Rendite und Risiko. LinearSeparation (-2,83) und TimesFM (-6,88) weisen negative Sharpe Ratios auf, was auf hohe Volatilität bei geringen Renditen hindeutet.

Der durchschnittliche Maximum Drawdown liegt bei SVR am niedrigsten (13,95%), gefolgt von TimesFM (15,83%) und LinearSeparation (17,58%). Dies deutet wiederum auf ein besseres Risikomanagement des SVR-Modells hin.

Bei der reinen Vorhersagepräzision zeigt TimesFM den niedrigsten MAPE (1,08%), gefolgt von LinearSeparation (1,13%) und SVR (1,30%), was eine interessante Gegenüberstellung zeigt, da das Modell mit der besten Vorhersagequalität nicht die beste Trading-Performance

hat. Der geringe Unterschied zwischen den Werten deutet darauf hin, dass alle drei Modelle ähnlich nahe an den tatsächlichen Kursen liegen.

Die DA zeigt SVR als Spitzenreiter (51,8%), gefolgt von LinearSeparation (51,3%) und TimesFM (50,0% exakt am Zufallsniveau). Die Unterschiede sind marginal, aber SVR zeigt eine konsistent leichte Überlegenheit bei der Richtungsvorhersage.

5.5.2. Handelsverhalten

SVR zeigt mit durchschnittlich 20,7 Trades pro Aktie die höchste Handelsaktivität, was etwa einem Trade alle 18 Tage entspricht. TimesFM (13,0 Trades) und LinearSeparation (12,2 Trades) handeln deutlich konservativer mit etwa einem Trade alle 29-31 Tage.

Die niedrigeren Signal-Schwellenwerte bei TimesFM ($\varepsilon = 0,29\%$) und SVR ($\varepsilon = 0,32\%$) im Vergleich zu LinearSeparation ($\varepsilon = 0,54\%$) erklären die unterschiedliche Handelsfrequenz teilweise. SVR kombiniert niedrige Schwellenwerte mit besserer Richtungsvorhersage, was zu mehr profitablen Trades führt.

5.5.3. Interpretation und Schlussfolgerungen

Das SVR-Modell zeigt über die meisten Performancekategorien hinweg die besten Ergebnisse und erreicht mit 6,56% die höchste durchschnittliche Gesamtrendite. Mehrere Designentscheidungen tragen zu dieser Überlegenheit bei. Die Integration technischer Indikatoren (RSI, MACD, Bollinger Bands) liefert zusätzliche Trendsignale, die reine Kurshistorien nicht erfassen können. Auch die Verwendung von exponentiell gewichteten News-Sentiments, könnte ein Grund für die bessere Performance sein. Die aufwendige, aktienspezifische Hyperparameter-Optimierung durch Grid-Search passt das Modell besser an die individuellen Parameter jeder Aktie an, was in den stark variierenden optimalen Parametern $C \in [0.1, 1000]$, $\gamma \in [0.001, 10]$ sichtbar wird.

Die höhere Handelsfrequenz von durchschnittlich 20,7 Trades pro Aktie ermöglicht es der SVR, mehr Marktgelegenheiten zu nutzen. Der niedrigere Signal-Schwellenwert von $\varepsilon = 0,32\%$ führt zu häufigeren Handelssignalen, die durch die bessere Richtungsvorhersage öfter profitabel sind. Dies zeigt sich besonders bei Aktien mit starken Aufwärtstrends wie

CTAS (+25,73%) und GWW (+16,82%), wo das Modell Momentum effektiv ausnutzt. Auch der niedrigste durchschnittliche Maximum Drawdown von 13,95% deutet auf ein überlegenes Risikomanagement hin. Dies könnte begründet sein durch die höhere Trade-Frequenz, welche schnellere Reaktionen auf negative Marktentwicklungen ermöglicht und damit Eindämmung der Verluste.

Allerdings wurde gezeigt, dass SVR nicht in allen Kategorien die beste Performance erzielt. Bei der reinen Punktvorhersage liefern die Fehlermaße von TimesFM eine bessere Evaluation als SVR. Dies könnte auf das 512-Tage-Kontextfenster zurückzuführen sein, das langfristige Kursmuster besser interpolieren kann. Auch beim $OOS-R^2$ schneidet TimesFM mit $-0,03$ am besten ab, während SVR mit $-0,43$ deutlich schlechter liegt. Dies könnte sich durch die Komplexität des SVR-Modells erklären lassen. Die vielen Features (technische Indikatoren, Sentiment) können bei kurzfristigen Bewegungen zu Overfitting führen, während TimesFM durch seinen Zero-Shot-Ansatz näher an der naiven Baseline bleibt.

Keines der Modelle übertrifft Buy-and-Hold konsistent. Die negativen $OOS-R^2$ -Werte zeigen, dass alle Modelle Schwierigkeiten haben, eine zufällige Schätzung zu überbieten. Die DA liegt nur knapp über Zufall (50-52%), was die fundamentale Schwierigkeit der Kursvorhersage unterstreicht.

Eine zentrale Beobachtung aller Modelle ist die Diskrepanz zwischen guter Punktvorhersagequalität und schwacher Trading-Performance. Die MAPE-Werte von 1,08–1,30% zeigen, dass alle Modelle die Kurse mit hoher Präzision vorhersagen. Im Durchschnitt weichen die Vorhersagen nur etwa 1% vom tatsächlichen Kurs ab. Trotz dieser scheinbar guten Punktvorhersagen liegt die durchschnittliche Rendite bei nur 4,00–6,56%, deutlich unter Buy-and-Hold (11,62%).

Diese Diskrepanz lässt sich durch mehrere Faktoren erklären:

- **Signal-Threshold:** Der Schwellenwert ε filtert kleine Vorhersagen heraus. Viele präzise Vorhersagen führen zu keinem Trade, während wenige große Fehlvorhersagen zu Verlusten führen können.
- **Timing-Kosten:** Selbst bei korrekter Richtung kann falsches Timing (meist zu spät) die Profitabilität beeinträchtigen.

- **Random-Walk-Nähe:** Die negativen OOS- R^2 -Werte zeigen, dass die Modelle oft den Kurs vom Vortag als Vorhersage nutzen (was einen niedrigen MAPE ergibt), aber keine echte Vorhersagekraft hat. Ein MAPE von 1% ist nicht beeindruckend, wenn die naive Vorhersage $\hat{p}_t = p_{t-1}$ ähnlich gut abschneidet.

Diese Beobachtung unterstreicht den wichtigen Punkt, dass gute Punktvorhersagen keine profitable Trading-Strategie garantieren. Die Profitabilität hängt von der Fähigkeit ab, handelbare Signale zu generieren, also Vorhersagen, die konsistent in die richtige Richtung zeigen und groß genug sind, um den Signal-Threshold zu überschreiten. Die DA von nur 50–52% zeigt, dass alle drei Modelle diese Fähigkeit nur marginal besitzen.

6. Zusammenfassung

Ziel der Arbeit war es, eine Strategie zu entwickeln, die rentable Aktien auswählt, auf Basis dieser Aktien Modelle trainiert und dann mit einer selbst entwickelten Handelsstrategie und den prognostizierten Renditen der Aktien profitabel handelt. Um die Modelle testen zu können, sollte außerdem eine Testumgebung entwickelt werden, mit der realistische Backtests durchgeführt werden können.

Zur Auswahl der Aktien wurde deshalb ein Verfahren entwickelt, das mit einer SDE die langfristige Entwicklung der Aktienkurse modelliert und dann die Renditen der Aktien prognostiziert. Die prognostizierten Renditen weichen dabei von der tatsächlichen Rendite ab. Um einen Lookahead-Bias zu vermeiden, wurden für die Modelle trotzdem die 10 Aktien mit den höchsten prognostizierten Renditen ausgewählt.

Um die tagesaktuellen Renditen der Aktien zu prognostizieren, wurden drei Modelle entwickelt. Ein rein lineares Modell, das mit HP-Filter Trends erkennt und diese dann mit OLS extrapoliert. Neben dem langfristigen und kurzfristigen Trend wurden auch zyklische Schwankungen mithilfe eines ARMA-Modells berücksichtigt. Das zweite Modell ist eine Preprocessed SVR. Dieses Modell nutzt neben den Aktienkursen auch andere relevante Informationen, um die Vorhersagegenauigkeit zu verbessern. Das dritte Modell nutzt das Foundation Model TimesFM in einem Zero-Shot-Ansatz.

Alle drei Modelle wurden auf den vorher ausgewählten Aktien trainiert und evaluiert. Die Ergebnisse zeigen, dass die SVR die beste Rendite erzielt hat (6,56%), gefolgt von dem linearen Modell (4,06%) und dem TimesFM (4,00%). Bei der reinen Vorhersagepräzision ist die Reihenfolge genau andersrum. Hier ist TimesFM am besten, gefolgt vom linearen Modell und der SVR. Hier sieht man gut, dass die Vorhersagepräzision nicht unbedingt mit der erzielten Rendite korreliert. Die Rendite korreliert eher mit der Anzahl der Trades. Die SVR hat mit 20 Trades im Vergleich zu 12 bzw. 13 Trades deutlich mehr Trades getätigt als die anderen Modelle.

Auch die Handelsstrategie hat großen Einfluss auf die Anzahl der Trades. Es wurde allerdings nur eine Handelsstrategie entwickelt, die mit einem Schwellwert arbeitet, der

dem MAE des Modells auf dem Validierungszeitraum entspricht. Durch diesen festen Schwellwert werden somit Trades mit sehr kleiner prognostizierter Rendite vermieden, was die Anzahl der Trades reduziert.

Im Vergleich zu einem Buy-and-Hold Ansatz haben alle Modelle im Durchschnitt eine deutlich niedrigere Rendite erzielt. Das lineare Modell hat nur in drei Fällen die Buy-and-Hold Strategie übertroffen, die SVR in sechs Fällen und das TimesFM in vier Fällen. Die Modelle sind deshalb nicht in der Lage, mit aktivem Handel passive Anleger zu übertreffen.

Um zu überprüfen, wie der gesamte Prozess von der Aktienausswahl über die Modellierung bis hin zur Handelsstrategie funktioniert, wurde eine Testumgebung entwickelt. In dieser Testumgebung können realistische Backtests durchgeführt werden, um die Performance der Modelle und der Handelsstrategie zu evaluieren. Die Testumgebung basiert auf dem Framework Backtrader und evaluiert die Modelle nach verschiedenen Fehlermaßen und finanzwirtschaftlichen Kennzahlen.

Die Ergebnisse der Arbeit müssen unter Berücksichtigung der folgenden Einschränkungen interpretiert werden. Alle Modelle wurden nur auf einer Aktie trainiert und evaluiert. Mit dieser Arbeit lässt sich deshalb keine Aussage darüber treffen, wie die Performance der Modelle und Strategien auf anderen Aktien oder in anderen Zeiträumen ist.

Zudem behandelt die Arbeit keine notwendigen Anpassungen der Renditenberechnung und der Handelsstrategie, um Transaktionskosten, Kommissionen, Steuern oder andere Kosten zu berücksichtigen, die bei realen Handelsaktivitäten anfallen. Deshalb lassen sich die Ergebnisse nicht auf den tatsächlichen Handel übertragen und sind nur als theoretische Performance der Modelle und Strategien zu verstehen.

7. Ausblick

Die vorliegende Arbeit liefert verschiedene Modelle und Ergebnisse, die als Grundlage für weiterführende Untersuchungen dienen können. Da nur eine Strategie zur Aktienausswahl entwickelt wurde, wäre es interessant, alternative Ansätze für die Aktienausswahl zu untersuchen und deren Einfluss auf die Gesamtrendite der Vorhersagemodelle zu messen. Denkbar wären beispielsweise fundamentale Kennzahlen wie das Kurs-Gewinn-Verhältnis oder die Dividendenrendite als Auswahlkriterien, um Aktien mit unterschiedlichen Risiko-Rendite-Profilen zu selektieren.

Eine weitere offene Weiterführung besteht darin, den Einfluss zusätzlicher Datenquellen zu analysieren und messbar zu vergleichen. Da in dieser Arbeit nur ein Modell externe Datenquellen integriert, bleibt offen, inwieweit technische Indikatoren oder Sentiment-Daten aus Nachrichten die Performance anderer Modellarchitekturen außer der SVR verbessern könnten. Insbesondere die Integration von NLP-basierten Sentiment-Scores aus Finanznachrichten oder Social-Media-Plattformen könnte kurzfristige Marktbewegungen besser abbilden und so die Vorhersagequalität aller Modelle steigern.

Darüber hinaus wäre die Anwendbarkeit der Modelle auf ein breiteres Aktienspektrum zu untersuchen. Ein Training auf mehreren Aktien gleichzeitig könnte Korrelationen zwischen verschiedenen Kursbewegungen nutzen und die Generalisierungsfähigkeit der Modelle verbessern. Auch Transfer-Learning, bei dem Modelle auf einem Aktienset trainiert und auf einem anderen getestet werden, könnte wertvolle Erkenntnisse über die Übertragbarkeit von Vorhersagemustern liefern.

Ein weiterer vielversprechender Ansatz wäre die Optimierung der Handelsstrategie selbst. In dieser Arbeit wurde lediglich ein fester Schwellwert basierend auf dem MAE verwendet. Dynamische Schwellwerte, die sich an die aktuelle Marktvolatilität anpassen, oder Ensemble-Ansätze, bei denen die Vorhersagen mehrerer Modelle kombiniert werden, könnten die Handelsentscheidungen verbessern. Auch eine Erweiterung um Short-Positionen würde es ermöglichen, nicht nur von steigenden, sondern auch von fallenden Kursen zu profitieren, was die Gesamtrendite erhöhen könnte.

Schließlich wäre eine Einbeziehung realistischer Transaktionskosten und Slippage in die Backtesting-Umgebung notwendig, um die praktische Umsetzbarkeit der Strategien besser beurteilen zu können. Ergänzend dazu könnte eine Risikomanagement-Komponente integriert werden, die durch Stop-Loss-Orders oder eine dynamische Positionsgrößenbestimmung das Verlustrisiko begrenzt und so die risikoadjustierte Rendite der Modelle optimiert.

Literaturverzeichnis

- [1] Malkiel, B. G. „Efficient market hypothesis“. In: *Finance*. Springer, 1989, S. 127–134.
- [2] Burton, K. *Inside a Moneymaking Machine Like No Other*. Archived from the original on 14 May 2017. Nov. 2016. URL: <https://www.bloomberg.com/news/articles/2016-11-21/how-renaissance-s-medallion-fund-became-finance-s-blackest-box> (besucht am 11.05.2017).
- [3] Sewell, M. „The Efficient Market Hypothesis: Empirical Evidence“. In: *International Journal of Statistics and Probability* 1.2 (2012), S. 164–178.
- [4] Prakash, A./ Tuo, R./ Ding, Y. „The Temporal Overfitting Problem with Applications in Wind Power Curve Modeling“. In: *Technometrics* 65.1 (2023), S. 70–82. URL: <https://arxiv.org/abs/2012.01349>.
- [5] Kumar, D./ Sarangi, P. K./ Verma, R. „A systematic review of stock market prediction using machine learning and statistical techniques“. In: *Materials Today: Proceedings* 49 (2022), S. 3187–3191.
- [6] Rundo, F. u. a. „Machine learning for quantitative finance applications: A survey“. In: *Applied Sciences* 9.24 (2019), S. 5574.
- [7] Shah, D./ Isah, H./ Zulkernine, F. „Stock market analysis: A review and taxonomy of prediction techniques“. In: *International Journal of Financial Studies* 7.2 (2019), S. 26.
- [8] Sasikumar, R./ Abdullah, A. S. „Applications of various stochastic models in financial prediction“. In: *International Journal of Scientific and Innovative Mathematical Research (IJSIMR)* 3.3 (2015), S. 852–857.
- [9] Ofomata, A. I. O. u. a. „A Stochastic Model of the Dynamics of Stock Price for Forecasting“. In: *Journal of Advances in Mathematics and Computer Science* 25.6 (2017), S. 1–24.

- [10] Gandhmal, D. P./ Kumar, K. „Systematic analysis and review of stock market prediction techniques“. In: *Computer Science Review* 34 (2019), S. 100190.
- [11] Ballings, M. u. a. „Evaluating multiple classifiers for stock price direction prediction“. In: *Expert systems with Applications* 42.20 (2015), S. 7046–7056.
- [12] Lu, W. u. a. „A CNN-BiLSTM-AM method for stock price prediction“. In: *Neural computing and applications* 33.10 (2021), S. 4741–4753.
- [13] Hodrick, R. J./ Prescott, E. C. „Postwar U.S. Business Cycles: An Empirical Investigation“. In: *Journal of Money, Credit and Banking* 29.1 (1997), S. 1–16.
- [14] Box, G. E. P. u. a. *Time Series Analysis: Forecasting and Control*. 5. Aufl. Hoboken, NJ: Wiley, 2015.
- [15] Dickey, D. A./ Fuller, W. A. „Distribution of the Estimators for Autoregressive Time Series with a Unit Root“. In: *Journal of the American Statistical Association* 74.366a (1979), S. 427–431.
- [16] Akaike, H. „A New Look at the Statistical Model Identification“. In: *IEEE Transactions on Automatic Control* 19.6 (1974), S. 716–723.
- [17] Hyndman, R. J./ Khandakar, Y. „Automatic Time Series Forecasting: The forecast Package for R“. In: *Journal of Statistical Software* 27.3 (2008), S. 1–22.
- [18] Drucker, H. u. a. „Support Vector Regression Machines“. In: *Advances in Neural Information Processing Systems (NIPS)*. Bd. 9. MIT Press, 1997.
- [19] Tay, F. E. H./ Cao, L. „Application of Support Vector Machines in Financial Time Series Forecasting“. In: *Omega* 29.4 (2001), S. 309–317.
- [20] Oliveira, N./ Cortez, P./ Areal, N. „Stock Price Prediction Using Support Vector Regression on Daily and Up to the Minute Prices“. In: *The Journal of Finance and Data Science* 4.2 (2018), S. 183–201.
- [21] Campbell, J. Y./ Lo, A. W./ MacKinlay, A. C. *The Econometrics of Financial Markets*. Princeton University Press, 1997.

- [22] Fama, E. F. „Efficient Capital Markets: A Review of Theory and Empirical Work“. In: *The Journal of Finance* 25.2 (1970), S. 383–417.
- [23] Tetlock, P. C. „Giving Content to Investor Sentiment: The Role of Media in the Stock Market“. In: *The Journal of Finance* 62.3 (2007), S. 1139–1168.
- [24] Alpha Vantage. *Alpha Vantage API Documentation – News and Sentiment Data*. Accessed: 2026-05-14. 2026. URL: <https://www.alphavantage.co/documentation/>.
- [25] Wilder, J. W. *New Concepts in Technical Trading Systems*. Trend Research, 1978.
- [26] Appel, G. *The Moving Average Convergence-Divergence Trading Method*. Traders Press, 1979.
- [27] Bollinger, J. A. *Bollinger on Bollinger Bands*. McGraw-Hill, 2001.
- [28] Engle, R. F. „Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation“. In: *Econometrica* 50.4 (1982), S. 987–1007.
- [29] French, K. R. „Stock Returns and the Weekend Effect“. In: *Journal of Financial Economics* 8.1 (1980), S. 55–69.
- [30] Schölkopf, B./ Smola, A. J. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.
- [31] López de Prado, M. „Chaos, overfitting and equilibrium: To what extent can machine learning beat the financial market?“ In: *Journal of Financial Data Science* 2.4 (2020), S. 8–25.
- [32] Das, A. u. a. „A Decoder-Only Foundation Model for Time-Series Forecasting“. In: *arXiv preprint arXiv:2310.10688* (2024). URL: <https://arxiv.org/abs/2310.10688>.
- [33] Aït-Sahalia, Y./ Hansen, L. P. *Handbook of Financial Econometrics*. Elsevier, 2010.

- [34] Lo, A. W./ Mamaysky, H./ Wang, J. „Foundations of Technical Analysis: Computational Algorithms, Statistical Inference, and Empirical Implementation“. In: *The Journal of Finance* 55.4 (2000), S. 1705–1765.
- [35] Asness, C. u. a. *Fact, Fiction and Momentum Investing*. AQR Capital Management, 2015.
- [36] Avellaneda, M./ Lee, J.-H. „Statistical Arbitrage in the US Equities Market“. In: *Quantitative Finance* 10.7 (2010), S. 761–782.
- [37] Prado, M. L. de. *Advances in Financial Machine Learning*. Wiley, 2018.
- [38] Kelly, J. L. „A New Interpretation of Information Rate“. In: *Bell System Technical Journal* 35.4 (1956), S. 917–926.
- [39] Thorp, E. O. „The Kelly Criterion in Blackjack, Sports Betting, and the Stock Market“. In: *Handbook of Asset and Liability Management*. Elsevier, 2006.
- [40] MacLean, L. C./ Thorp, E. O./ Ziemba, W. T. „The Kelly Capital Growth Investment Criterion“. In: *World Scientific* (2011).
- [41] Jones, C. M. *A Century of Stock Market Liquidity and Trading Costs*. Working Paper SSRN 313681. Posted September 13, 2002; written May 23, 2002. Columbia University, 2002. URL: <https://ssrn.com/abstract=313681>.
- [42] Loras, R. „The impact of transactions costs and slippage on algorithmic trading performance“. In: (Sep. 2024).
- [43] Olorunnimbe, K./ Viktor, H. „Deep learning in the stock market—a systematic survey of practice, backtesting, and applications“. In: *Artificial Intelligence Review* 56.3 (2023), S. 2057–2109. URL: <https://doi.org/10.1007/s10462-022-10226-0>.
- [44] „A systematic review of stock market prediction using machine learning and statistical techniques“. In: *Materials Today: Proceedings* (2021). URL: <https://www.sciencedirect.com/science/article/abs/pii/S2214785320390337>.

- [45] „Stock price prediction with optimized deep LSTM network with artificial rabbits optimization algorithm“. In: *Expert Systems with Applications* (2023). URL: <https://www.sciencedirect.com/science/article/pii/S0957417423008485>.
- [46] „Predicting Economic Trends and Stock Market Prices with Deep Learning and Advanced Machine Learning Techniques“. In: *Electronics* 13.17 (2024), S. 3396. URL: <https://www.mdpi.com/2079-9292/13/17/3396>.
- [47] Tan, H. u. a. „Comparing LSTM Models for Stock Market Prediction: A Case Study with Apple’s Historical Prices“. In: *Nature of Computation and Communication (ICTCC 2023)*. Bd. 586. LNICST. Springer, 2024.
- [48] Balamohan, S./ Khanaa, V./ Sivaraman, K. „Effective Stock Market Pricing Prediction Using Long Short Term Memory-Upgraded Model (LSTM-UP) on Evolving Data Sets“. In: *SN Computer Science* 4 (2023), S. 658.
- [49] „Deep Learning for Stock Performance Prediction: A Sharpe Ratio-Optimized Approach“. In: *Asia Pacific Economic and Management Review* 2.2 (2025). URL: <https://ojs.apspublisher.com/index.php/apemr/article/view/210>.
- [50] „Deep Reinforcement Learning for Automated Stock Trading: An Ensemble Strategy“. In: *arXiv* (2025). URL: <https://arxiv.org/abs/2511.12120>.
- [51] „Deep Learning in Long-Short Stock Portfolio Allocation: An Empirical Study“. In: *arXiv* (2024). URL: <https://arxiv.org/abs/2411.13555>.
- [52] „Stock Market Analysis, Forecasting, and Automated Trading Using Deep Learning“. In: *Engineering Proceedings* 128.1 (2025), S. 42. URL: <https://www.mdpi.com/2673-4591/128/1/42>.
- [53] Rodriguez, D. *Backtrader*. Accessed: 2026-05-15. 2026. URL: <https://www.backtrader.com>.
- [54] Campbell, J. Y./ Thompson, S. B. „Predicting excess stock returns out of sample: Can anything beat the historical average?“ In: *The Review of Financial Studies* 21.4 (2008), S. 1509–1531.

- [55] Hsu, C.-W./ Chang, C.-C./ Lin, C.-J. *A Practical Guide to Support Vector Classification*. Techn. Ber. Department of Computer Science, National Taiwan University, 2003. URL: <https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>.
- [56] Jäkel, F./ Schölkopf, B./ Wichmann, F. A. „A Tutorial on Kernel Methods for Categorization“. In: *Journal of Mathematical Psychology* 51.6 (Dez. 2007), S. 343–358.
- [57] Burges, C. J. C. „A Tutorial on Support Vector Machines for Pattern Recognition“. In: *Data Mining and Knowledge Discovery* 2.2 (Juni. 1998), S. 121–167. URL: <https://doi.org/10.1023/A:1009715923555>.

A. Mathematische Definitionen der Metriken

Dieses Kapitel enthält die formalen Definitionen aller in dieser Arbeit verwendeten Evaluationsmetriken. Die Metriken sind in Fehlermaße (Anhang A.1) und finanzwirtschaftliche Kennzahlen (Anhang A.2) unterteilt.

A.1. Fehlermaße

Für die folgenden Definitionen sei ein Signal $[x_1, x_2, \dots, x_n]$ und eine zugehörige Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ gegeben.

Mean Absolute Percentage Error (MAPE)

Der MAPE misst die durchschnittliche prozentuale Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right|.$$

Da der MAPE relativ zum tatsächlichen Wert x_i normiert ist, ermöglicht er einen skaleninvarianten Vergleich über verschiedene Zeitreihen hinweg. Theoretisch neigt er dazu negative Fehler asymmetrisch zu bestrafen. Dies ist praktisch im Falle von Aktienkursen aber vernachlässigbar.

Out-of-Sample R^2 (OOS- R^2)

Der OOS- R^2 nach [54] misst, ob ein Modell bessere Vorhersagen liefert als ein naiver Benchmark. Sei $\hat{x}_i$ die Modellvorhersage und $\hat{x}_i^{\text{RW}} = x_{i-1}$ die Vorhersage eines Random-Walk-Modells, welches den letzten bekannten Wert als Schätzung verwendet. Der OOS- R^2 ist definiert als

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{\sum_{i=1}^n (x_i - \hat{x}_i^{\text{RW}})^2}.$$

Ein Wert $R_{\text{OOS}}^2 > 0$ zeigt an, dass das Modell den Random Walk übertrifft, während $R_{\text{OOS}}^2 \leq 0$ bedeutet, dass die naive Baseline mindestens gleichwertig ist.

Directional Accuracy (DA)

Die DA misst, wie gut ein Modell die Richtung der Kursbewegung vorhersagt, unabhängig von der genauen Höhe des Preises. Für ein Signal $[x_1, x_2, \dots, x_n]$ und eine Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird DA definiert nach

$$DA = \frac{1}{n} \sum_{i=2}^n \mathbf{1}(\text{sign}(x_i - x_{i-1}) = \text{sign}(\hat{x}_i - x_{i-1})),$$

wobei $\mathbf{1}(\cdot)$ die Indikatorfunktion ist, die den Wert 1 annimmt, wenn die Vorhersage die gleiche Richtung wie die tatsächliche Kursbewegung hat, und 0 sonst.

Ein Wert von $DA = 1$ entspricht einer perfekten Klassifikation, während $DA = ,5$ einem zufälligen Raten entspricht.

A.2. Finanzwirtschaftliche Kennzahlen

Gesamtrendite (Return)

Die Gesamtrendite gibt die insgesamt erzielte Rendite über den gesamten Zeitraum an:

$$R_{\text{cum}} = \frac{V_T - V_0}{V_0},$$

wobei V_0 der Anfangswert und V_T der Endwert des Portfolios ist. Sie zeigt die absolute Profitabilität der Strategie.

Excess Return

Der Excess Return misst die Überrendite einer Strategie gegenüber einer passiven Buy-and-Hold-Strategie:

$$R_{\text{excess}} = R_{\text{cum}} - R_{\text{B\&H}},$$

wobei $R_{\text{B\&H}} = \frac{P_T - P_0}{P_0}$ die Buy-and-Hold-Rendite ist, mit P_0 als Anfangspreis und P_T als Endpreis der Aktie im Testzeitraum.

Sharpe Ratio

Das Sharpe Ratio misst das Rendite-Risiko-Verhältnis eines Portfolios, indem es die Portfoliorendite ohne die risikofreie Rendite ins Verhältnis zur Volatilität setzt. Es wird berechnet nach

$$S = \frac{R_p - R_f}{\sigma(R_p)},$$

wobei R_p die Rendite des Portfolios, R_f der risikofreie Zinssatz und $\sigma(R_p)$ die Volatilität der Portfoliorendite ist. Die Volatilität $\sigma(R_p)$ wird über die empirische Standardabweichung ermittelt:

$$\sigma(R_p) = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_{P,t} - \bar{R}_P)^2}$$

Ein hohes Sharpe Ratio bedeutet eine hohe Rendite im Vergleich zum Risiko.

Maximum Drawdown (MDD)

Der Maximum Drawdown (MDD) beschreibt den größten Verlust eines Portfolios vom höchsten Punkt (Peak) bis zum Tiefpunkt (Trough) innerhalb des betrachteten Zeitraums:

$$\text{MDD} = \max_t \frac{\text{Peak}_t - \text{Value}_t}{\text{Peak}_t}.$$

Ein niedriger Maximum Drawdown zeigt, dass das untersuchte Investment nur geringe zwischenzeitliche Verluste erlitt.

B. SVR Modellierung

Die SVR-Modellierung orientiert sich an der Beschreibung in [18]. Die Vorhersage der Rendite erfolgt nach

$$\hat{r}_{t+1} = \langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle + b, \quad (\text{B.1})$$

wobei

- $\mathbf{w}$ der Gewichtsvektor ist, welcher angibt, wie stark welches Feature aus $\mathbf{x}$ in die Vorhersage eingeht,
- $\phi(x)$ eine Funktion ist, die die Input-Features in einen Raum höherer Dimension transformiert,
- b der Achsenabschnitt der Vorhersage ist.

Die Wahl von $\phi(x)$ wird später diskutiert, da sie über den Kernel-Trick vereinfacht wird und $\mathbf{w}$ und b werden durch das Lösen des folgenden Optimierungsproblems bestimmt (vgl. [18]):

$$\min_{\mathbf{w}, b, \xi, \xi^*} \underbrace{\frac{1}{2} \|\mathbf{w}\|^2}_{\text{Funktionsglätte}} + C \underbrace{\sum_{t=1}^n (\xi_t + \xi_t^*)}_{\text{Fehlerterme}} \quad (\text{B.2})$$

unter den Nebenbedingungen

$$r_{t+1} - \langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle - b \leq \varepsilon + \xi_t \quad (\text{B.3})$$

$$\langle \mathbf{w}, \phi(\mathbf{x}_t) \rangle + b - r_{t+1} \leq \varepsilon + \xi_t^* \quad (\text{B.4})$$

$$\xi_t, \xi_t^* \geq 0. \quad (\text{B.5})$$

Hierbei sorgt $\frac{1}{2}\|\mathbf{w}\|^2$ dafür, dass die Glätte der Funktion in die Optimierung miteingeht. Dies sorgt dafür, dass die Regressionsfunktion nicht overfittet, was ein häufiges Problem bei Aktienprognosemodellen ist. Der ε -Schlauch definiert dabei einen Toleranzbereich um die Regressionsfunktion, innerhalb dessen Abweichungen nicht als Fehler gewertet werden. Dies ist im Falle von Aktienrenditen hilfreich, um Rauschen zu ignorieren. Um Trainingspunkte, die außerhalb dieses Schlauchs liegen, dennoch zuzulassen, werden ξ_i und ξ_i^* eingeführt, welche die Abweichung dieser Punkte messen und in das Optimierungsproblem einbeziehen, wodurch es lösbar bleibt. Der Parameter C steuert dabei die Gewichtung zwischen Funktionsglätte und den Fehlern von Trainingsdaten, die außerhalb des ε -Schlauches liegen. Die Nebenbedingungen B.3, B.4 und B.5 sorgen dafür, dass die über- bzw. unterschätzten Werte in die Minimierung eingehen.

C und ε werden im Validierungszeitraum V mit einer Grid-Search bestimmt. Das bedeutet es werden für C und ε diskrete Wertebereiche G_C und G_ε gewählt und alle möglichen Kombinationen getestet. Die Kombination, die auf dem Validierungsdatensatz im Sinne des RMSE das beste Ergebnis erzielt, wird gewählt. Die Wertebereiche werden nach der Empfehlung aus [55] gewählt.

$$G_C = \{0.1, 1, 10, 100, 1000\}$$

$$G_\varepsilon = \{0.001, 0.01, 0.1, 0.5, 1\}$$

Die Abbildungsfunktion $\phi(\mathbf{x})$ transformiert die Eingabedaten in einen höherdimensionalen Raum, in dem vorher nicht-lineare Zusammenhänge linear approximiert werden können. Damit $\phi(\mathbf{x})$ jedoch explizit weder gewählt noch berechnet werden muss, wird der Kernel-Trick [56] angewendet. Das in Gleichung (B.2) definierte Optimierungsproblem ist konvex und lässt sich daher durch die Lagrange-Dualität in eine äquivalente duale Form überführen [57]. In dieser dualen Form lässt sich zeigen, dass $\mathbf{w}$ als Linearkombination der transformierten Trainingspunkte dargestellt werden kann:

$$\mathbf{w} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \phi(\mathbf{x}_i), \quad (\text{B.6})$$

wobei $\alpha_i, \alpha_i^* \geq 0$ die dualen Variablen sind. Damit lässt sich die Vorhersagefunktion schreiben als:

$$\hat{r}_{t+1} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_t) \rangle + b. \quad (\text{B.7})$$

In dieser Form tritt $\phi(\mathbf{x})$ ausschließlich in Skalarprodukten der Form $\langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ auf. Diese Skalarprodukte können direkt durch eine Kernel-Funktion $K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$ berechnet werden, ohne ϕ explizit zu kennen. Als Kernel-Funktion wird der Radial Basis Function (RBF)-Kernel [57] nach Gleichung (B.8) gewählt, da Aktienrenditen hochgradig nichtlineare und zeitvariante Abhängigkeiten aufweisen. Ein polynomialer Kernel setzt einen festen Grad der Nichtlinearität voraus und ist deshalb nicht geeignet. Der RBF-Kernel bildet die Eingabedaten in einen unendlich-dimensionalen Merkmalsraum ab und kann dadurch beliebig komplexe Abhängigkeiten erfassen, ohne dass deren funktionale Form vorab spezifiziert werden muss.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2), \quad (\text{B.8})$$

wobei γ ein Hyperparameter ist, der bestimmt wie stark der Kernel auf Rauschen reagiert. γ geht ebenfalls in die Grid-Search ein, mit den empfohlenen Werten nach [55]:

$$G_\gamma = \{0.01, 0.1, 1, 10, 50, 100\}.$$

Aus dem Ergebnis der SVR $\hat{r}_{t+1}$ ergibt sich die Preisvorhersage nach

$$\hat{P}_{t+1} = P_t * \exp(\hat{r}_{t+1}). \quad (\text{B.9})$$

C. Vollständige Ergebnisse der Aktienauswahl

Dieses Kapitel enthält die vollständigen Ergebnisse der SDE-basierten Aktienauswahl aus Abschnitt 5.1. Die Daten umfassen alle 450 analysierten Aktien aus dem S&P500-Universum (Stand Januar 2020).

C.1. Dominante Faktorpaare aller Aktien

Tabelle C.1 zeigt für jede der 450 analysierten Aktien das zugewiesene dominante Faktorpaar sowie die zugehörige Beta-Summe $\sum |\beta|$. Die Tabelle ist alphabetisch nach Ticker sortiert und verwendet ein zweispaltiges Format zur besseren Ausnutzung der Seitenbreite.

Tabelle C.1.: Dominante Faktorpaare aller analysierten Aktien

Ticker	Faktor 1	Faktor 2	$\sum \beta $	Ticker	Faktor 1	Faktor 2	$\sum \beta $
A	Gold	S&P500	0.577	AAL	S&P500	Dollar	0.443
AAP	Öl	S&P500	0.361	AAPL	Staatsanleihe	S&P500	0.628
ABBV	Staatsanleihe	S&P500	0.315	ABT	S&P500	Dollar	0.456
ACN	Staatsanleihe	S&P500	0.641	ADBE	Staatsanleihe	S&P500	0.587
ADI	Staatsanleihe	S&P500	0.589	ADM	Öl	S&P500	0.425
ADP	S&P500	Inflation	0.625	ADSK	Staatsanleihe	S&P500	0.595
AEE	Gold	S&P500	0.336	AEP	Staatsanleihe	S&P500	0.390
AES	Öl	S&P500	0.478	AFL	Staatsanleihe	S&P500	0.536
AIG	Staatsanleihe	S&P500	0.525	AIV	S&P500	Dollar	0.459
AIZ	Staatsanleihe	S&P500	0.447	AJG	S&P500	Dollar	0.469
AKAM	Staatsanleihe	S&P500	0.505	ALB	S&P500	Dollar	0.498
ALGN	S&P500	Dollar	0.532	ALK	S&P500	Dollar	0.431
ALL	Staatsanleihe	S&P500	0.391	ALLE	S&P500	Dollar	0.534

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
AMAT	S&P500	Dollar	0.563	AMCR	S&P500	Dollar	0.478
AMD	Gold	S&P500	0.480	AME	Öl	S&P500	0.577
AMGN	S&P500	Inflation	0.338	AMP	Staatsanleihe	S&P500	0.628
AMT	Staatsanleihe	S&P500	0.495	AMZN	S&P500	Dollar	0.514
ANET	Gold	S&P500	0.518	AON	Gold	S&P500	0.443
AOS	S&P500	Dollar	0.491	APA	Öl	S&P500	0.626
APD	S&P500	Dollar	0.552	APH	Öl	S&P500	0.596
APTV	Staatsanleihe	S&P500	0.580	ARE	S&P500	Dollar	0.457
ATO	Gold	S&P500	0.304	AVB	S&P500	Dollar	0.435
AVGO	S&P500	Inflation	0.590	AVY	Staatsanleihe	S&P500	0.552
AWK	Staatsanleihe	S&P500	0.451	AXP	Staatsanleihe	S&P500	0.593
AZO	Öl	S&P500	0.324	BA	S&P500	Dollar	0.419
BAC	Staatsanleihe	S&P500	0.592	BAX	Gold	S&P500	0.347
BBY	Gold	S&P500	0.468	BDX	Öl	S&P500	0.339
BEN	Öl	S&P500	0.536	BF-B	S&P500	Dollar	0.445
BIIB	Öl	S&P500	0.415	BIO	S&P500	Dollar	0.411
BK	Staatsanleihe	S&P500	0.541	BKNG	S&P500	Dollar	0.530
BKR	Öl	S&P500	0.532	BLK	Gold	S&P500	0.620
BMY	Staatsanleihe	S&P500	0.308	BR	Öl	S&P500	0.525
BRK-B	Staatsanleihe	S&P500	0.576	BSX	S&P500	Dollar	0.469
BWA	Öl	S&P500	0.459	BXP	S&P500	Dollar	0.469
C	Staatsanleihe	S&P500	0.572	CAG	Öl	S&P500	0.238
CAH	Staatsanleihe	S&P500	0.410	CARR	Öl	Gold	0.000
CAT	Öl	S&P500	0.529	CB	Staatsanleihe	S&P500	0.450
CBOE	Gold	S&P500	0.373	CBRE	S&P500	Dollar	0.566
CCI	Gold	S&P500	0.379	CCL	Staatsanleihe	S&P500	0.469
CDNS	Staatsanleihe	S&P500	0.571	CDW	Gold	S&P500	0.615
CE	S&P500	Dollar	0.509	CF	Öl	S&P500	0.396
CFG	Staatsanleihe	S&P500	0.549	CHD	Staatsanleihe	S&P500	0.272
CHRW	Öl	S&P500	0.395	CHTR	Staatsanleihe	S&P500	0.429
CI	Staatsanleihe	S&P500	0.368	CINF	Staatsanleihe	S&P500	0.464
CL	Staatsanleihe	S&P500	0.384	CLX	Staatsanleihe	S&P500	0.281
CMCSA	S&P500	Dollar	0.507	CME	Öl	S&P500	0.379

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
CMG	S&P500	Dollar	0.476	CMI	Staatsanleihe	S&P500	0.495
CMS	Staatsanleihe	S&P500	0.366	CNC	Staatsanleihe	S&P500	0.343
CNP	Gold	S&P500	0.314	COF	Staatsanleihe	S&P500	0.563
COO	S&P500	Dollar	0.532	COP	Öl	S&P500	0.624
COST	Staatsanleihe	S&P500	0.521	CPB	S&P500	Inflation	0.197
CPRT	S&P500	Dollar	0.541	CRM	Gold	S&P500	0.540
CSCO	Gold	S&P500	0.612	CSX	Öl	S&P500	0.567
CTAS	S&P500	Dollar	0.587	CTSH	Öl	S&P500	0.573
CTVA	Öl	S&P500	0.456	CVS	Staatsanleihe	S&P500	0.388
CVX	Öl	S&P500	0.608	D	Staatsanleihe	S&P500	0.355
DAL	S&P500	Dollar	0.437	DD	Öl	S&P500	0.577
DE	Staatsanleihe	S&P500	0.450	DG	Staatsanleihe	S&P500	0.315
DGX	S&P500	Dollar	0.333	DHI	Staatsanleihe	S&P500	0.498
DHR	Staatsanleihe	S&P500	0.492	DIS	S&P500	Dollar	0.529
DLR	Staatsanleihe	S&P500	0.506	DLTR	Öl	S&P500	0.394
DOV	S&P500	Dollar	0.590	DOW	Öl	S&P500	0.567
DPZ	Staatsanleihe	S&P500	0.356	DRI	Staatsanleihe	S&P500	0.407
DTE	Staatsanleihe	S&P500	0.300	DUK	Staatsanleihe	S&P500	0.290
DVA	S&P500	Dollar	0.360	DVN	Öl	S&P500	0.614
DXC	Staatsanleihe	S&P500	0.539	DXCM	Öl	S&P500	0.428
EA	Staatsanleihe	S&P500	0.378	EBAY	S&P500	Inflation	0.446
ECL	S&P500	Dollar	0.610	ED	Staatsanleihe	S&P500	0.296
EFX	Staatsanleihe	S&P500	0.510	EIX	Gold	S&P500	0.366
EL	Gold	S&P500	0.582	EMN	S&P500	Dollar	0.543
EMR	Staatsanleihe	S&P500	0.604	EOG	Öl	S&P500	0.565
EQIX	Staatsanleihe	S&P500	0.522	EQR	S&P500	Dollar	0.463
ES	Staatsanleihe	S&P500	0.364	ESS	S&P500	Dollar	0.443
ETN	Öl	S&P500	0.548	ETR	Staatsanleihe	S&P500	0.347
ETSY	Gold	S&P500	0.358	EVRG	Staatsanleihe	S&P500	0.379
EW	S&P500	Dollar	0.474	EXC	Staatsanleihe	S&P500	0.421
EXPD	Öl	S&P500	0.492	EXPE	Staatsanleihe	S&P500	0.501
EXR	Staatsanleihe	S&P500	0.394	F	Staatsanleihe	S&P500	0.450
FANG	Öl	S&P500	0.606	FAST	S&P500	Inflation	0.539

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
FCX	S&P500	Dollar	0.545	FDX	Staatsanleihe	S&P500	0.489
FE	Staatsanleihe	S&P500	0.335	FFIV	Gold	S&P500	0.531
FIS	S&P500	Dollar	0.484	FISV	S&P500	Dollar	0.502
FITB	Staatsanleihe	S&P500	0.560	FLS	Öl	S&P500	0.539
FMC	S&P500	Dollar	0.451	FOX	Staatsanleihe	S&P500	0.400
FOXA	S&P500	Dollar	0.395	FRT	S&P500	Dollar	0.469
FTI	Öl	S&P500	0.431	FTNT	S&P500	Dollar	0.519
FTV	S&P500	Dollar	0.573	GD	Öl	S&P500	0.454
GE	Staatsanleihe	S&P500	0.447	GILD	Gold	S&P500	0.340
GIS	Staatsanleihe	S&P500	0.214	GL	Staatsanleihe	S&P500	0.536
GLW	S&P500	Dollar	0.568	GM	Staatsanleihe	S&P500	0.509
GOOG	S&P500	Inflation	0.615	GOOGL	S&P500	Dollar	0.596
GPC	Staatsanleihe	S&P500	0.419	GPN	S&P500	Dollar	0.530
GRMN	S&P500	Dollar	0.558	GS	Staatsanleihe	S&P500	0.556
GWW	Öl	S&P500	0.436	HAL	Öl	S&P500	0.623
HAS	Staatsanleihe	S&P500	0.443	HBAN	Staatsanleihe	S&P500	0.548
HCA	Öl	S&P500	0.445	HD	Staatsanleihe	S&P500	0.526
HIG	Staatsanleihe	S&P500	0.431	HII	Staatsanleihe	S&P500	0.386
HLT	Staatsanleihe	S&P500	0.494	HOLX	S&P500	Dollar	0.420
HON	S&P500	Dollar	0.570	HPE	Öl	S&P500	0.525
HPQ	S&P500	Dollar	0.585	HRL	Gold	S&P500	0.187
HSIC	S&P500	Dollar	0.424	HST	S&P500	Dollar	0.478
HSY	Staatsanleihe	S&P500	0.355	HUM	S&P500	Inflation	0.312
HWM	Staatsanleihe	S&P500	0.479	IBM	Öl	S&P500	0.463
ICE	S&P500	Dollar	0.488	IDXX	Staatsanleihe	S&P500	0.520
IEX	S&P500	Dollar	0.478	IFF	S&P500	Dollar	0.518
ILMN	Staatsanleihe	S&P500	0.417	INCY	Gold	S&P500	0.279
INTC	S&P500	Dollar	0.574	INTU	Staatsanleihe	S&P500	0.616
IP	Staatsanleihe	S&P500	0.469	IPGP	Öl	S&P500	0.509
IQV	Öl	S&P500	0.569	IR	Öl	S&P500	0.579
IRM	S&P500	Dollar	0.474	ISRG	Staatsanleihe	S&P500	0.592
IT	Öl	S&P500	0.550	ITW	S&P500	Dollar	0.575
IVZ	Öl	S&P500	0.560	J	Öl	S&P500	0.441

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
JBHT	Öl	S&P500	0.386	JCI	S&P500	Dollar	0.505
JKHY	Staatsanleihe	S&P500	0.463	JNJ	S&P500	Dollar	0.340
JPM	Staatsanleihe	S&P500	0.580	KEY	Staatsanleihe	S&P500	0.539
KEYS	S&P500	Dollar	0.559	KHC	Staatsanleihe	S&P500	0.236
KIM	Öl	S&P500	0.483	KLAC	S&P500	Dollar	0.560
KMB	Staatsanleihe	S&P500	0.284	KMI	Öl	S&P500	0.604
KMX	Staatsanleihe	S&P500	0.493	KO	S&P500	Dollar	0.441
KR	Öl	S&P500	0.200	KSS	Staatsanleihe	S&P500	0.440
L	Staatsanleihe	S&P500	0.585	LDOS	Öl	S&P500	0.372
LEG	Staatsanleihe	S&P500	0.508	LEN	Staatsanleihe	S&P500	0.540
LH	S&P500	Dollar	0.352	LHX	Öl	S&P500	0.352
LIN	S&P500	Dollar	0.582	LKQ	Staatsanleihe	S&P500	0.535
LLY	Gold	S&P500	0.315	LMT	Öl	S&P500	0.317
LNT	Staatsanleihe	S&P500	0.386	LOW	Öl	S&P500	0.470
LRCX	S&P500	Dollar	0.551	LUMN	Staatsanleihe	S&P500	0.319
LUV	Öl	S&P500	0.417	LVS	Staatsanleihe	S&P500	0.444
LW	Staatsanleihe	S&P500	0.375	LYB	Öl	S&P500	0.563
LYV	Staatsanleihe	S&P500	0.531	MA	S&P500	Dollar	0.581
MAA	Staatsanleihe	S&P500	0.424	MAR	S&P500	Dollar	0.498
MAS	S&P500	Dollar	0.541	MCD	S&P500	Dollar	0.407
MCHP	S&P500	Dollar	0.592	MCK	Staatsanleihe	S&P500	0.375
MCO	Staatsanleihe	S&P500	0.646	MDLZ	S&P500	Dollar	0.405
MDT	S&P500	Dollar	0.491	MET	Staatsanleihe	S&P500	0.579
MGM	Staatsanleihe	S&P500	0.509	MHK	S&P500	Dollar	0.498
MKC	Staatsanleihe	S&P500	0.384	MKTX	Staatsanleihe	S&P500	0.388
MLM	S&P500	Dollar	0.535	MMM	S&P500	Dollar	0.458
MNST	S&P500	Dollar	0.492	MO	S&P500	Dollar	0.288
MOS	Öl	S&P500	0.451	MPC	Öl	S&P500	0.501
MRK	Öl	S&P500	0.244	MS	Öl	S&P500	0.567
MSCI	Staatsanleihe	S&P500	0.582	MSFT	Staatsanleihe	S&P500	0.660
MSI	S&P500	Dollar	0.543	MTB	Staatsanleihe	S&P500	0.500
MTD	S&P500	Dollar	0.475	MU	S&P500	Dollar	0.508
NCLH	Staatsanleihe	S&P500	0.457	NDAQ	Staatsanleihe	S&P500	0.553

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
NEE	Gold	S&P500	0.470	NEM	Gold	S&P500	0.525
NFLX	Staatsanleihe	S&P500	0.450	NI	Staatsanleihe	S&P500	0.299
NKE	Öl	S&P500	0.507	NOC	Staatsanleihe	S&P500	0.264
NOV	Öl	S&P500	0.499	NOW	Staatsanleihe	S&P500	0.525
NRG	Öl	S&P500	0.389	NSC	Öl	S&P500	0.498
NTAP	Öl	S&P500	0.490	NTRS	Staatsanleihe	S&P500	0.535
NUE	Öl	S&P500	0.502	NVDA	S&P500	Dollar	0.525
NVR	Staatsanleihe	S&P500	0.486	NWL	Staatsanleihe	S&P500	0.444
NWS	S&P500	Dollar	0.513	NWSA	S&P500	Dollar	0.507
O	Staatsanleihe	S&P500	0.390	ODFL	S&P500	Dollar	0.482
OKE	Öl	S&P500	0.609	OMC	S&P500	Dollar	0.482
ORCL	Staatsanleihe	S&P500	0.437	ORLY	Gold	S&P500	0.315
OTIS	Öl	Gold	0.000	OXY	Öl	S&P500	0.610
PAYC	S&P500	Dollar	0.495	PAYX	Öl	S&P500	0.596
PCAR	Öl	S&P500	0.468	PEG	Staatsanleihe	S&P500	0.328
PEP	Staatsanleihe	S&P500	0.432	PFE	Staatsanleihe	S&P500	0.279
PFG	Staatsanleihe	S&P500	0.571	PG	S&P500	Dollar	0.350
PGR	Staatsanleihe	S&P500	0.347	PH	Staatsanleihe	S&P500	0.600
PHM	Staatsanleihe	S&P500	0.462	PKG	Staatsanleihe	S&P500	0.385
PLD	Staatsanleihe	S&P500	0.509	PM	S&P500	Dollar	0.391
PNC	Staatsanleihe	S&P500	0.551	PNR	Öl	S&P500	0.512
PNW	Staatsanleihe	S&P500	0.296	PPG	S&P500	Dollar	0.548
PPL	S&P500	Dollar	0.374	PRGO	S&P500	Dollar	0.392
PRU	Staatsanleihe	S&P500	0.599	PSA	Staatsanleihe	S&P500	0.385
PSX	Öl	S&P500	0.504	PVH	Staatsanleihe	S&P500	0.444
PWR	Öl	S&P500	0.540	PYPL	Staatsanleihe	S&P500	0.530
QCOM	S&P500	Dollar	0.572	QRVO	S&P500	Dollar	0.549
RCL	Staatsanleihe	S&P500	0.479	REG	S&P500	Dollar	0.463
REGN	Staatsanleihe	S&P500	0.378	RF	Staatsanleihe	S&P500	0.546
RHI	Staatsanleihe	S&P500	0.520	RJF	Staatsanleihe	S&P500	0.584
RL	Öl	S&P500	0.416	RMD	S&P500	Dollar	0.448
ROK	Staatsanleihe	S&P500	0.568	ROL	Staatsanleihe	S&P500	0.428
ROP	Staatsanleihe	S&P500	0.543	ROST	Staatsanleihe	S&P500	0.530

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
RSG	S&P500	Inflation	0.414	RTX	Staatsanleihe	S&P500	0.446
SBAC	Staatsanleihe	S&P500	0.466	SBUX	S&P500	Dollar	0.569
SCHW	Staatsanleihe	S&P500	0.555	SEE	S&P500	Dollar	0.453
SHW	Staatsanleihe	S&P500	0.570	SJM	S&P500	Dollar	0.185
SLB	Öl	S&P500	0.575	SLG	S&P500	Dollar	0.413
SNA	Öl	S&P500	0.514	SNPS	Staatsanleihe	S&P500	0.598
SO	Staatsanleihe	S&P500	0.384	SPG	S&P500	Dollar	0.476
SPGI	Staatsanleihe	S&P500	0.585	SRE	Öl	S&P500	0.369
STE	S&P500	Inflation	0.490	STT	Staatsanleihe	S&P500	0.583
STX	S&P500	Dollar	0.513	STZ	S&P500	Inflation	0.444
SWK	S&P500	Dollar	0.544	SWKS	S&P500	Dollar	0.599
SYF	Staatsanleihe	S&P500	0.488	SYK	S&P500	Dollar	0.545
SYU	Staatsanleihe	S&P500	0.452	T	S&P500	Dollar	0.335
TAP	S&P500	Dollar	0.330	TDG	S&P500	Dollar	0.533
TDY	Öl	S&P500	0.540	TEL	Gold	S&P500	0.656
TER	S&P500	Dollar	0.567	TFC	Staatsanleihe	S&P500	0.569
TFX	Staatsanleihe	S&P500	0.458	TGT	Öl	S&P500	0.424
TJX	Staatsanleihe	S&P500	0.499	TMO	Gold	S&P500	0.468
TMUS	S&P500	Dollar	0.435	TPR	Staatsanleihe	S&P500	0.440
TROW	S&P500	Dollar	0.592	TRV	Staatsanleihe	S&P500	0.469
TSCO	S&P500	Dollar	0.361	TSN	S&P500	Inflation	0.315
TT	S&P500	Dollar	0.505	TTWO	Staatsanleihe	S&P500	0.399
TXN	Öl	S&P500	0.638	TXT	Staatsanleihe	S&P500	0.551
TYL	Staatsanleihe	S&P500	0.553	UA	S&P500	Dollar	0.462
UAA	Staatsanleihe	S&P500	0.466	UAL	S&P500	Dollar	0.412
UDR	S&P500	Dollar	0.440	UHS	Gold	S&P500	0.428
ULTA	Staatsanleihe	S&P500	0.438	UNH	Staatsanleihe	S&P500	0.365
UNM	Staatsanleihe	S&P500	0.544	UNP	Öl	S&P500	0.461
UPS	S&P500	Dollar	0.417	URI	Öl	S&P500	0.520
USB	Staatsanleihe	S&P500	0.478	V	S&P500	Dollar	0.560
VFC	Staatsanleihe	S&P500	0.424	VLO	Öl	S&P500	0.476
VMC	S&P500	Dollar	0.500	VNO	S&P500	Dollar	0.445
VRSK	Staatsanleihe	S&P500	0.539	VRSN	Staatsanleihe	S&P500	0.577

Fortsetzung auf nächster Seite

Tabelle C.1 Fortsetzung

Ticker	Faktor 1	Faktor 2	$\Sigma \beta $	Ticker	Faktor 1	Faktor 2	$\Sigma \beta $
VRTX	S&P500	Dollar	0.292	VTR	S&P500	Dollar	0.394
VZ	S&P500	Inflation	0.318	WAB	Öl	S&P500	0.541
WAT	S&P500	Dollar	0.422	WDC	S&P500	Dollar	0.515
WEC	Staatsanleihe	S&P500	0.368	WELL	S&P500	Dollar	0.389
WFC	Staatsanleihe	S&P500	0.525	WHR	S&P500	Dollar	0.449
WM	Gold	S&P500	0.425	WMB	Öl	S&P500	0.527
WMT	S&P500	Inflation	0.324	WRB	Staatsanleihe	S&P500	0.452
WST	S&P500	Dollar	0.445	WU	S&P500	Dollar	0.394
WY	S&P500	Dollar	0.540	WYNN	Staatsanleihe	S&P500	0.456
XEL	Staatsanleihe	S&P500	0.337	XOM	Öl	S&P500	0.605
XRAY	S&P500	Dollar	0.468	XXR	S&P500	Dollar	0.466
XYL	S&P500	Dollar	0.543	YUM	S&P500	Dollar	0.485
ZBH	S&P500	Dollar	0.454	ZBRA	S&P500	Dollar	0.546
ZION	Staatsanleihe	S&P500	0.520	ZTS	S&P500	Dollar	0.522

C.2. Durchschnittliche simulierte ROIs

Tabelle C.2 zeigt für jede der 450 analysierten Aktien den durchschnittlich simulierten ROI aus der SDE-basierten Aktienausswahl. Die Tabelle ist absteigend nach ROI sortiert.

Tabelle C.2.: Durchschnittliche simulierte ROIs aller analysierten Aktien

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
IT	25.7447 %	AJG	25.3924 %
RSG	24.4984 %	CTAS	24.4781 %
TT	23.3894 %	GOOG	23.2101 %
ABBV	22.9243 %	PEP	22.9158 %
GWV	22.7370 %	CARR	22.6819 %
ORLY	21.6539 %	VRSK	21.5144 %
WMB	21.4489 %	AFL	21.4471 %
FE	21.3520 %	ISRG	20.6758 %
GD	20.4991 %	AKAM	20.2207 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
AME	19.9581 %	TDY	19.8492 %
COST	19.6419 %	SNPS	19.1518 %
IDXX	19.1177 %	CPRT	18.9348 %
ODFL	18.8614 %	TRV	18.6148 %
NRG	18.6128 %	NVDA	18.5597 %
MCO	18.4580 %	HD	18.3650 %
RMD	18.3501 %	WM	18.0908 %
AIZ	18.0458 %	CDNS	18.0335 %
ADM	17.6503 %	EFX	17.6324 %
PHM	17.5526 %	GPC	17.5271 %
A	17.4686 %	IEX	17.4672 %
MTD	17.4022 %	FTNT	17.3902 %
PLD	17.3419 %	ORCL	17.3175 %
BLK	17.2431 %	MCK	17.2055 %
NOW	17.1089 %	PNR	17.0451 %
MO	16.9324 %	TDG	16.8189 %
PM	16.7021 %	MSI	16.6690 %
ROL	16.6197 %	FAST	16.5359 %
ADBE	16.5062 %	PWR	16.4865 %
JKHY	16.4138 %	JCI	16.4060 %
TROW	16.4053 %	PAYC	16.3063 %
LOW	16.3007 %	PG	16.2214 %
HWM	16.2119 %	GOOGL	16.2052 %
MSFT	16.1938 %	NVR	16.0323 %
KO	16.0171 %	IRM	15.7024 %
CL	15.6868 %	ADP	15.6340 %
AZO	15.5829 %	ROP	15.5161 %
DOV	15.4712 %	PCAR	15.3499 %
OTIS	15.2204 %	BRK-B	15.1788 %
VRTX	14.9623 %	MPC	14.7995 %
ITW	14.7912 %	AVGO	14.7907 %
APH	14.7759 %	CHD	14.7753 %
YUM	14.7732 %	ACN	14.6466 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
HPQ	14.6225 %	DHI	14.5306 %
CLX	14.5243 %	ATO	14.5240 %
CMS	14.4851 %	ETN	14.4034 %
ROK	14.3484 %	CI	14.3100 %
DXCM	14.3033 %	CMCSA	14.2725 %
DHR	14.2662 %	AIG	14.1926 %
LIN	14.1912 %	NSC	14.1311 %
UNH	14.0673 %	DVA	13.9473 %
NI	13.9358 %	PAYX	13.7488 %
WST	13.6285 %	DTE	13.5287 %
CMG	13.5247 %	LH	13.4553 %
AEE	13.3928 %	TSCO	13.3409 %
AEP	13.3270 %	NTAP	13.3047 %
STE	13.1803 %	RJF	13.1337 %
VRSN	13.0497 %	UNP	12.9741 %
MCD	12.9719 %	ADI	12.9602 %
BIO	12.9361 %	STZ	12.9214 %
WRB	12.9119 %	CNP	12.8141 %
EXC	12.6699 %	WHR	12.6383 %
LLY	12.5645 %	BR	12.5616 %
DE	12.2536 %	AMAT	12.1881 %
PSA	12.1550 %	MKC	12.1312 %
ECL	12.0694 %	BSX	12.0161 %
PEG	11.9764 %	BBY	11.9401 %
ETR	11.8205 %	KR	11.8109 %
HON	11.7741 %	PH	11.7722 %
MDLZ	11.7057 %	PGR	11.6143 %
APD	11.5835 %	IR	11.5245 %
MAS	11.5207 %	ANET	11.4260 %
ARE	11.3705 %	CAH	11.3529 %
CHRW	11.3470 %	TMO	11.2586 %
OKE	11.2421 %	CB	11.2290 %
AAPL	11.2158 %	MNST	11.2044 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
SPGI	11.2030 %	EXPD	11.1245 %
DGX	11.1068 %	NUE	11.0948 %
UNM	11.0613 %	IBM	11.0121 %
INTU	10.9937 %	MET	10.9919 %
AON	10.9451 %	SYK	10.9137 %
HIG	10.9017 %	SO	10.8381 %
RHI	10.8359 %	SRE	10.6626 %
MSCI	10.5729 %	NOC	10.5486 %
TMUS	10.5476 %	SNA	10.4755 %
KEYS	10.4754 %	SJM	10.4069 %
V	10.3378 %	AMP	10.3134 %
EA	10.2587 %	SHW	10.2495 %
EQIX	10.1694 %	KIM	10.1592 %
CBOE	10.1276 %	CVX	10.0902 %
O	10.0821 %	DLR	10.0742 %
FDX	10.0376 %	ED	9.9507 %
AVB	9.9082 %	CRM	9.8926 %
AMCR	9.7886 %	CHTR	9.7788 %
L	9.7227 %	HRL	9.7069 %
HCA	9.7052 %	SPG	9.4940 %
BK	9.4812 %	FANG	9.4523 %
EIX	9.3985 %	ULTA	9.3664 %
WELL	9.3629 %	WU	9.3474 %
RL	9.3471 %	MA	9.3230 %
ALB	9.3077 %	XRX	9.2851 %
HUM	9.2814 %	CAT	9.2399 %
DUK	9.2377 %	LEN	9.1613 %
EXR	9.1457 %	LDOS	9.0550 %
KLAC	8.9906 %	FISV	8.9683 %
CDW	8.9437 %	CTVA	8.9078 %
AWK	8.8993 %	VMC	8.8024 %
CE	8.7769 %	ALL	8.7757 %
LW	8.7534 %	WY	8.7285 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
STT	8.7095 %	TPR	8.6628 %
UA	8.6526 %	AMZN	8.5172 %
ADSK	8.5083 %	KHC	8.4548 %
LMT	8.4479 %	NDAQ	8.4342 %
COF	8.4077 %	HSY	8.3149 %
URI	8.3010 %	GL	8.2930 %
MLM	8.2150 %	HII	8.1151 %
TEL	8.0056 %	QCOM	7.9440 %
WMT	7.8921 %	HAS	7.8694 %
ICE	7.7252 %	BKR	7.7163 %
HLT	7.7114 %	BAX	7.7005 %
J	7.6005 %	TTWO	7.5940 %
AES	7.5327 %	CMI	7.5189 %
XRAY	7.4919 %	ESS	7.4359 %
DPZ	7.4288 %	MOS	7.3254 %
XYL	7.2596 %	AVY	7.2151 %
GRMN	7.1827 %	GIS	7.1595 %
TXT	7.1540 %	EVRG	7.1080 %
TER	7.0376 %	CCI	6.9574 %
NTRS	6.8855 %	IQV	6.8309 %
VTR	6.7768 %	UHS	6.7527 %
EBAY	6.7400 %	ZTS	6.6648 %
PPG	6.5090 %	WAT	6.4993 %
TYL	6.4824 %	LKQ	6.4769 %
DRI	6.2597 %	NWSA	6.1820 %
CME	6.1609 %	FLS	6.1497 %
ROST	6.0839 %	XEL	6.0573 %
DVN	6.0551 %	STX	6.0520 %
SYF	6.0330 %	KMB	5.9986 %
DLTR	5.9935 %	AOS	5.9128 %
COP	5.7812 %	SEE	5.7445 %
LYB	5.7121 %	CSCO	5.7114 %
NEE	5.6471 %	ALLE	5.6141 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
MCHP	5.5943 %	JBHT	5.5528 %
BDX	5.4558 %	AXP	5.4305 %
PRU	5.3082 %	HPE	5.2888 %
FTV	5.2473 %	DOW	5.2444 %
BKNG	5.2438 %	TXN	5.2432 %
CINF	5.2394 %	NWS	5.2321 %
FFIV	5.2131 %	REG	5.1810 %
MU	5.1372 %	ZBRA	5.1298 %
UAA	5.1089 %	PNW	5.0555 %
SBAC	5.0535 %	GE	4.9853 %
PNC	4.9820 %	PKG	4.9767 %
CSX	4.9303 %	ABT	4.8778 %
UDR	4.7040 %	FITB	4.5525 %
PFG	4.5470 %	EMN	4.4456 %
FRT	4.3549 %	IVZ	4.3441 %
DXC	4.2994 %	PYPL	4.2789 %
GPN	4.2614 %	CBRE	4.1281 %
PPL	4.1249 %	MAR	4.0006 %
MTB	3.9429 %	GLW	3.8896 %
CNC	3.8826 %	WAB	3.8279 %
XOM	3.7520 %	BWA	3.6955 %
MS	3.6759 %	EQR	3.4969 %
MAA	3.4928 %	EW	3.4217 %
NWL	3.3325 %	CAG	3.3131 %
PSX	3.1975 %	TFC	3.1943 %
RF	3.1183 %	TGT	2.9608 %
SWKS	2.9488 %	BAC	2.8983 %
OMC	2.8106 %	CPB	2.7203 %
CTSH	2.6534 %	VFC	2.5676 %
FIS	2.4425 %	APA	2.4319 %
TAP	2.3935 %	FMC	2.3738 %
HOLX	2.3404 %	LNT	2.2917 %
WDC	2.2715 %	DG	2.2649 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
SLB	2.2415 %	SLG	2.1801 %
ETSY	2.1093 %	IPGP	2.0821 %
T	2.0411 %	SBUX	2.0139 %
MRK	1.9977 %	EL	1.9967 %
KMX	1.9700 %	QRVO	1.9660 %
JPM	1.8980 %	D	1.8883 %
KMI	1.7960 %	BF-B	1.7899 %
TFX	1.7497 %	EMR	1.7437 %
TJX	1.7405 %	INTC	1.7267 %
WEC	1.6807 %	SCHW	1.6493 %
CF	1.6143 %	UPS	1.5664 %
CVS	1.2629 %	LHX	1.1662 %
MDT	1.1134 %	WFC	0.8451 %
GS	0.8379 %	LRCX	0.7300 %
NFLX	0.6751 %	GM	0.5226 %
C	0.4917 %	ZION	0.4833 %
HST	0.3644 %	MMM	0.3546 %
JNJ	0.1374 %	AMD	0.0198 %
REGN	-0.0500 %	FOXA	-0.1068 %
NKE	-0.3099 %	ES	-0.5022 %
APTV	-0.6737 %	RTX	-0.7481 %
DD	-0.9682 %	CFG	-0.9861 %
COO	-0.9875 %	F	-1.1391 %
USB	-1.1433 %	MGM	-1.3073 %
HSIC	-1.3563 %	NOV	-1.7142 %
VLO	-1.7762 %	AIV	-1.8146 %
BEN	-1.8752 %	FTI	-1.8921 %
KEY	-2.0250 %	AAP	-2.0571 %
PVH	-2.4244 %	IP	-2.4933 %
LYV	-2.5125 %	RCL	-2.6225 %
ALK	-2.6424 %	MKTX	-2.8071 %
BXP	-3.0923 %	SYY	-3.1464 %
HAL	-3.2572 %	BA	-3.2848 %

Fortsetzung auf nächster Seite

Tabelle C.2 Fortsetzung

Ticker	Ø sim. ROI	Ticker	Ø sim. ROI
WYNN	-3.5153 %	ILMN	-3.6057 %
FCX	-3.7223 %	TSN	-3.8837 %
VZ	-3.9767 %	LUMN	-4.1821 %
EXPE	-4.1929 %	IFF	-4.2558 %
LEG	-4.3368 %	BMY	-4.4097 %
SWK	-4.8371 %	HBAN	-4.9149 %
OXY	-5.3337 %	UAL	-5.5634 %
AMT	-5.7659 %	NEM	-6.0286 %
GILD	-6.1786 %	MHK	-6.3131 %
PRGO	-6.3339 %	DAL	-6.3369 %
VNO	-6.4606 %	AMGN	-6.6113 %
EOG	-7.0431 %	ZBH	-7.5005 %
LUV	-7.7926 %	NCLH	-8.2685 %
DIS	-8.3437 %	INCY	-8.5144 %
AAL	-8.6742 %	FOX	-9.1064 %
LVS	-10.3665 %	KSS	-10.3719 %
ALGN	-12.2289 %	BIIB	-12.8876 %
CCL	-13.5110 %	PFE	-15.4255 %