



Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

Studienarbeit (T3_3101)

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Informatik

an der Dualen Hochschule Baden-Württemberg Karlsruhe

von

Max Katzenberger und Mathis Köder

Abgabedatum:	01. Februar 2025
Bearbeitungszeitraum:	01.10.2024 - 31.01.2025
Matrikelnummer, Kurs:	0000000, TINF23B2
Ausbildungsfirma:	SAP SE Dietmar-Hopp-Allee 16 69190 Walldorf, Deutschland
Gutachter der Dualen Hochschule:	apl. Prof. Dr. Markus Reischl

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich meine Studienarbeit (T3_3101) mit dem Thema:

Untersuchung von mathematischen Verfahren zur Vorhersage von Aktienkursen

gemäß § 5 der "Studien- und Prüfungsordnung DHBW Technik" vom 29. September 2017 selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, den March 15, 2026

Nachname, Vorname

Abstract

- English -

This is the starting point of the Abstract. For the final bachelor thesis, there must be an abstract included in your document. So, start now writing it in German and English. The abstract is a short summary with around 200 to 250 words.

Try to include in this abstract the main question of your work, the methods you used or the main results of your work.

Abstract

- Deutsch -

Dies ist der Beginn des Abstracts. Für die finale Bachelorarbeit musst du ein Abstract in deinem Dokument mit einbauen. So, schreibe es am besten jetzt in Deutsch und Englisch. Das Abstract ist eine kurze Zusammenfassung mit ca. 200 bis 250 Wörtern.

Versuche in das Abstract folgende Punkte aufzunehmen: Fragestellung der Arbeit, methodische Vorgehensweise oder die Hauptergebnisse deiner Arbeit.

Contents

Formelverzeichnis	V
Abkürzungsverzeichnis	VI
List of Figures	VII
List of Tables	VIII
Quellcodeverzeichnis	IX
1 Einleitung	1
1.1 Motivation	1
1.2 Probleme	1
1.3 Ziel der Arbeit	2
2 Stand der Forschung	4
2.1 Grundlagen	4
2.2 Zeitreihenanalyse	4
3 Konzeption	5
3.1 Überblick	5
3.2 Daten und Benchmarking	6
3.3 Bewertungskriterien	9
3.4 Modellentwicklung	13
3.5 Marktstrategie	14
4 Implementierung	15
5 Ergebnisse und Bewertung	16
5.1 Variante1	16
5.2 Variante2	16
6 Zusammenfassung und Ausblick	17
Literaturverzeichnis	X

Formelverzeichnis

A	mm ²	Fläche
D	mm	Werkstückdurchmesser
$d_{\min}$	mm	kleinster Schaftdurchmesser
L_1	mm	Länge des Werkstückes Nr. 1
	Grad	Freiwinkel
	Grad	Keilwinkel

Abkürzungsverzeichnis

EMH	Efficient Market Hypothesis
DoS	Definition of Success
RMSE	Root Mean Squared Error
DA	Directional Accuracy
MDD	Maximum Drawdown
LSTM	Long Short Term Memory
SVM	Support Vector Machines

List of Figures

List of Tables

3.1	Ausgewählte Aktien	7
-----	------------------------------	---

Quellcodeverzeichnis

1 Einleitung

1.1 Motivation

Die Vorhersage von Aktienkursen stellt eine zentrale Herausforderung der Finanzökonomie dar. Trotz umfangreicher Forschung bleibt die präzise Prognose zukünftiger Kursbewegungen aufgrund der Komplexität und Volatilität der Märkte schwierig. In den letzten Jahren wurden vermehrt mathematische und datengetriebene Methoden untersucht, um Muster in Finanzkursen zu identifizieren und Vorhersagen zu verbessern. Da ein zuverlässiger und konsistenter Algorithmus zur Vorhersage von Aktienkursen potenziell erhebliche finanzielle Vorteile bieten würde, ist das Interesse an der Entwicklung solcher Verfahren entsprechend groß.

1.2 Probleme

Ein zentrales theoretisches Problem bei der Vorhersage von Aktienkursen ergibt sich aus der Efficient Market Hypothesis (EMH). Die EMH besagt, dass alle verfügbaren Informationen bereits vollständig in den aktuellen Marktpreisen enthalten sind, sodass zukünftige Kursbewegungen per Definition nicht systematisch vorhergesagt werden können. Unter dieser Annahme verhalten sich Preisänderungen wie ein zufälliger Prozess, der durch keinen Algorithmus vorhergesagt werden kann und die Machbarkeit des Ziels dieser Arbeit in Frage stellt [1]. Trotz der theoretischen Einschränkungen durch die Markteffizienzhypothese existieren empirische Beispiele erfolgreicher quantitativer Handelsstrategien. Renaissance Technologies nutzt seit Jahrzehnten fast ausschließlich mathematis-

che Modelle und Algorithmen zur Kursprognose und erzielt mit dem Medallion Fund Renditen in Höhe von 66% p.a. Dies zeigt, dass systematische Modelle wiederkehrende Muster in Finanzdaten sehr wohl erkennen und wirtschaftlich nutzen können. Hierbei sei anzumerken, dass die genaue Funktionsweise der verwendeten Algorithmen selbstverständlich unbekannt ist. Quantitative Fonds agieren als "Black-Box", was die wissenschaftliche Nachvollziehbarkeit erschwert und somit kein gesichertes Gegenbeispiel zur EMH ist [2]. Des Weiteren gibt es empirische, öffentliche Analysen, die zeigen, dass nicht-lineare Vorhersagemethoden durchaus Gewinne erzielen können [3]. Neben der Frage nach der allgemeinen Machbarkeit ergeben sich eine Vielzahl praktischer Probleme, die die Entwicklung erschweren. Zunächst enthalten Kursdaten viel Rauschen. Es ist schwer den tatsächlichen Signalanteil des Preises herauszufiltern, um zu den Trend zu erkennen. Des Weiteren ist es eine große Schwierigkeit, den korrekten Komplexitätsgrad des Modells zu finden. Zu komplexe Modelle „overfitten“, passen sich also zu stark an historische Daten an und generalisieren somit schlecht auf neuen, realen Daten. Dies betrifft vor allem Deep Learning Modelle, welche zu viele Freiheitsgrade haben, und somit den vergangenen Kurs oder das Rauschen selbst abbilden und den Trend dabei nicht erkennen. Auf der anderen Seite sind zu simple Modelle nicht in der Lage nicht-lineare Zusammenhänge zu erkennen und generalisieren zu stark [4].

1.3 Ziel der Arbeit

Das Ziel dieser Arbeit ist die Untersuchung bestehender Algorithmen und Strategien auf deren Rentabilität und Stabilität. Es soll eine Testumgebung geschaffen werden, mit welcher verschiedene Analysemodelle getestet und auf realen, vergangenen Daten ausprobiert werden können. Des Weiteren soll ein eigenes Modell durch neue Ideen und eine Kombination von vorhandenen Strategien geschaffen werden. Diese Strategien sollen zum einen mathematischer,

quantitativer Natur sein, und zum anderen durch live Nachrichten und Social Media Posts angereichert werden. Schließlich soll jedes Modell evaluiert und bewertet werden.

2 Stand der Forschung

2.1 Grundlagen

2.2 Zeitreihenanalyse

2.2.1 stochastische Differentialgleichungen

2.2.2 ARIMA usw

:

2.2.3 Zusammenfassung

3 Konzeption

3.1 Überblick

In diesem Kapitel wird die Entwicklung der in dieser Arbeit verwendeten Modelle zur Vorhersage von Aktienkursen beschrieben. Dabei werden verschiedene Ansätze aus der Zeitreihenanalyse und dem maschinellen Lernen konzeptioniert.

Der Aufbau erfolgt schrittweise. Zunächst werden einfache lineare Modelle betrachtet, die ausschließlich auf historischen Kursreihen basieren. Diese Modelle dienen als Referenzpunkt für spätere, komplexere Ansätze. Sie ermöglichen es, grundlegende zeitliche Strukturen wie Trends oder Autokorrelationen in den Daten zu untersuchen.

Anschließend wird untersucht, ob sich Informationen aus mehreren Aktien gleichzeitig nutzen lassen. Unternehmen innerhalb eines Marktes weisen häufig gemeinsame Bewegungen auf, beispielsweise durch Zusammenhänge oder Geschäftssektoren. Daher wird eine Korrelationsstruktur zwischen den betrachteten Aktien berechnet und als zusätzliches Merkmal für weitere Modelle verwendet.

Unter anderem darauf aufbauend werden Verfahren des maschinellen Lernens eingesetzt. Es werden verschiedene nicht-lineare Vorhersagemethoden untersucht. Darunter Transformer, Long Short Term Memory (LSTM) und Support Vector Machines (SVM).

Neben historischen Kursdaten werden auch externe Informationsquellen betrachtet. Finanzmärkte reagieren immer häufiger auf Nachrichten oder öffentliche Meinungen. Daher wird eine einfache Sentiment-Analyse von Echtzeitinfor-

mationen integriert, um mögliche Zusammenhänge zwischen öffentlichen Informationen und Kursbewegungen zu untersuchen. Hierbei sollen sowohl das allgemeine öffentliche Marktgefühl, ausgedrückt durch die Anzahl an Posts, als auch der Einfluss von Nachrichten, die von einflussreichen Personen veröffentlicht werden.

Abschließend werden Modelle betrachtet, die mehrere zuvor berechnete Merkmale kombinieren. Dazu gehören beispielsweise Ergebnisse aus Zeitreihenmodellen, Korrelations- oder Sentimentinformationen. Diese werden gemeinsam als Eingabe für maschinelle Lernverfahren verwendet, um zu prüfen, ob sich durch die Kombination verschiedener Informationsquellen bessere Vorhersagen erzielen lassen.

Neben der Modellierung der Kursbewegungen wird am Ende des Kapitels auch die Umsetzung der Vorhersagen in einer Handelsstrategie beschrieben. Dabei werden insbesondere das Risikomanagements, der Positionsgrößen sowie des Vorhersagehorizonts betrachtet, um die praktische Anwendbarkeit der Modelle zu analysieren.

3.2 Daten und Benchmarking

Für die Analyse wird ein festes Aktienuniversum herangezogen, bestehend aus den im Jahr 2020 im S&P500 gelisteten Unternehmen. Diese Auswahl stellt sicher, dass ein Survivorship Bias vermieden wird, da nur Unternehmen berücksichtigt werden, die zu Beginn des Analysezeitraums tatsächlich existierten und zum Zeitpunkt der Auswahl keine zukünftigen Informationen die Wahl der Trainings- oder Testaktien beeinflussen.

Die Kursdaten jeder Aktie werden als Zeitreihe betrachtet. Für jede Zeitreihe wird eine Unterteilung in drei disjunkte Abschnitte vorgenommen:

- **Trainingszeitraum (T):** 01.2020–12.2023, in dem die Modelle auf den historischen Kursen trainiert werden.
- **Validierungszeitraum (P):** 12.2023–06.2024, der zur Optimierung der Modellparameter dient.
- **Testzeitraum (S):** 06.2024–12.2025, der ausschließlich für die abschließende Evaluierung der Modelle auf bisher ungesehenen Daten verwendet wird.

Die Modelle werden zunächst auf den Trainingsdaten trainiert. Anschließend erfolgt die Optimierung der Hyperparameter anhand des Validierungszeitraums. Die finale Leistung wird schließlich auf dem Testzeitraum bewertet, um die zeitliche Generalisierbarkeit der Modelle zu überprüfen.

Für die Analyse werden 10 Aktien verwendet. Somit sollen Ausreißer einzelner Unternehmen den Gesamterfolg der Modelle nicht übermäßig beeinflussen. Durch diese Vorgehensweise wird sowohl die zeitliche Trennung der Daten als auch die Übertragbarkeit der Modelle innerhalb des ausgewählten Universums gewährleistet. Die Auswahl dieser Aktien muss stets anhand von Informationen erfolgen, die vor dem Trainingszeitraum bekannt waren, um einen Lookahead Bias zu verhindern. Da die Auswahl geeigneter Zeitreihen nicht Teil dieser Arbeit ist, werden die hier verwendeten untersuchten Aktien zufällig aus dem S&P500 vom Jahresbeginn 2020 ausgewählt. Diese Auswahl bleibt über den Gesamtzeitraum der Arbeit bestehen. Die ausgewählten Aktien sind zu sehen in Tabelle 3.1.

Table 3.1: Ausgewählte Aktien

Unternehmen	Tickersymbol	Kurs bei Trainingszeitraumbeginn
Tesla	TSLA	100
...	...	...

Die verwendeten Zeitreihen bestehen aus Tagesöffnungs- und Tagesschlusskursen. Hierfür wird die öffentliche API von Yahoo Finance verwendet. Alle Kursdaten erfolgen in US\$, um unabhängig von Währungsänderungen zu sein. Da die Analysen stets auf Backtests basieren, ist eine Bereinigung der historischen Aktienkurse notwendig, da sich die nominalen Preise im Zeitverlauf durch Ereignisse wie Aktiensplits, Dividendenzahlungen oder andere Aktionen verändern können, ohne dass sich der tatsächliche Unternehmenswert und demnach der Aktienwert geändert hat. Ohne eine solche Anpassung würden historische Kursbewegungen verzerrt dargestellt, was zu falsch trainierten Modellen oder falschen Tests führt.

Die Bereinigung erfolgt durch die Anpassung historischer Preise, um Effekte von Aktiensplits und Dividendenzahlungen zu berücksichtigen. Sei P_t der beobachtete Schlusskurs einer Aktie zum Zeitpunkt t . Der bereinigte Preis $\tilde{P}_t$ ergibt sich aus dem ursprünglichen Preis multipliziert mit einem Anpassungsfaktor A_t :

$$\tilde{P}_t = P_t \cdot A_t.$$

Der Anpassungsfaktor wird rekursiv berechnet. Sei P_t für $t = 1, \dots, n$ gegeben, gilt $A_n = 1$. Bei einem Aktiensplit zum Zeitpunkt t mit Verhältnis $s_t = \frac{\text{neue Aktien}}{\text{alte Aktien}}$ gilt

$$A_{t-1} = \frac{A_t}{s_t}.$$

Beispielsweise führt ein 2:1-Split ($s_t = 2$) dazu, dass alle historischen Preise vor dem Split halbiert werden.

Dividendenzahlungen werden ebenfalls berücksichtigt, um eine konsistente Renditereihe zu erhalten. Sei D_t die Dividende zum Zeitpunkt t . Dann wird der Anpassungsfaktor wie folgt aktualisiert:

$$A_{t-1} = A_t \cdot \frac{P_t - D_t}{P_t}.$$

Somit ist der historische Preis mit dem die Modelle trainiert und getestet werden abhängig vom letzten betrachteten Wert. Der letzte Wert entspricht somit dem aktuellen, realisierbaren Aktienwert, alle anderen Werte potenziell aber nicht den damaligen Werten. Durch die Anwendung dieser Anpassungen entsteht eine konsistente Preisreihe $\tilde{P}_t$, welche die tatsächliche Wertentwicklung der Aktie widerspiegelt und somit eine geeignete Grundlage für Modeltraining und Backtests darstellt.

3.3 Bewertungskriterien

Da diese Arbeit sowohl Zeitreihenprognosemodelle als auch Klassifizierungsmodelle untersucht, erfolgt die Bewertung der Modelle sowohl anhand statistischer Kennzahlen (3.3.1) als auch finanzwirtschaftlicher Kennzahlen (3.3.2). Für jedes Modell werden die möglichen Analysen berechnet und betrachtet. Anhand dieser werden die Modelle dann verglichen.

3.3.1 Fehlermaße

Root Mean Squared Error (RMSE)

Gegeben sei ein Signal $[x_1, x_2, \dots, x_n]$ sowie eine zugehörige Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$. Der RMSE misst die durchschnittliche quadratische Abweichung zwischen den vorhergesagten und den tatsächlichen Werten und ist definiert als

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{x}_i - x_i)^2}.$$

Der RMSE gewichtet Ausreißer durch die Quadratisierung stärker und ist durch die Wurzel interpretierbar, da er in derselbe Einheit wie die Werte der Zeitreihe angegeben wird.

Bestimmtheitsmaß (R^2 -Score)

Für das Signal $[x_1, x_2, \dots, x_n]$ wird zunächst der Mittelwert berechnet:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Darauf aufbauend wird die totale Quadratsumme

$$SS_{\text{tot}} = \sum_{i=1}^n (x_i - \bar{x})^2$$

sowie die Residuenquadratsumme

$$SS_{\text{res}} = \sum_{i=1}^n (x_i - \hat{x}_i)^2$$

bestimmt. Das Bestimmtheitsmaß ergibt sich daraus zu

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}.$$

Ein Wert von R^2 nahe 1 zeigt eine sehr gute Modellanpassung an die Daten an. Werte nahe 0 bedeuten, dass die Vorhersagen kaum besser sind als eine konstante Vorhersage des Mittelwerts. Negative Werte deuten darauf hin, dass das Modell schlechter abschneidet als diese einfache Baseline. Hierbei ist für diese Arbeit relevant dass Aktien meistens nicht stationär sind und dieses Fehlermaß demnach auf differenzierten Werten verwendet wird.

Directional Accuracy (DA)

Die DA misst, wie gut ein Modell die Richtung der Kursbewegung vorhersagt, unabhängig von der genauen Höhe des Preises. Diese Metrik ist sowohl für Vorhersage- als auch Klassifizierungsmodelle sinnvoll. Für Vorhersagemodelle definieren wir sie folgendermaßen. Für ein Signal $[x_1, x_2, \dots, x_n]$ und eine Vorhersage $[\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n]$ wird DA berechnet als

$$DA = \frac{1}{n} \sum_{i=2}^n \mathbf{1}(\text{sign}(x_i - x_{i-1}) = \text{sign}(\hat{x}_i - x_{i-1})),$$

wobei $\mathbf{1}(\cdot)$ die Indikatorfunktion ist, die den Wert 1 annimmt, wenn die Vorhersage die gleiche Richtung wie die tatsächliche Kursbewegung hat, und 0 sonst.

Da Klassifizierungsmodelle keinen Preis vorhersagen definieren wir DA für diese folgendermaßen.

DA für Klassifizierungsmodelle misst, wie gut die vorhergesagten Signale mit den tatsächlichen Marktbewegungen übereinstimmen. Sei $y_i \in \{+1, -1\}$ das tatsächliche Marktsignal für den Zeitpunkt i (+1 für Kursanstieg, -1 für Kursrückgang) und $\hat{y}_i \in \{+1, -1\}$ die vom Modell prognostizierte Richtung. Dann wird DA berechnet als

$$DA = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(\hat{y}_i = y_i),$$

Ein Wert von $DA = 1$ entspricht einer perfekten Klassifikation, während $DA = 0.5$ einem zufälligen Raten entspricht.

3.3.2 Finanzwirtschaftliche Kennzahlen

Gesamtrendite

Die Gesamtrendite gibt die insgesamt erzielte Rendite über den gesamten Zeitraum an:

$$R_{cum} = \frac{V_T - V_0}{V_0},$$

wobei V_0 der Anfangswert und V_T der Endwert des Portfolios ist. Sie zeigt die absolute Profitabilität der Strategie.

Der Vergleichswert hierfür ist die Gesamtrendite einer Buy-and-hold Strategie. Also die Rendite die erreicht wird, wenn die Aktie über den gesamten Betrachtungszeitraum gehalten wird:

$$R_{BH} = \frac{P_T - P_0}{P_0}.$$

Hiermit soll analysiert werden, ob die Modelle eine bessere Strategie darstellen als einfach "in den Markt zu investieren".

Sharpe Ratio

Die Sharpe Ratio misst das Rendite-Risiko-Verhältnis eines Portfolios und wird berechnet als

$$S = \frac{\frac{1}{T} \sum_{t=1}^T (R_{p,t} - R_{f,t})}{\sigma(R_p)},$$

wobei R_p die Rendite des Portfolios, R_f der risikofreie Zinssatz und $\sigma(R_p)$ die Standardabweichung der Portfoliorenditen ist. Eine hohe Sharpe Ratio deutet auf eine hohe Rendite bei gleichzeitig niedrigem Risiko hin.

Maximum Drawdown (MDD)

Der MDD beschreibt den größten Verlust eines Portfolios vom höchsten Punkt (Peak) bis zum Tiefpunkt (Trough) innerhalb des betrachteten Zeitraums:

$$MDD = \max_t \frac{Peak_t - Value_t}{Peak_t}.$$

Ein niedriger Maximum Drawdown zeigt, dass die Strategie relativ robust gegenüber großen Verlusten ist.

3.4 Modellentwicklung

3.4.1 Lineare Modelle

3.4.2 Korrelationsmatrix

Matrix mit allen Unternehmen je auf x und y. Dann berechne den Einfluss der Rendite von x in t-1 auf die von y für t über: $R_i * R_j / \text{abs}(R_i) * \text{abs}(R_j)$
Mache das für die letzten x Tage (5) daraus ein Vektor

und eine Matrix Tage gewichten => Wird wohl besser auf Intraday Daten funktionieren, aber können wir ja trotzdem schonmal implementieren

3.4.3 Support Vector Machines (SVM)

3.4.4 Sentiment-Analyse mit Echtzeitinformationen

3.4.5 SVMs mit Analyse Features

3.5 Marktstrategie

4 Implementierung

5 Ergebnisse und Bewertung

5.1 Variante1

5.2 Variante2

6 Zusammenfassung und Ausblick

Literaturverzeichnis

- [1] Malkiel, B. G., “Efficient market hypothesis,” in *Finance*, Springer, 1989, pp. 127–134.
- [2] Burton, K. “Inside a moneymaking machine like no other.” Archived from the original on 14 May 2017, Accessed: 05/11/2017. [Online]. Available: <https://www.bloomberg.com/news/articles/2016-11-21/how-renaissance-s-medallion-fund-became-finance-s-blackest-box>.
- [3] Sewell, M., “The efficient market hypothesis: Empirical evidence,” *International Journal of Statistics and Probability*, vol. 1, no. 2, pp. 164–178, 2012.
- [4] Prakash, A./ Tuo, R./ Ding, Y., “The temporal overfitting problem with applications in wind power curve modeling,” *Technometrics*, vol. 65, no. 1, pp. 70–82, 2023. [Online]. Available: <https://arxiv.org/abs/2012.01349>.